FUNDAMENTOS Y HERRAMIENTAS PARA LA MODELIZACIÓN DE PROCESOS TÉCNICOS-CIENTÍFICOS DE INVESTIGACIÓN

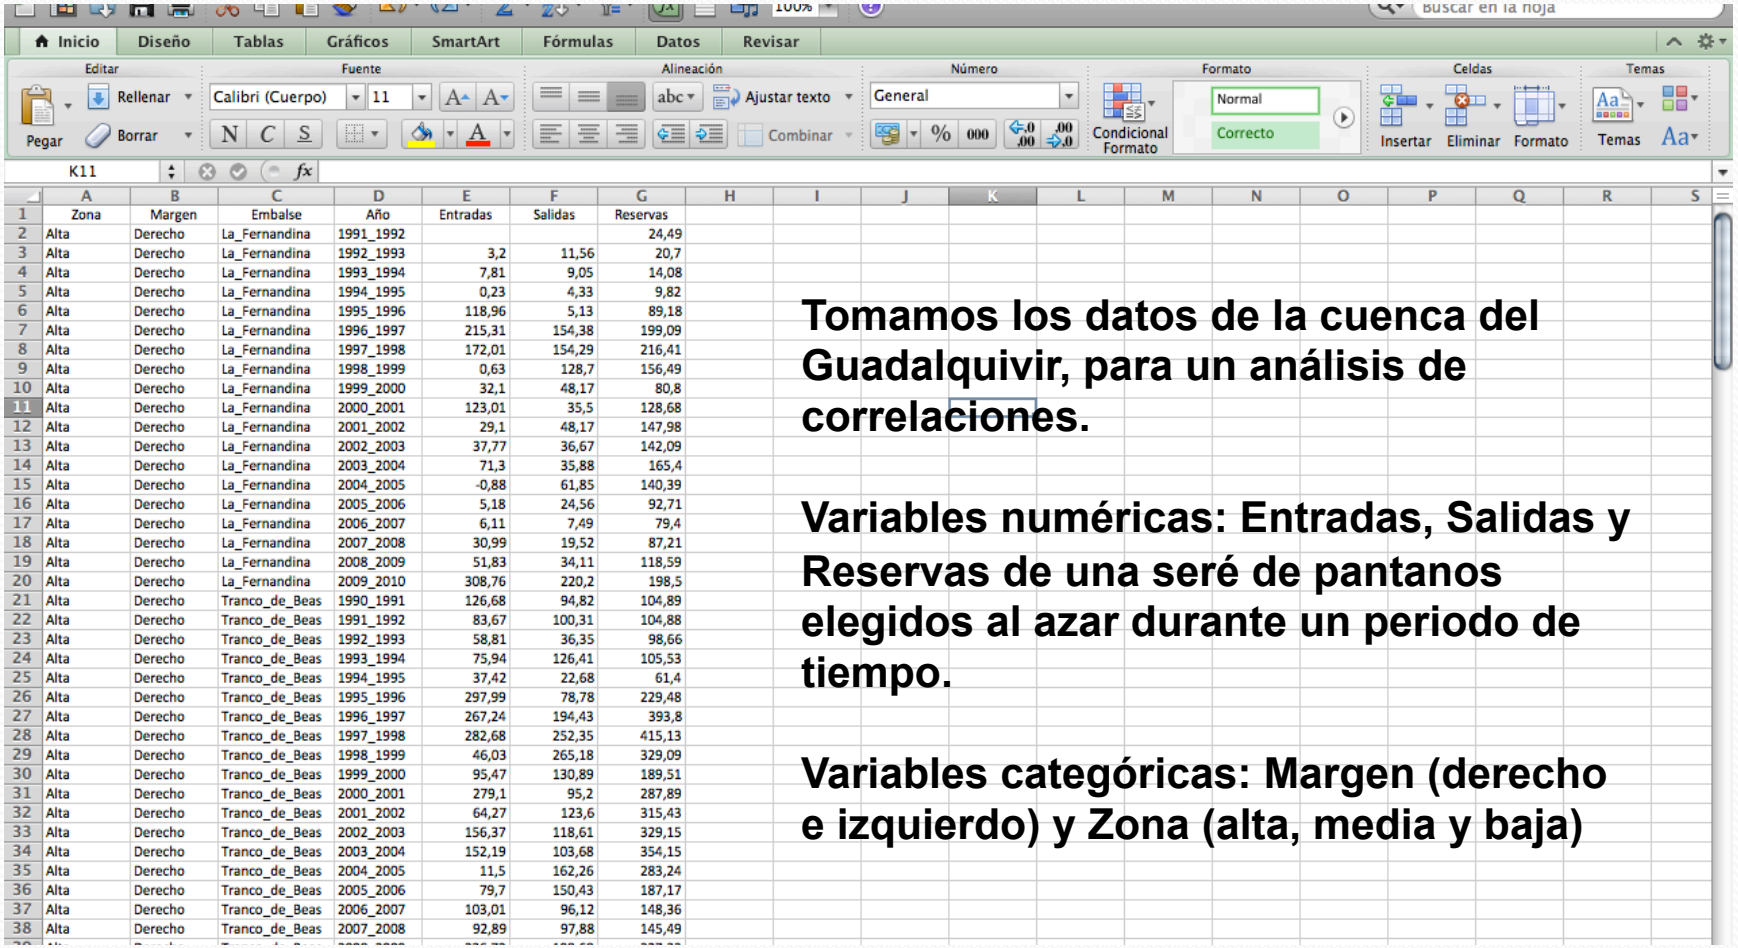
Bloque III: Modelización estadística.

Regresión y correlación con R (Rcommander)



Roberto Espejo Mohedano e-mail: ma1esmor@uco.es

Correlación



	A	B	C	D	E	F	G
1	Zona	Margen	Embalse	Año	Entradas	Salidas	Reservas
2	Alta	Derecho	La_Fernandina	1991_1992			24,49
3	Alta	Derecho	La_Fernandina	1992_1993	3,2	11,56	20,7
4	Alta	Derecho	La_Fernandina	1993_1994	7,81	9,05	14,08
5	Alta	Derecho	La_Fernandina	1994_1995	0,23	4,33	9,82
6	Alta	Derecho	La_Fernandina	1995_1996	118,96	5,13	89,18
7	Alta	Derecho	La_Fernandina	1996_1997	215,31	154,38	199,09
8	Alta	Derecho	La_Fernandina	1997_1998	172,01	154,29	216,41
9	Alta	Derecho	La_Fernandina	1998_1999	0,63	128,7	156,49
10	Alta	Derecho	La_Fernandina	1999_2000	32,1	48,17	80,8
11	Alta	Derecho	La_Fernandina	2000_2001	123,01	35,5	128,68
12	Alta	Derecho	La_Fernandina	2001_2002	29,1	48,17	147,98
13	Alta	Derecho	La_Fernandina	2002_2003	37,77	36,67	142,09
14	Alta	Derecho	La_Fernandina	2003_2004	71,3	35,88	165,4
15	Alta	Derecho	La_Fernandina	2004_2005	-0,88	61,85	140,39
16	Alta	Derecho	La_Fernandina	2005_2006	5,18	24,56	92,71
17	Alta	Derecho	La_Fernandina	2006_2007	6,11	7,49	79,4
18	Alta	Derecho	La_Fernandina	2007_2008	30,99	19,52	87,21
19	Alta	Derecho	La_Fernandina	2008_2009	51,83	34,11	118,59
20	Alta	Derecho	La_Fernandina	2009_2010	308,76	220,2	198,5
21	Alta	Derecho	Tranco_de_Beas	1990_1991	126,68	94,82	104,89
22	Alta	Derecho	Tranco_de_Beas	1991_1992	83,67	100,31	104,88
23	Alta	Derecho	Tranco_de_Beas	1992_1993	58,81	36,35	98,66
24	Alta	Derecho	Tranco_de_Beas	1993_1994	75,94	126,41	105,53
25	Alta	Derecho	Tranco_de_Beas	1994_1995	37,42	22,68	61,4
26	Alta	Derecho	Tranco_de_Beas	1995_1996	297,99	78,78	229,48
27	Alta	Derecho	Tranco_de_Beas	1996_1997	267,24	194,43	393,8
28	Alta	Derecho	Tranco_de_Beas	1997_1998	282,68	252,35	415,13
29	Alta	Derecho	Tranco_de_Beas	1998_1999	46,03	265,18	329,09
30	Alta	Derecho	Tranco_de_Beas	1999_2000	95,47	130,89	189,51
31	Alta	Derecho	Tranco_de_Beas	2000_2001	279,1	95,2	287,89
32	Alta	Derecho	Tranco_de_Beas	2001_2002	64,27	123,6	315,43
33	Alta	Derecho	Tranco_de_Beas	2002_2003	156,37	118,61	329,15
34	Alta	Derecho	Tranco_de_Beas	2003_2004	152,19	103,68	354,15
35	Alta	Derecho	Tranco_de_Beas	2004_2005	11,5	162,26	283,24
36	Alta	Derecho	Tranco_de_Beas	2005_2006	79,7	150,43	187,17
37	Alta	Derecho	Tranco_de_Beas	2006_2007	103,01	96,12	148,36
38	Alta	Derecho	Tranco_de_Beas	2007_2008	92,89	97,88	145,49

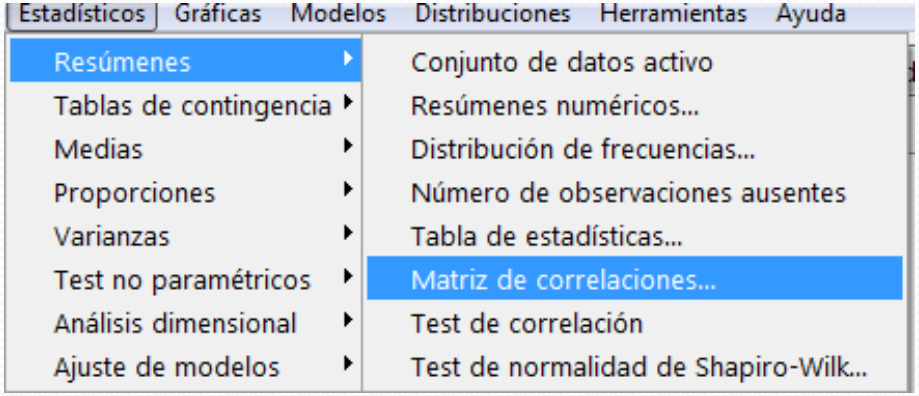
Tomamos los datos de la cuenca del Guadalquivir, para un análisis de correlaciones.

Variables numéricas: Entradas, Salidas y Reservas de una seré de pantanos elegidos al azar durante un periodo de tiempo.

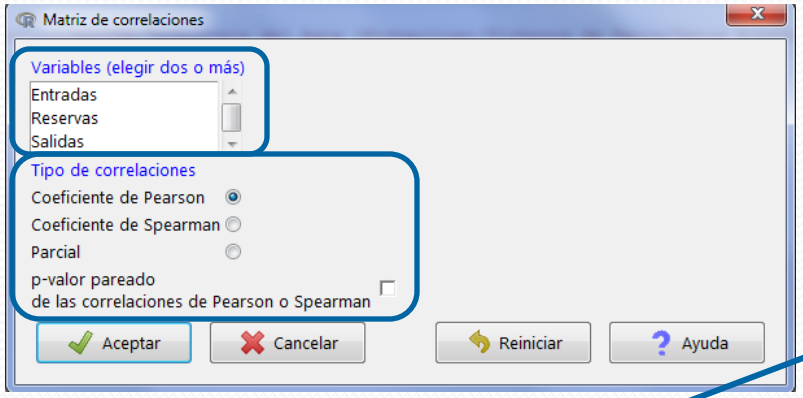
Variables categóricas: Margen (derecho e izquierdo) y Zona (alta, media y baja)


CONFEDERACIÓN HIDROGRÁFICA DEL GUADALQUIVIR
PLANO GENERAL
AÑO : 2009-2010
N
Zona Media
Zona Alta
Zona Baja
Margen Derecho
Margen Izquierdo
GUADIANA
MONTORO III
EL YEGUAS
MARMOLEJO
JÁNDULA
ENCINAREJO
LA FRESNEDA (AZUD)
LA FRESNEDA
RUMBLAR
VÍBORAS
QUIEBRAJANO
LA FERNANDINA
DAÑADOR
GUADALMENA
SAN RAFAEL DE NAVALLANA
GUADALMELLATO
GUADANUÑO-CERRO MURIANO
PUENTE NUEVO
LA BRENA II
SIERRA BOYERA
BEMBÉZAR
HORNACHUELOS
RETORTILLO
RETORTILLO (DERIVACIÓN)
EL PINTADO
LOS MELONARES
CANTILLANA
HUESNA
JOSE TORÁN
MARTÍN GONZALO
ARENOSO
EL CARPIO
VILLAFRANCA
VADOMOJÓN
GUADALÉN
GIRIBAILE
TRANCO DE BEAS
ACUASCEBAS
SAN CLEMENTE
EL PORTILLO
LA BOLERA
DOÑA ALDONZA
NEGRATÍN
FRANCISCO ABELLÁN-PEÑÓN DE LOS GITANOS
PEDRO MARÍN
QUENTAR
CANALES
CUBILLAS
COLOMERA
LOS BERMEJALES
MALPASILLO-JAUJA
IZNÁJAR
CORDOBILLA
PUEBLA DE CAZALLA
TORRE DEL ÁGUILA
ALCALÁ DEL RÍO
AGRIO
EL GERGAL
LA MINILLA
ZUFRE
ARACENA
CALA
CÓRDOBA
JAÉN
SEVILLA
GRANADA

Coeficientes de Correlación Simples



$$R_{xy} = \frac{S_{xy}}{S_x S_y} \in (-1;1)$$



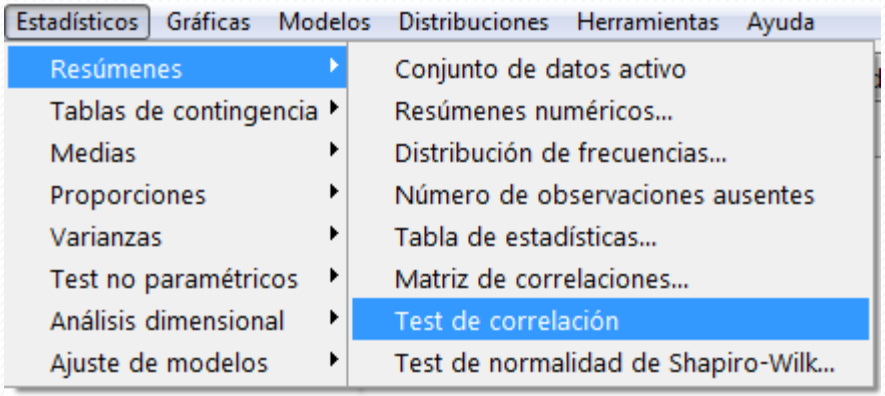
$$\Gamma_{yx_1x_2\ldots} = \begin{pmatrix} 1 & R_{yx_1} & R_{yx_2} & \cdots \\ R_{yx_1} & 1 & R_{x_1x_2} & \cdots \\ R_{yx_2} & R_{x_1x_2} & 1 & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{pmatrix}$$

$$R_{ER} = 0.4170537$$
$$R_{ES} = 0.9116159$$
$$R_{SR} = 0.3835474$$

```
> cor(Datos[,c("Entradas","Reservas","Salidas")], use="complete.obs")
           Entradas  Reservas   Salidas
Entradas  1.0000000 0.4170537 0.9116159
Reservas  0.4170537 1.0000000 0.3835474
Salidas   0.9116159 0.3835474 1.0000000
```

¿Son significativos estos Coeficientes?

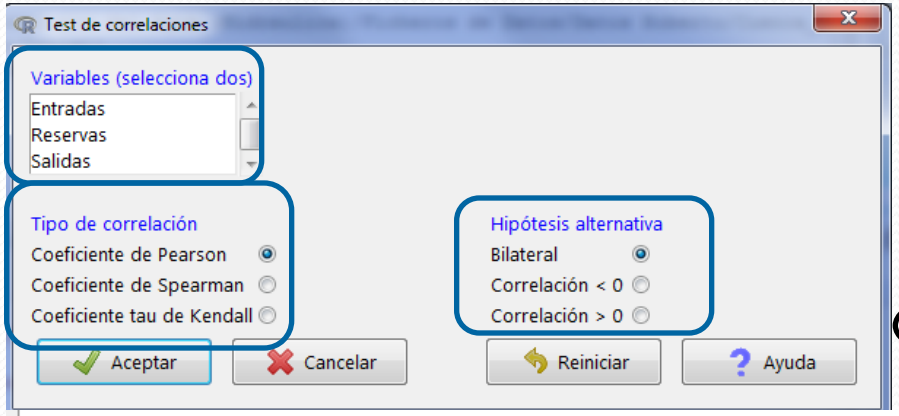
Test T sobre los Coeficientes de Correlación Simples




```
        Pearson's product-moment correlation

data:  Datos$Entradas and Datos$Reservas
t = 7.4415, df = 263, p-value = 1.417e-12
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.3122469 0.5118306
sample estimates:
      cor
0.4170537
```

Rechazamos H_o en ambos casos




```
        Pearson's product-moment correlation

data:  Datos$Reservas and Datos$Salidas
t = 6.7352, df = 263, p-value = 1.026e-10
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.2757951 0.4817796
sample estimates:
      cor
0.3835474
```

$$\begin{cases} H_0: X \text{ está incorrelada con Y} \\ H_1: X \text{ está correlada con Y} \end{cases} \Rightarrow \begin{cases} H_0: \rho_{xy} = 0 \\ H_1: \rho_{xy} \neq 0 \end{cases}$$

```
> cor.test(Datos$Entradas, Datos$Salidas, alternative="two.sided", method="pearson")

        Pearson's product-moment correlation

data:  Datos$Entradas and Datos$Salidas
t = 35.9669, df = 263, p-value < 2.2e-16
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.8887445 0.9299599
sample estimates:
      cor
0.9116159
```

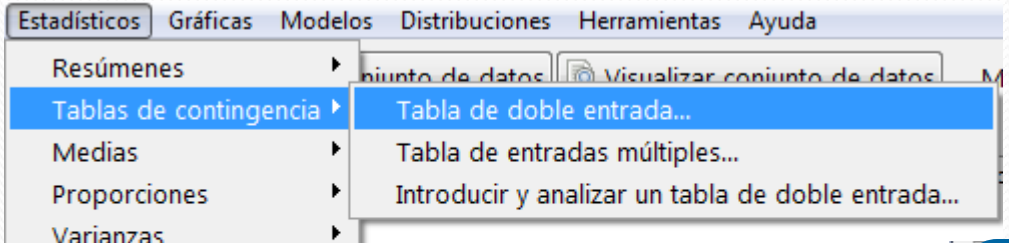
Decisión: Para todo $\alpha \leq p$ ➔ se acepta H_o
Para todo $\alpha > p$ ➔ se rechaza H_o

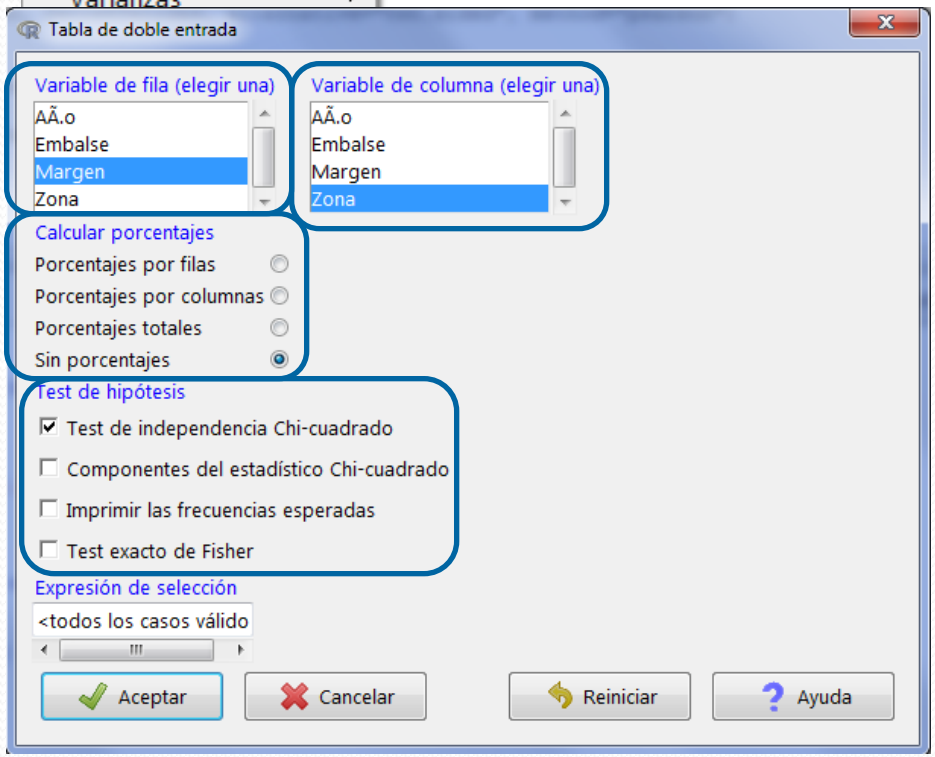
Rechazamos H_o

$I(R_{ES})_{0.95} = (0.8887445, 0.9299599)$

$R_{ES} = 0.9116159$

Test de Independencia para variables Categóricas






```
> .Table
          Zona
Margen     Alta Baja Media
  Derecho    39   38    59
  Izquierdo  60   37    38

> .Test <- chisq.test(.Table, correct=FALSE)

> .Test

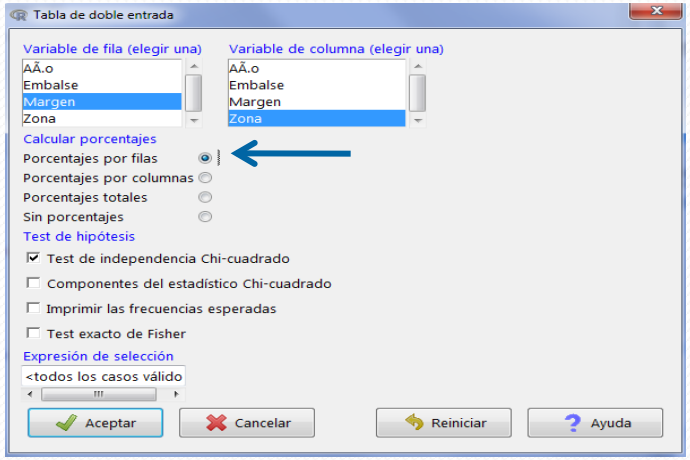
        Pearson's Chi-squared test

data:  .Table
X-squared = 9.0107, df = 2, p-value = 0.01105
```

$$\begin{cases} H_0 : X \text{ es independiente de } Y \\ H_1 : X \text{ esta relacionada con } Y \end{cases}$$

Decisión: Para todo $\alpha \leq p$ ➔ se acepta H_0
Para todo $\alpha > p$ ➔ se rechaza H_0

Rechazamos H_0 a nivel del 5%, es decir, existe relación entre los pantanos de uno u otro Margen con la Zona




```
> .Table
          Zona
Margen     Alta Baja Media
  Derecho    39   38    59
  Izquierdo  60   37    38
```

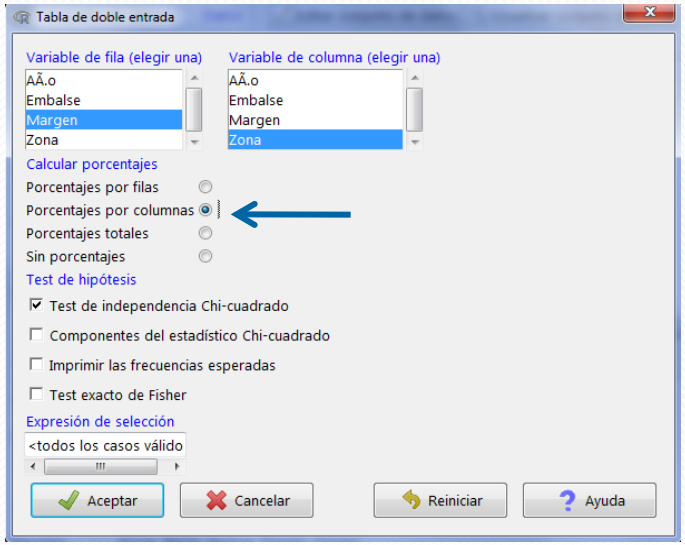
```
> rowPercents(.Table) # Row Percentages
          Zona
Margen     Alta Baja Media Total Count
  Derecho  28.7 27.9  43.4 100.0   136
  Izquierdo 44.4 27.4  28.1  99.9   135
```

```
> .Test <- chisq.test(.Table, correct=FALSE)

> .Test

        Pearson's Chi-squared test

data:  .Table
X-squared = 9.0107, df = 2, p-value = 0.01105
```




```
> .Table
          Zona
Margen     Alta Baja Media
  Derecho    39   38    59
  Izquierdo  60   37    38
```

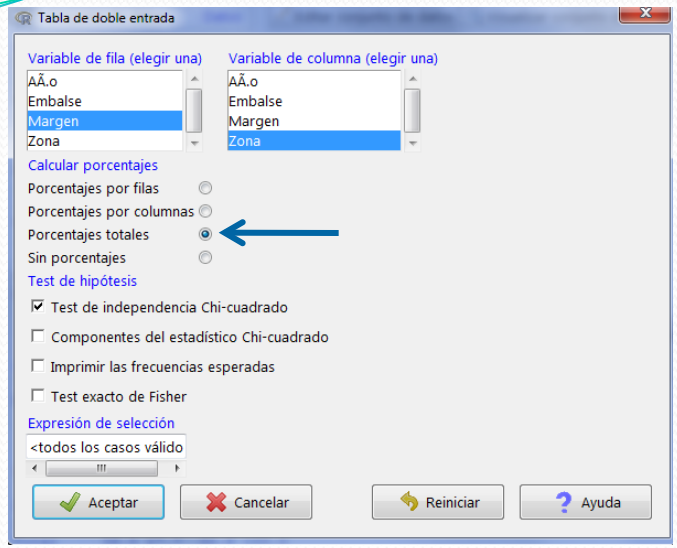
```
> colPercents(.Table) # Column Percentages
          Zona
Margen     Alta  Baja Media
  Derecho  39.4  50.7  60.8
  Izquierdo 60.6  49.3  39.2
  Total   100.0 100.0 100.0
  Count    99.0  75.0  97.0
```

```
> .Test <- chisq.test(.Table, correct=FALSE)

> .Test

        Pearson's Chi-squared test

data:  .Table
X-squared = 9.0107, df = 2, p-value = 0.01105
```




```
> .Table
          Zona
Margen     Alta Baja Media
  Derecho    39   38    59
  Izquierdo  60   37    38

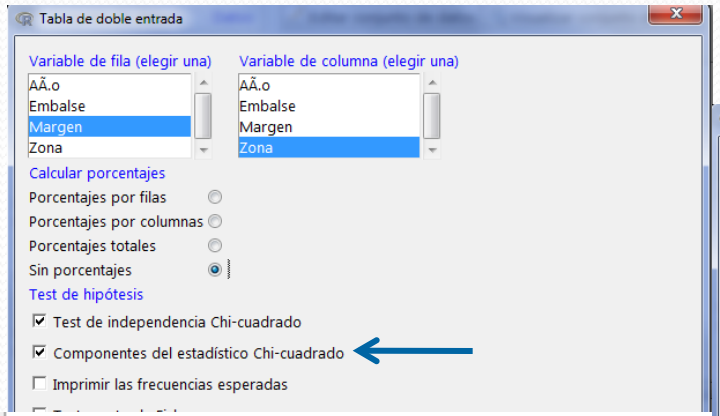
> totPercents(.Table) # Percentage of Total
          Alta Baja Media Total
Derecho   14.4 14.0  21.8  50.2
Izquierdo 22.1 13.7  14.0  49.8
Total     36.5 27.7  35.8 100.0

> .Test <- chisq.test(.Table, correct=FALSE)

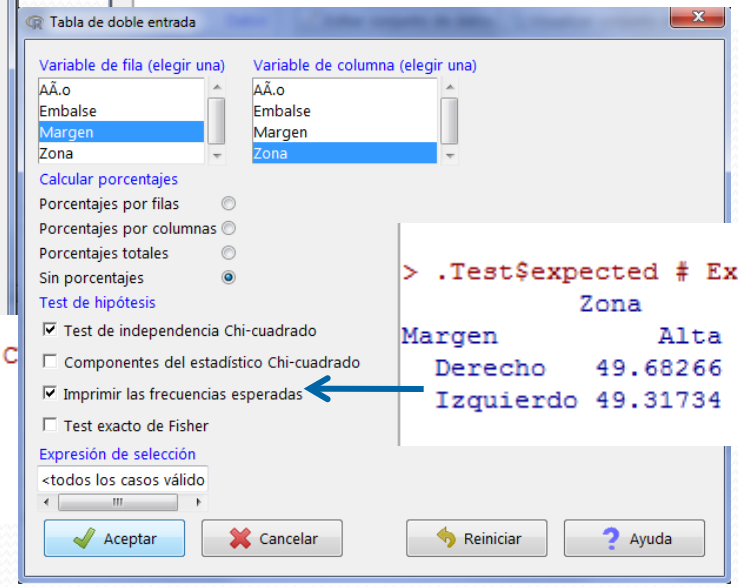
> .Test

        Pearson's Chi-squared test

data:  .Table
X-squared = 9.0107, df = 2, p-value = 0.01105
```

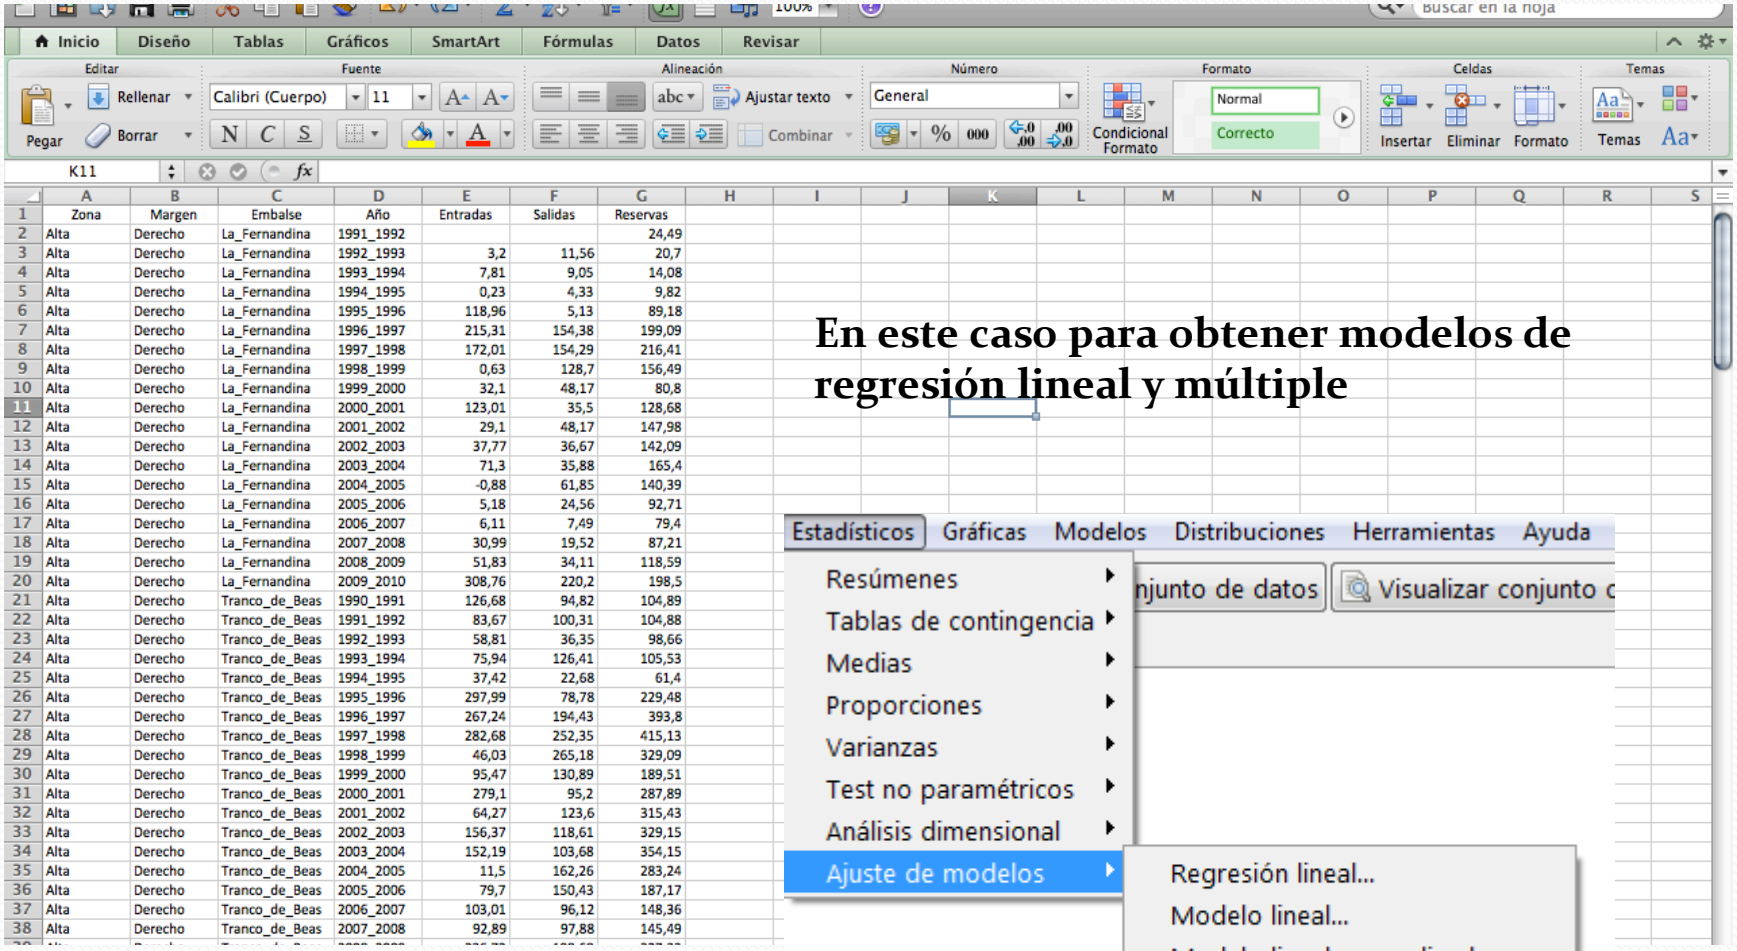



```
> round(.Test$residuals^2, 2) # Chi-square C
          Zona
Margen     Alta Baja Media
  Derecho  2.30 0.00  2.19
  Izquierdo 2.31 0.00  2.20
```



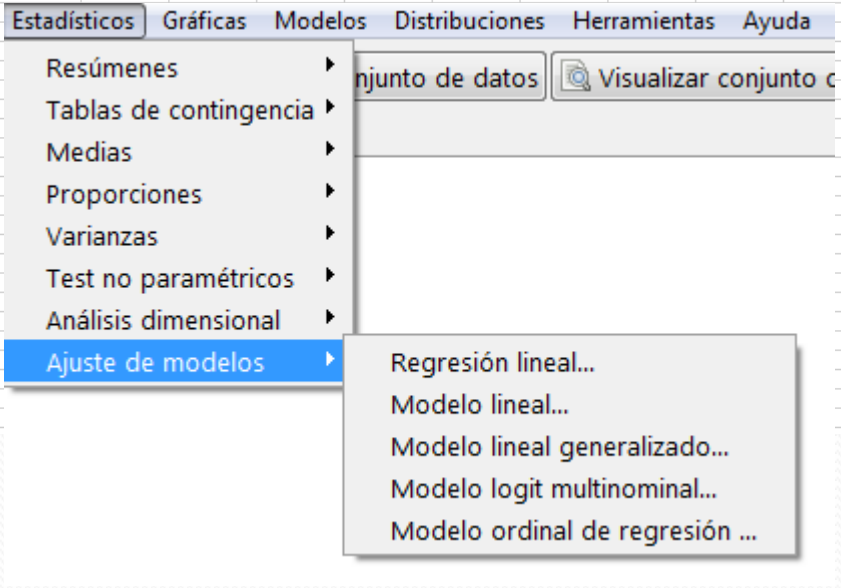

```
> .Test$expected # Expected Counts
          Zona
Margen          Alta     Baja    Media
  Derecho   49.68266 37.63838 48.67897
  Izquierdo 49.31734 37.36162 48.32103
```

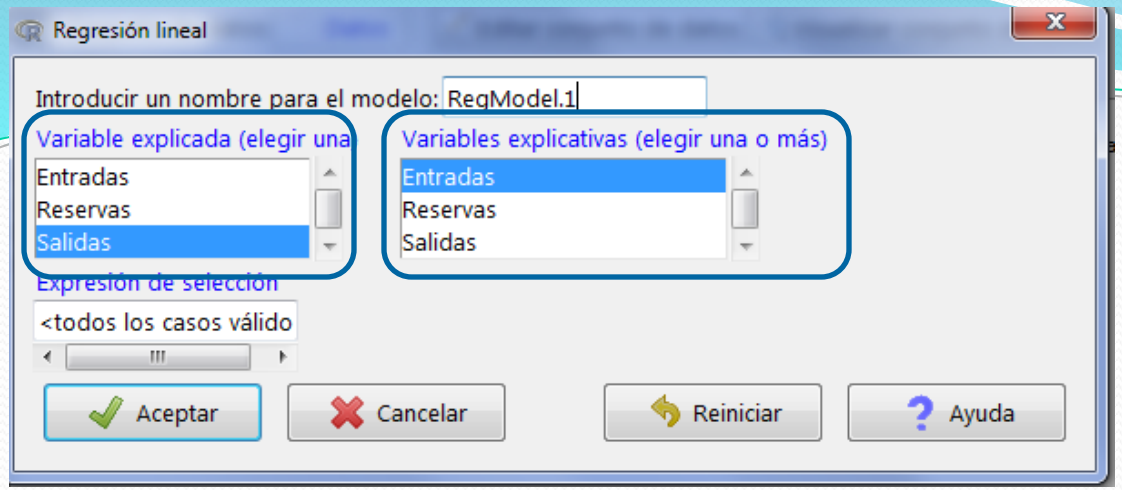
Modelos de Regresión



	Zona	Margen	Embalse	Año	Entradas	Salidas	Reservas
2	Alta	Derecho	La_Fernandina	1991_1992			24,49
3	Alta	Derecho	La_Fernandina	1992_1993	3,2	11,56	20,7
4	Alta	Derecho	La_Fernandina	1993_1994	7,81	9,05	14,08
5	Alta	Derecho	La_Fernandina	1994_1995	0,23	4,33	9,82
6	Alta	Derecho	La_Fernandina	1995_1996	118,96	5,13	89,18
7	Alta	Derecho	La_Fernandina	1996_1997	215,31	154,38	199,09
8	Alta	Derecho	La_Fernandina	1997_1998	172,01	154,29	216,41
9	Alta	Derecho	La_Fernandina	1998_1999	0,63	128,7	156,49
10	Alta	Derecho	La_Fernandina	1999_2000	32,1	48,17	80,8
11	Alta	Derecho	La_Fernandina	2000_2001	123,01	35,5	128,68
12	Alta	Derecho	La_Fernandina	2001_2002	29,1	48,17	147,98
13	Alta	Derecho	La_Fernandina	2002_2003	37,77	36,67	142,09
14	Alta	Derecho	La_Fernandina	2003_2004	71,3	35,88	165,4
15	Alta	Derecho	La_Fernandina	2004_2005	-0,88	61,85	140,39
16	Alta	Derecho	La_Fernandina	2005_2006	5,18	24,56	92,71
17	Alta	Derecho	La_Fernandina	2006_2007	6,11	7,49	79,4
18	Alta	Derecho	La_Fernandina	2007_2008	30,99	19,52	87,21
19	Alta	Derecho	La_Fernandina	2008_2009	51,83	34,11	118,59
20	Alta	Derecho	La_Fernandina	2009_2010	308,76	220,2	198,5
21	Alta	Derecho	Tranco_de_Beas	1990_1991	126,68	94,82	104,89
22	Alta	Derecho	Tranco_de_Beas	1991_1992	83,67	100,31	104,88
23	Alta	Derecho	Tranco_de_Beas	1992_1993	58,81	36,35	98,66
24	Alta	Derecho	Tranco_de_Beas	1993_1994	75,94	126,41	105,53
25	Alta	Derecho	Tranco_de_Beas	1994_1995	37,42	22,68	61,4
26	Alta	Derecho	Tranco_de_Beas	1995_1996	297,99	78,78	229,48
27	Alta	Derecho	Tranco_de_Beas	1996_1997	267,24	194,43	393,8
28	Alta	Derecho	Tranco_de_Beas	1997_1998	282,68	252,35	415,13
29	Alta	Derecho	Tranco_de_Beas	1998_1999	46,03	265,18	329,09
30	Alta	Derecho	Tranco_de_Beas	1999_2000	95,47	130,89	189,51
31	Alta	Derecho	Tranco_de_Beas	2000_2001	279,1	95,2	287,89
32	Alta	Derecho	Tranco_de_Beas	2001_2002	64,27	123,6	315,43
33	Alta	Derecho	Tranco_de_Beas	2002_2003	156,37	118,61	329,15
34	Alta	Derecho	Tranco_de_Beas	2003_2004	152,19	103,68	354,15
35	Alta	Derecho	Tranco_de_Beas	2004_2005	11,5	162,26	283,24
36	Alta	Derecho	Tranco_de_Beas	2005_2006	79,7	150,43	187,17
37	Alta	Derecho	Tranco_de_Beas	2006_2007	103,01	96,12	148,36
38	Alta	Derecho	Tranco_de_Beas	2007_2008	92,89	97,88	145,49

En este caso para obtener modelos de regresión lineal y múltiple






```
> RegModel.1 <- lm(Salidas~Entradas, data=Datos)

> summary(RegModel.1)

Call:
lm(formula = Salidas ~ Entradas, data = Datos)

Residuals:
    Min      1Q  Median      3Q     Max
-314.62  -18.65   -7.18   20.30  435.09

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 19.75000    5.36355   3.682 0.000281 ***
Entradas     0.81685    0.02271  35.967  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 69.55 on 263 degrees of freedom
  (6 observations deleted due to missingness)
Multiple R-squared: 0.831,  Adjusted R-squared: 0.8304
F-statistic:  1294 on 1 and 263 DF,  p-value: < 2.2e-16
```

Salidas = 19.75 + 0.81685 Entradas + Error

Test F sobre el Modelo de Regresión

$$\begin{cases} H_0 : \text{Rechazo Gobalmente el modelo} \\ H_1 : \text{Acepto Gobalmente el modelo} \end{cases}$$

Aceptamos Globalmente el Modelo

Test T sobre los Coeficientes del Modelo

$$\begin{cases} H_0 : \beta_{Ent} = 0 \\ H_1 : \beta_{Ent} \neq 0 \end{cases}$$

Aceptamos β_{Ent} como válido

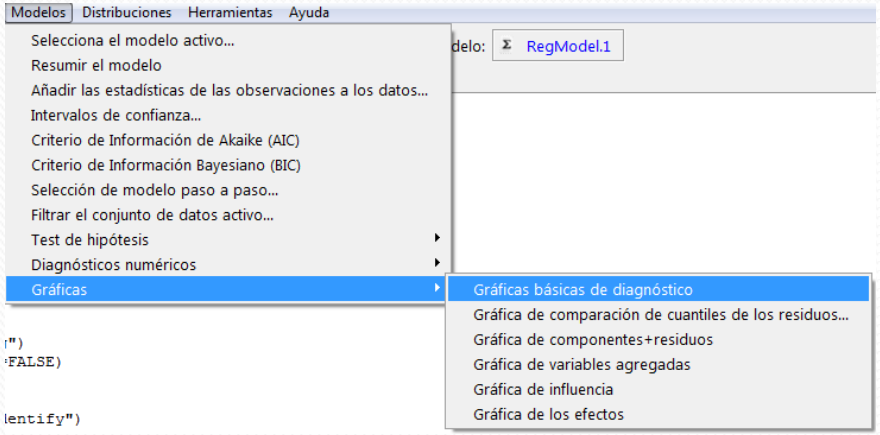
Las Salidas son explicadas en un 83.1% por las Entradas de acuerdo con el modelo calculado.

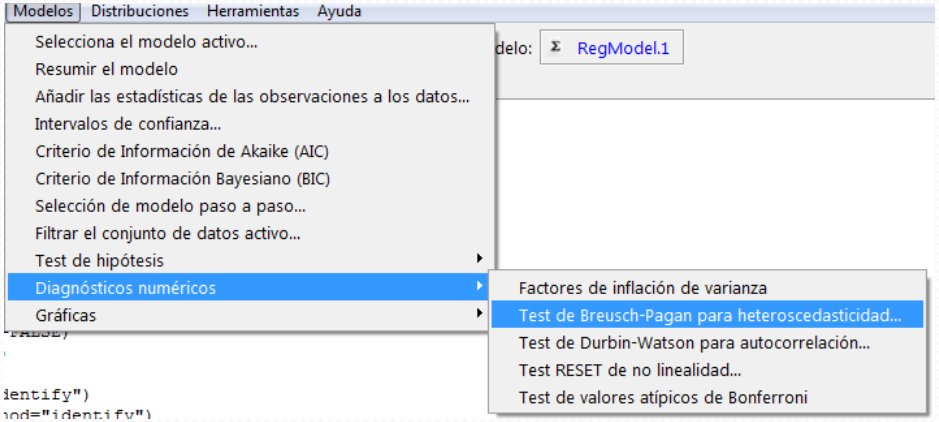
Decisión: Para todo $\alpha \leq p$ ➔ se acepta H_o
Para todo $\alpha > p$ ➔ se rechaza H_o

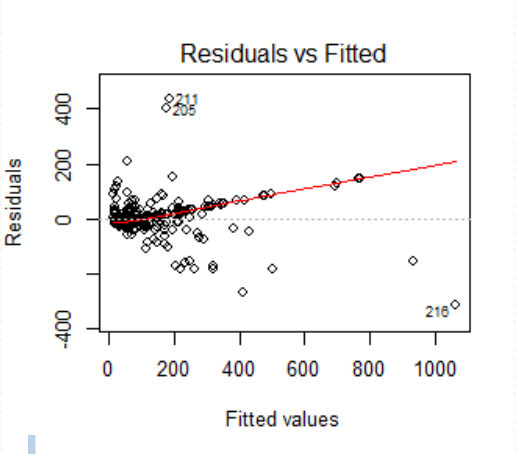
Análisis de Residuos

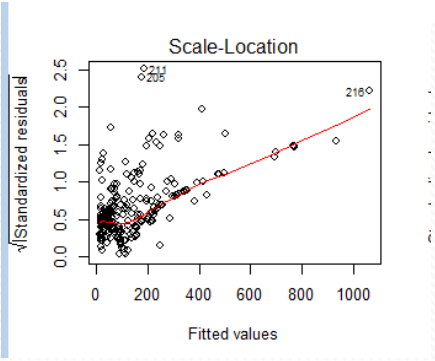
1ª.- $\bar{e} = 0$

2ª.- $Var(\varepsilon_i) = cte$ Varianza constante. (homocedásticos)







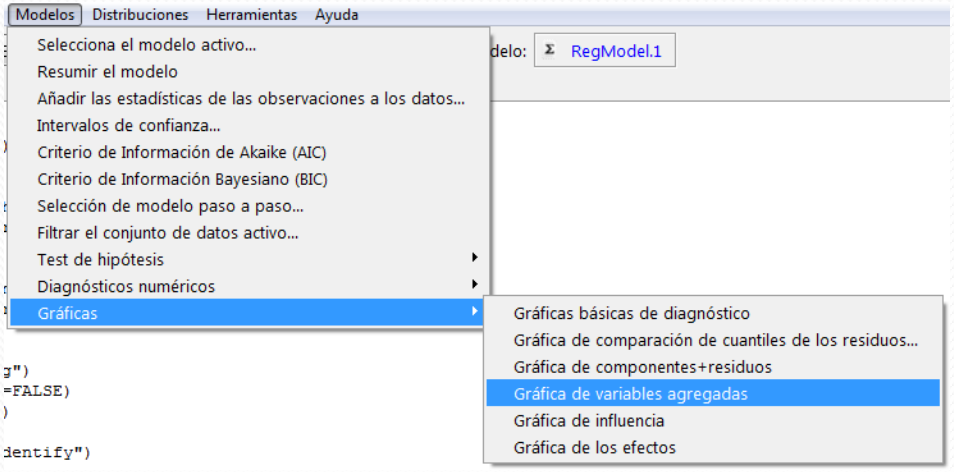


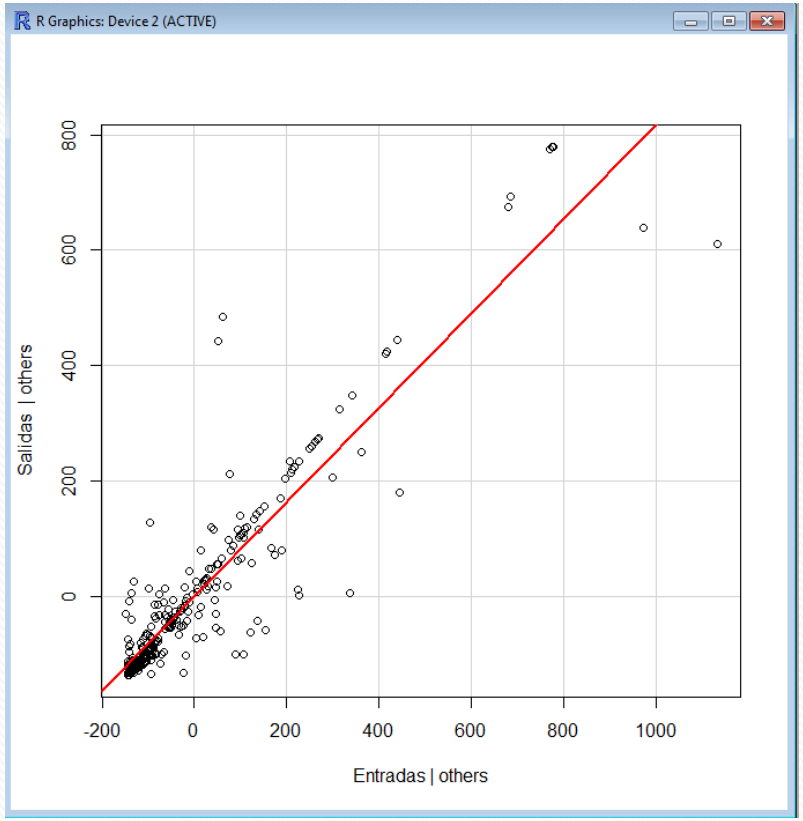
Existe Heterocedasticidad

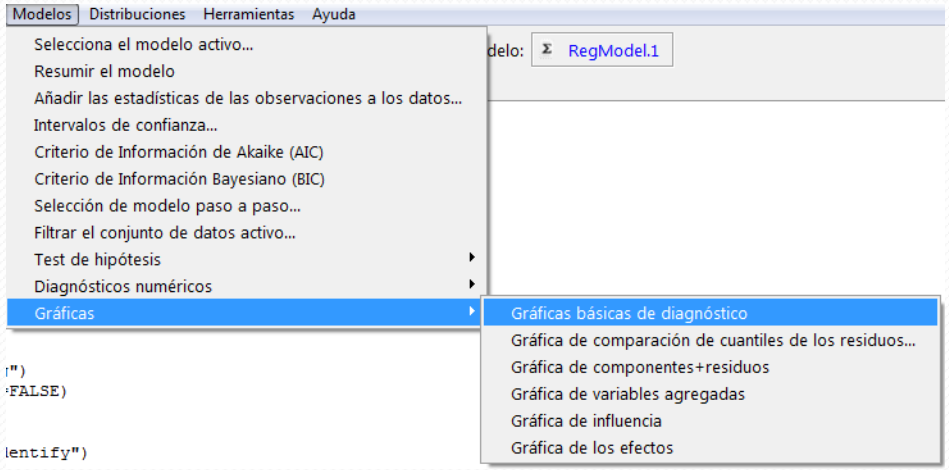
$$\begin{cases} H_0 : \text{Homocedasticidad} \\ H_1 : \text{Heterocedasticidad} \end{cases}$$

```
        Breusch-Pagan test

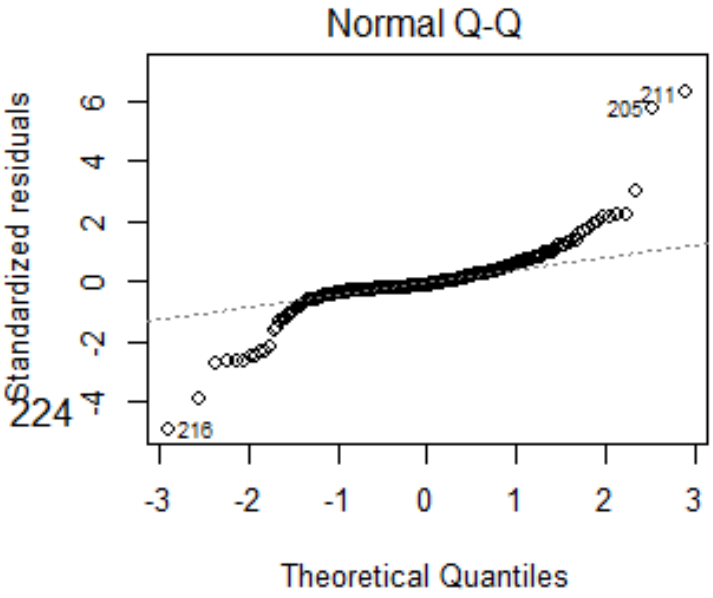
data:  Salidas ~ Entradas
BP = 217.8706, df = 1, p-value < 2.2e-16
```


Modelos
Distribuciones
Herramientas
Ayuda
Selecciona el modelo activo...
Resumir el modelo
Añadir las estadísticas de las observaciones a los datos...
Intervalos de confianza...
Criterio de Información de Akaike (AIC)
Criterio de Información Bayesiano (BIC)
Selección de modelo paso a paso...
Filtrar el conjunto de datos activo...
Test de hipótesis
Diagnósticos numéricos
Gráficas
Gráficas básicas de diagnóstico
Gráfica de comparación de cuantiles de los residuos...
Gráfica de componentes+residuos
Gráfica de variables agregadas
Gráfica de influencia
Gráfica de los efectos
delo:
RegModel.1
g")
=FALSE)
)
dentify")


R Graphics: Device 2 (ACTIVE)
Salidas | others
Entradas | others
0
200
400
600
800
-200
0
200
400
600
800
1000



4ª.- Normales $\quad e \in N\left(\mu = 0; \sigma^2 = S_e^2\right)$



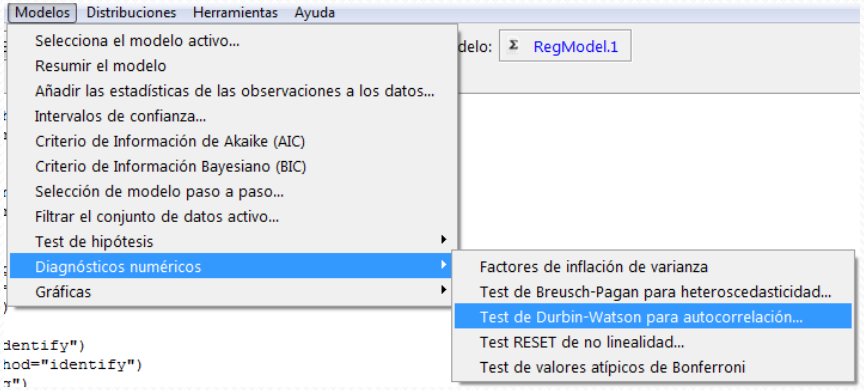
3ª.- Los residuos han de estar incorrelados entre si.

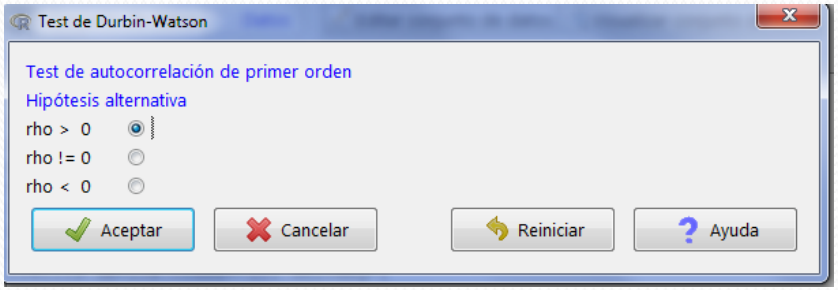
$$\begin{cases} H_0 : \rho = 0 \rightarrow \text{Incorrelados} \\ H_1 : \rho \begin{cases} > 0 \rightarrow \text{Autocorrelacion Positiva} \\ \neq 0 \rightarrow \text{Autocorrelados} \\ < 0 \rightarrow \text{Autocorrelacion Negativa} \end{cases} \end{cases}$$

Estadístico de Durbin-Watson

$$DW = \frac{\sum_{i=2}^{n} (e_i - e_{i-1})^2}{\sum_{i=1}^{n} e_i^2} \in [0\,;\,4]$$

DW ≈ 2, Incorrelados
DW ≈ 4 Autocorrelación negativa
DW ≈ 0 Autocorrelación positiva





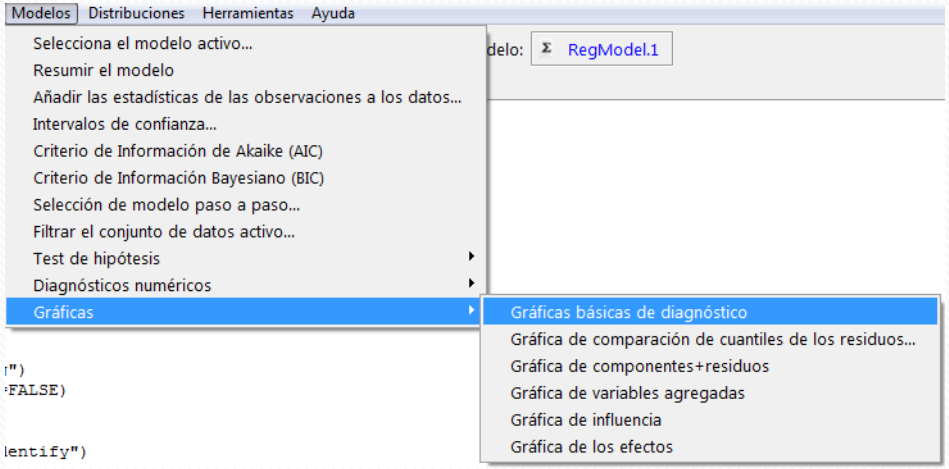

```
> dwtest(Salidas ~ Entradas, alternative="greater", data=Datos)

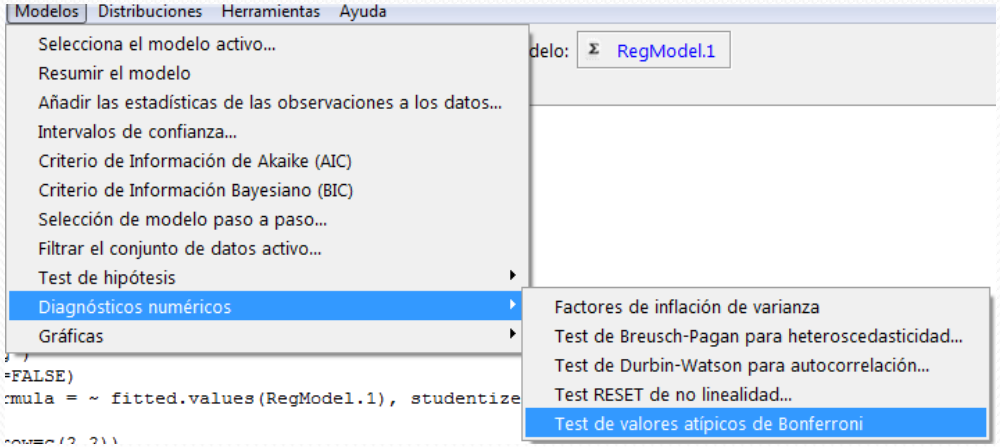
        Durbin-Watson test

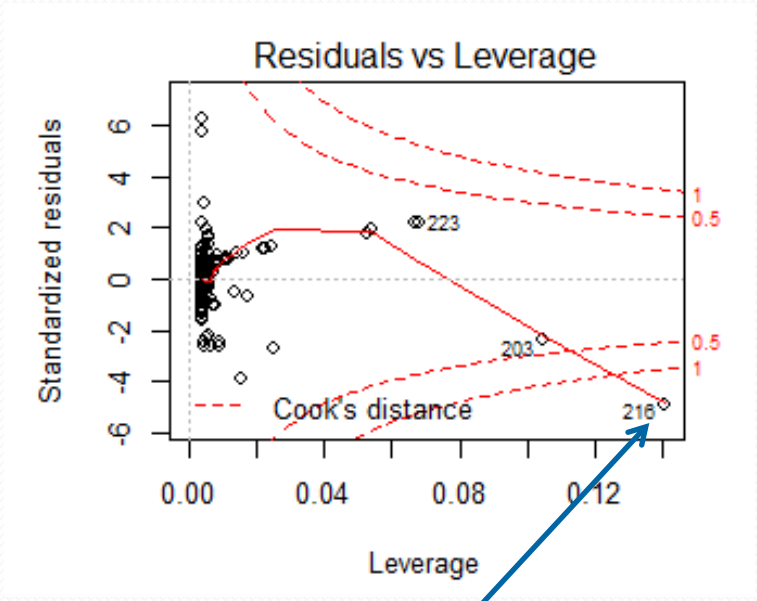
data:  Salidas ~ Entradas
DW = 1.5642, p-value = 0.0001611
alternative hypothesis: true autocorrelation is greater than 0
```

Decisión: Para todo $\alpha \leq p$ ➔ se acepta H_o
Para todo $\alpha > p$ ➔ se rechaza H_o

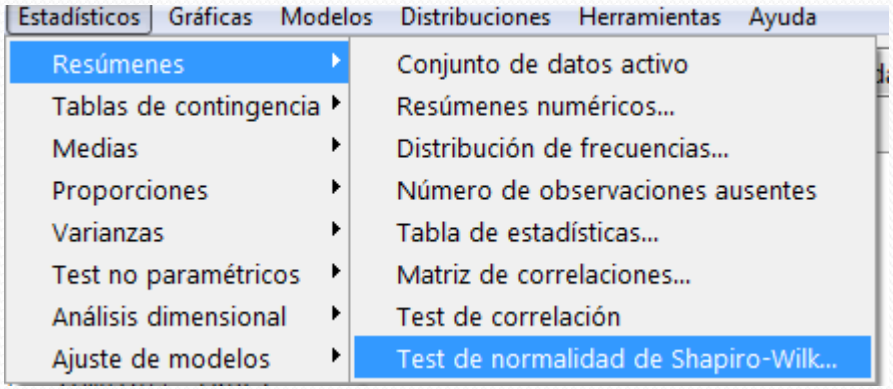
A pesar de que DW=1.5642, existe autocorrelación positiva

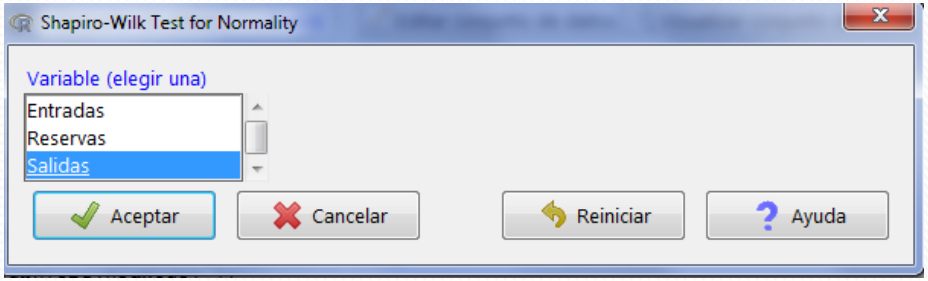







```
> outlierTest(RegModel.1)
     rstudent unadjusted p-value Bonferonni p
211  6.784652          7.7222e-11   2.0464e-08
205  6.149760          2.8842e-09   7.6432e-07
216 -5.107167          6.3007e-07   1.6697e-04
202 -3.990202          8.5738e-05   2.2721e-02
```





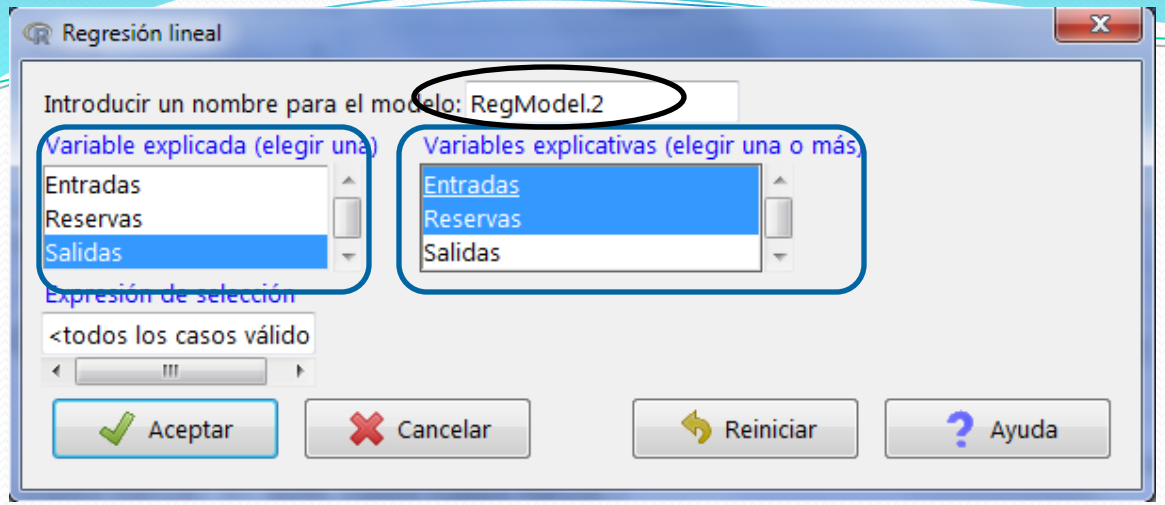

```
> shapiro.test(Datos$Salidas)

        Shapiro-Wilk normality test

data:  Datos$Salidas
W = 0.7171, p-value < 2.2e-16
```

La variable Dependiente, Salidas, No es Normal.

Regresión Múltiple



Modelo: RegModel.2

```
Call:
lm(formula = Salidas ~ Entradas + Reservas, data = Datos)

Residuals:
    Min      1Q  Median      3Q     Max
-315.72  -18.53   -7.17   19.87  432.74

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) 19.484519   5.675519   3.433 0.000693 ***
Entradas     0.815330   0.025035  32.568  < 2e-16 ***
Reservas     0.004439   0.030544   0.145 0.884549
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 69.68 on 262 degrees of freedom
  (6 observations deleted due to missingness)
Multiple R-squared: 0.8311, Adjusted R-squared: 0.8298
F-statistic: 644.4 on 2 and 262 DF,  p-value: < 2.2e-16
```

Las Salidas son explicadas en un 83.11% por las Entradas de acuerdo con el modelo calculado.

Salidas = 19.484519 + 0.81533 Entradas + 0.004439 Reservas + Error

Test F sobre el Modelo de Regresión

$$\begin{cases} H_0: \text{Rechazo Gobalmente el modelo} \\ H_1: \text{Acepto Gobalmente el modelo} \end{cases}$$

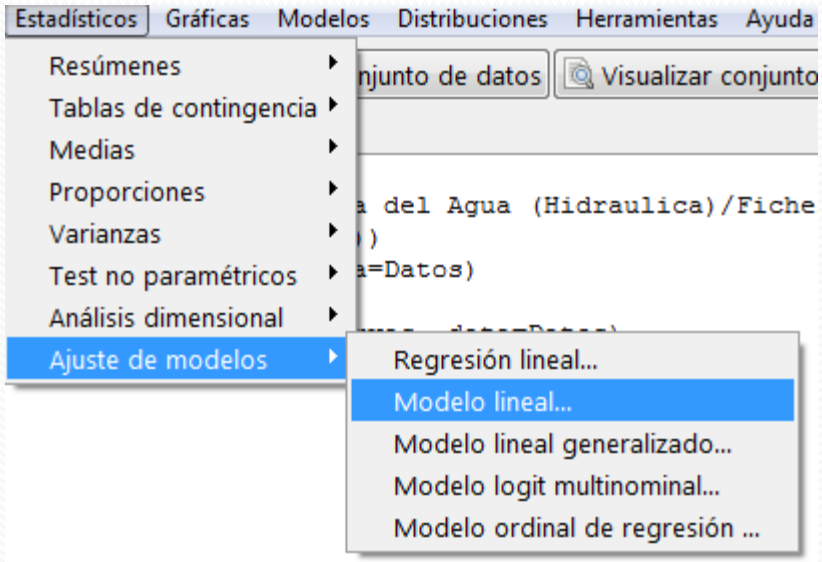
Decisión: Para todo $\alpha \leq p$ ➔ se acepta H_0
Para todo $\alpha > p$ ➔ se rechaza H_0

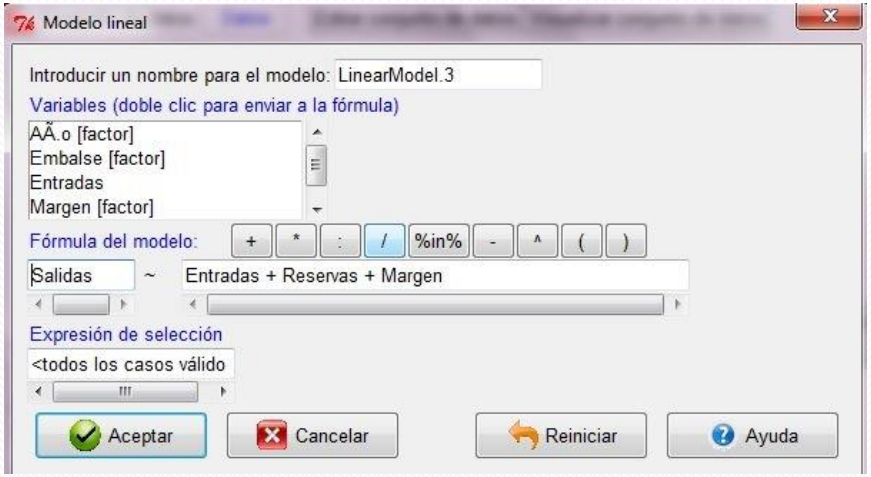
Aceptamos Globalmente el Modelo

Test T sobre los Coeficientes del Modelo

$$\begin{cases} H_0: \beta_{Ent} = 0 \\ H_1: \beta_{Ent} \neq 0 \end{cases} \qquad \begin{cases} H_0: \beta_{Res} = 0 \\ H_1: \beta_{Res} \neq 0 \end{cases}$$

Aceptamos β_{Ent} como válido y se Rechaza β_{Res}





Permite introducir en los modelos de regresión anteriores variables tipo factor

Ventana de resultados

Ejecutar

```
Call:
lm(formula = Salidas ~ Entradas + Reservas + Margen, data = Datos)

Residuals:
    Min      1Q  Median      3Q     Max
-311.01  -23.42   -5.08   19.92  425.14

Coefficients:
                 Estimate Std. Error t value Pr(>|t|)
(Intercept)     12.684011   6.674167   1.900   0.0585 .
Entradas         0.803853   0.025622  31.376   <2e-16 ***
Reservas         0.004278   0.030390   0.141   0.8882
Margen[T.Izquierdo] 16.849950   8.814666   1.912   0.0570 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 69.33 on 261 degrees of freedom
  (6 observations deleted due to missingness)
Multiple R-squared: 0.8334, Adjusted R-squared: 0.8315
F-statistic: 435.2 on 3 and 261 DF,  p-value: < 2.2e-16
```

Test T sobre los Coeficientes del Modelo

$$\begin{cases} H_0 : \beta_{Ent} = 0 \\ H_1 : \beta_{Ent} \neq 0 \end{cases} \quad \begin{cases} H_0 : \beta_{Res} = 0 \\ H_1 : \beta_{Res} \neq 0 \end{cases} \quad \begin{cases} H_0 : \beta_{Mar} = 0 \\ H_1 : \beta_{Mar} \neq 0 \end{cases}$$

Decisión: Para todo $\alpha \leq p$ ➔ se acepta H_0
Para todo $\alpha > p$ ➔ se rechaza H_0

Aceptamos sólo β_{Ent} como parámetro válido en el modelo

No son significativas ni las reservas ni el margen

Modelo:
Salidas= 12.684011 + 0.803853*Entradas + 0.004278*Reservas + 16.849950*Margen

Donde Margen = 0 en el caso de considerarse el derecho y 1 en el caso de ser el izquierdo

Tabla de modelos

Modelo	Instrucción	Ecuación
Lineal	>lm($Y \sim X$, data=Datos)	$Y = a + b \cdot X$
Lineal sin término independiente	>lm($Y \sim 0 + X$, data=Datos)	$Y = a \cdot X$
Polinomial	>lm($Y \sim X + I(X^2) +$ $+ I(X^3) + \cdots + I(X^n)$, data=Datos)	$Y = a_0 + a_1 \cdot X +$ $+ \cdots + a_n \cdot X^n$
Polinomial sin término independiente	>lm($Y \sim 0 + X + I(X^2) +$ $+ I(X^3) + \cdots + I(X^n)$, data=Datos)	$Y = a_1 \cdot X +$ $+ \cdots + a_n \cdot X^n$
Potencial	>lm($\log(Y) \sim \log(X)$, data=Datos)	$Y = a' \cdot X^b$, (1)
Exponencial	>lm($\log(Y) \sim X$, data=Datos)	$Y = e^{a+b \cdot X}$
Logarítmico	>lm($Y \sim \log(X)$, data=Datos)	$Y = a + b \cdot \log(X)$
Hiperbólico	>lm($Y \sim I(1/X)$, data=Datos)	$Y = a + \frac{b}{X}$
Doble inverso	>lm($I(1/Y) \sim I(1/X)$, data=Datos)	$Y = \frac{1}{a + \frac{b}{X}}$
Lineal generalizado	>glm(fórmula, family= =familia(link), data=Datos)	(2)

(1) Los coeficientes a y b obtenidos en **Rcmdr** corresponden a la ecuación $\log(Y) = a + b \cdot \log(X)$, con lo que el modelo potencial sería $Y = e^a \cdot X^b$.

(2) `familia` puede tomar los valores `gaussian`, `binomial`, `poisson`, `Gamma`, `inverse.gauss` `quasibinomial` y `quasipoisson`. La función de enlace (`link`) puede tomar distintos valores según la familia seleccionada. Podemos ver las distintas opciones consultando en la ayuda de **R** la función `family` (`help(family)` o `?family`).

Transformaciones no lineales.

Tratan de corregir la falta de simetría de algunas distribuciones de datos. En ocasiones, estas transformaciones corrigen las desviaciones de normalidad.

La transformación mas utilizada es el logaritmo aunque existen otras mas simples como la raíz cuadrada o la inversa.

La transformación de Box-Cox (perteneciente a las transformaciones logarítmicas) también es muy usada y suele corregir las desviaciones de los supuestos necesarios para los modelos de regresión.

Dada una variable *X*, su transformada de Box-Cox se define como:

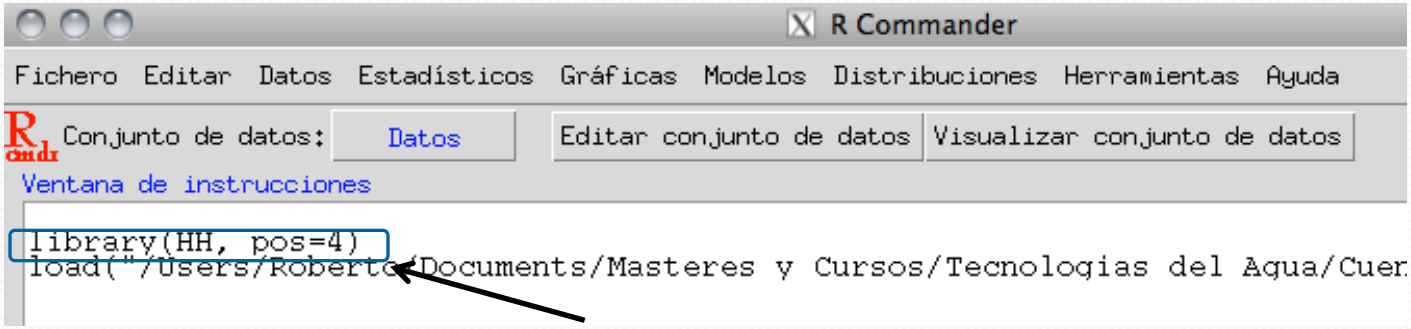
$$X^* = \left\{ \begin{array}{lll} \dfrac{(X+m)^{\lambda}-1}{\lambda} & si & \lambda \neq 0 \\ \ln(X+m) & si & \lambda = 0 \end{array} \right\}$$

m se escoge de tal forma que (*X* + *m*) sea positivo.

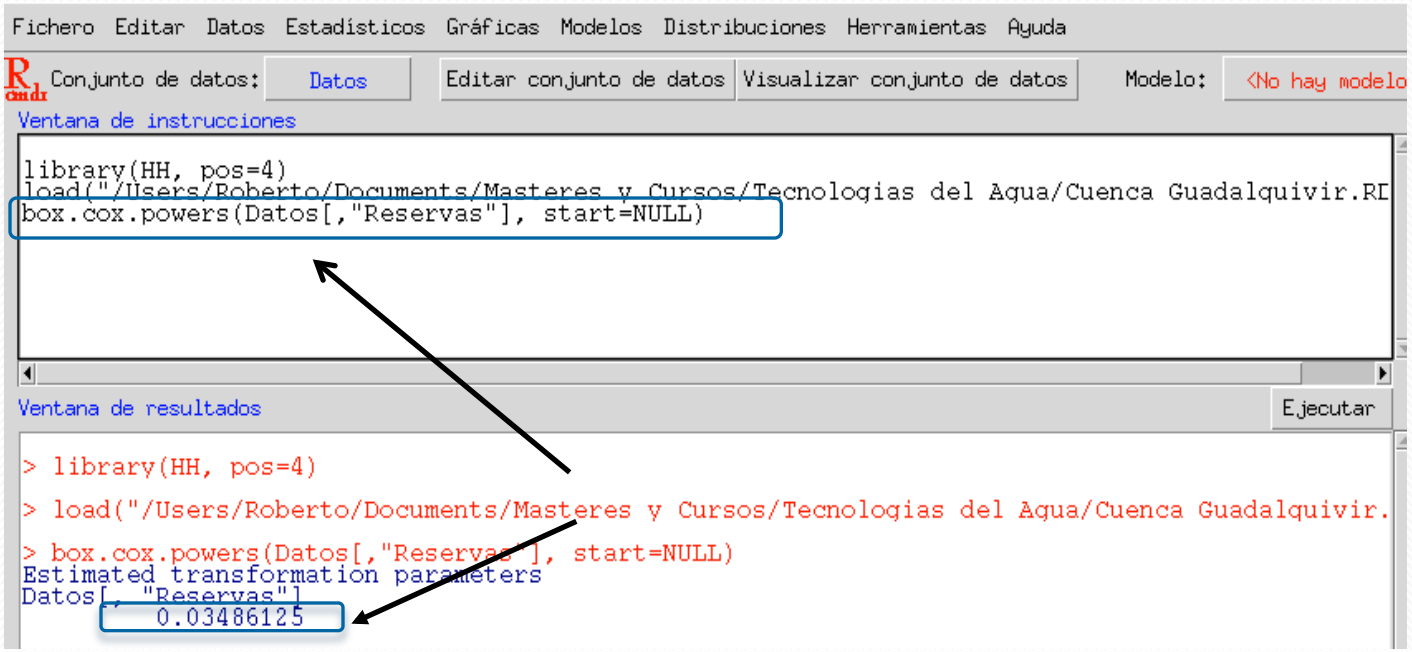
Si λ > 1 se corrige la asimetría a la izquierda y si λ < 1 la asimetría a la derecha.

Transformación de Box-Cox en R.

En primer lugar hay que instalar y cargar, entre otras posibles (p.e MASS), la librería HH.



Si existiese algún dato negativo, hay que sumar una constante *m* para que esto no ocurra.
A continuación, hay que determinar el mejor valor posible para el parámetro λ.



Obtener la nueva serie de datos transformados, o bien con la opción de transformación o bien mediante comandos y agregar al fichero de datos.

Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda

Conjunto de datos: Datos | Editar conjunto de datos | Visualizar conjunto de datos | Modelo: <No hay modelo

Ventana de instrucciones

```
library(HH, pos=4)
load("/Users/Roberto/Documents/Masteres y Cursos/Tecnologias del Agua/Cuenca Guadalquivir.RD
box.cox.powers(Datos[,"Reservas"], start=NULL)
nuevodato<-box.cox(Datos[,"Reservas"], 0.03486125)
nuevodato
Datos$ReserBoxCox <-nuevodato
```

Realizamos la transformación
Visualizamos los datos
Se añade una columna con los datos transformados al fichero de datos

Ventana de resultados — Ejecutar

```
> nuevodato<-box.cox(Datos[,"Reservas"], 0.03486125)
> nuevodato
  [1] 3.3833763 3.1959640 2.7705129 2.3778478 4.8612465 5.8137183 5.9141887
 [8] 5.5253686 4.7460417 5.2928103 5.4587482 5.4104366 5.5914734 5.3961330
[15] 4.9066755 4.7256774 4.8351333 5.1962246 5.8101491 5.0515368 5.0514247
[22] 4.9795978 5.0586919 4.4275732 5.9849926 6.6438761 6.7089017 6.4234771
[29] 5.7544592 6.2601540 6.3716275 6.4237002 6.5134155 6.2403221 5.7395455
[36] 5.4618010 5.4385550 5.9736172 6.4998654 3.7860418 3.3152170 2.2907408
[43] 2.0316265 2.2702928 3.8514024 3.8978484 3.9518290 3.4602029 3.8283521
[50] 3.8949066 3.8310543 3.8895928 3.9699318 3.2135473 2.5254135 3.7236591
[57] 3.8027263 4.2160577 4.9016124 5.1234879 4.1450549 3.8695997 3.8617488
```

	Zona	Margen	Embalse	Año	Entradas	Salidas	Reservas	ReserBoxCox
1	Alta	Derecho	La Fernandina	1991 1992	NA	NA	24.49	3.3833760
2	Alta	Derecho	La Fernandina	1992 1993	3.20	11.56	20.70	3.1959640
3	Alta	Derecho	La Fernandina	1993 1994	7.81	9.05	14.08	2.7705130
4	Alta	Derecho	La Fernandina	1994 1995	0.23	4.33	9.82	2.3778480
5	Alta	Derecho	La Fernandina	1995 1996	118.96	5.13	89.18	4.8612460
6	Alta	Derecho	La Fernandina	1996 1997	215.31	154.38	199.09	5.8137180
7	Alta	Derecho	La Fernandina	1997 1998	172.01	154.29	216.41	5.9141890
8	Alta	Derecho	La Fernandina	1998 1999	0.63	128.70	156.49	5.5253690
9	Alta	Derecho	La Fernandina	1999 2000	32.10	48.17	80.80	4.7460420
10	Alta	Derecho	La Fernandina	2000 2001	123.01	35.50	128.68	5.2928100

FUNDAMENTOS Y HERRAMIENTAS PARA LA MODELIZACIÓN DE PROCESOS TÉCNICOS-CIENTÍFICOS DE INVESTIGACIÓN

Bloque III: Modelización estadística.

Regresión y correlación con R (Rcommander)



Roberto Espejo Mohedano e-mail: ma1esmor@uco.es