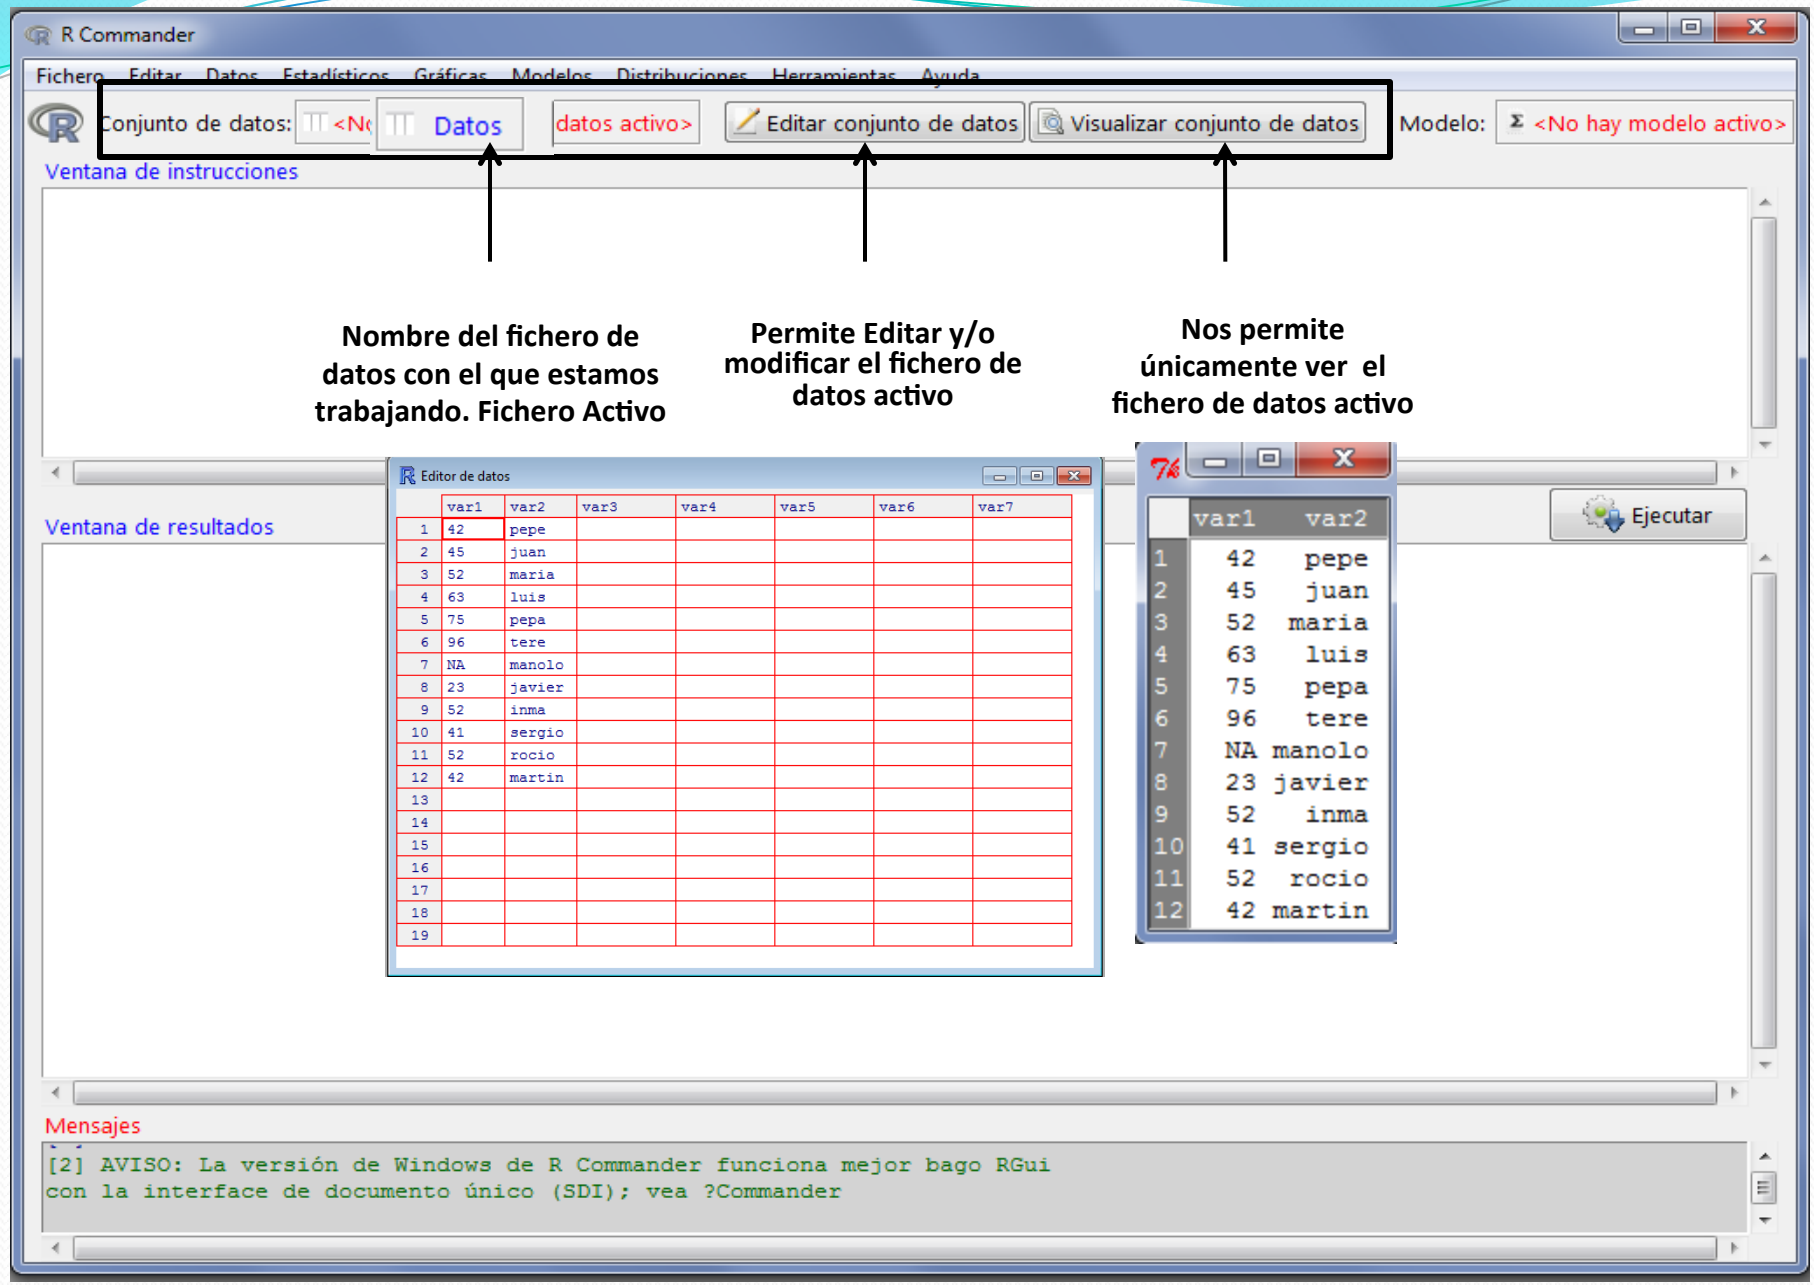
FUNDAMENTOS Y HERRAMIENTAS PARA LA MODELIZACIÓN DE PROCESOS TÉCNICOS-CIENTÍFICOS DE INVESTIGACIÓN

Bloque III: Modelización estadística.

Manipulación de datos con R Commander



Roberto Espejo Mohedano e-mail: ma1esmor@uco.es


R Commander
Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda
Conjunto de datos:
Datos
datos activo>
Editar conjunto de datos
Visualizar conjunto de datos
Modelo:
<No hay modelo activo>
Ventana de instrucciones
Nombre del fichero de datos con el que estamos trabajando. Fichero Activo
Permite Editar y/o modificar el fichero de datos activo
Nos permite únicamente ver el fichero de datos activo
Editor de datos
var1 var2 var3 var4 var5 var6 var7
1 42 pepe
2 45 juan
3 52 maria
4 63 luis
5 75 pepa
6 96 tere
7 NA manolo
8 23 javier
9 52 inma
10 41 sergio
11 52 rocio
12 42 martin
Ventana de resultados
Ejecutar
Mensajes
[2] AVISO: La versión de Windows de R Commander funciona mejor bago RGui
con la interface de documento único (SDI); vea ?Commander

Introducción de Datos con R

Los datos se pueden introducir en el paquete R por tres procedimientos diferentes:

- Nuevo conjunto de Datos

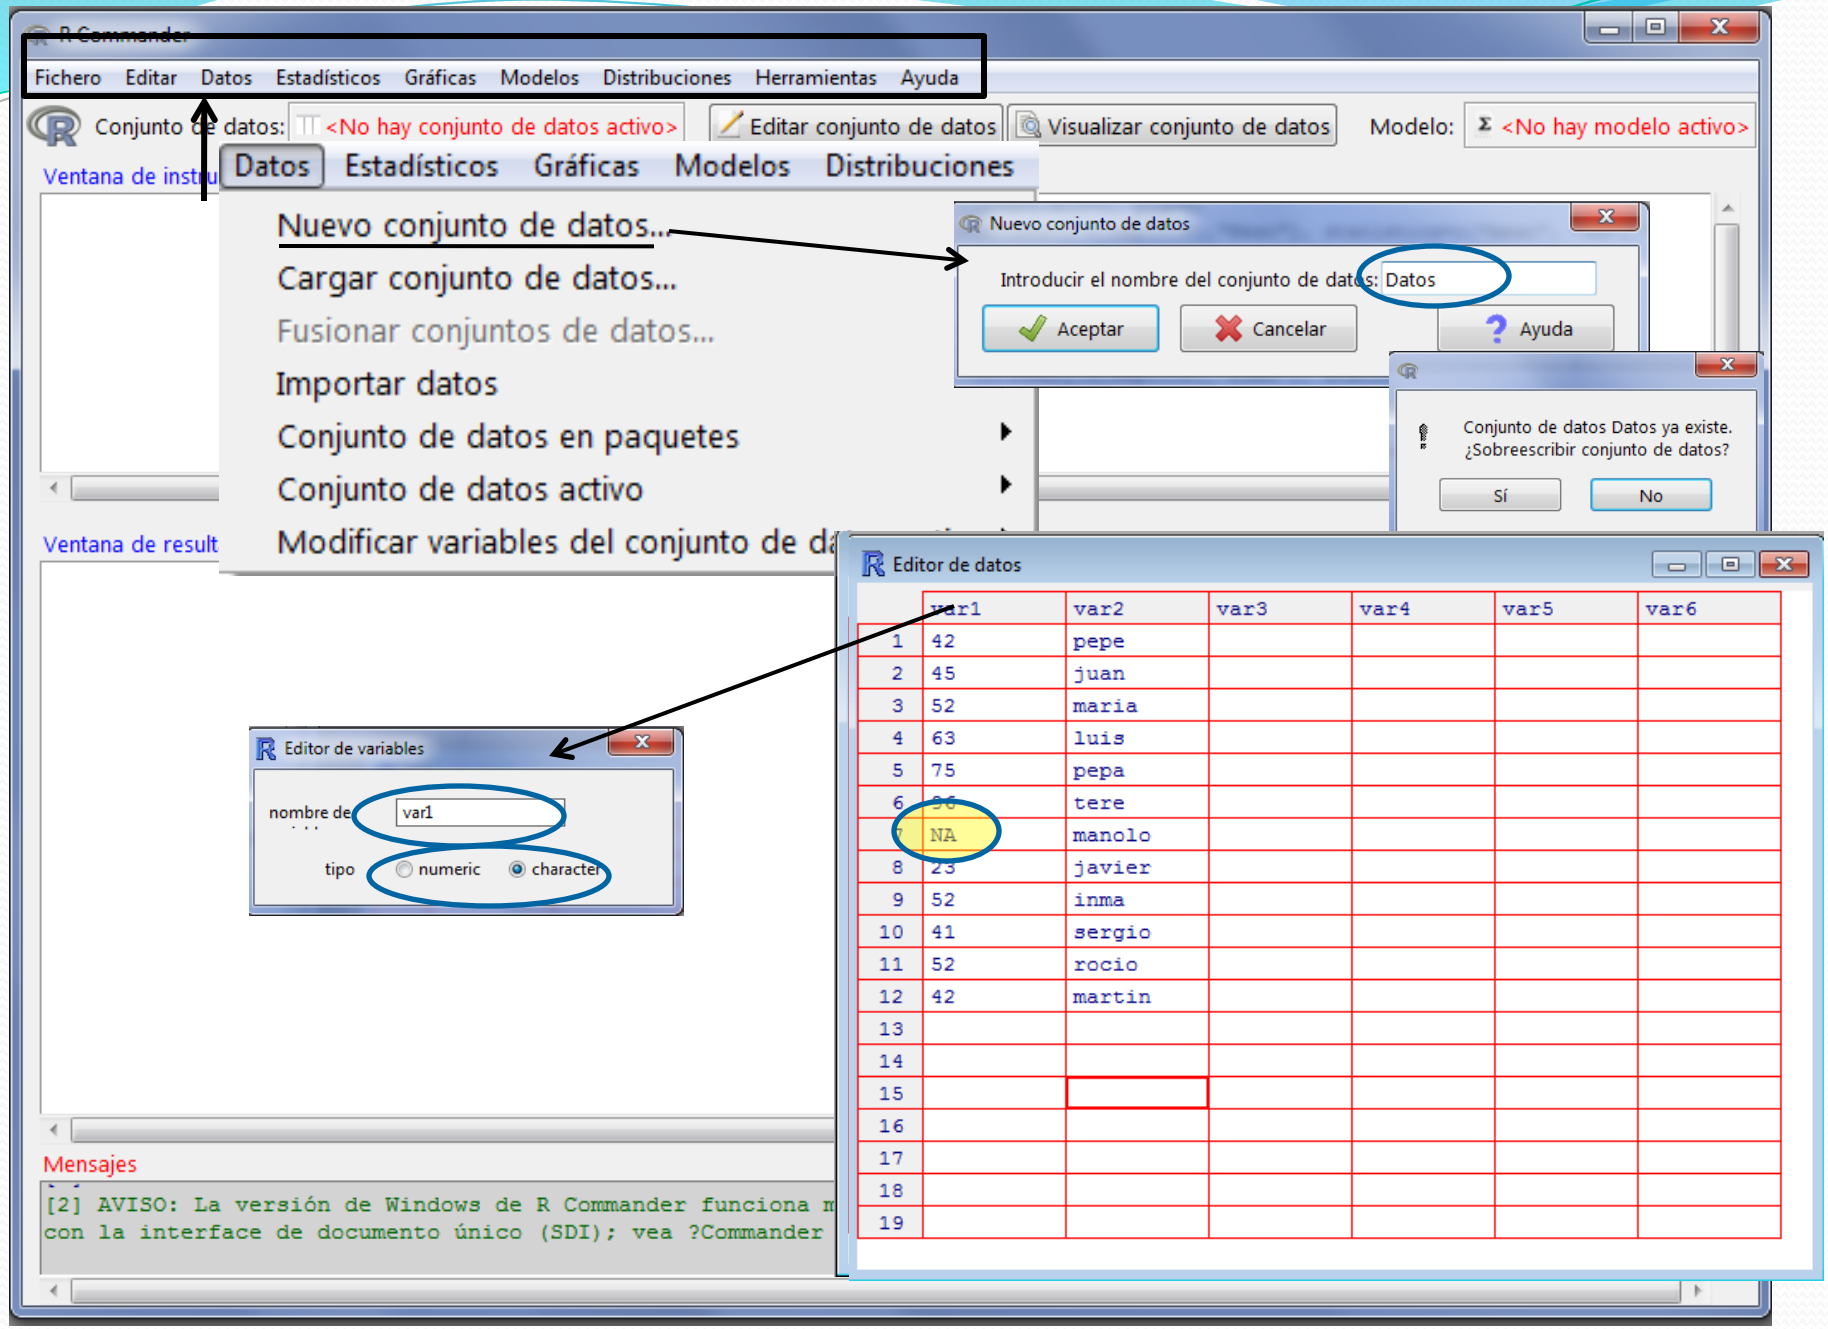
  Introducir datos desde el teclado del ordenador.

- Cargar conjunto de Datos

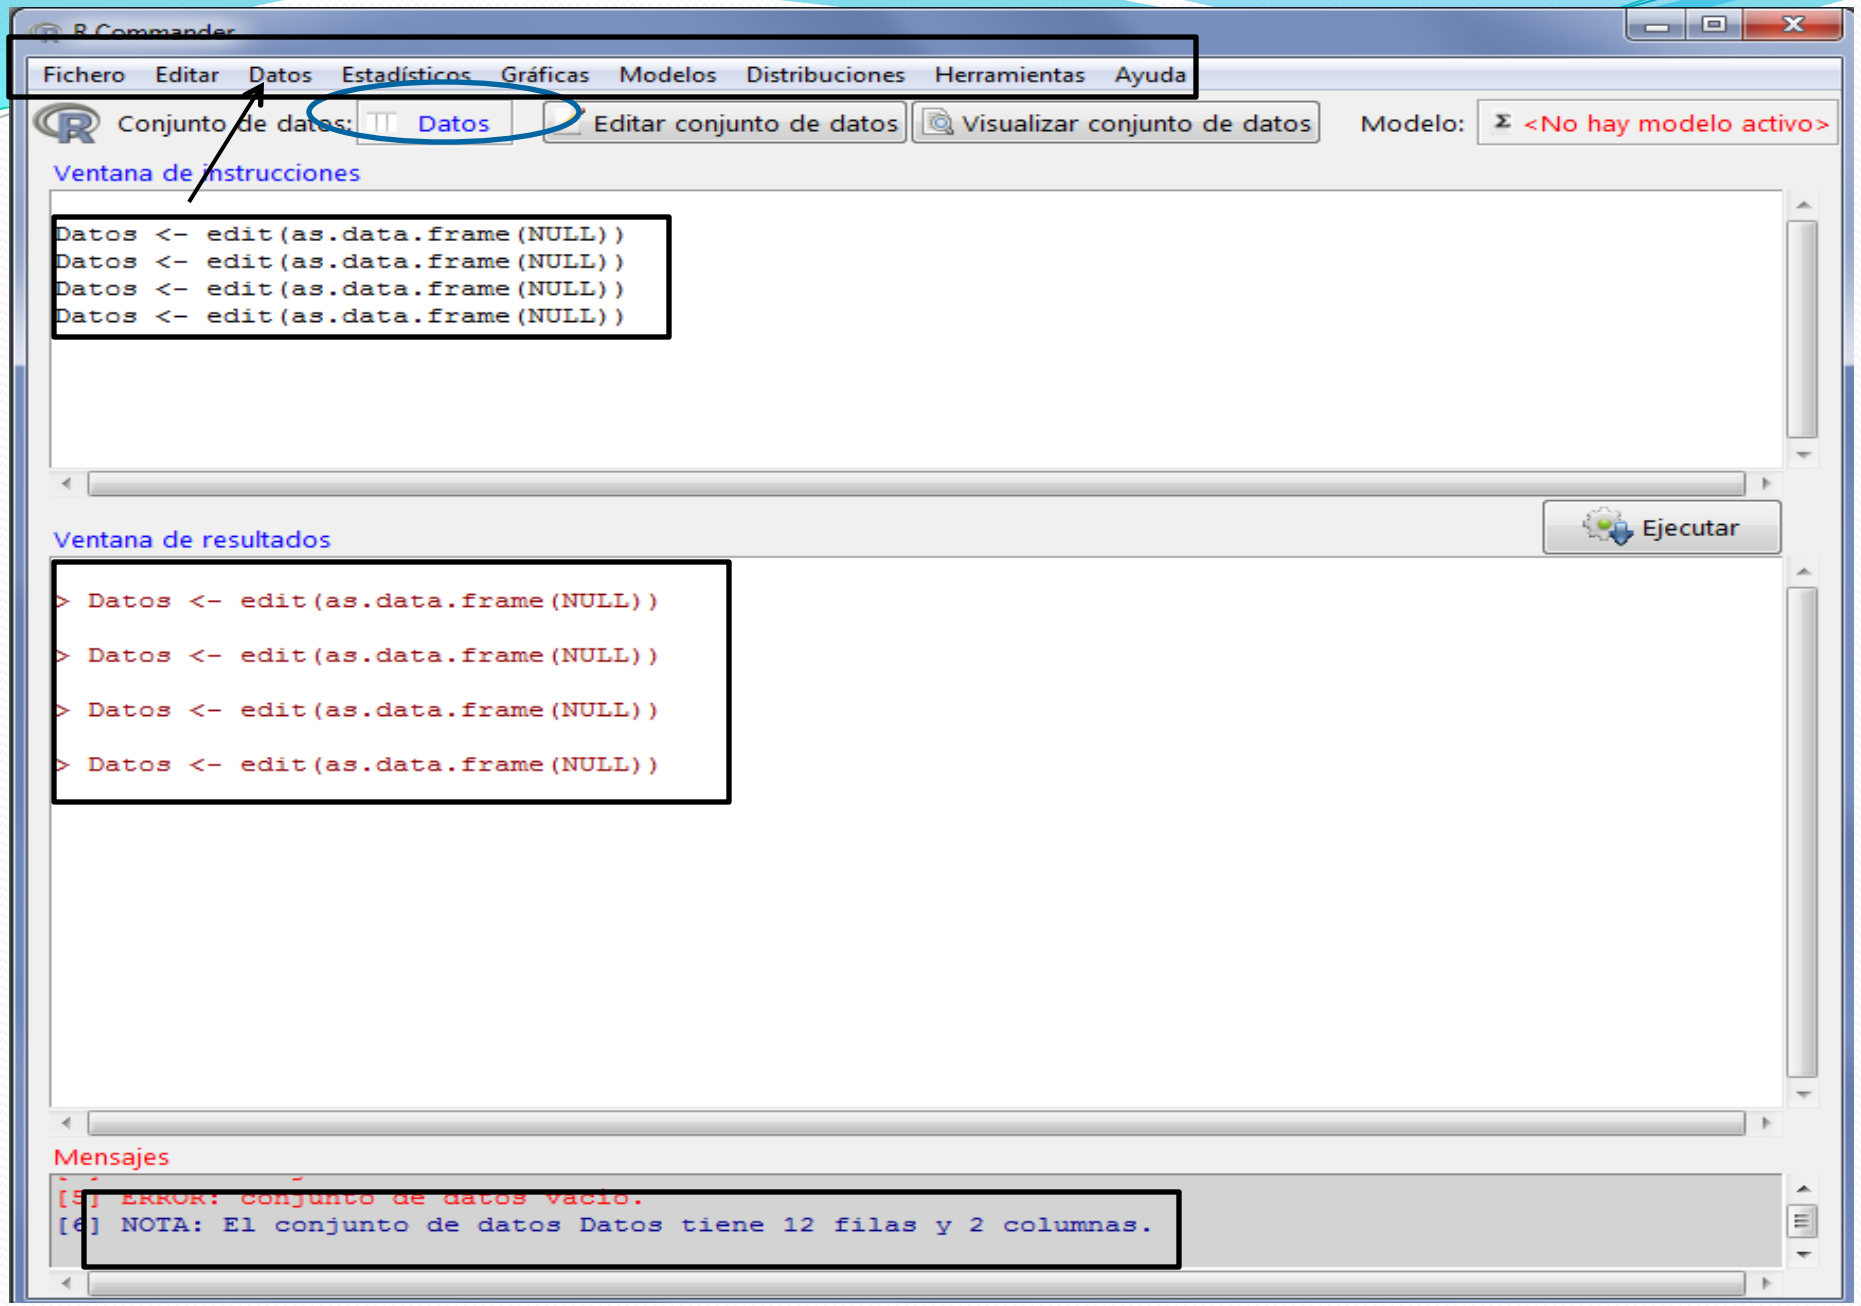
  Introducir datos desde un fichero en formato R.

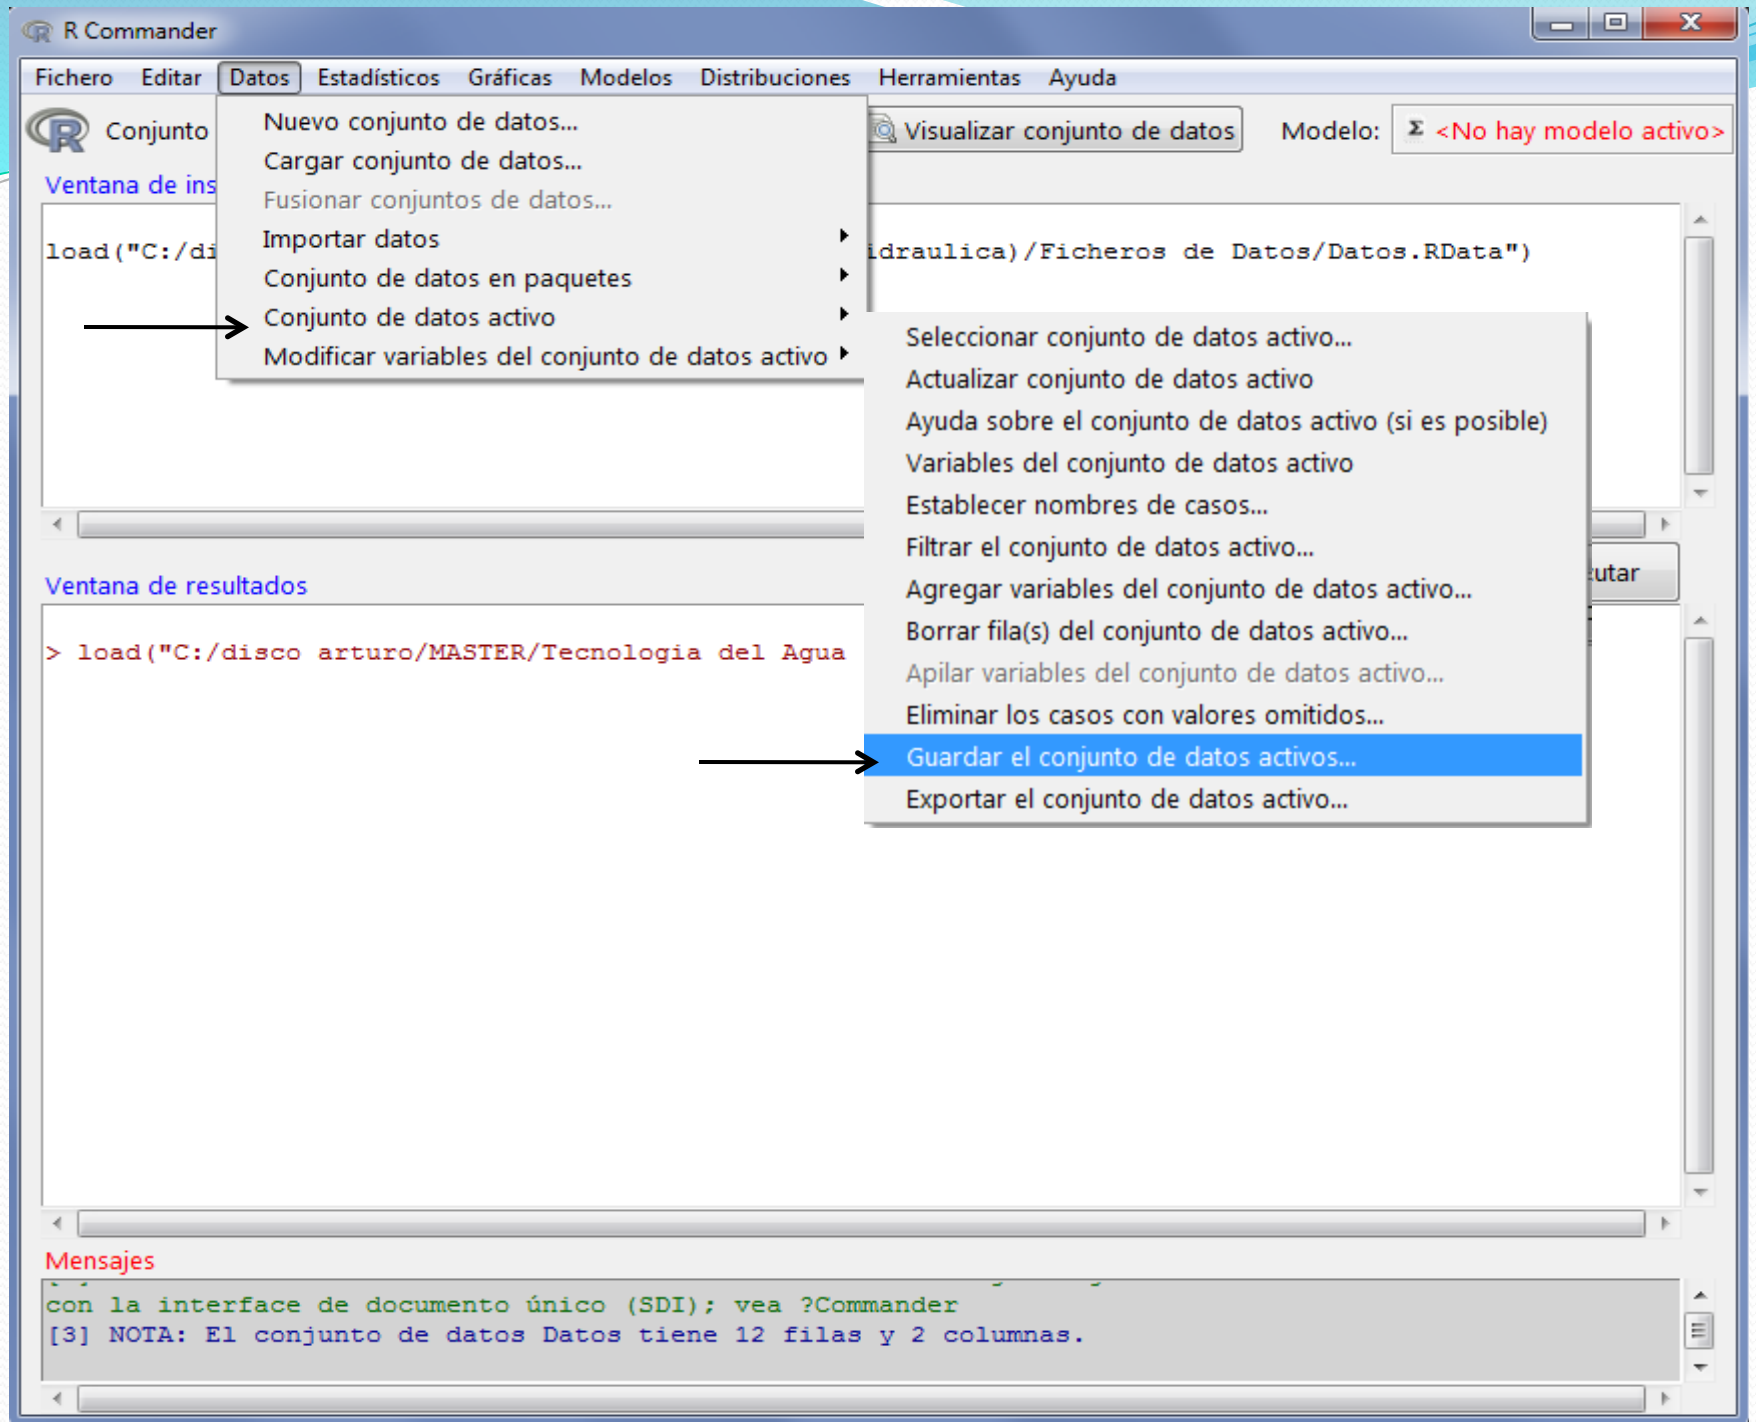
- Importar Datos

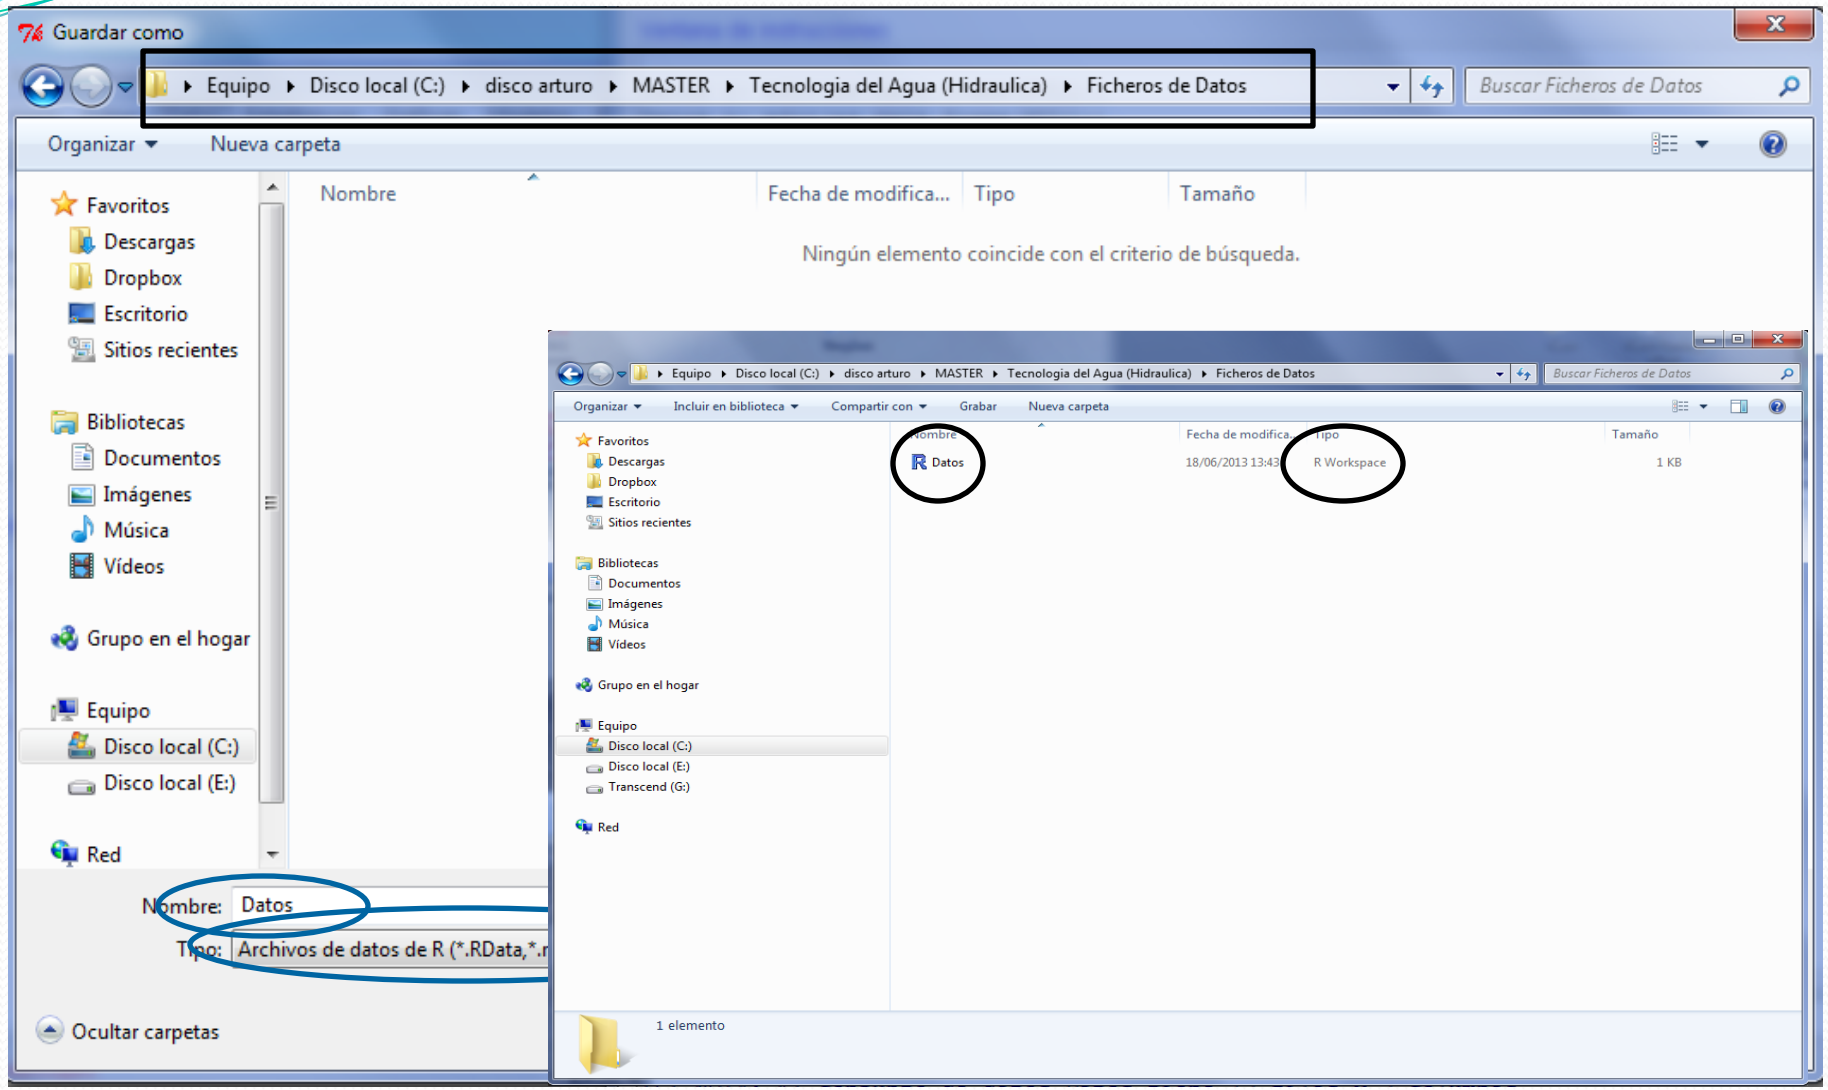
  Introducir datos importándolos desde ficheros: Texto, portapapeles, URL, otros Paquetes Estadísticos, Excel, etc.

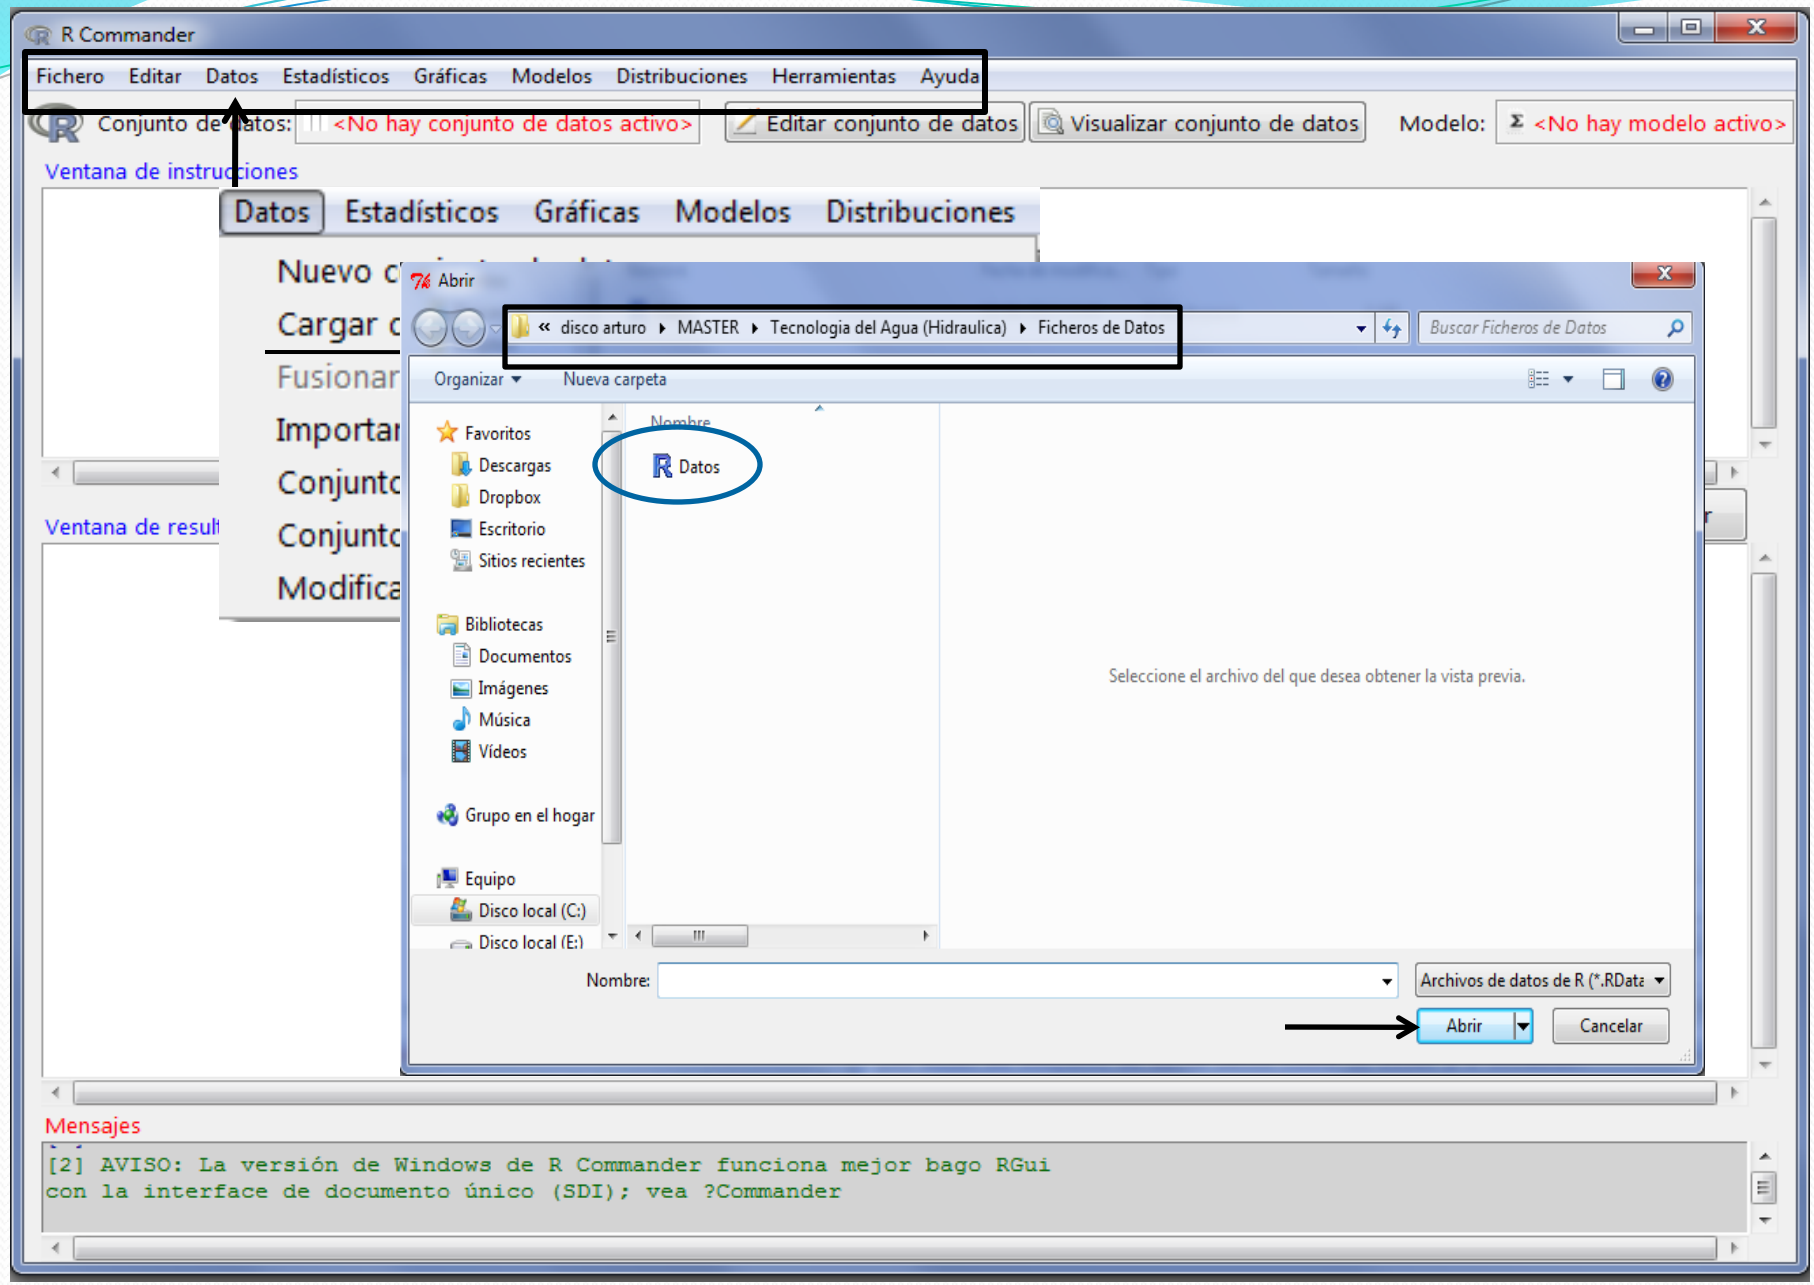


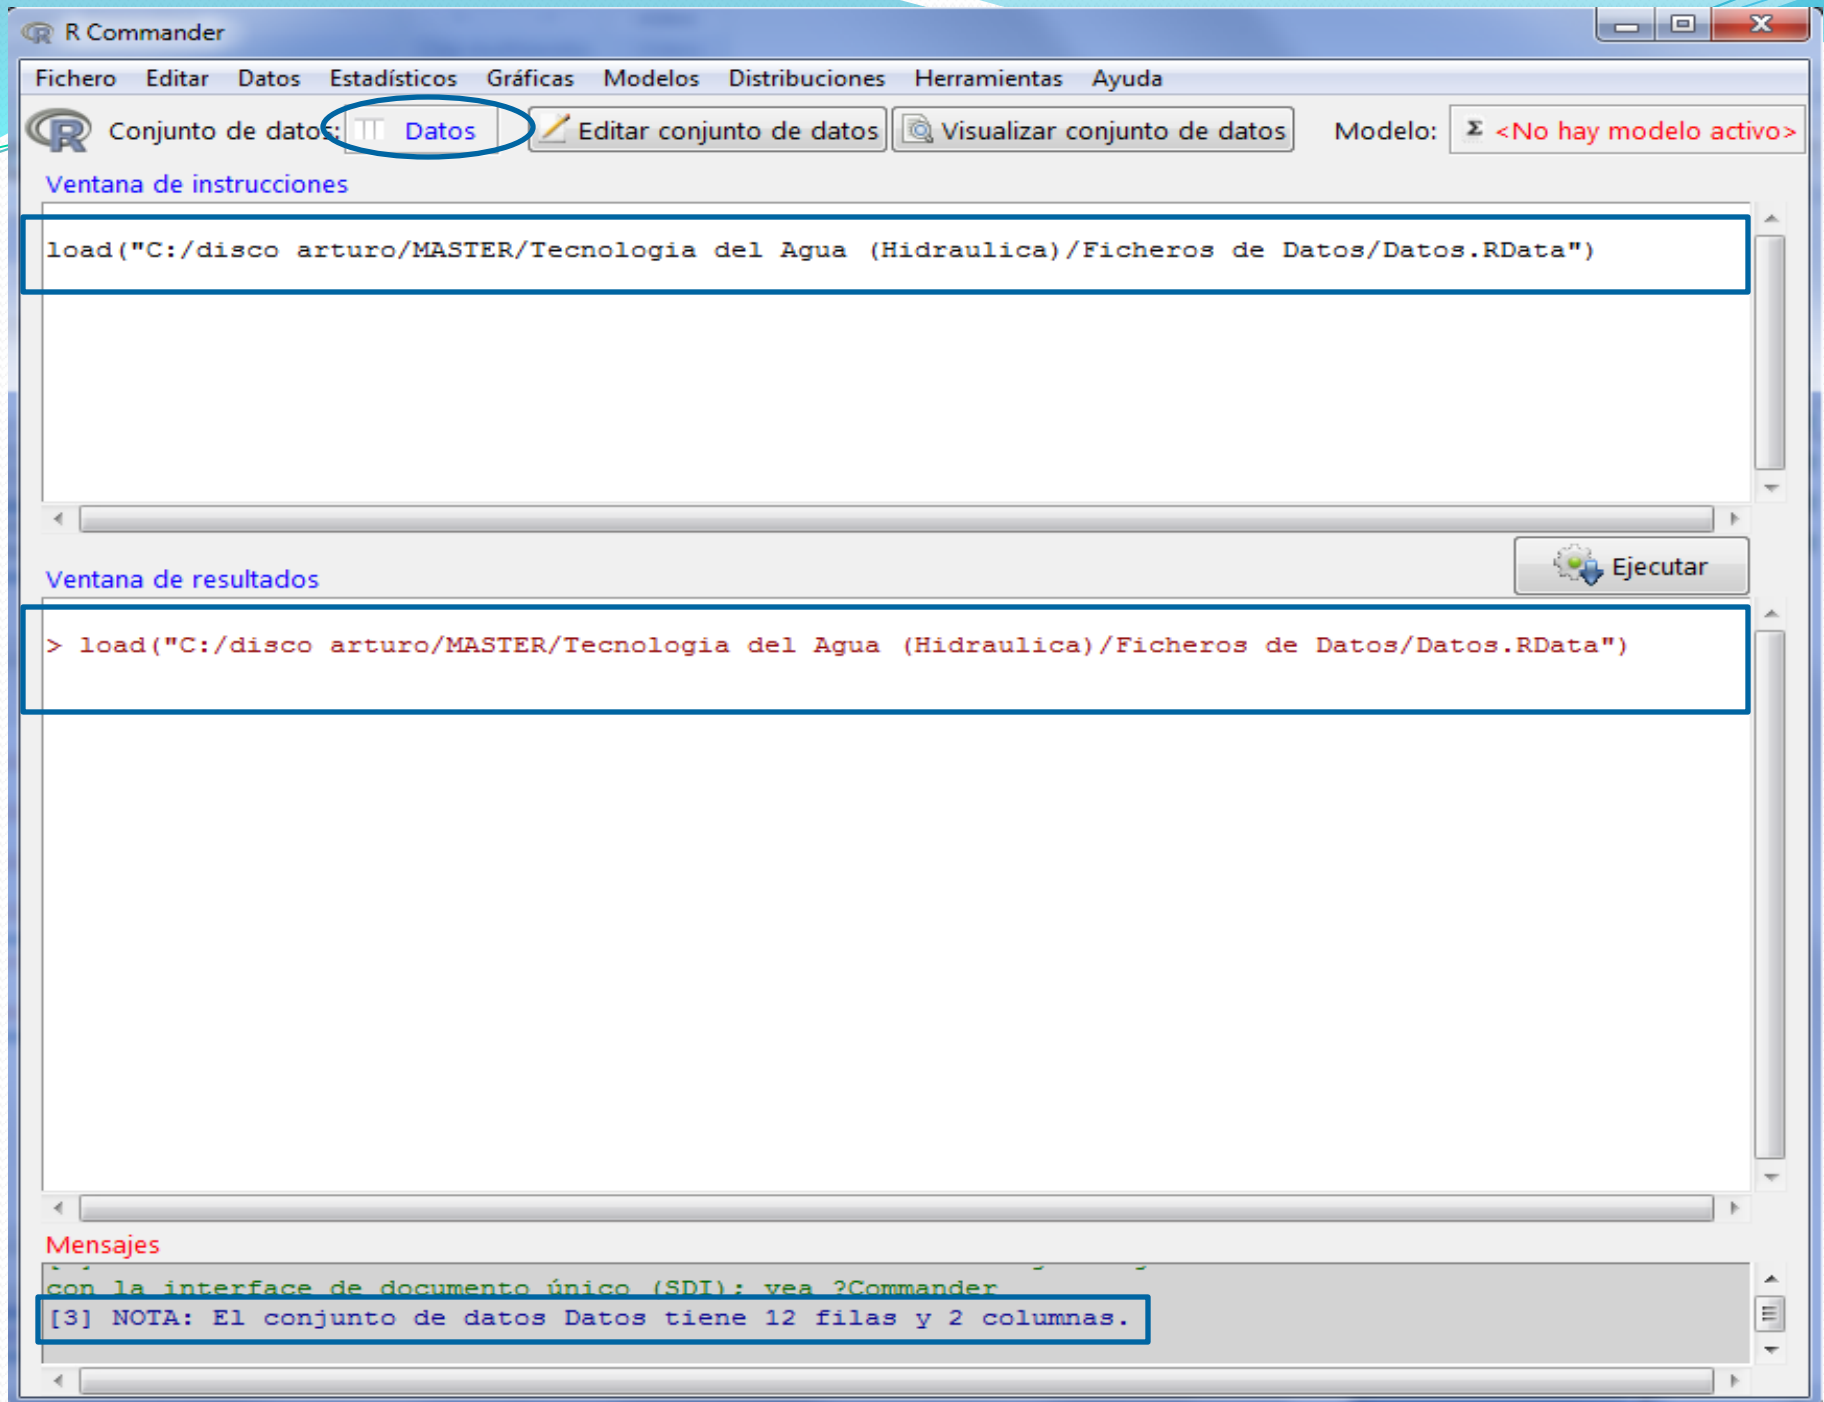
	var1	var2	var3	var4	var5	var6
1	42	pepe				
2	45	juan				
3	52	maria				
4	63	luis				
5	75	pepa				
6	[illegible]	tere				
7	NA	manolo				
8	23	javier				
9	52	inma				
10	41	sergio				
11	52	rocio				
12	42	martin				
13						
14						
15						
16						
17						
18						
19						

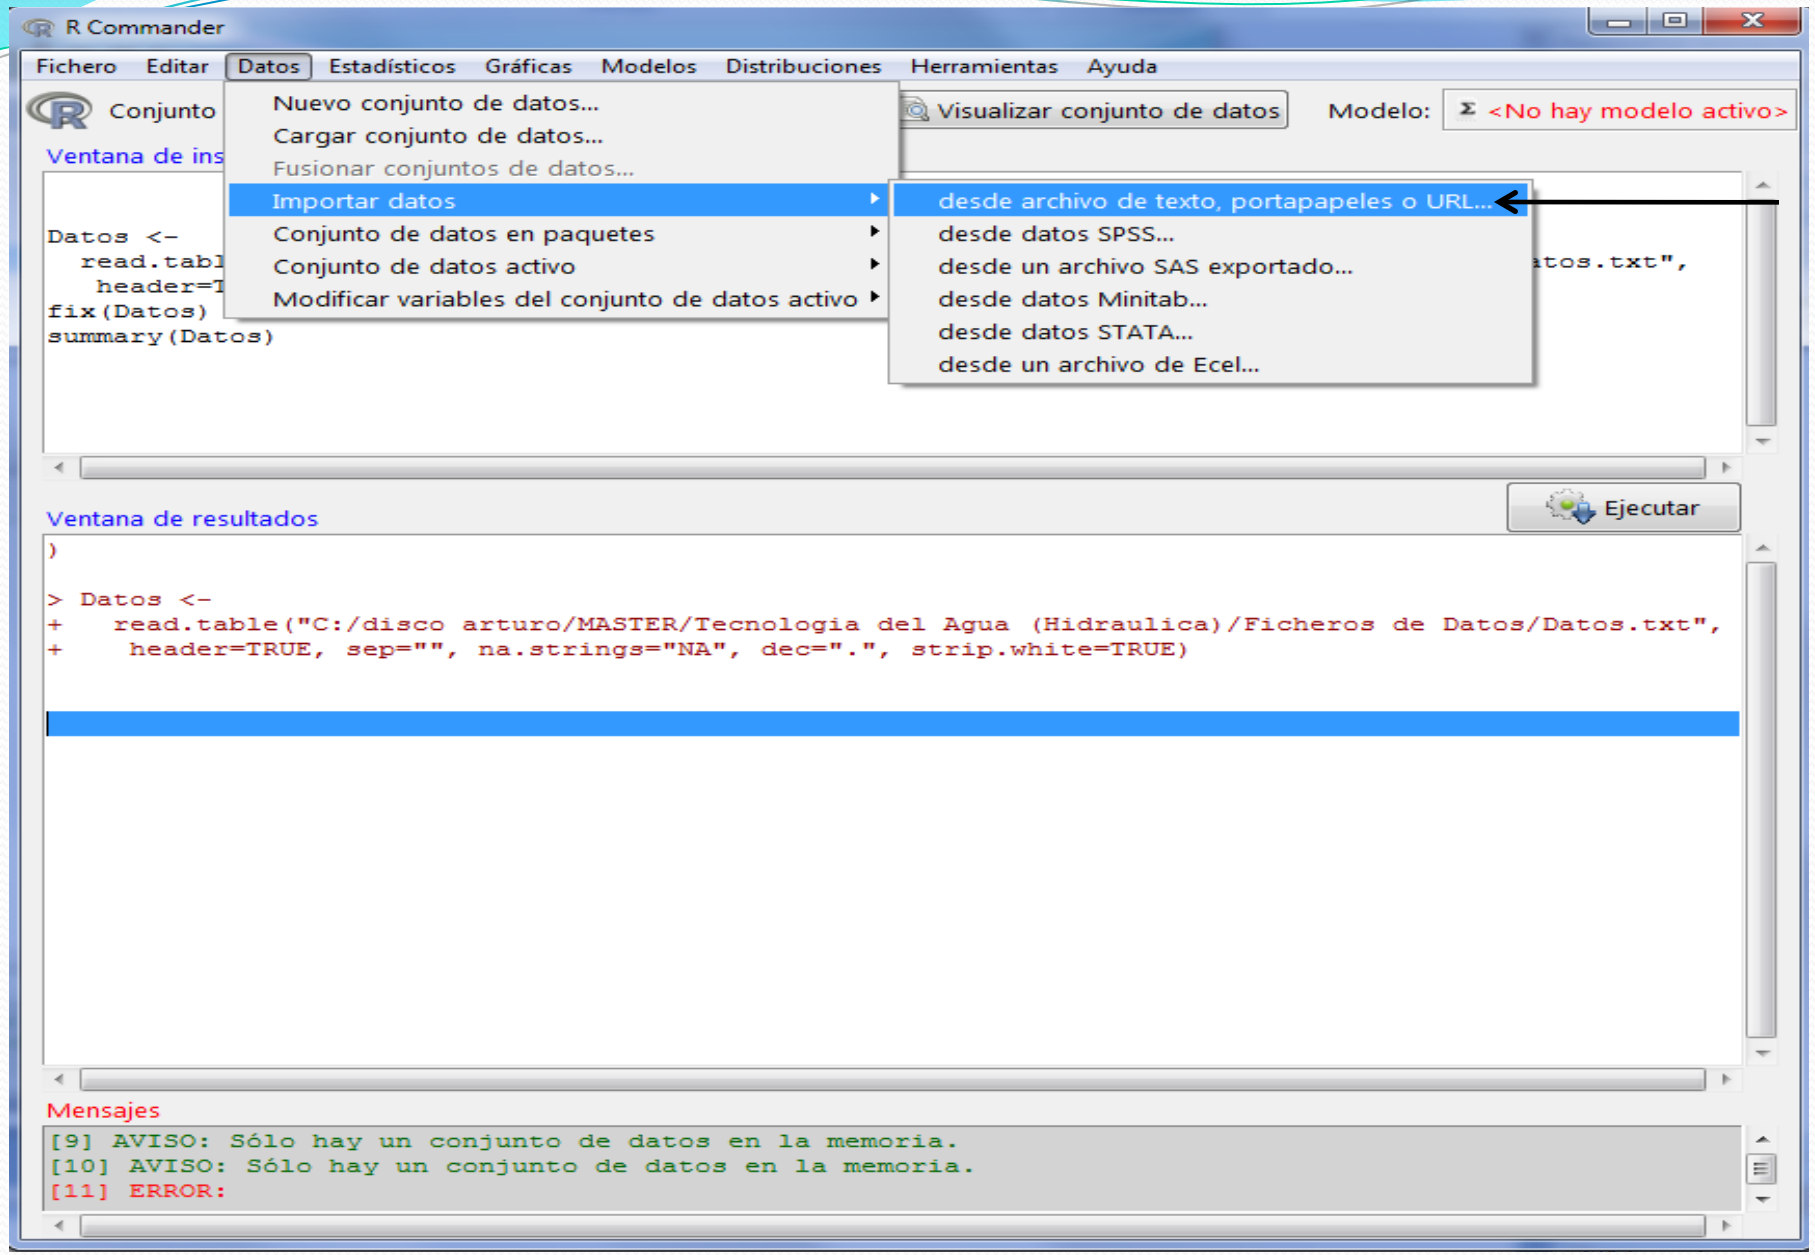

R Commander
Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda
Conjunto de datos: Datos
Editar conjunto de datos
Visualizar conjunto de datos
Modelo: <No hay modelo activo>
Ventana de instrucciones
Datos <- edit(as.data.frame(NULL))
Datos <- edit(as.data.frame(NULL))
Datos <- edit(as.data.frame(NULL))
Datos <- edit(as.data.frame(NULL))
Ejecutar
Ventana de resultados
> Datos <- edit(as.data.frame(NULL))
> Datos <- edit(as.data.frame(NULL))
> Datos <- edit(as.data.frame(NULL))
> Datos <- edit(as.data.frame(NULL))
Mensajes
[6] NOTA: El conjunto de datos Datos tiene 12 filas y 2 columnas.


R Commander
Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda
Conjunto
Visualizar conjunto de datos
Modelo: <No hay modelo activo>
Nuevo conjunto de datos...
Cargar conjunto de datos...
Fusionar conjuntos de datos...
Importar datos
Conjunto de datos en paquetes
Conjunto de datos activo
Modificar variables del conjunto de datos activo
Seleccionar conjunto de datos activo...
Actualizar conjunto de datos activo
Ayuda sobre el conjunto de datos activo (si es posible)
Variables del conjunto de datos activo
Establecer nombres de casos...
Filtrar el conjunto de datos activo...
Agregar variables del conjunto de datos activo...
Borrar fila(s) del conjunto de datos activo...
Apilar variables del conjunto de datos activo...
Eliminar los casos con valores omitidos...
Guardar el conjunto de datos activos...
Exportar el conjunto de datos activo...
Ventana de ins
load("C:/di
idraulica)/Ficheros de Datos/Datos.RData")
Ventana de resultados
> load("C:/disco arturo/MASTER/Tecnologia del Agua
Mensajes
con la interface de documento único (SDI); vea ?Commander
[3] NOTA: El conjunto de datos Datos tiene 12 filas y 2 columnas.

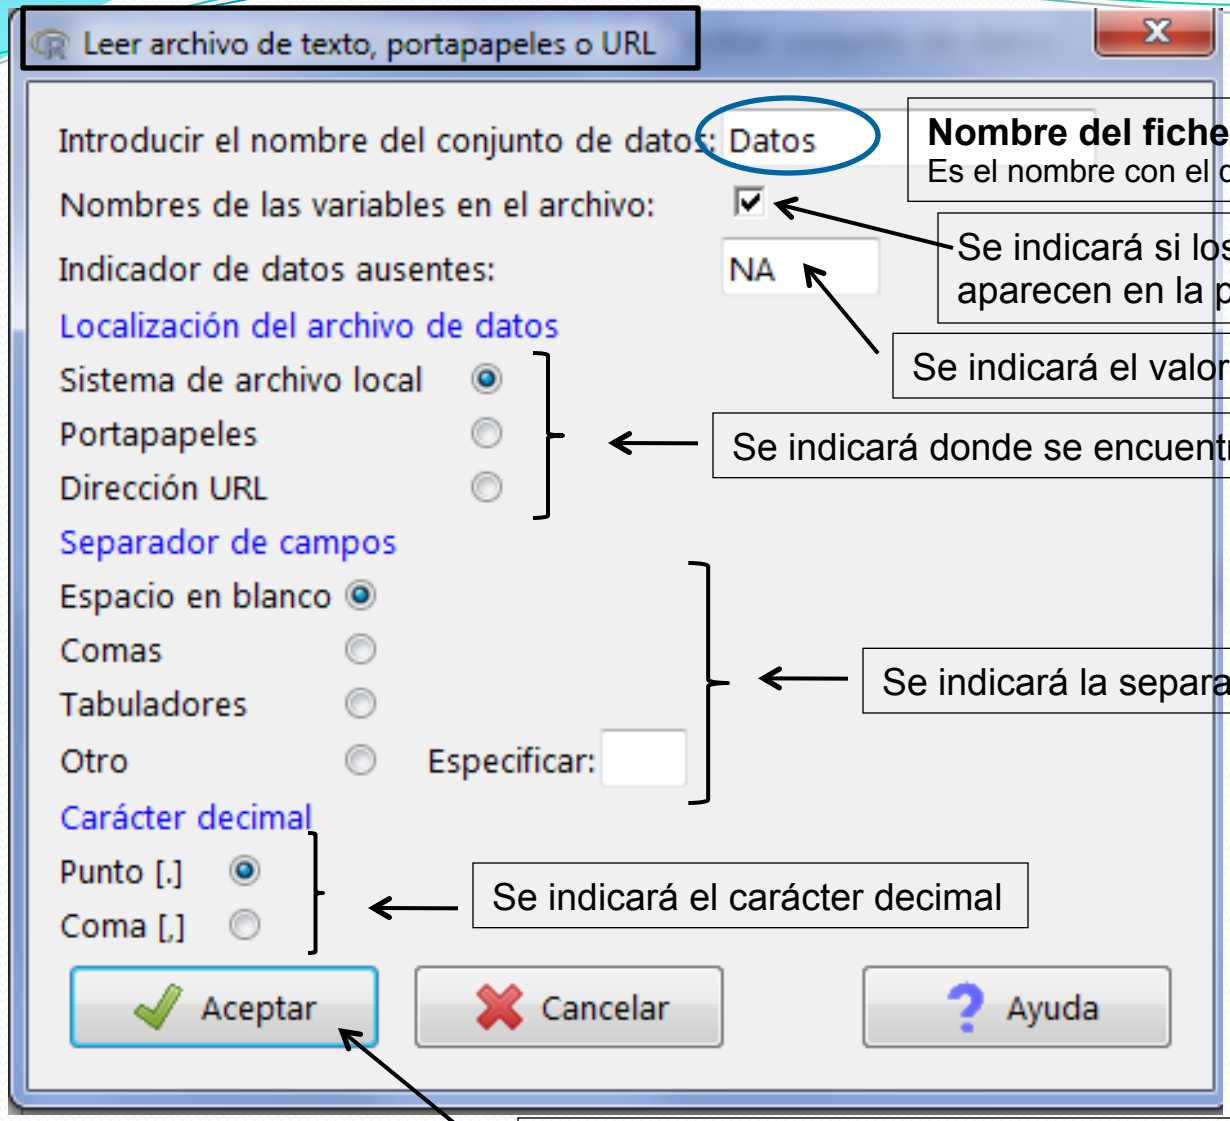

Guardar como
Equipo ▸ Disco local (C:) ▸ disco arturo ▸ MASTER ▸ Tecnologia del Agua (Hidraulica) ▸ Ficheros de Datos
Buscar Ficheros de Datos
Organizar
Nueva carpeta
Favoritos
Descargas
Dropbox
Escritorio
Sitios recientes
Bibliotecas
Documentos
Imágenes
Música
Vídeos
Grupo en el hogar
Equipo
Disco local (C:)
Disco local (E:)
Red
Nombre
Fecha de modifica...
Tipo
Tamaño
Ningún elemento coincide con el criterio de búsqueda.
Nombre: Datos
Tipo: Archivos de datos de R (*.RData,*.r
Ocultar carpetas
Equipo ▸ Disco local (C:) ▸ disco arturo ▸ MASTER ▸ Tecnologia del Agua (Hidraulica) ▸ Ficheros de Datos
Buscar Ficheros de Datos
Organizar
Incluir en biblioteca
Compartir con
Grabar
Nueva carpeta
Favoritos
Descargas
Dropbox
Escritorio
Sitios recientes
Bibliotecas
Documentos
Imágenes
Música
Vídeos
Grupo en el hogar
Equipo
Disco local (C:)
Disco local (E:)
Transcend (G:)
Red
Nombre
Fecha de modifica...
Tipo
Tamaño
Datos
18/06/2013 13:43
R Workspace
1 KB
1 elemento


R Commander
Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda
Conjunto de datos: <No hay conjunto de datos activo>
Editar conjunto de datos
Visualizar conjunto de datos
Modelo: <No hay modelo activo>
Ventana de instrucciones
Datos Estadísticos Gráficas Modelos Distribuciones
Nuevo c
Cargar c
Fusionar
Importar
Conjunto
Conjunto
Modifica
Abrir
« disco arturo ▸ MASTER ▸ Tecnologia del Agua (Hidraulica) ▸ Ficheros de Datos
Buscar Ficheros de Datos
Organizar
Nueva carpeta
Favoritos
Descargas
Dropbox
Escritorio
Sitios recientes
Bibliotecas
Documentos
Imágenes
Música
Vídeos
Grupo en el hogar
Equipo
Disco local (C:)
Disco local (E:)
Nombre
Datos
Seleccione el archivo del que desea obtener la vista previa.
Nombre:
Archivos de datos de R (*.RData
Abrir
Cancelar
Ventana de resul
Mensajes
[2] AVISO: La versión de Windows de R Commander funciona mejor bago RGui
con la interface de documento único (SDI); vea ?Commander


R Commander
Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda
Conjunto de datos: Datos
Editar conjunto de datos
Visualizar conjunto de datos
Modelo: <No hay modelo activo>
Ventana de instrucciones
load("C:/disco arturo/MASTER/Tecnologia del Agua (Hidraulica)/Ficheros de Datos/Datos.RData")
Ejecutar
Ventana de resultados
> load("C:/disco arturo/MASTER/Tecnologia del Agua (Hidraulica)/Ficheros de Datos/Datos.RData")
Mensajes
con la interface de documento único (SDI); vea ?Commander
[3] NOTA: El conjunto de datos Datos tiene 12 filas y 2 columnas.


R Commander
Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda
Conjunto
Visualizar conjunto de datos
Modelo: <No hay modelo activo>
Nuevo conjunto de datos...
Cargar conjunto de datos...
Fusionar conjuntos de datos...
Importar datos
Conjunto de datos en paquetes
Conjunto de datos activo
Modificar variables del conjunto de datos activo
desde archivo de texto, portapapeles o URL...
desde datos SPSS...
desde un archivo SAS exportado...
desde datos Minitab...
desde datos STATA...
desde un archivo de Ecel...
Ventana de ins
Datos <-
read.tabl
header=T
fix(Datos)
summary(Datos)
atos.txt",
Ejecutar
Ventana de resultados
)
> Datos <-
+ read.table("C:/disco arturo/MASTER/Tecnologia del Agua (Hidraulica)/Ficheros de Datos/Datos.txt",
+ header=TRUE, sep="", na.strings="NA", dec=".", strip.white=TRUE)
Mensajes
[9] AVISO: Sólo hay un conjunto de datos en la memoria.
[10] AVISO: Sólo hay un conjunto de datos en la memoria.
[11] ERROR:

Se han de proporcionar las características del fichero Texto donde se encuentran los datos



Nombre del fichero que vamos a crear
Es el nombre con el que R va a reconocer los datos

Se indicará si los nombres de las variables aparecen en la primera fila del fichero texto o no

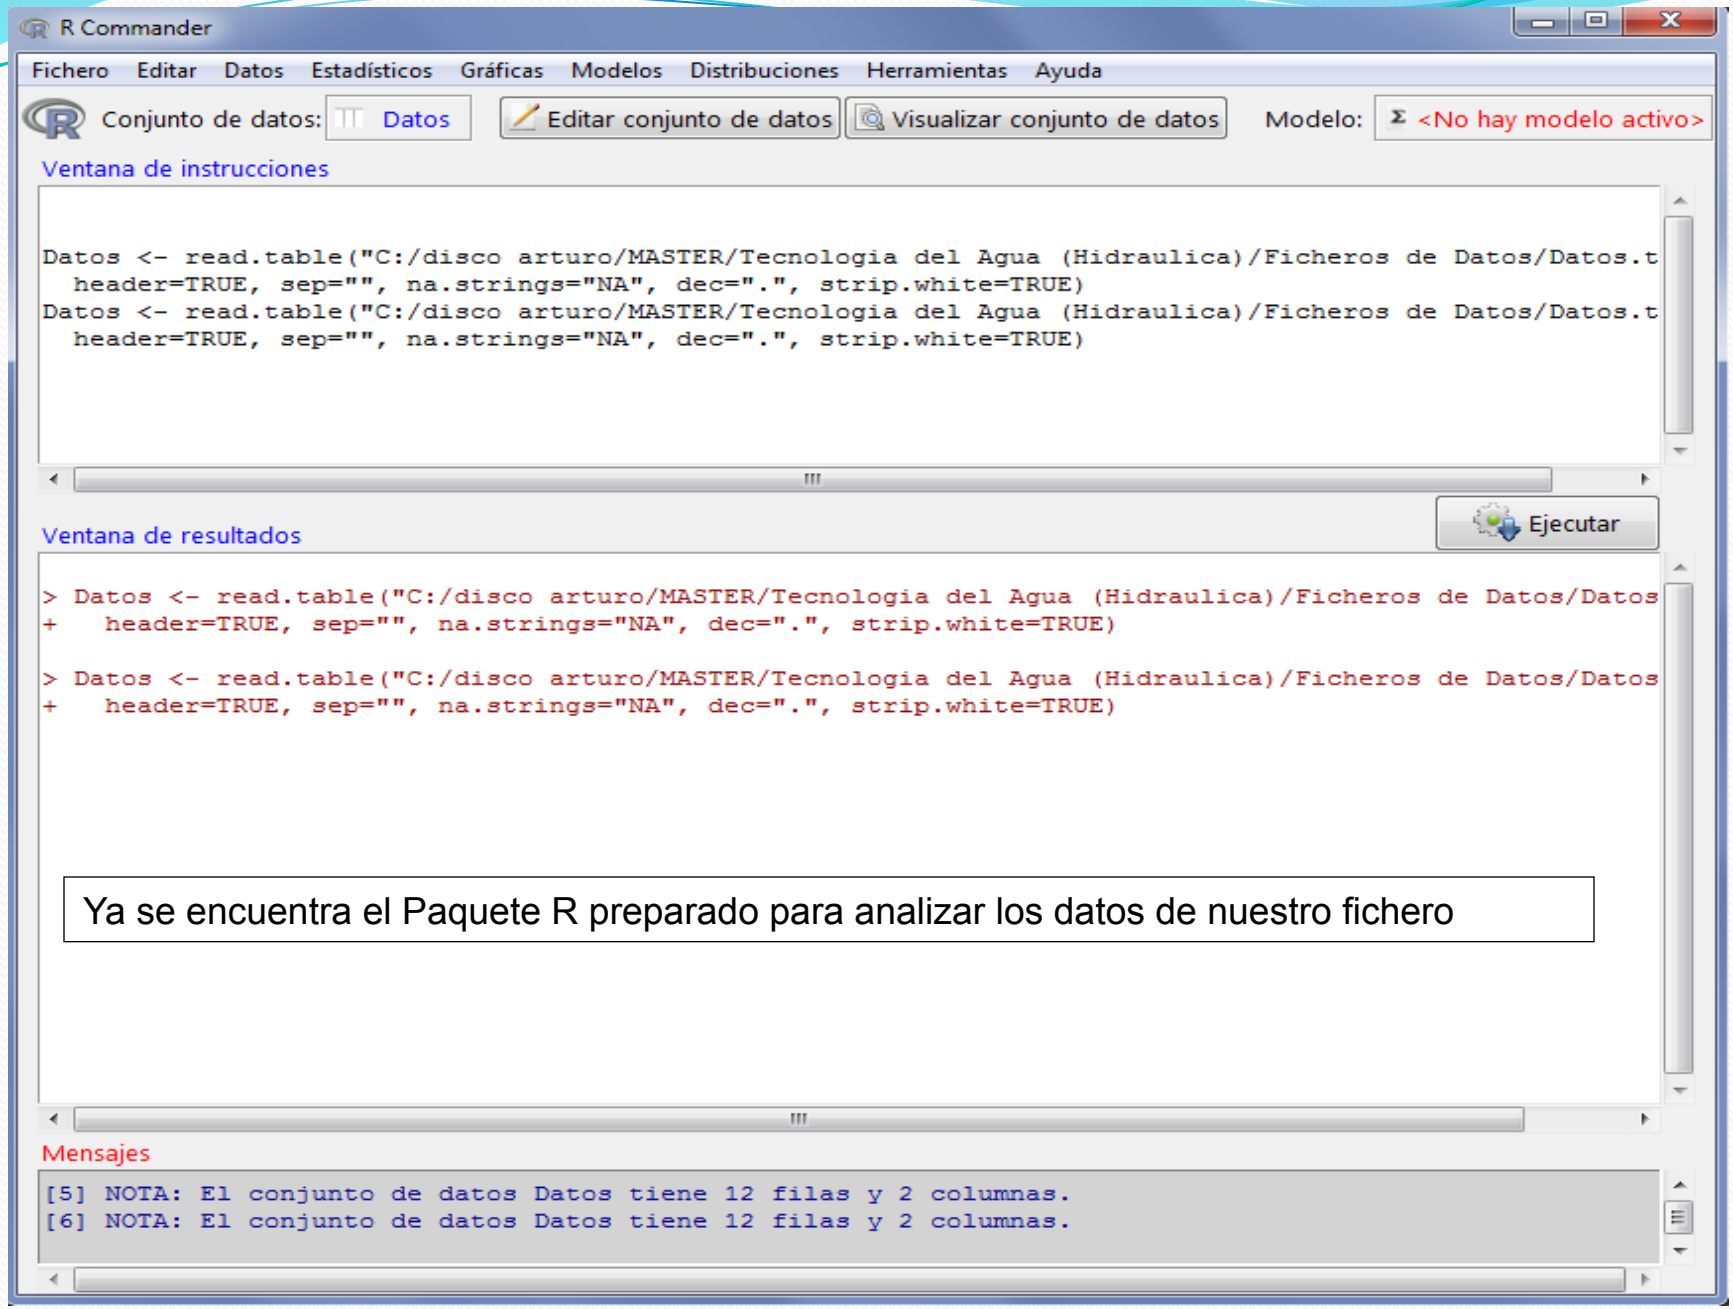
Se indicará el valor de los datos ausentes

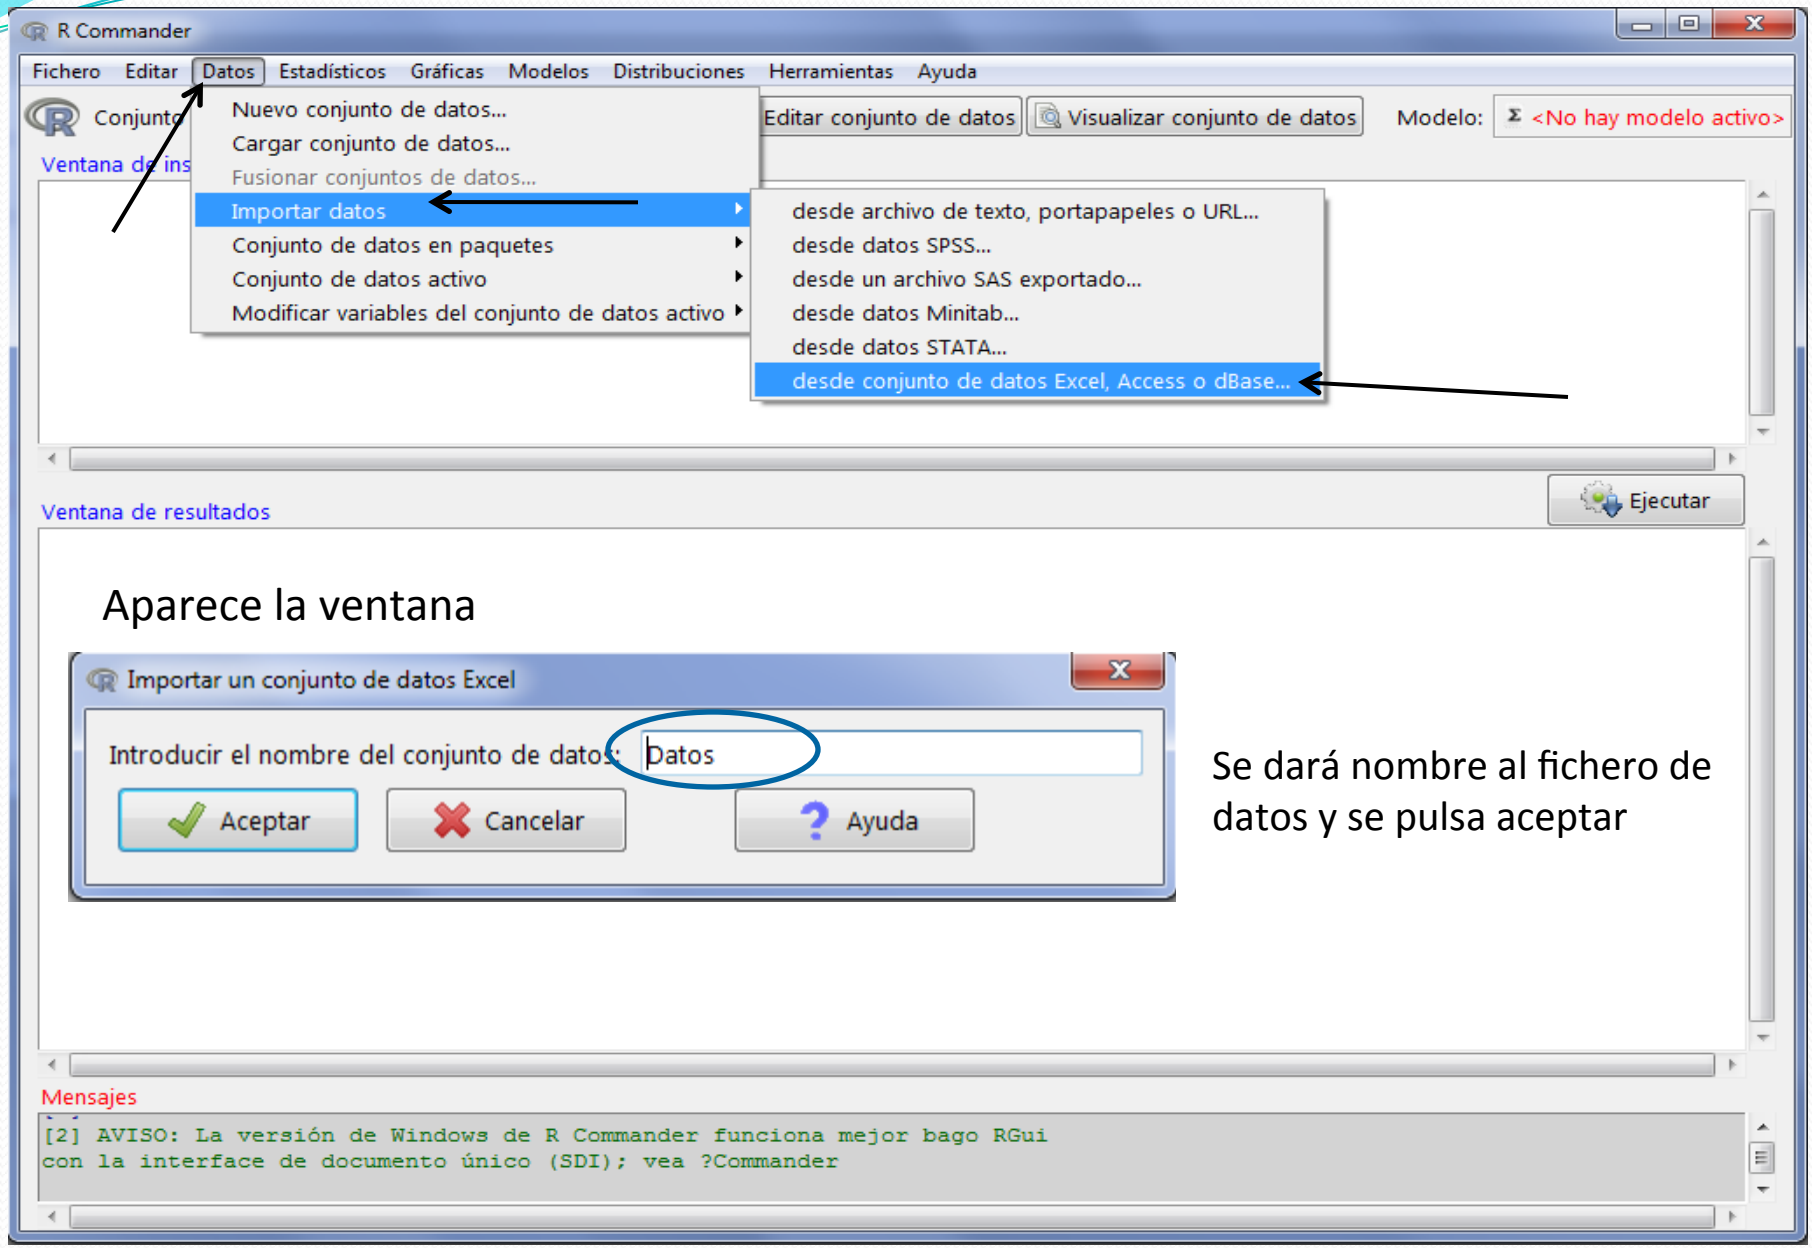
Se indicará donde se encuentran los datos

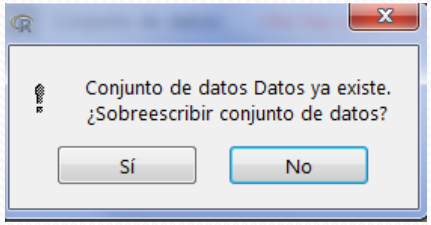
Se indicará la separación entre columnas de datos

Se indicará el carácter decimal

Una vez proporcionadas las características de los datos, pulsamos Aceptar

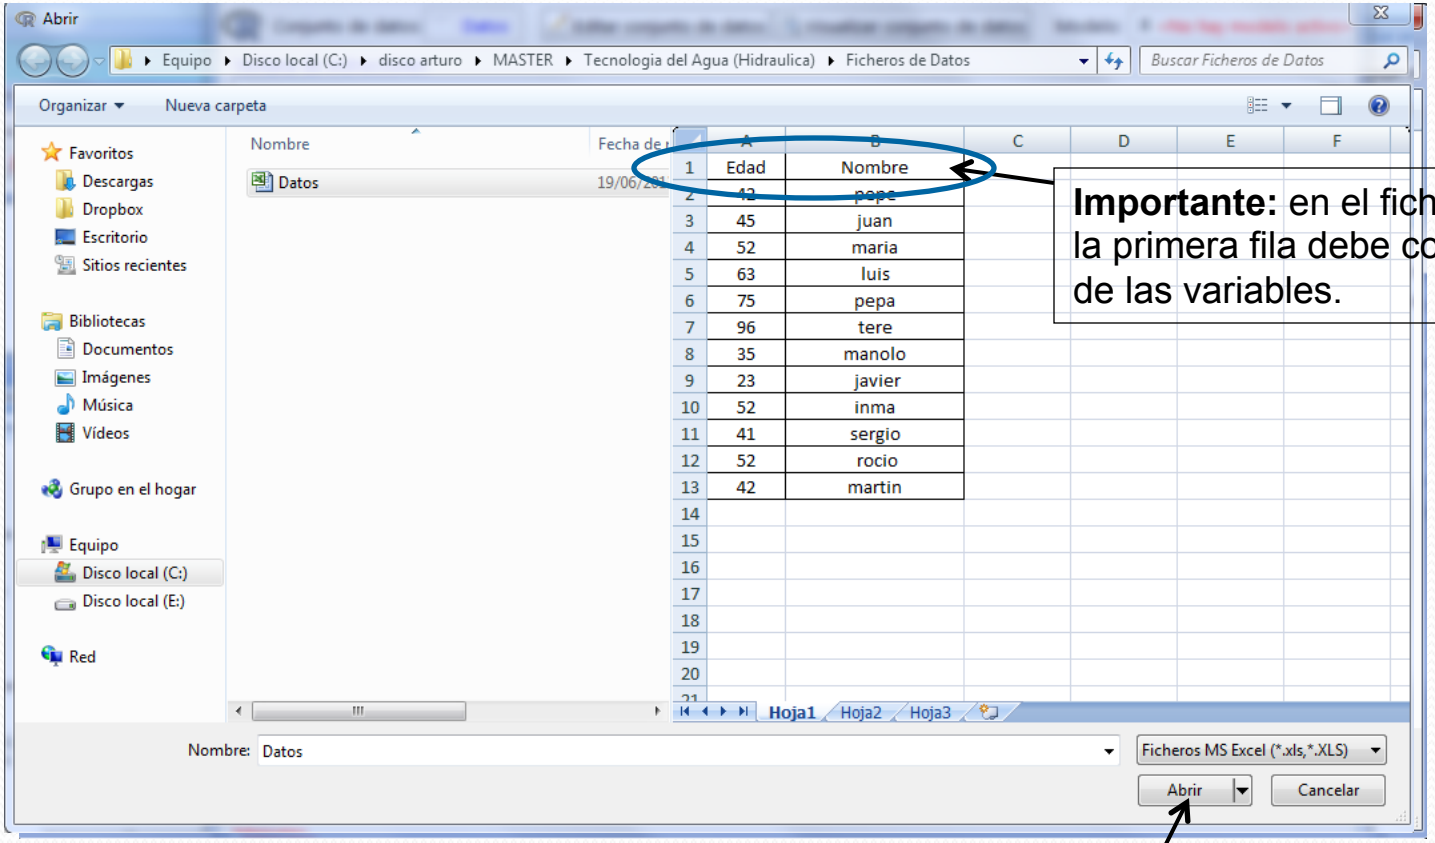

R Commander
Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda
Conjunto de datos: Datos
Editar conjunto de datos
Visualizar conjunto de datos
Modelo: <No hay modelo activo>
Ventana de instrucciones
Datos <- read.table("C:/disco arturo/MASTER/Tecnologia del Agua (Hidraulica)/Ficheros de Datos/Datos.t
header=TRUE, sep="", na.strings="NA", dec=".", strip.white=TRUE)
Datos <- read.table("C:/disco arturo/MASTER/Tecnologia del Agua (Hidraulica)/Ficheros de Datos/Datos.t
header=TRUE, sep="", na.strings="NA", dec=".", strip.white=TRUE)
Ejecutar
Ventana de resultados
> Datos <- read.table("C:/disco arturo/MASTER/Tecnologia del Agua (Hidraulica)/Ficheros de Datos/Datos
+ header=TRUE, sep="", na.strings="NA", dec=".", strip.white=TRUE)
> Datos <- read.table("C:/disco arturo/MASTER/Tecnologia del Agua (Hidraulica)/Ficheros de Datos/Datos
+ header=TRUE, sep="", na.strings="NA", dec=".", strip.white=TRUE)
Ya se encuentra el Paquete R preparado para analizar los datos de nuestro fichero
Mensajes
[5] NOTA: El conjunto de datos Datos tiene 12 filas y 2 columnas.
[6] NOTA: El conjunto de datos Datos tiene 12 filas y 2 columnas.


R Commander
Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda
Nuevo conjunto de datos...
Cargar conjunto de datos...
Fusionar conjuntos de datos...
Importar datos
Conjunto de datos en paquetes
Conjunto de datos activo
Modificar variables del conjunto de datos activo
desde archivo de texto, portapapeles o URL...
desde datos SPSS...
desde un archivo SAS exportado...
desde datos Minitab...
desde datos STATA...
desde conjunto de datos Excel, Access o dBase...
Editar conjunto de datos
Visualizar conjunto de datos
Modelo:
<No hay modelo activo>
Ventana de resultados
Ejecutar
Aparece la ventana
Importar un conjunto de datos Excel
Introducir el nombre del conjunto de datos:
Datos
Aceptar
Cancelar
Ayuda
Se dará nombre al fichero de datos y se pulsa aceptar
Mensajes
[2] AVISO: La versión de Windows de R Commander funciona mejor bago RGui
con la interface de documento único (SDI); vea ?Commander



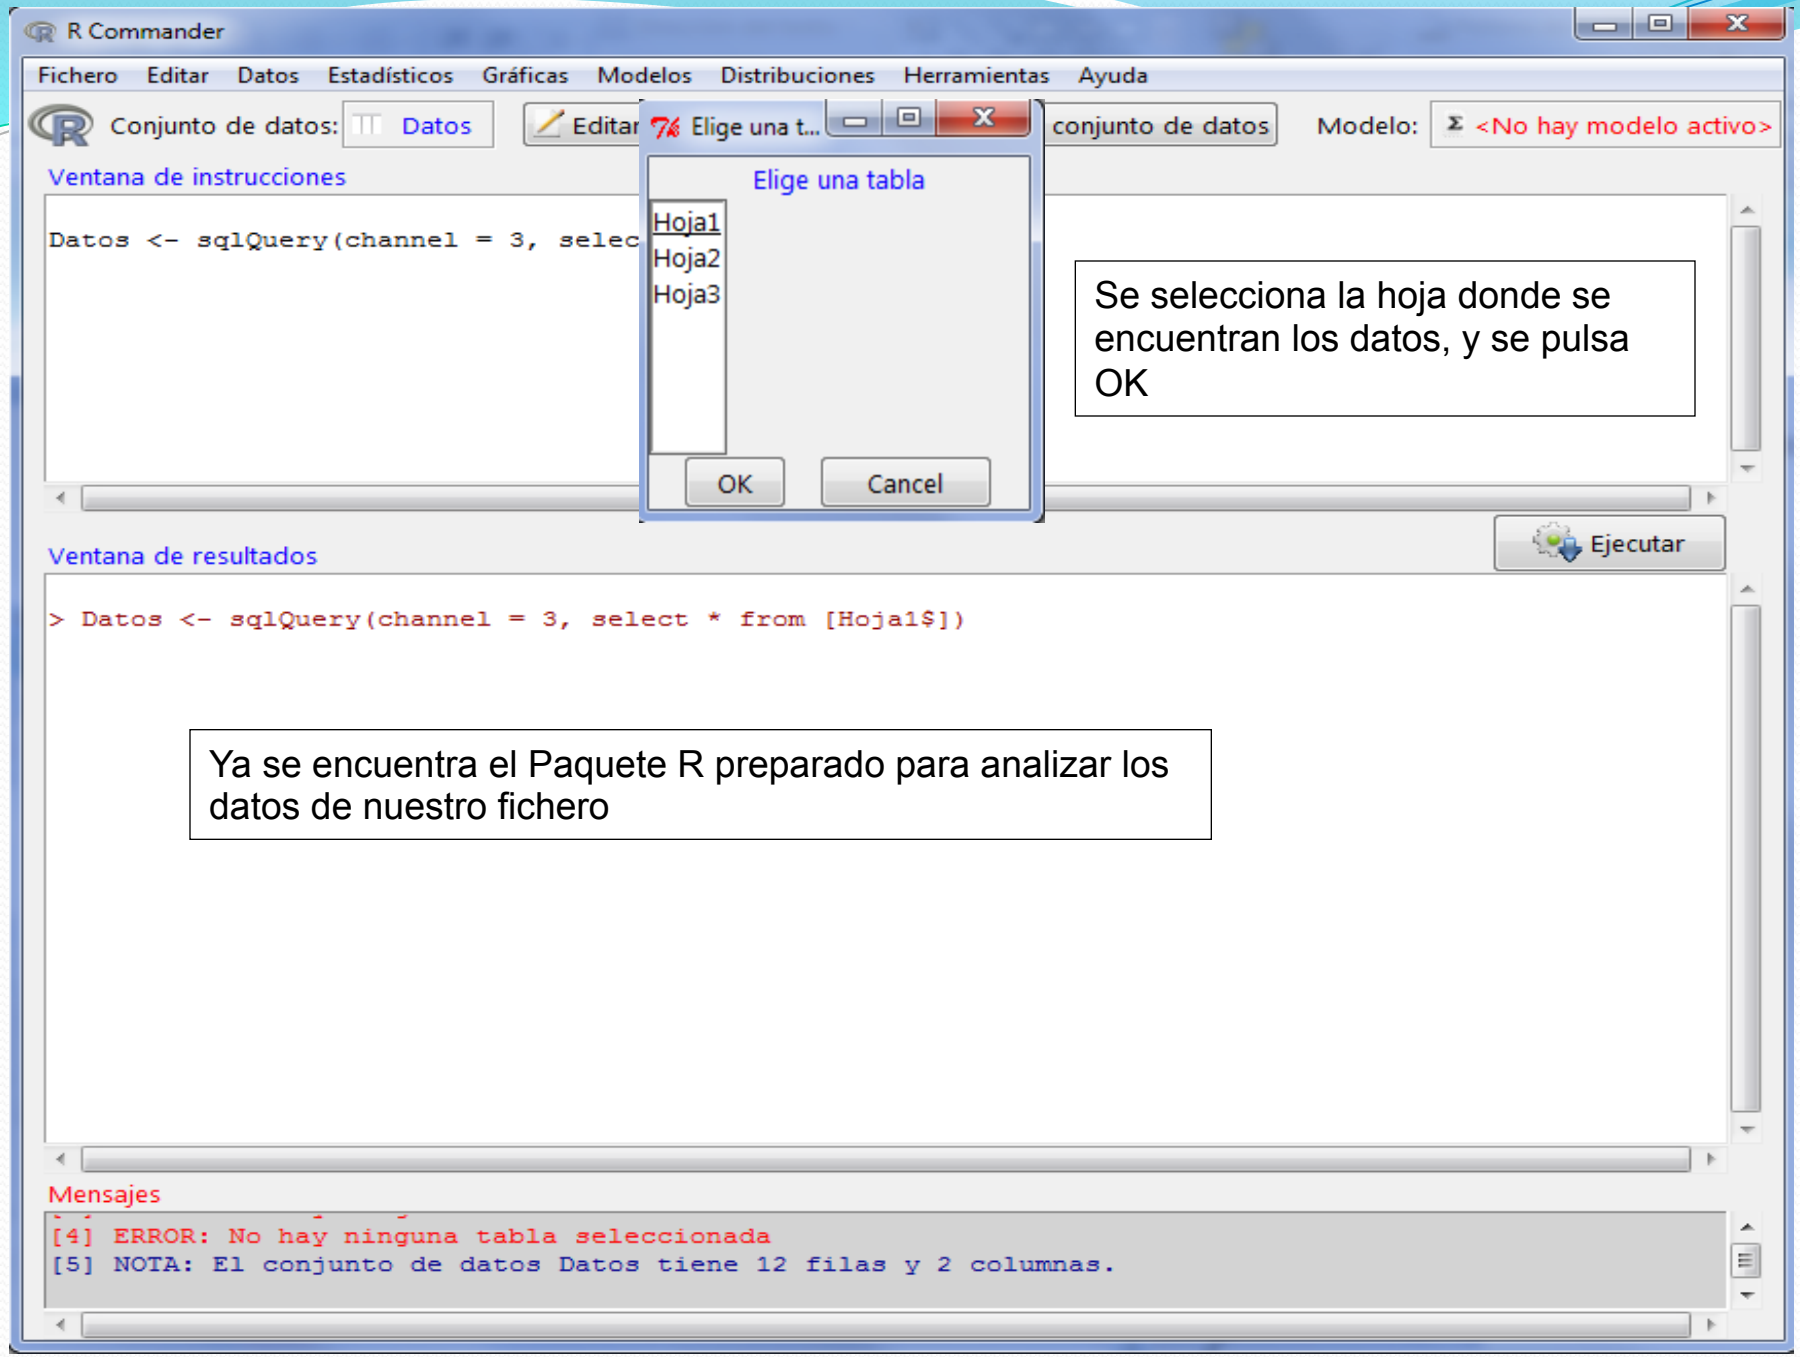
Si el Nombre del conjunto de datos activo ya existe, nos dará el siguiente mensaje:

Si pulsamos NO, volvemos a la pantalla anterior y se cambiaría el nombre del conjunto de datos



Importante: en el fichero de datos excel, la primera fila debe contener el nombre de las variables.

Se pulsa Abrir


R Commander
Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda
Conjunto de datos: Datos
Editar
conjunto de datos
Modelo: <No hay modelo activo>
Ventana de instrucciones
Datos <- sqlQuery(channel = 3, selec
Elige una t...
Elige una tabla
Hoja1
Hoja2
Hoja3
OK
Cancel
Se selecciona la hoja donde se encuentran los datos, y se pulsa OK
Ejecutar
Ventana de resultados
> Datos <- sqlQuery(channel = 3, select * from [Hoja1$])
Ya se encuentra el Paquete R preparado para analizar los datos de nuestro fichero
Mensajes
[4] ERROR: No hay ninguna tabla seleccionada
[5] NOTA: El conjunto de datos Datos tiene 12 filas y 2 columnas.

FUNDAMENTOS Y HERRAMIENTAS PARA LA MODELIZACIÓN DE PROCESOS TÉCNICOS-CIENTÍFICOS DE INVESTIGACIÓN

Bloque III: Modelización estadística.

Manipulación de datos con R Commander



Roberto Espejo Mohedano e-mail: ma1esmor@uco.es

FUNDAMENTOS Y HERRAMIENTAS PARA LA MODELIZACIÓN DE PROCESOS TÉCNICOS-CIENTÍFICOS DE INVESTIGACIÓN

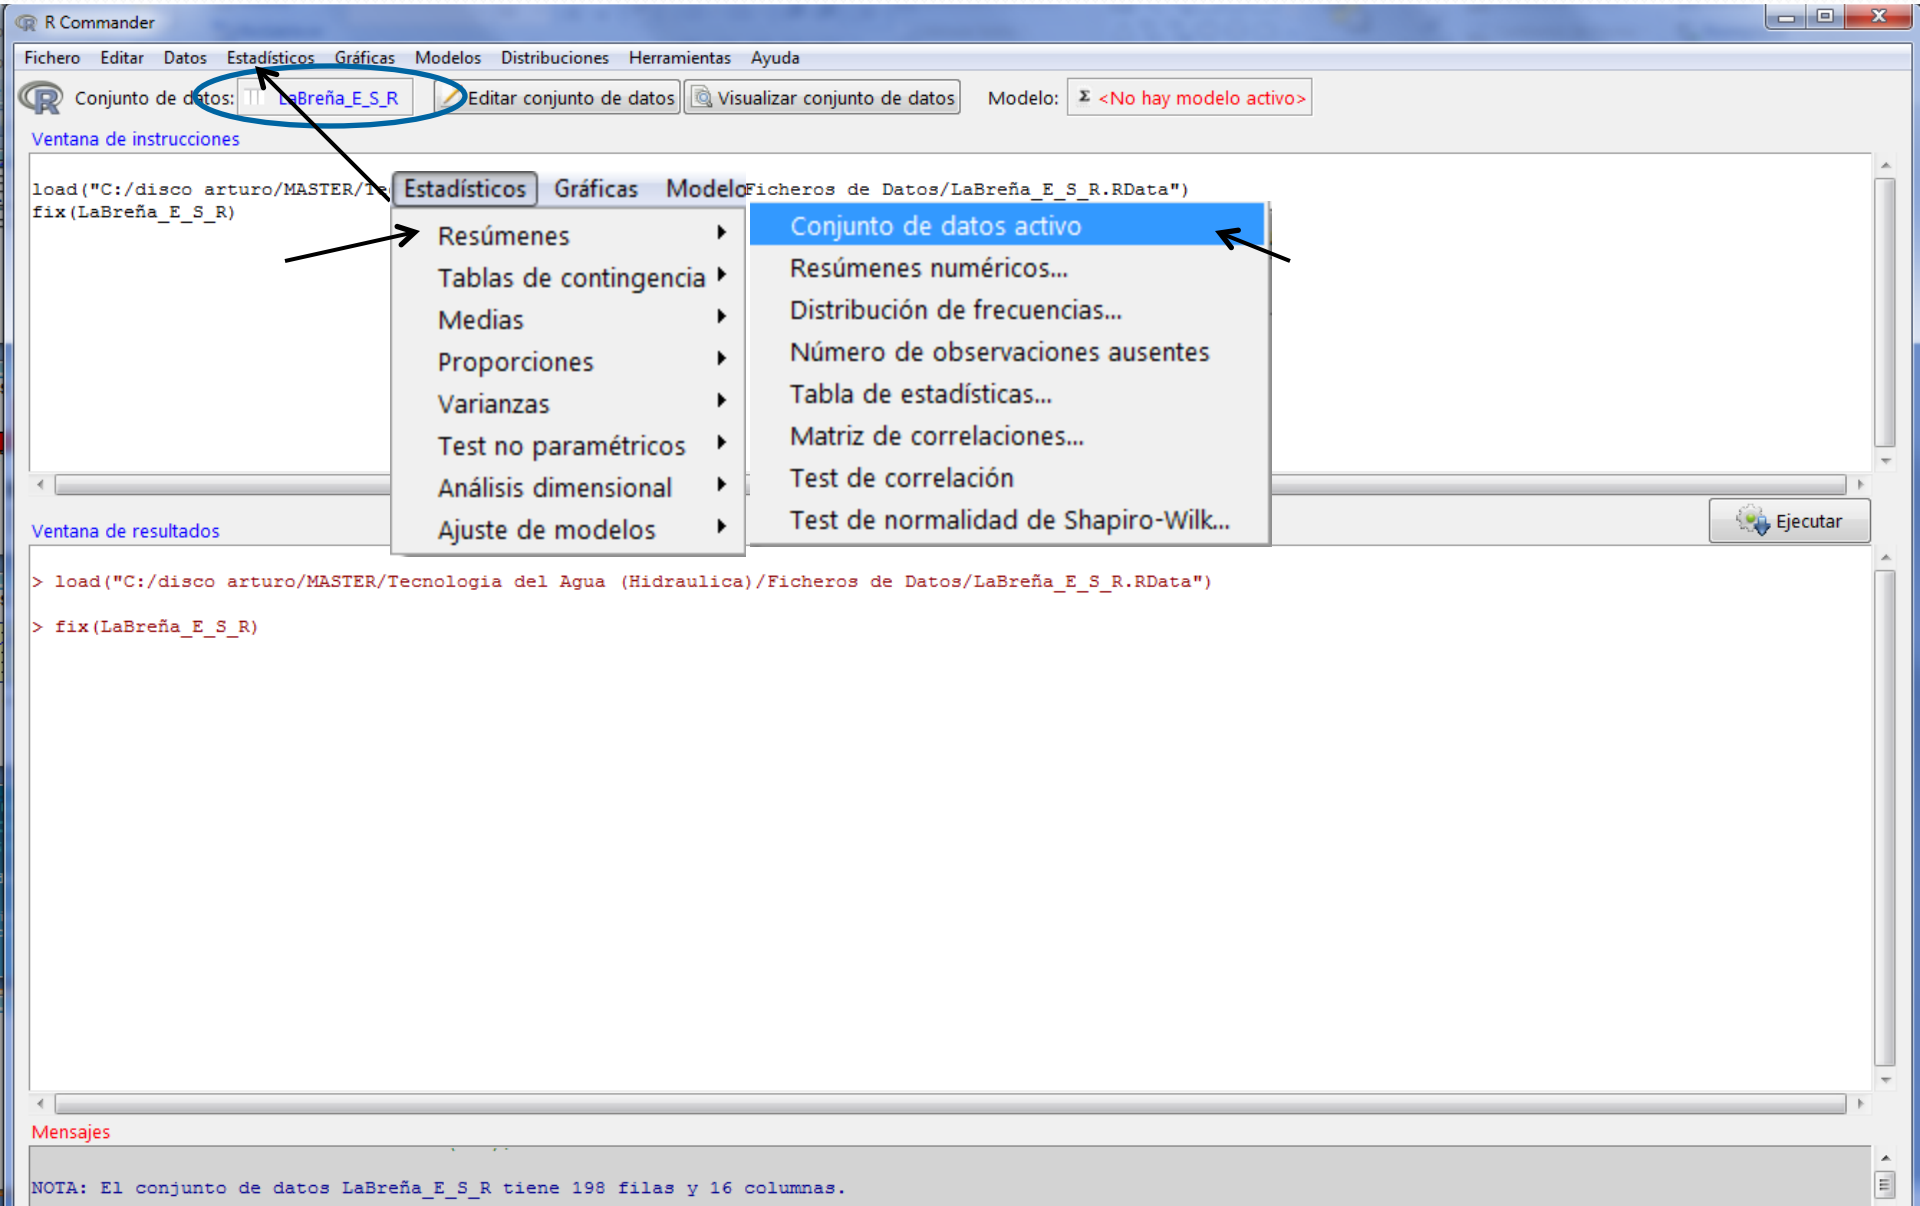
Bloque III: Modelización estadística.

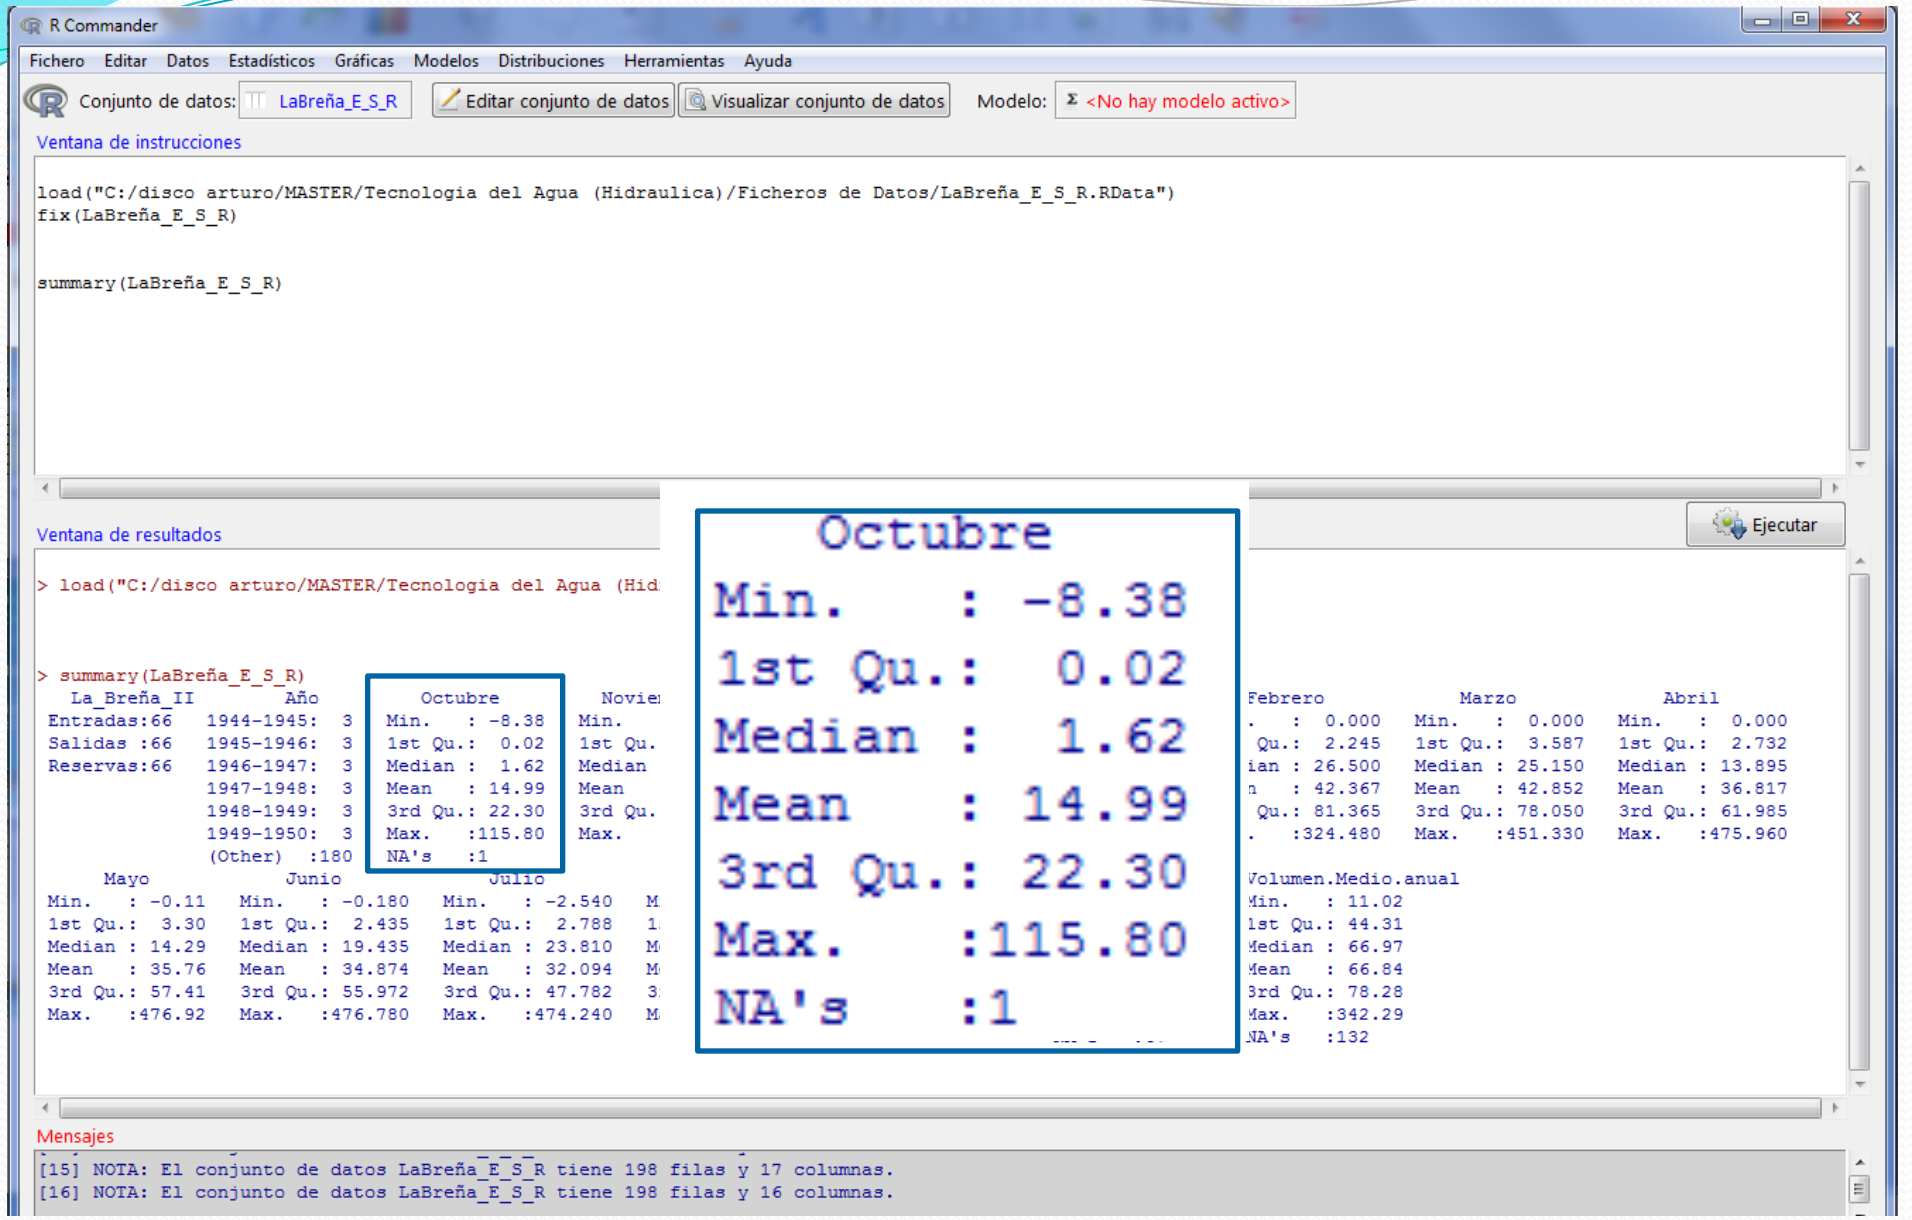
Estadística descriptiva con R (Rcommander)



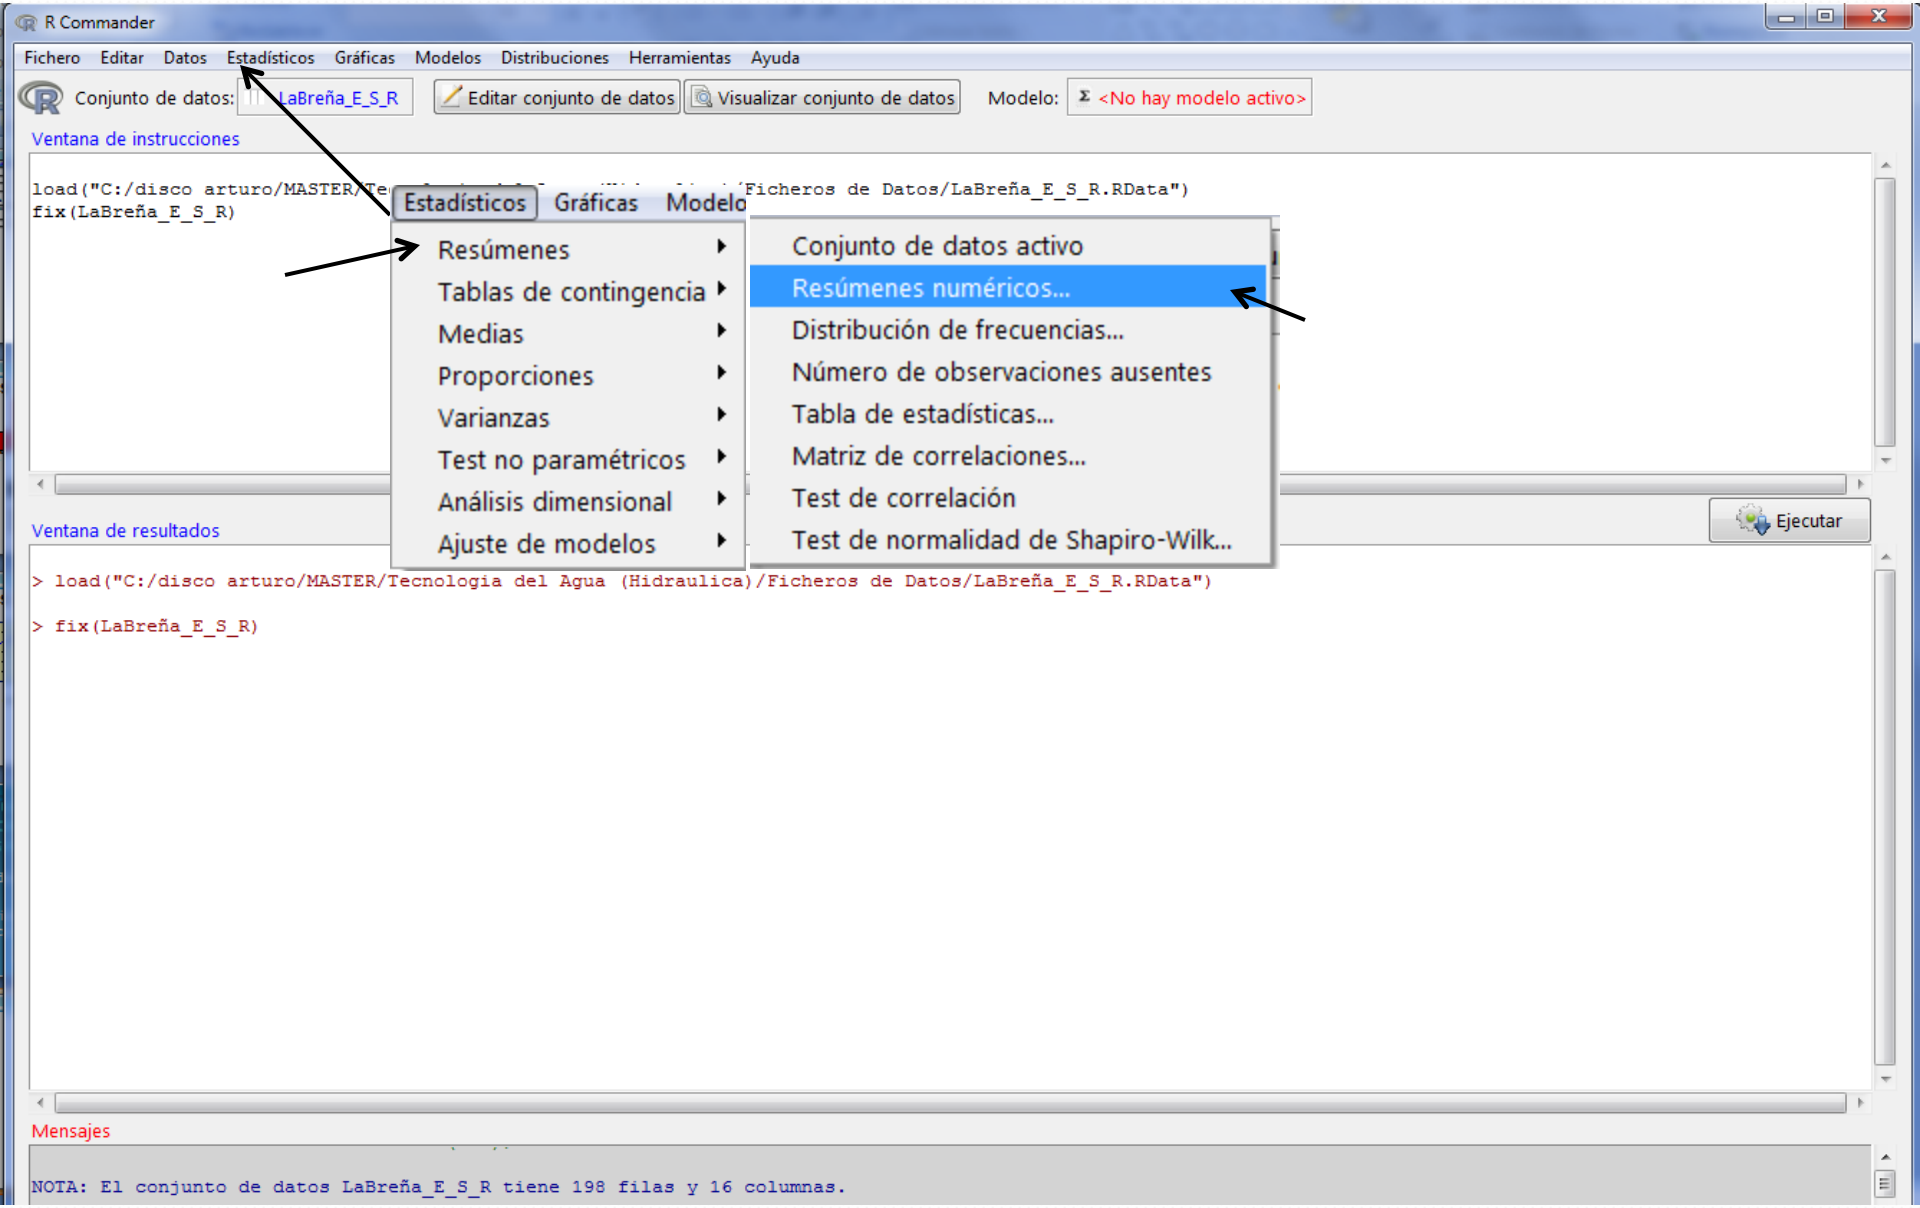
Roberto Espejo Mohedano e-mail: ma1esmor@uco.es

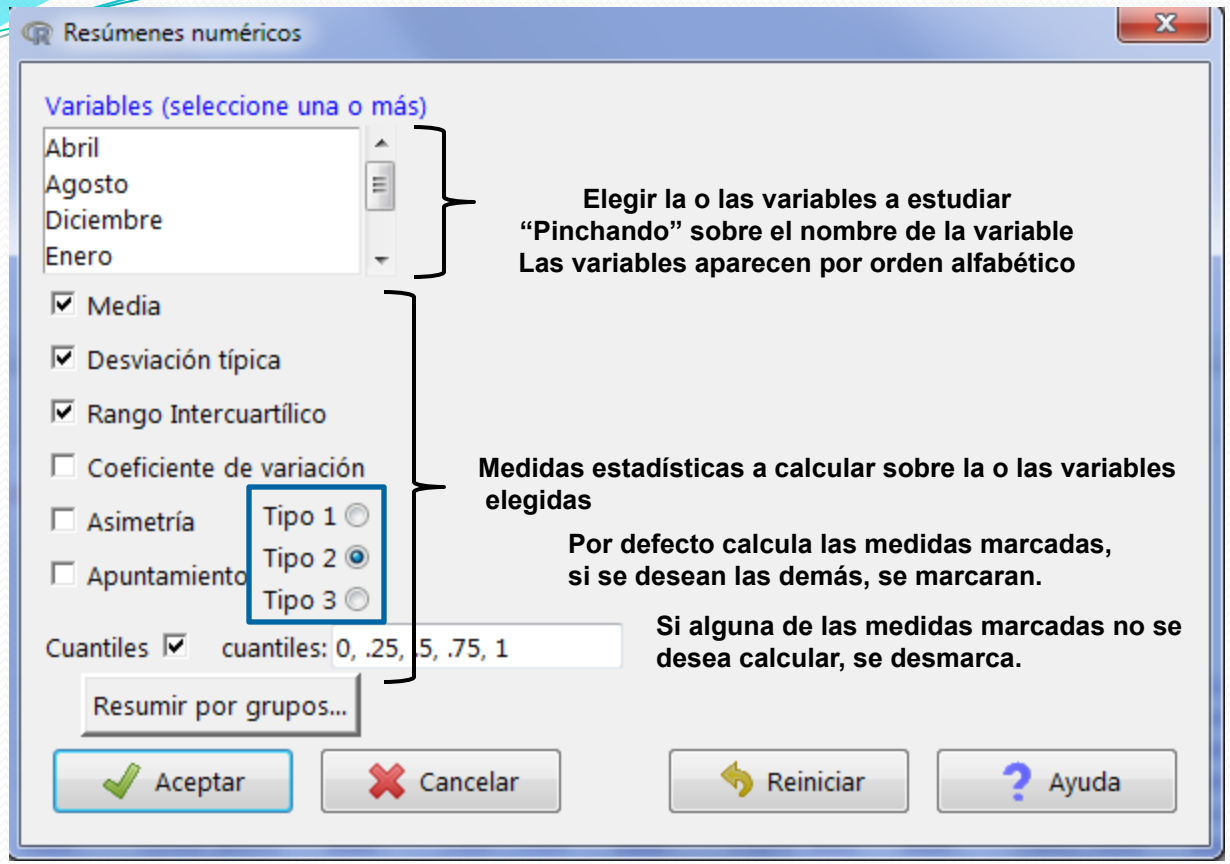
DESCRIPTIVA: Resúmenes Conjunto de Datos:



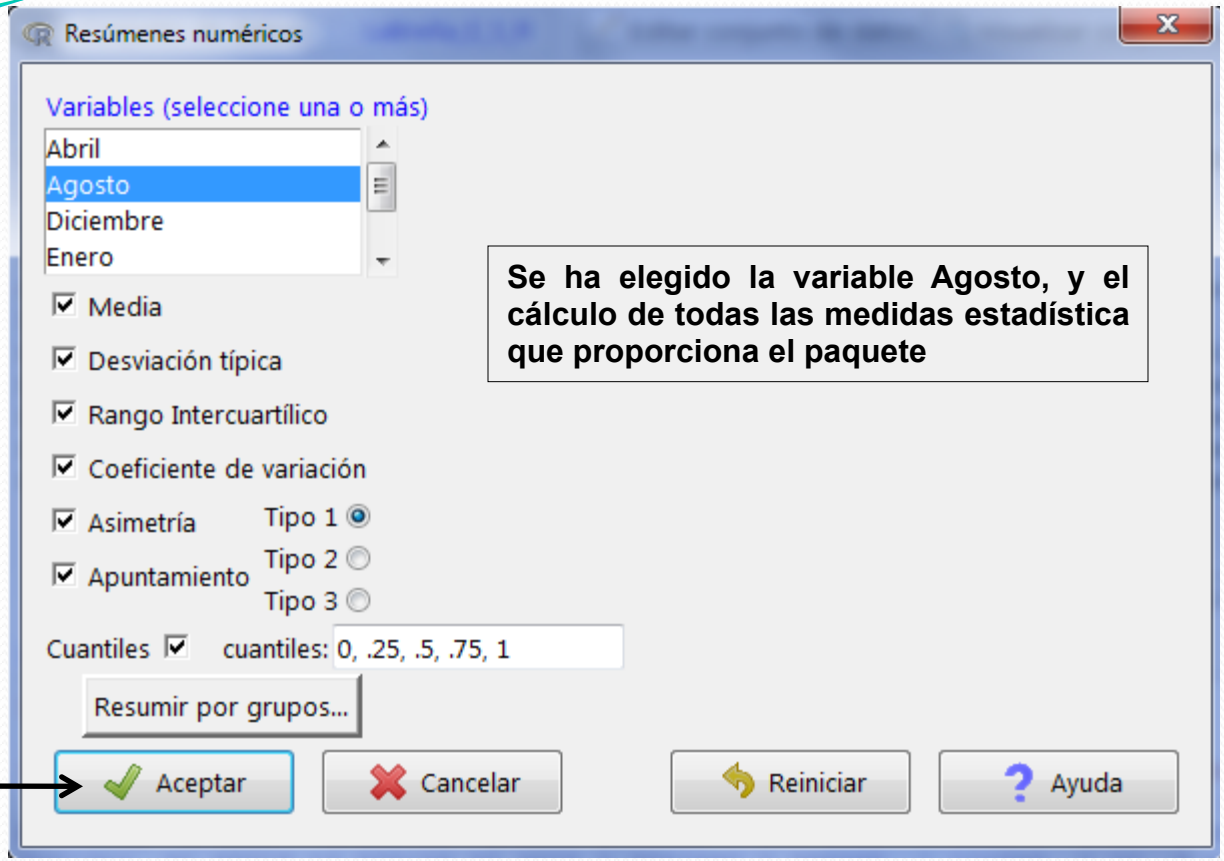

R Commander
Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda
Conjunto de datos: LaBreña_E_S_R
Editar conjunto de datos
Visualizar conjunto de datos
Modelo: <No hay modelo activo>
Ventana de instrucciones
load("C:/disco arturo/MASTER/Tecnologia del Agua (Hidraulica)/Ficheros de Datos/LaBreña_E_S_R.RData")
fix(LaBreña_E_S_R)
summary(LaBreña_E_S_R)
Ejecutar
Ventana de resultados
> load("C:/disco arturo/MASTER/Tecnologia del Agua (Hid
> summary(LaBreña_E_S_R)
La_Breña_II Año Octubre Novie
Entradas:66 1944-1945: 3 Min. : -8.38 Min.
Salidas :66 1945-1946: 3 1st Qu.: 0.02 1st Qu.
Reservas:66 1946-1947: 3 Median : 1.62 Median
1947-1948: 3 Mean : 14.99 Mean
1948-1949: 3 3rd Qu.: 22.30 3rd Qu.
1949-1950: 3 Max. :115.80 Max.
(Other) :180 NA's :1
Mayo Junio Julio
Min. : -0.11 Min. : -0.180 Min. : -2.540
1st Qu.: 3.30 1st Qu.: 2.435 1st Qu.: 2.788
Median : 14.29 Median : 19.435 Median : 23.810
Mean : 35.76 Mean : 34.874 Mean : 32.094
3rd Qu.: 57.41 3rd Qu.: 55.972 3rd Qu.: 47.782
Max. :476.92 Max. :476.780 Max. :474.240
Octubre
Min. : -8.38
1st Qu.: 0.02
Median : 1.62
Mean : 14.99
3rd Qu.: 22.30
Max. :115.80
NA's :1
Febrero Marzo Abril
. : 0.000 Min. : 0.000 Min. : 0.000
Qu.: 2.245 1st Qu.: 3.587 1st Qu.: 2.732
ian : 26.500 Median : 25.150 Median : 13.895
n : 42.367 Mean : 42.852 Mean : 36.817
Qu.: 81.365 3rd Qu.: 78.050 3rd Qu.: 61.985
. :324.480 Max. :451.330 Max. :475.960
Volumen.Medio.anual
Min. : 11.02
1st Qu.: 44.31
Median : 66.97
Mean : 66.84
3rd Qu.: 78.28
Max. :342.29
NA's :132
Mensajes
[15] NOTA: El conjunto de datos LaBreña_E_S_R tiene 198 filas y 17 columnas.
[16] NOTA: El conjunto de datos LaBreña_E_S_R tiene 198 filas y 16 columnas.

DESCRIPTIVA: Resúmenes de Datos:





Opción Tipo: Aparece Tipo 2 por defecto, pero marcamos Tipo 1



Se ha elegido la variable Agosto, y el cálculo de todas las medidas estadística que proporciona el paquete

R Commander

Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda

Conjunto de datos: LaBreña_E_S_R | Editar conjunto de datos | Visualizar conjunto de datos | Modelo: <No hay modelo activo>

Ventana de instrucciones

```
load("C:/disco arturo/MASTER/Tecnologia del Agua (Hidraulica)/Ficheros de Datos/LaBreña_E_S_R.RData")
library(abind, pos=4)
library(e1071, pos=4)
library(relimp, pos=4)
showData(LaBreña_E_S_R, placement='-20+200', font=getRcmdr('logFont'), maxwidth=80, maxheight=30)
fix(LaBreña_E_S_R)
```

```
numSummary(LaBreña_E_S_R[,"Agosto"], statistics=c("mean", "sd", "IQR", "quantiles", "cv", "skewness", "kurtosis"), quantiles=c(0,.25,.5,.75,1), type="1")
```

Ventana de resultados

Ejecutar

```
> summary(LaBreña_E_S_R)
   La_Breña_II        Año          Octubre         Noviembre         Diciembre          Enero            Febrero           Marzo             Abril             Mayo             Junio       
 Entradas:66   1944-1945:  3   Min.   : -8.38   Min.   : -0.1100   Min.   :  0.0000   Min.   :  0.000   Min.   :  0.000   Min.   :  0.000   Min.   :  0.000   Min.   : -0.11   Min.   : -0.180  
 Salidas :66   1945-1946:  3   1st Qu.:  0.02   1st Qu.:  0.0525   1st Qu.:  0.4375   1st Qu.:  1.345   1st Qu.:  2.245   1st Qu.:  3.587   1st Qu.:  2.732   1st Qu.:  3.30   1st Qu.:  2.435  
 Reservas:66   1946-1947:  3   Median :  1.62   Median :  4.9800   Median : 12.8400   Median : 22.900   Median : 26.500   Median : 25.150   Median : 13.895   Median : 14.29   Median : 19.435  
               1947-1948:  3   Mean   : 14.99   Mean   : 20.8750   Mean   : 33.8007   Mean   : 43.982   Mean   : 42.367   Mean   : 42.852   Mean   : 36.817   Mean   : 35.76   Mean   : 34.874  
               1948-1949:  3   3rd Qu.: 22.30   3rd Qu.: 30.0625   3rd Qu.: 51.2000   3rd Qu.: 63.782   3rd Qu.: 81.365   3rd Qu.: 78.050   3rd Qu.: 61.985   3rd Qu.: 57.41   3rd Qu.: 55.972  
               1949-1950:  3   Max.   :115.80   Max.   :143.5300   Max.   :249.9000   Max.   :357.090   Max.   :324.480   Max.   :451.330   Max.   :475.960   Max.   :476.92   Max.   :476.780  
               (Other)  :180   NA's   :1                                                                                                                                                          
     Julio             Agosto          Septiembre      Volumen.anual     Volumen.Medio.anual
 Min.   : -2.54   Min.   : -1.930   Min.   : -1.840   Min.   :  0.07   Min.   : 11.02      
 1st Qu.:  2.78   1st Qu.:  0.265   1st Qu.:  0.115   1st Qu.: 70.75   1st Qu.: 44.31      
 Median : 23.81   Median : 17.050   Median :  7.840   Median :134.05   Median : 66.97      
 Mean   : 32.09   Mean   : 24.861   Mean   : 17.367   Mean   :169.10   Mean   : 66.84      
 3rd Qu.: 47.78   3rd Qu.: 31.308   3rd Qu.: 21.593   3rd Qu.:223.90   3rd Qu.: 78.28      
 Max.   :474.24   Max.   :472.310   Max.   :470.480   Max.   :595.36   Max.   :342.29      
                                                      NA's   :67       NA's   :132         
```

```
> numSummary(LaBreña_E_S_R[,"Agosto"], statistics=c("mean", "sd", "IQR", "quantiles", "cv", "skewness", "kurtosis"), quantiles=c(0,.25,.5,.75,1), type="1")
     mean       sd      IQR       cv skewness kurtosis    0%   25%   50%     75%   100%   n
 24.86152 40.54108 31.0425 1.630676 7.136536 73.41022 -1.93 0.265 17.05 31.3075 472.31 198
```

Si cambiamos la Opción Tipo: Las principales medidas de Posición y Dispersión no cambian de valores, únicamente cambia el valor de los Coeficientes de Asimetría y Curtosis, debido a la ecuación utilizada en su cálculo.

Coeficiente de Asimetría

Type 1:

g_1 = m_3 / m_2^(3/2)

. This is the typical definition used in many older textbooks.

Type 2:

*G_1 = g_1 * sqrt(n(n-1)) / (n-2)*

. Used in SAS and SPSS.

Type 3:

b_1 = m_3 / s^3 = g_1 ((n-1)/n)^(3/2)

. Used in MINITAB and BMDP.

Coeficiente de Curtosis

Type 1:

g_2 = m_4 / m_2^2 - 3

. This is the typical definition used in many older textbooks.

Type 2:

*G_2 = ((n+1) g_2 + 6) * (n-1) / ((n-2)(n-3))*

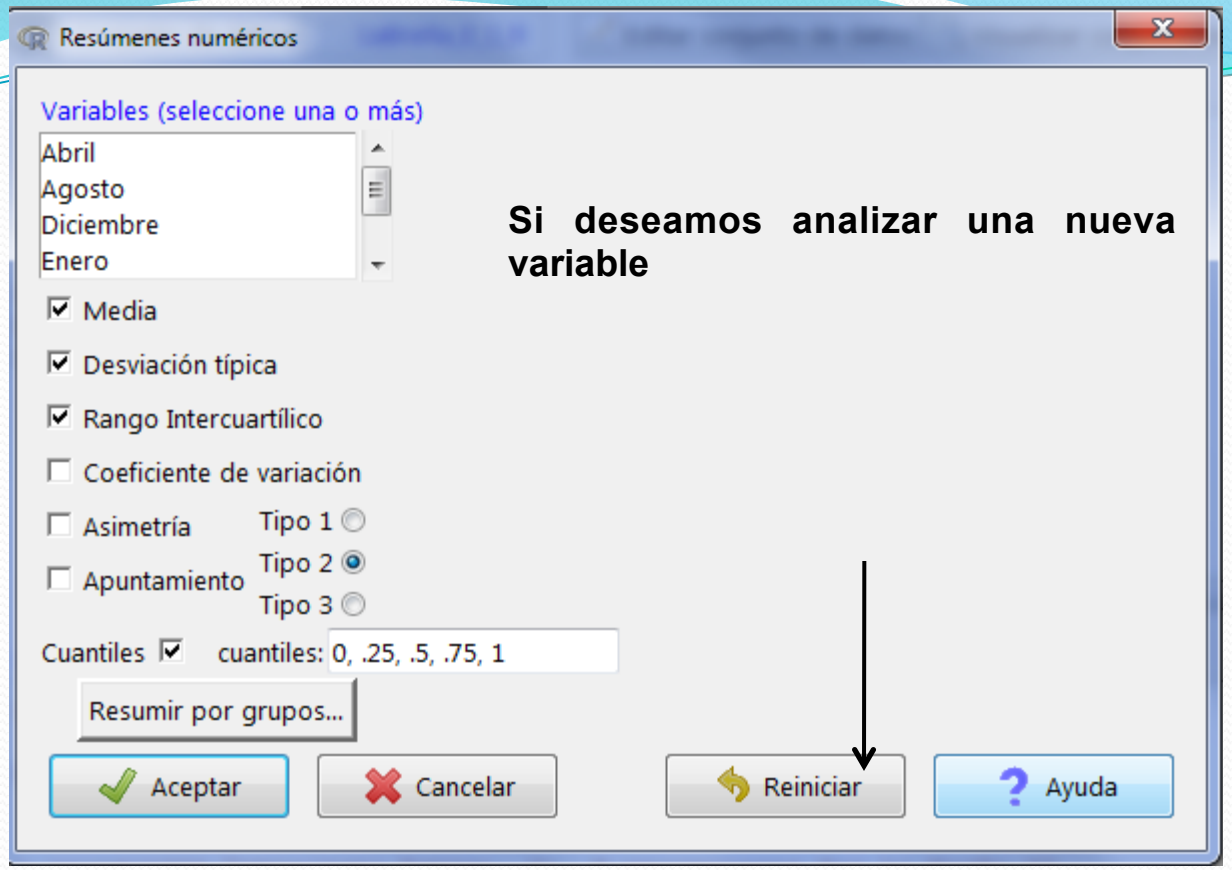
. Used in SAS and SPSS.

Type 3:

b_2 = m_4 / s^4 - 3 = (g_2 + 3) (1 - 1/n)^2 - 3

. Used in MINITAB and BMDP.

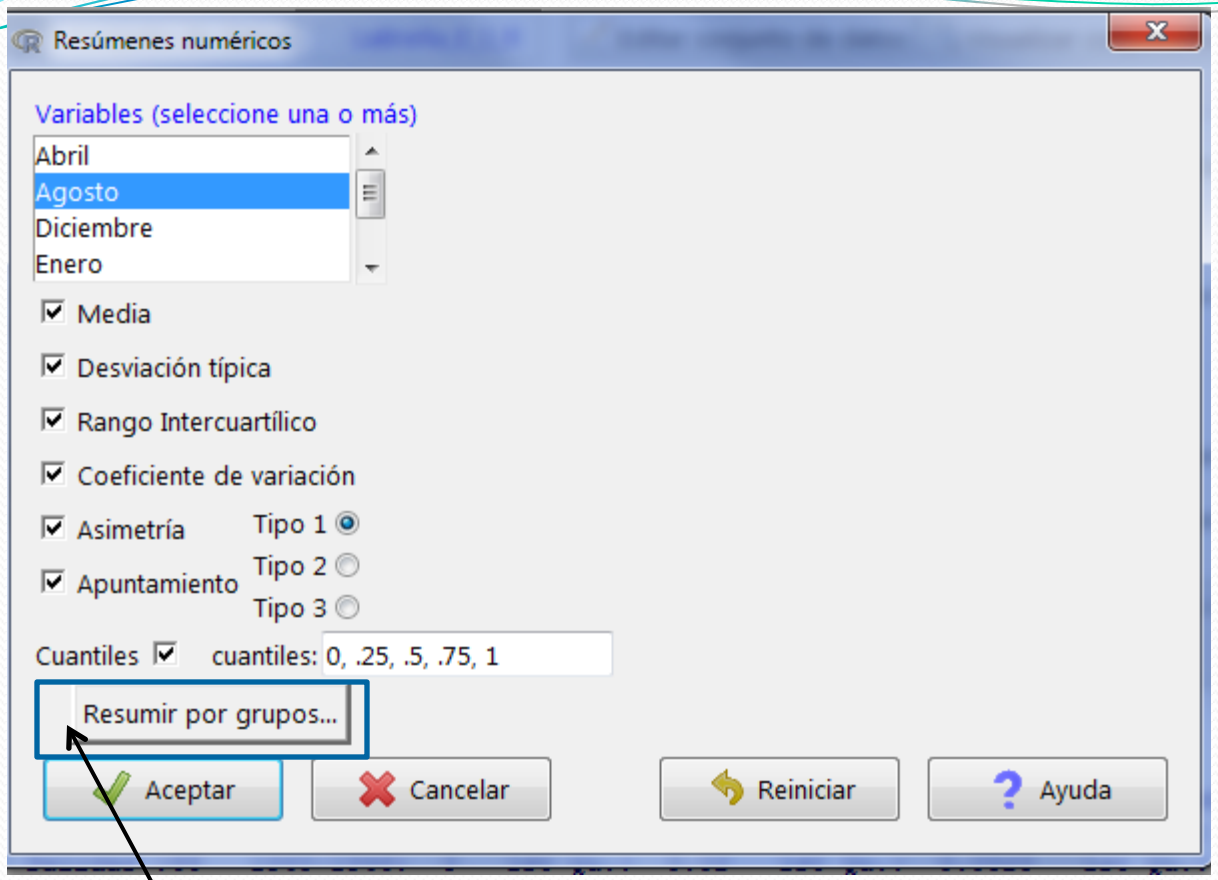
```
> numSummary(LaBreña_E_S_R[,"Agosto"], statistics=c("mean", "sd", "IQR", "quantiles", "cv", "skewness", "kurtosis"), quantiles=c(0,.25,.5,.75,1), type="1")
     mean       sd     IQR       cv skewness kurtosis    0%   25%   50%     75%   100%   n
 24.86152 40.54108 31.0425 1.630676 7.136536 73.41022 -1.93 0.265 17.05 31.3075 472.31 198
>  numSummary(LaBreña_E_S_R[,"Agosto"], statistics=c("mean", "sd", "IQR", "quantiles", "cv", "skewness", "kurtosis"), quantiles=c(0,.25,.5,.75,1), type="2")
     mean       sd     IQR       cv skewness kurtosis    0%   25%   50%     75%   100%   n
 24.86152 40.54108 31.0425 1.630676 7.191129 75.32922 -1.93 0.265 17.05 31.3075 472.31 198
> numSummary(LaBreña_E_S_R[,"Agosto"], statistics=c("mean", "sd", "IQR", "quantiles", "cv", "skewness", "kurtosis"), quantiles=c(0,.25,.5,.75,1), type="3")
     mean       sd     IQR       cv skewness kurtosis    0%   25%   50%     75%   100%   n
 24.86152 40.54108 31.0425 1.630676 7.082539 72.64035 -1.93 0.265 17.05 31.3075 472.31 198
```

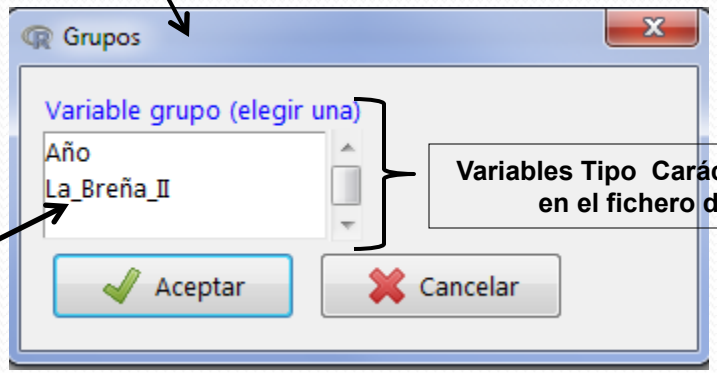


Si deseamos analizar una nueva variable

Marcaríamos las nuevas medidas a calcular, así como la o las nuevas variables a estudiar

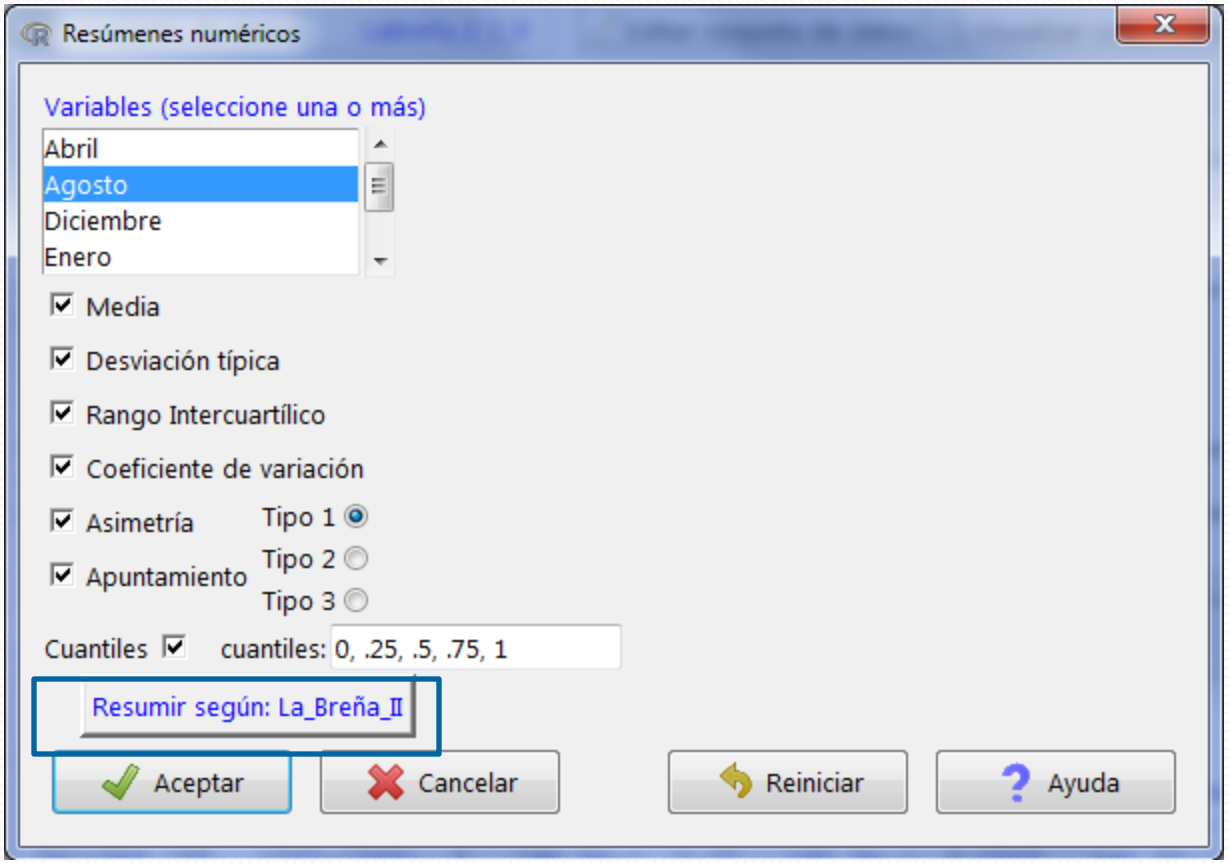
DESCRIPTIVA: Resumenes de Datos:





Variables Tipo Carácter existentes en el fichero de Datos

Nos proporciona las medidas estadísticas marcadas para la o las variables seleccionadas y para todos y cada una de las Categorías de una variable tipo carácter del fichero de datos



Al Aceptar vamos a obtener las medidas estadísticas marcadas para la variable o variables activas (Agosto) para cada una de la categorías de la variable nominal escogida (La_Breña_II)

R Commander

Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda

Conjunto de datos: LaBreña_E_S_R | Editar conjunto de datos | Visualizar conjunto de datos | Modelo: <No hay modelo activo>

Ventana de instrucciones

```
load("C:/disco arturo/MASTER/Tecnologia del Agua (Hidraulica)/Ficheros de Datos/LaBreña_E_S_R.RData")
library(abind, pos=4)
library(e1071, pos=4)
library(relimp, pos=4)
showData(LaBreña_E_S_R, placement='-20+200', font=getRcmdr('logFont'), maxwidth=80, maxheight=30)
fix(LaBreña_E_S_R)



numSummary(LaBreña_E_S_R[,"Agosto"], statistics=c("mean", "sd", "IQR", "quantiles", "cv", "skewness", "kurtosis"), quantiles=c(0,.25,.5,.75,1), type="1")
summary(LaBreña_E_S_R)
numSummary(LaBreña_E_S_R[,"Agosto"], statistics=c("mean", "sd", "IQR", "quantiles", "cv", "skewness", "kurtosis"), quantiles=c(0,.25,.5,.75,1), type="1")
numSummary(LaBreña_E_S_R[,"Agosto"], groups=LaBreña_E_S_R$La_Breña_II, statistics=c("mean", "sd", "IQR", "quantiles", "cv", "skewness", "kurtosis"), quantiles=c(0,.25,.5,.75,1), type="1")
```

```
> numSummary(LaBreña_E_S_R[,"Agosto"], groups=LaBreña_E_S_R$La_Breña_II,
```

Ejecutar

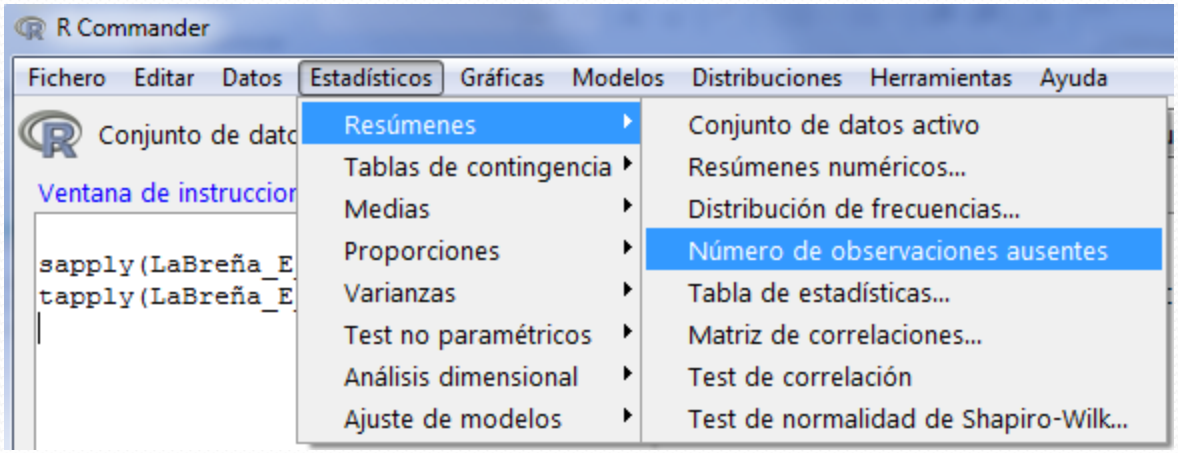
Ventana de resultados

```
 Reservas:66   1946-1947:  3   Median :  1.62   Median :  4.9800   Median : 12.8400   Median : 22.900   Median : 26.500   Median : 25.150   Median : 13.895   Median : 14.29   Median : 19.435
               1947-1948:  3   Mean   : 14.99   Mean   : 20.8750   Mean   : 33.8007   Mean   : 43.982   Mean   : 42.367   Mean   : 42.852   Mean   : 36.817   Mean   : 35.76   Mean   : 34.874
               1948-1949:  3   3rd Qu.: 22.30   3rd Qu.: 30.0625   3rd Qu.: 51.2000   3rd Qu.: 63.782   3rd Qu.: 81.365   3rd Qu.: 78.050   3rd Qu.: 61.985   3rd Qu.: 57.41   3rd Qu.: 55.972
               1949-1950:  3   Max.   :115.80   Max.   :143.5300   Max.   :249.9000   Max.   :357.090   Max.   :324.480   Max.   :451.330   Max.   :475.960   Max.   :476.92   Max.   :476.780
               (Other)  :180   NA's   :1
     Julio             Agosto          Septiembre      Volumen.anual    Volumen.Medio.anual
 Min.   : -2.540   Min.   : -1.930   Min.   : -1.840   Min.   :  0.07   Min.   : 11.02
 1st Qu.:  2.788   1st Qu.:  0.265   1st Qu.:  0.115   1st Qu.: 70.75   1st Qu.: 44.31
 Median : 23.810   Median : 17.050   Median :  7.840   Median :134.05   Median : 66.97
 Mean   : 32.094   Mean   : 24.861   Mean   : 17.367   Mean   :169.10   Mean   : 66.84
 3rd Qu.: 47.782   3rd Qu.: 31.308   3rd Qu.: 21.593   3rd Qu.:223.90   3rd Qu.: 78.28
 Max.   :474.240   Max.   :472.310   Max.   :470.480   Max.   :595.36   Max.   :342.29
                                                       NA's   :67       NA's   :132

> numSummary(LaBreña_E_S_R[,"Agosto"], statistics=c("mean", "sd", "IQR", "quantiles", "cv", "skewness", "kurtosis"), quantiles=c(0,.25,.5,.75,1), type="1")
     mean       sd     IQR       cv skewness kurtosis    0%   25%   50%     75%   100%   n
 24.86152 40.54108 31.0425 1.630676 7.136536 73.41022 -1.93 0.265 17.05 31.3075 472.31 198
```

	mean	sd	IQR	cv	skewness	kurtosis	0%	25%	50%	75%	100%	data:n
Entradas	3.42197	6.998468	1.6150	2.0451577	1.976452	2.919870	-1.93	-0.0575	0.000	1.5575	27.96	66
Salidas	21.58318	14.575106	20.6825	0.6752992	0.696465	1.104639	0.00	9.5575	22.325	30.2400	72.01	66
Reservas	49.57939	60.182098	44.8225	1.2138530	5.517340	38.073159	3.68	22.9925	33.055	67.8150	472.31	66

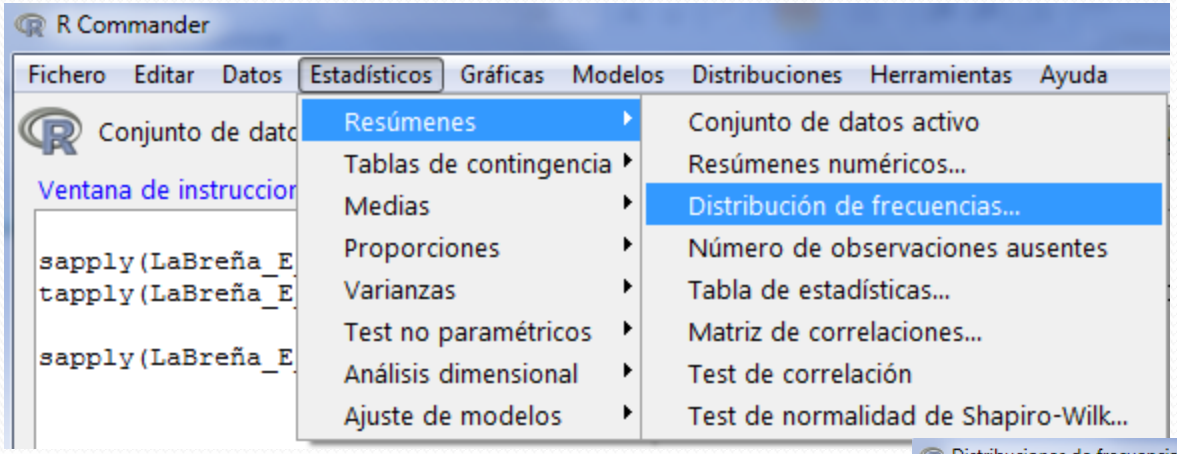
DESCRIPTIVA: Número de Observaciones ausentes



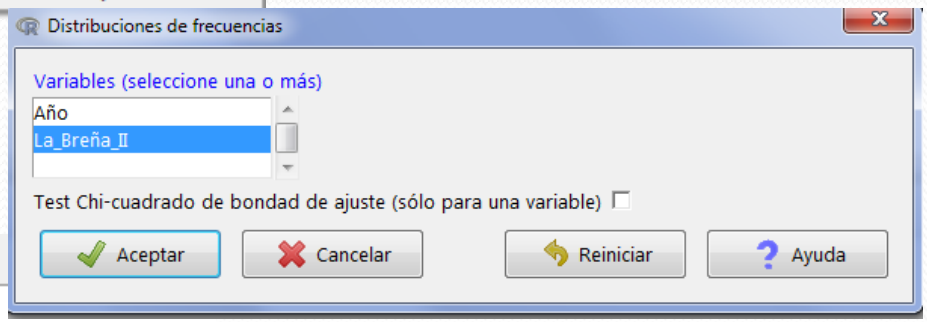
Nos proporciona información acerca del número de observaciones ausentes en todas y cada una de las variables del fichero de datos activo.

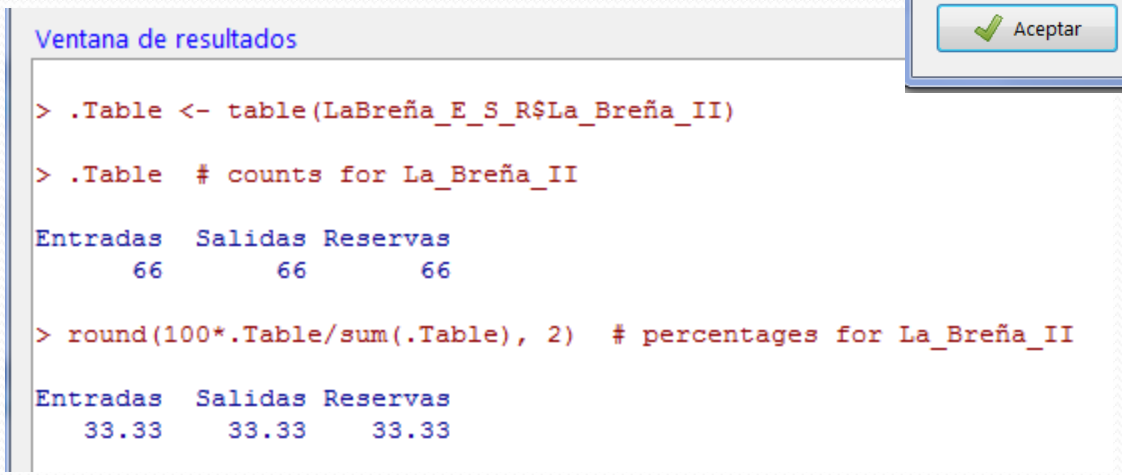
```
> sapply(LaBreña_E_S_R, function(x)(sum(is.na(x)))) # NA counts
      La_Breña_II               Año           Octubre         Noviembre 
                0                 0                 1                 0 
        Diciembre             Enero           Febrero             Marzo 
                0                 0                 0                 0 
            Abril             Mayo             Junio             Julio 
                0                 0                 0                 0 
           Agosto        Septiembre   Volumen.anual Volumen.Medio.anual 
                0                 0                67               132 
```

DESCRIPTIVA: Distribución de Frecuencias

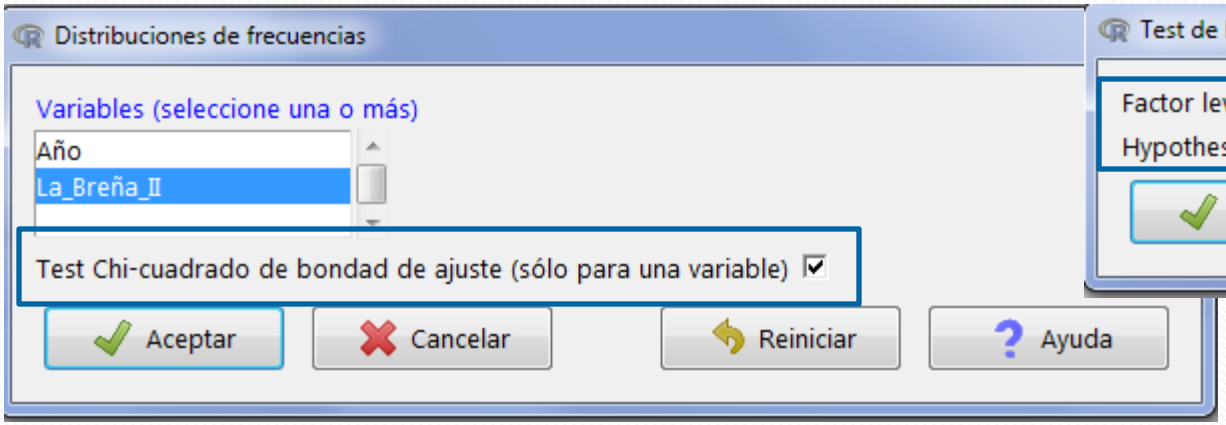


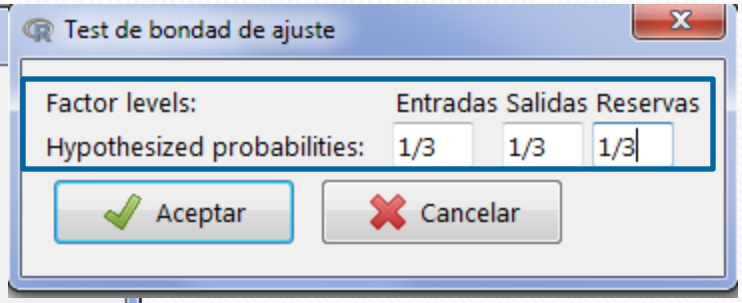
Nos proporciona la frecuencia absoluta (n_i) y la frecuencia relativa (f_i) de la o las variables categóricas del fichero de datos activo.





DESCRIPTIVA: Distribución de Frecuencias





Ventana de resultados

```
> .Table  # counts for La_Breña_II

Entradas  Salidas Reservas
      66       66       66

> round(100*.Table/sum(.Table), 2)  # percentages for La_Breña_II

Entradas  Salidas Reservas
   33.33    33.33    33.33

> .Probs <- c(0.333333333333333,0.333333333333333,0.333333333333333)

> chisq.test(.Table, p=.Probs)

        Chi-squared test for given probabilities

data:  .Table
X-squared = 0, df = 2, p-value = 1
```

Hipótesis (por defecto):

$$\begin{cases} H_0 : p_1 = 1/3 ; p_2 = 1/3 ; p_3 = 1/3 \\ H_1 : \text{Algún } p_i \neq \overrightarrow{p_0} \end{cases}$$

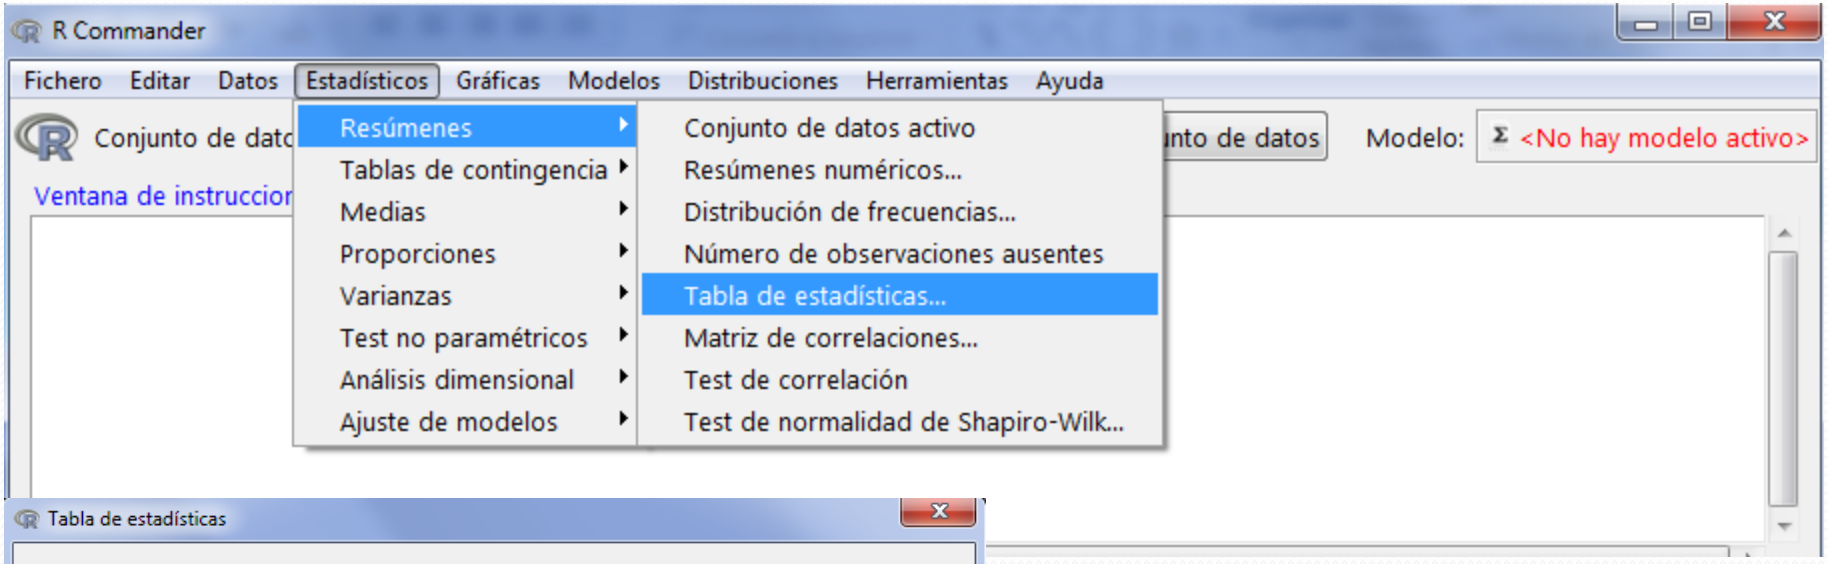
Donde: p_1, p_2 y p_3 son las proporciones de cada una de las categorías de la variable La_Breña_II
Con la condición: $p_1 + p_2 + p_3 = 1$

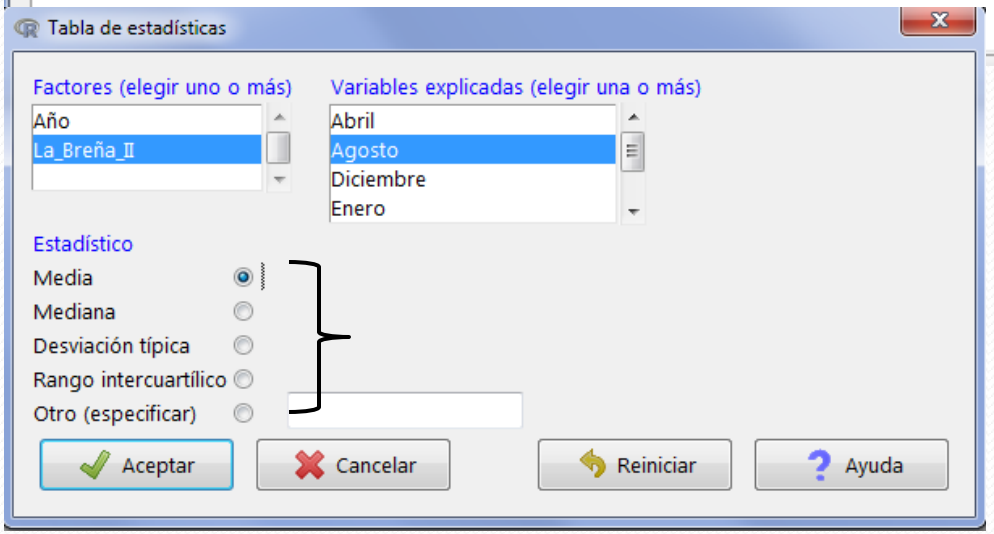
<u>Decisión</u>: **Para todo $\alpha \leq p$ ➔ se acepta H_0**
Para todo $\alpha > p$ ➔ se rechaza H_0

α = 0.10, <u>0.05</u>, 0.01

Se acepta H_0 , es decir, la proporción de cada una de las categorías es de 1/3

DESCRIPTIVA: Tabla de estadísticas

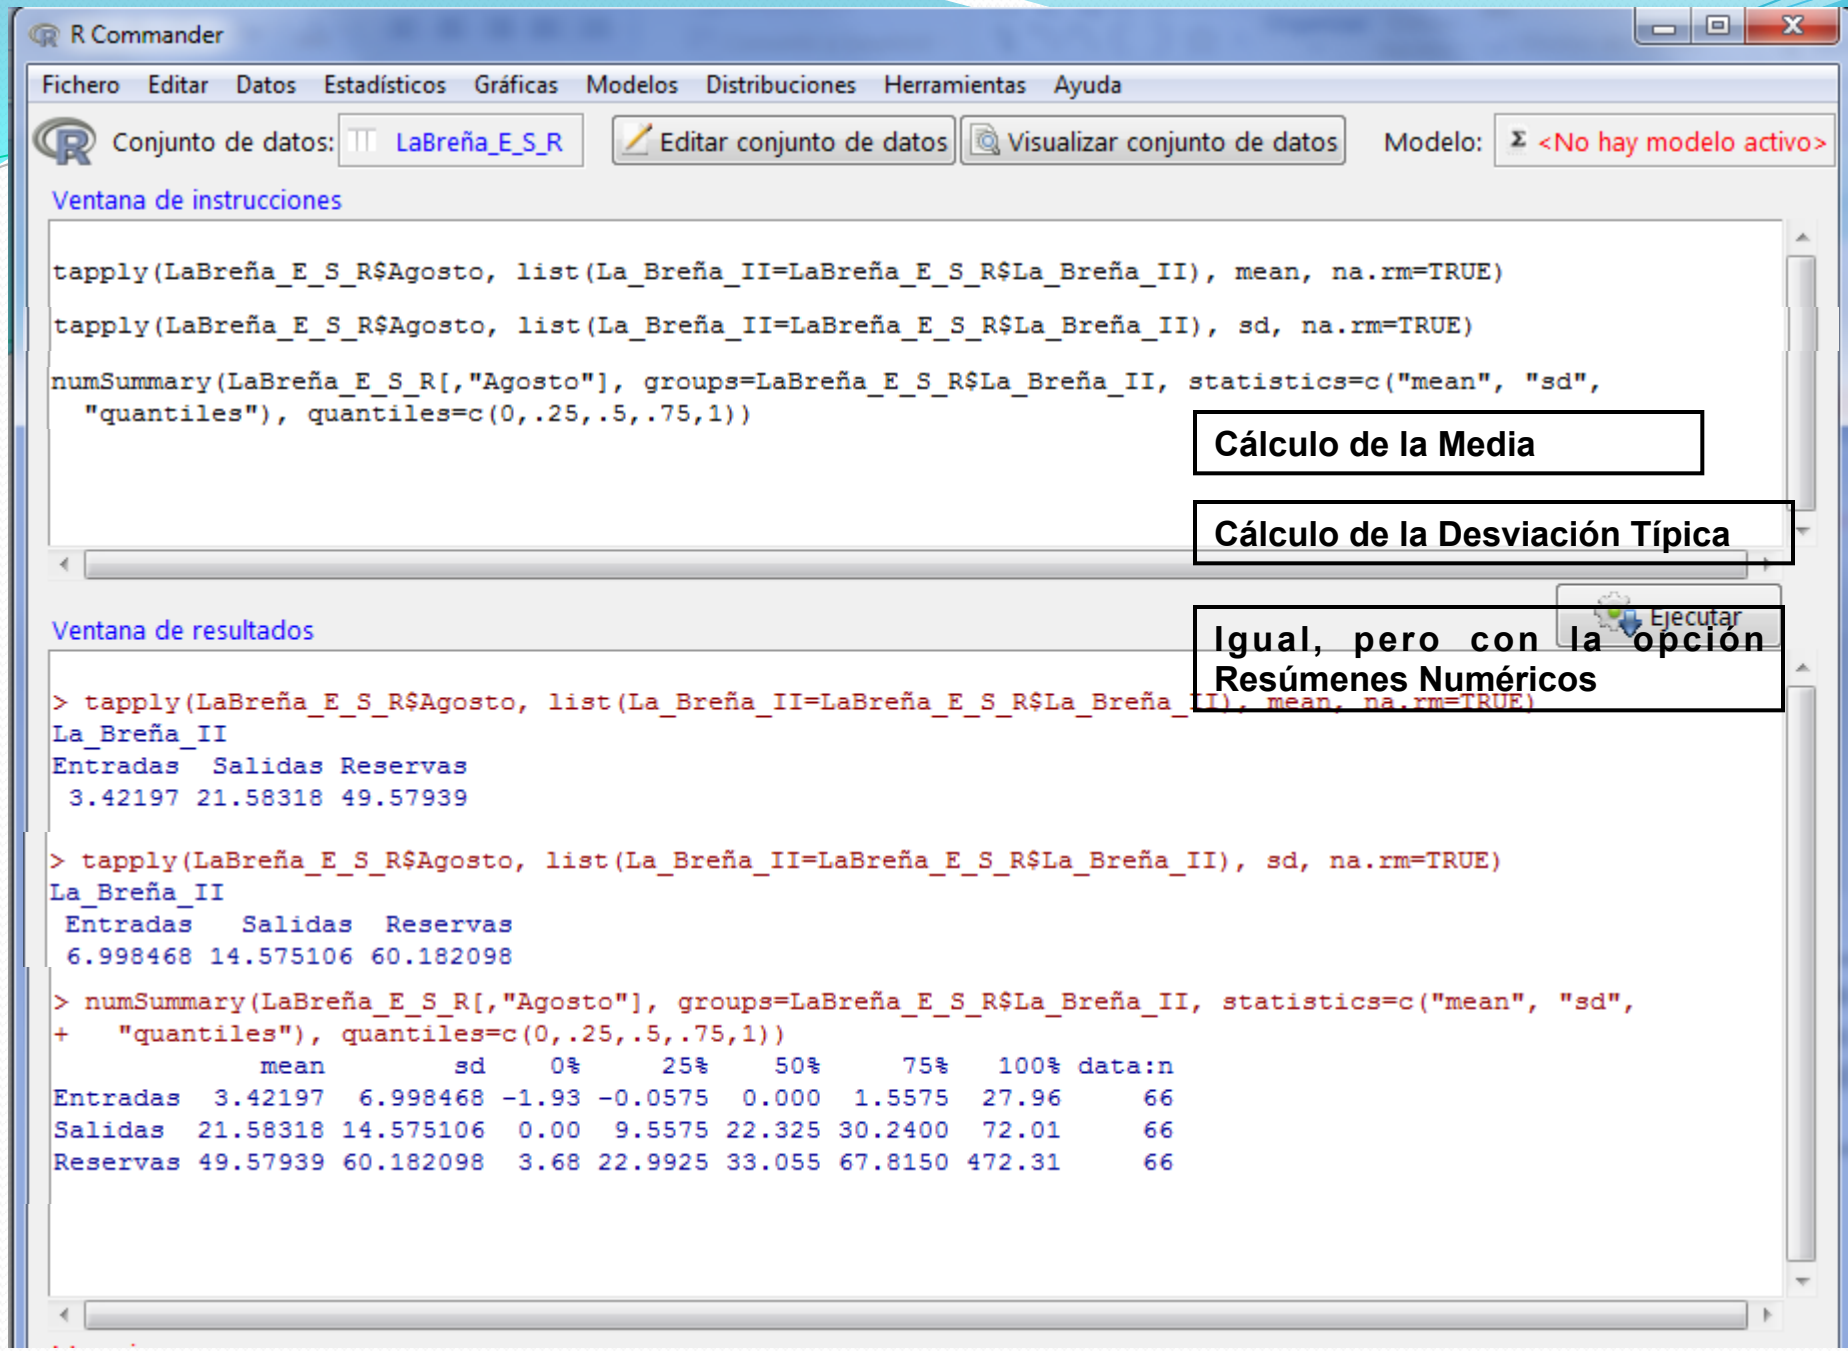




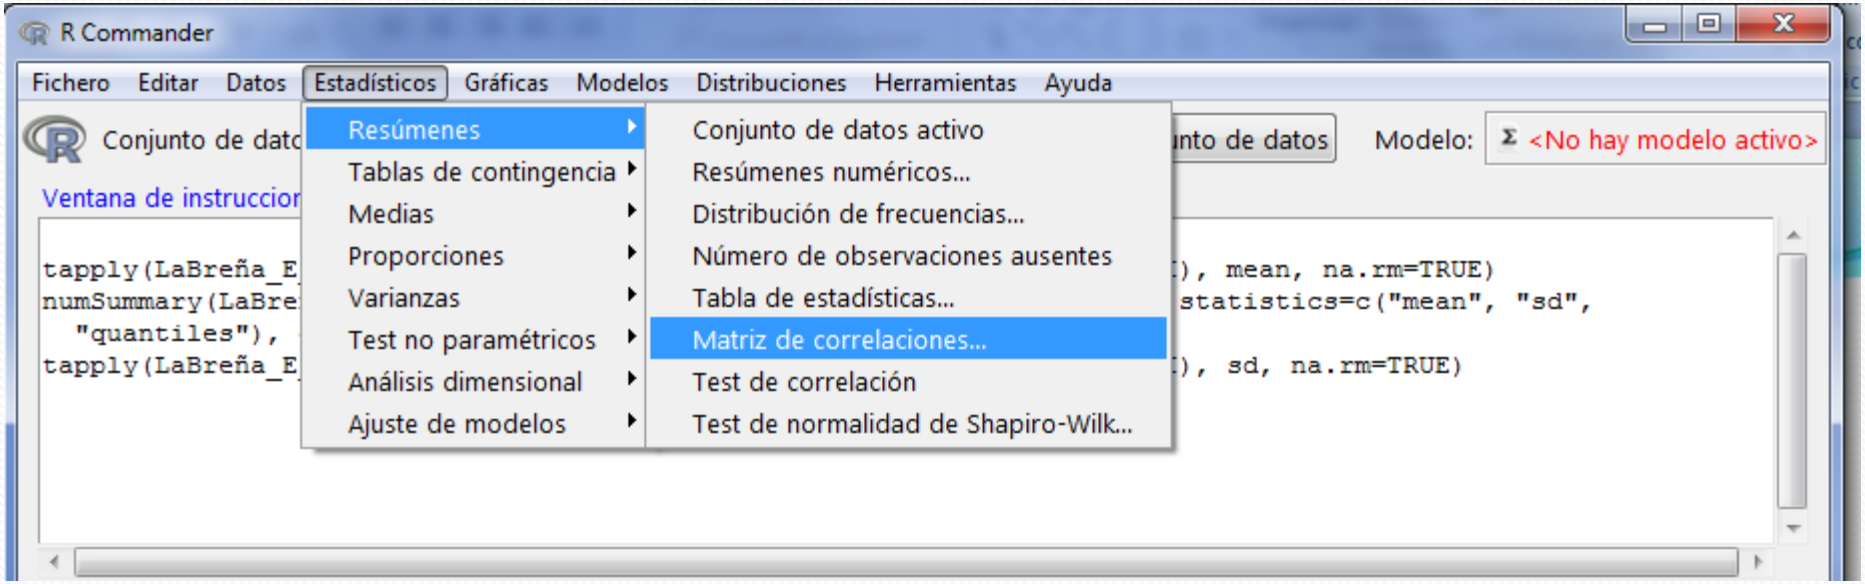
Nos proporciona la medida estadística seleccionada para la/s variables numéricas marcadas de la/s variables categóricas del fichero de datos activo.

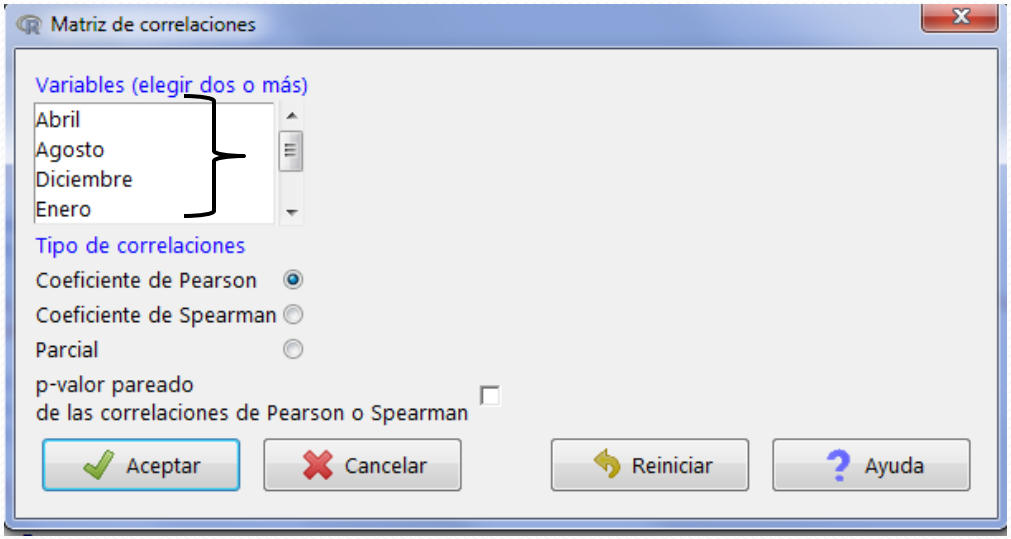
La opción marcada calculará la Media para cada una de las categorías de la variable La_Breña_II

Si se desea otra medida, habría que comenzar de nuevo marcado la medida elegida.


R Commander
Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda
Conjunto de datos: LaBreña_E_S_R
Editar conjunto de datos
Visualizar conjunto de datos
Modelo: <No hay modelo activo>
Ventana de instrucciones
tapply(LaBreña_E_S_R$Agosto, list(La_Breña_II=LaBreña_E_S_R$La_Breña_II), mean, na.rm=TRUE)
tapply(LaBreña_E_S_R$Agosto, list(La_Breña_II=LaBreña_E_S_R$La_Breña_II), sd, na.rm=TRUE)
numSummary(LaBreña_E_S_R[,"Agosto"], groups=LaBreña_E_S_R$La_Breña_II, statistics=c("mean", "sd",
"quantiles"), quantiles=c(0,.25,.5,.75,1))
Cálculo de la Media
Cálculo de la Desviación Típica
Ejecutar
Igual, pero con la opción Resúmenes Numéricos
Ventana de resultados
> tapply(LaBreña_E_S_R$Agosto, list(La_Breña_II=LaBreña_E_S_R$La_Breña_II), mean, na.rm=TRUE)
La_Breña_II
Entradas Salidas Reservas
3.42197 21.58318 49.57939
> tapply(LaBreña_E_S_R$Agosto, list(La_Breña_II=LaBreña_E_S_R$La_Breña_II), sd, na.rm=TRUE)
La_Breña_II
Entradas Salidas Reservas
6.998468 14.575106 60.182098
> numSummary(LaBreña_E_S_R[,"Agosto"], groups=LaBreña_E_S_R$La_Breña_II, statistics=c("mean", "sd",
+ "quantiles"), quantiles=c(0,.25,.5,.75,1))
mean sd 0% 25% 50% 75% 100% data:n
Entradas 3.42197 6.998468 -1.93 -0.0575 0.000 1.5575 27.96 66
Salidas 21.58318 14.575106 0.00 9.5575 22.325 30.2400 72.01 66
Reservas 49.57939 60.182098 3.68 22.9925 33.055 67.8150 472.31 66

DESCRIPTIVA: Matriz de Correlaciones





Nos proporciona los Coeficientes de Correlación simple R_{xy} (Coeficiente de Pearson) de las variables numéricas incluidas en el fichero de datos.

Hay que marcar como mínimo dos variables

Si deseamos estudiar la relación entre el mes de Abril y el Volumen Anual, marcaríamos la variable Abril y la variable Volumen.anual, (utilizando la tecla Ctrl)

Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda

Conjunto de datos: LaBreña_E_S_R | Editar conjunto de datos | Visualizar conjunto de datos | Modelo: <No hay modelo activo>

Ventana de instrucciones

```
tapply(LaBreña_E_S_R$Agosto, list(La_Breña_II=LaBreña_E_S_R$La_Breña_II), mean, na.rm=TRUE)
numSummary(LaBreña_E_S_R[,"Agosto"], groups=LaBreña_E_S_R$La_Breña_II, statistics=c("mean", "sd",
  "quantiles"), quantiles=c(0,.25,.5,.75,1))
tapply(LaBreña_E_S_R$Agosto, list(La_Breña_II=LaBreña_E_S_R$La_Breña_II), sd, na.rm=TRUE)
cor(LaBreña_E_S_R[,c("Abril","Volumen.anual")], use="complete.obs")
```

Ejecutar

Ventana de resultados

```
> numSummary(LaBreña_E_S_R[,"Agosto"], groups=LaBreña_E_S_R$La_Breña_II, statistics=c("mean", "sd",
+   "quantiles"), quantiles=c(0,.25,.5,.75,1))
             mean        sd    0%     25%    50%     75%   100% data:n
Entradas  3.42197  6.998468 -1.93 -0.0575  0.000  1.5575  27.96     66
Salidas  21.58318 14.575106  0.00  9.5575 22.325 30.2400  72.01     66
Reservas 49.57939 60.182098  3.68 22.9925 33.055 67.8150 472.31     66

> tapply(LaBreña_E_S_R$Agosto, list(La_Breña_II=LaBreña_E_S_R$La_Breña_II), sd, na.rm=TRUE)
La_Breña_II
 Entradas   Salidas  Reservas
 6.998468 14.575106 60.182098

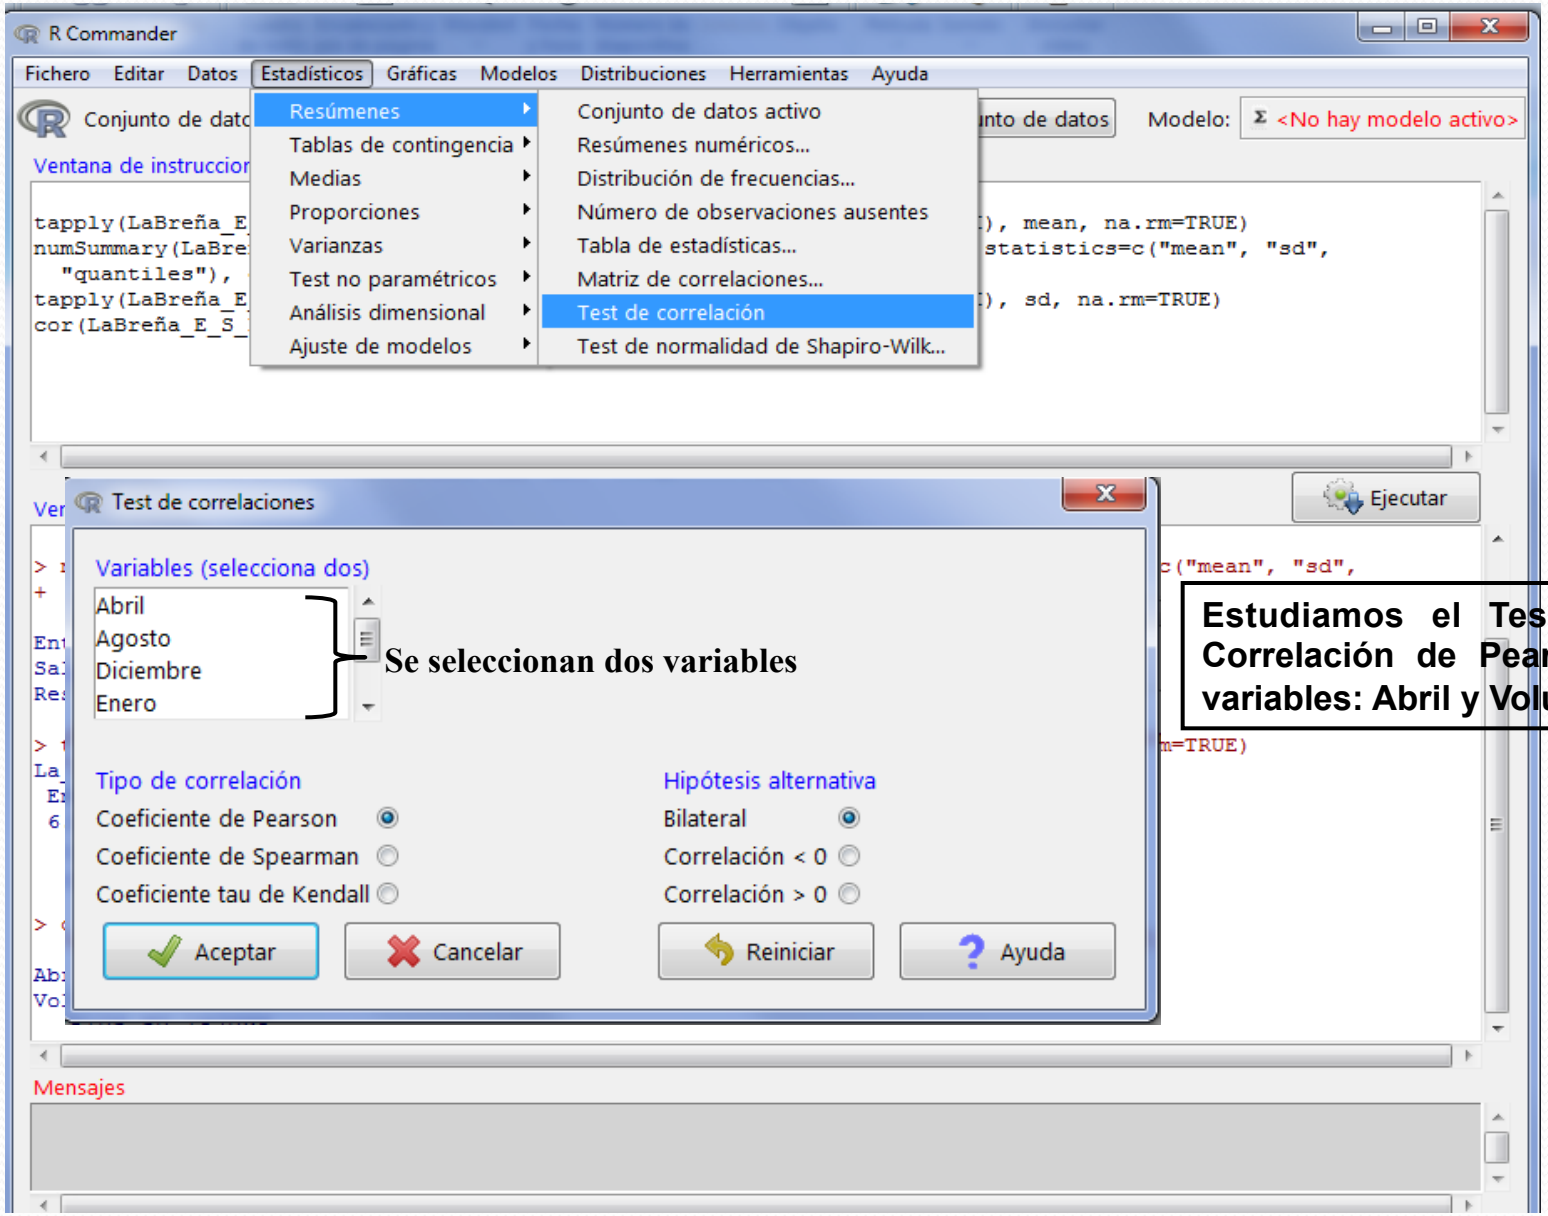

> cor(LaBreña_E_S_R[,c("Abril","Volumen.anual")], use="complete.obs")
                Abril Volumen.anual
Abril         1.0000000    0.4808236
Volumen.anual 0.4808236    1.0000000
```

¿Es significativo este valor?

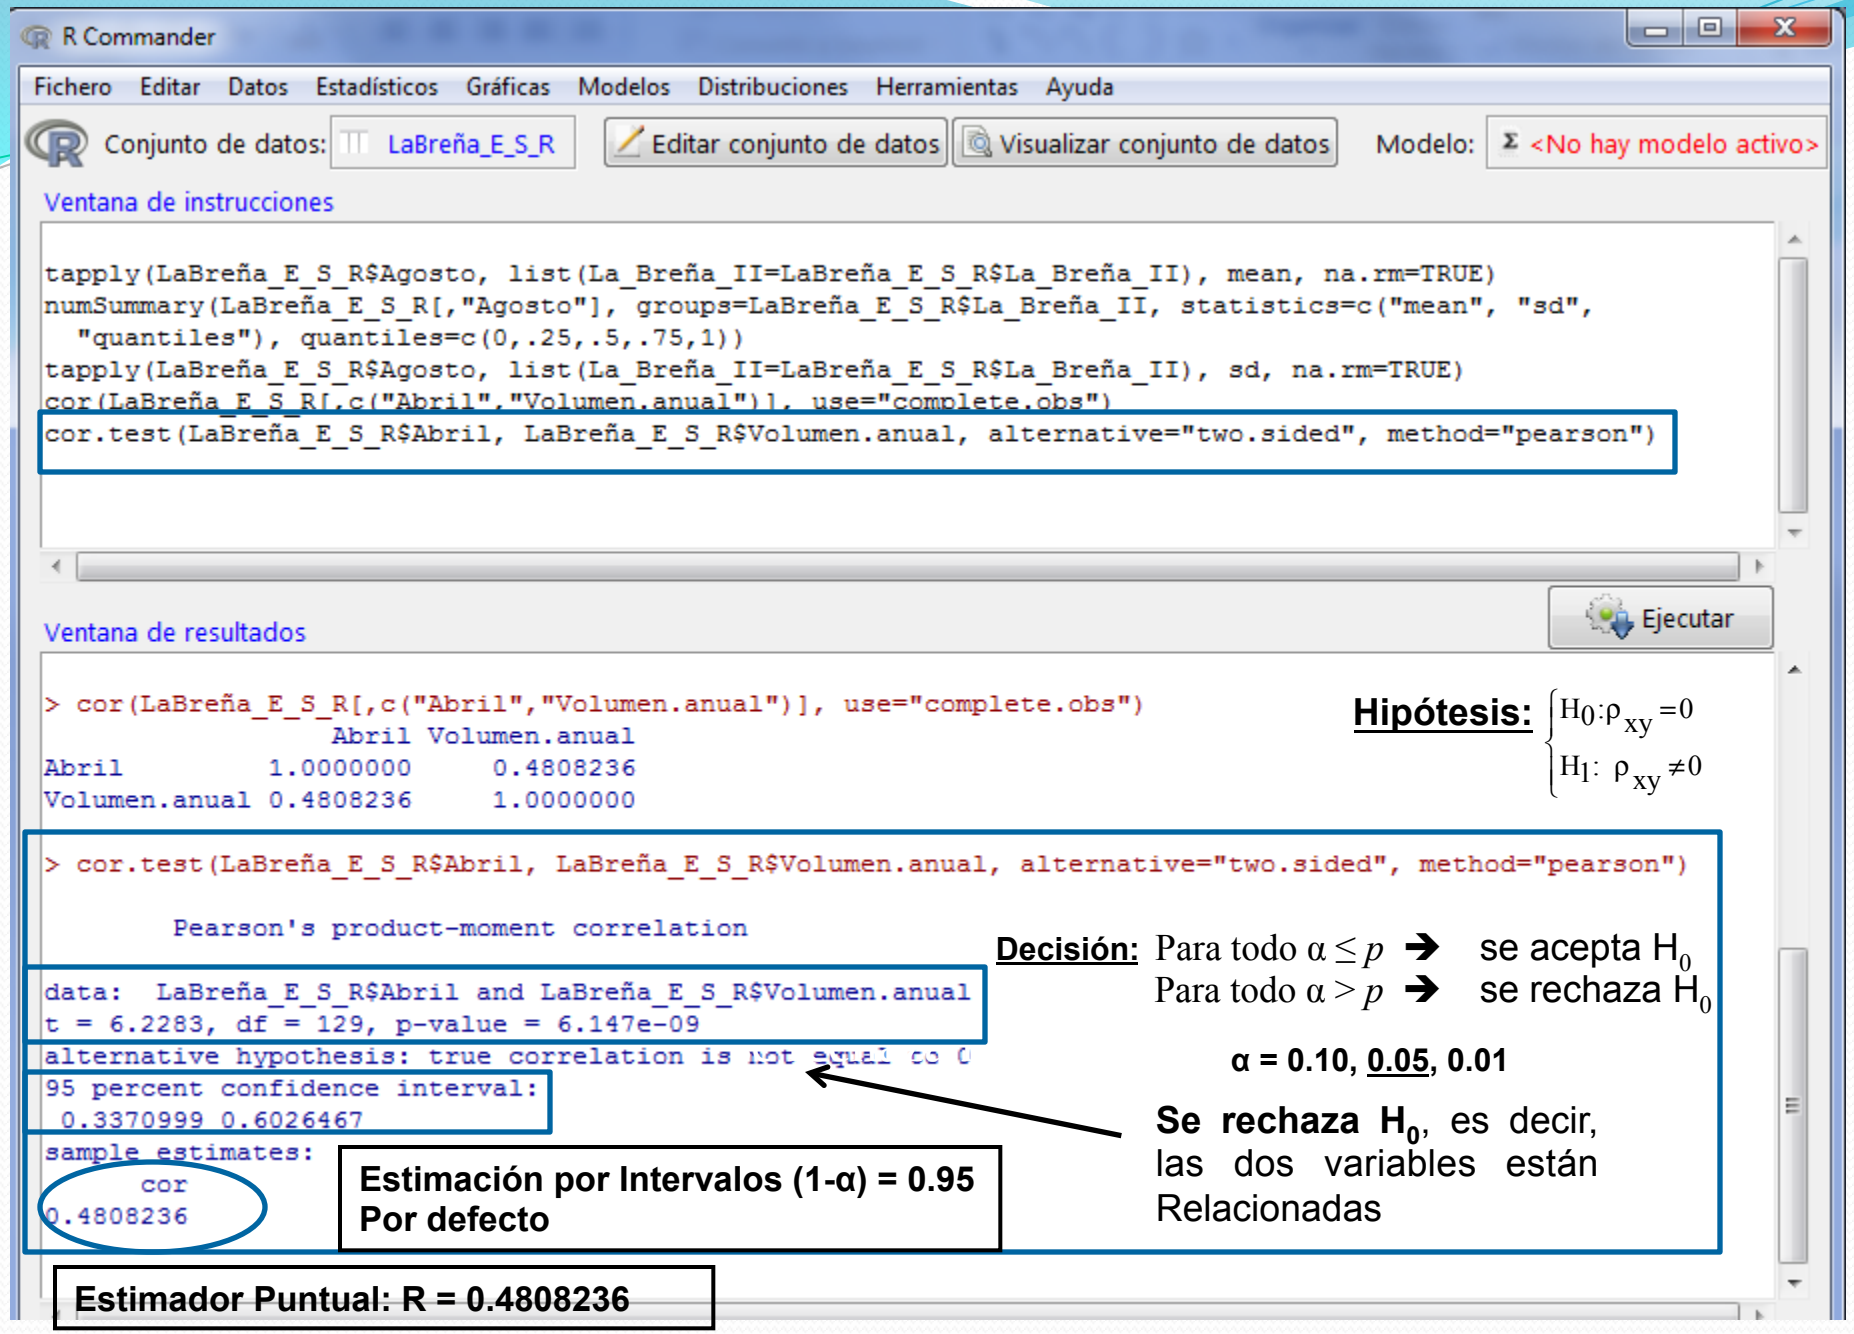
R = 0.4808236

Mensajes

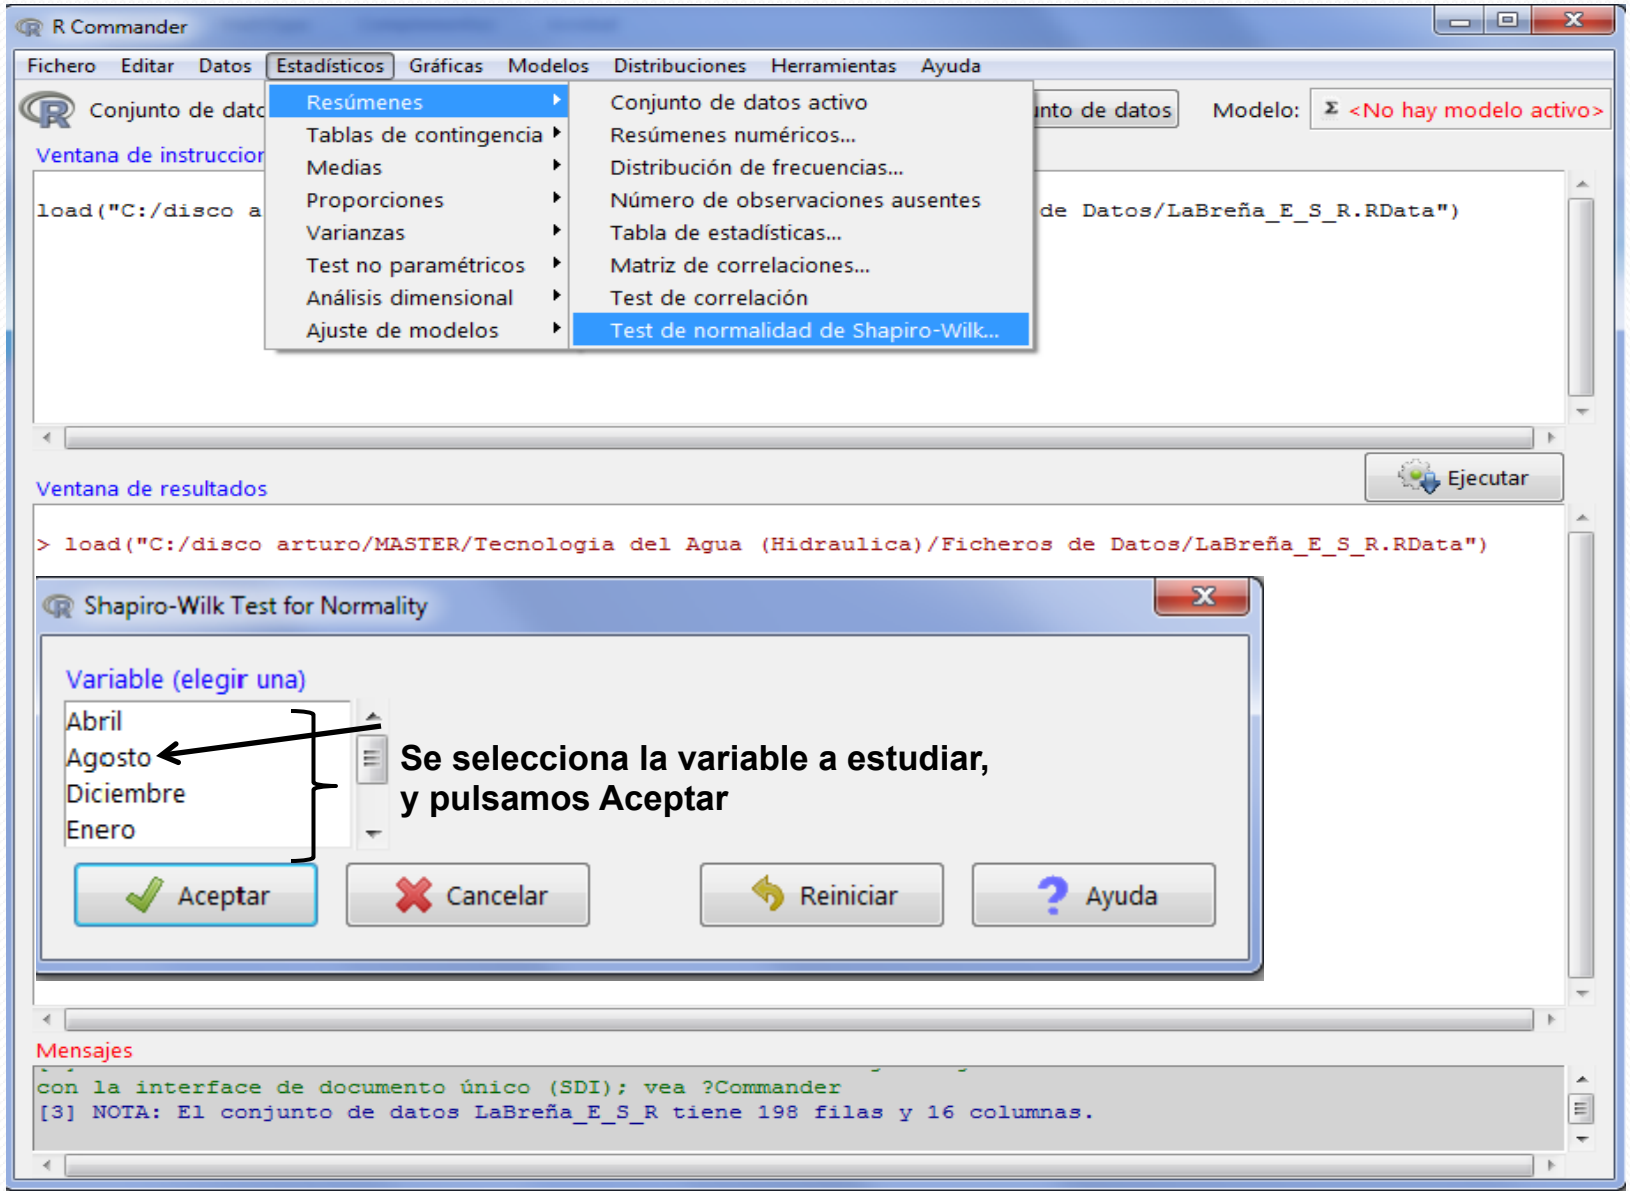
DESCRIPTIVA: Test de Correlación

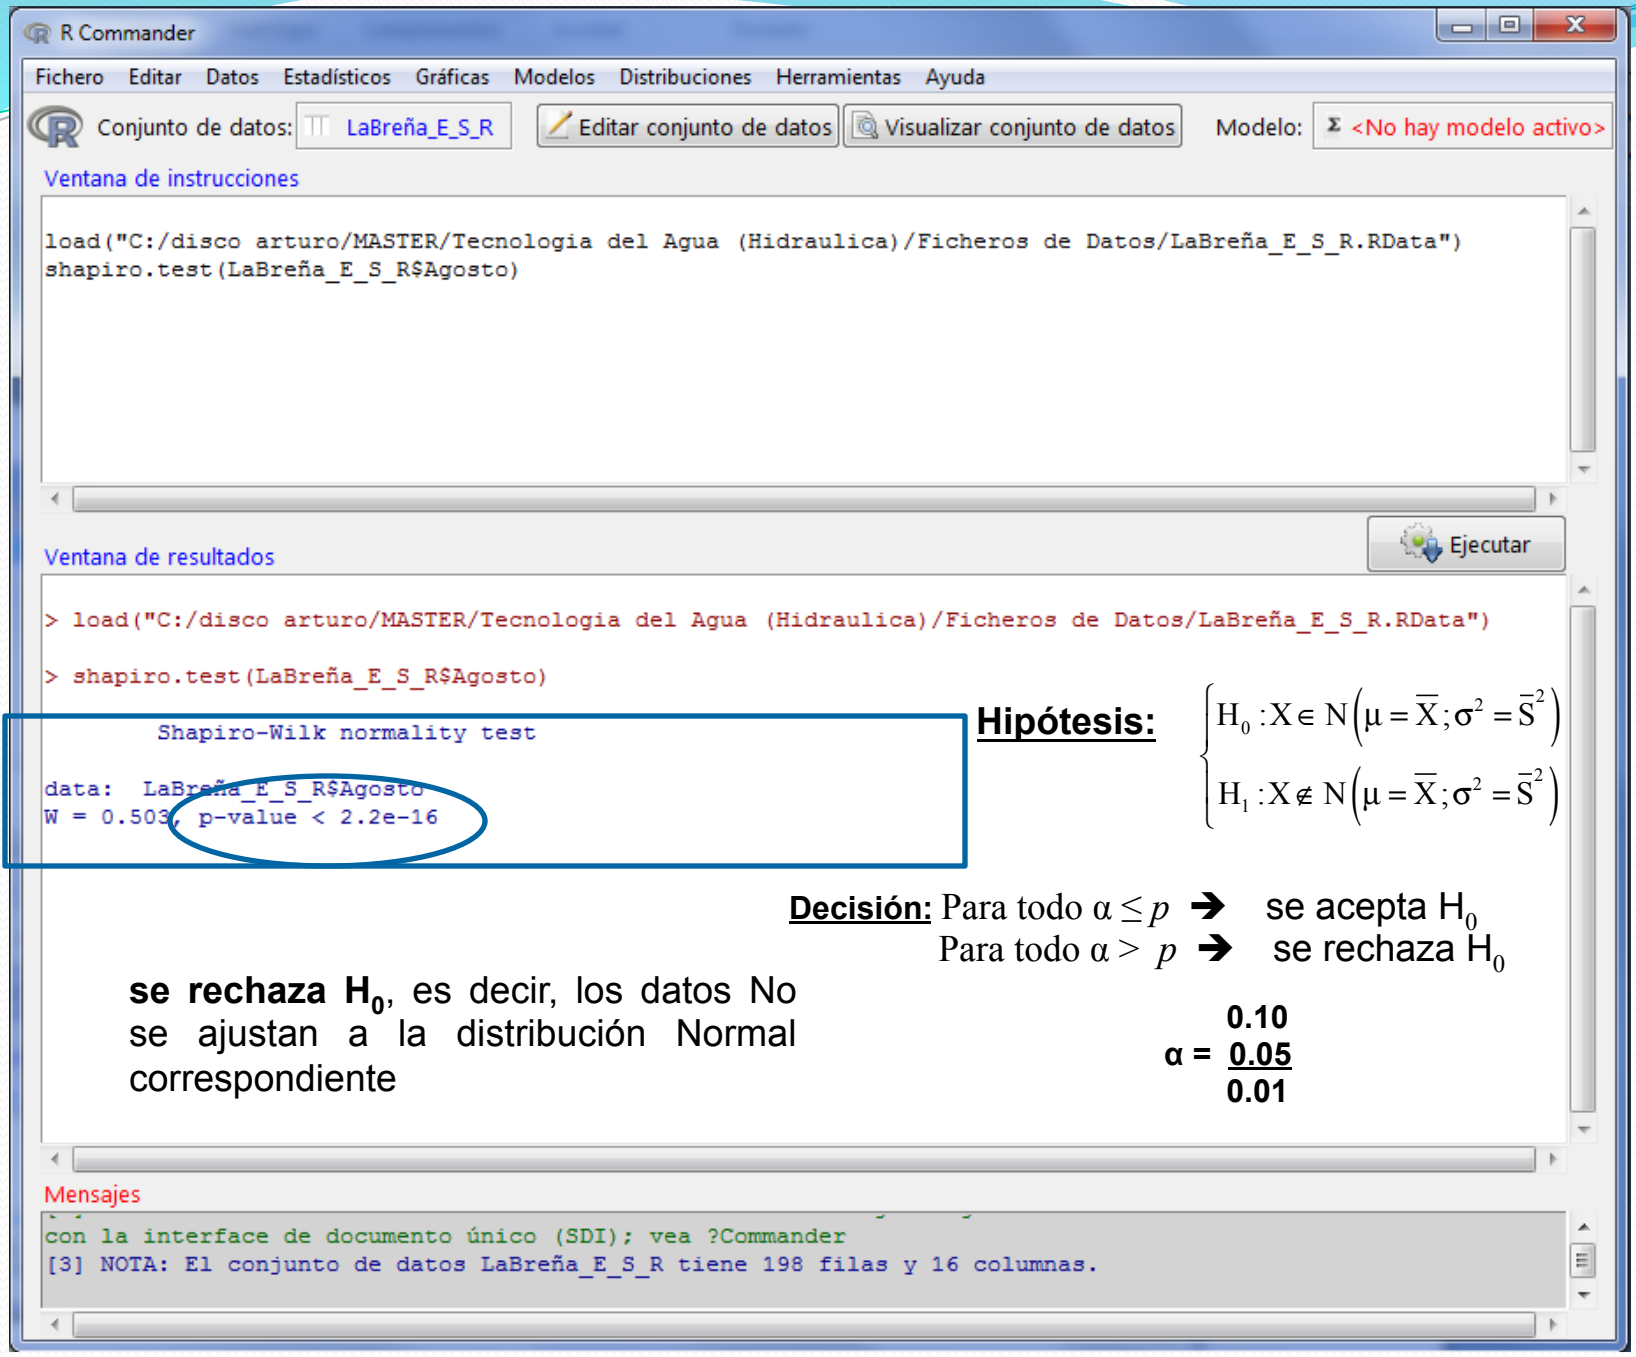


Estudiamos el Test bilateral de Correlación de Pearson para dos variables: Abril y Volumen.anual


R Commander
Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda
Conjunto de datos: LaBreña_E_S_R
Editar conjunto de datos
Visualizar conjunto de datos
Modelo: <No hay modelo activo>
Ventana de instrucciones
tapply(LaBreña_E_S_R$Agosto, list(La_Breña_II=LaBreña_E_S_R$La_Breña_II), mean, na.rm=TRUE)
numSummary(LaBreña_E_S_R[,"Agosto"], groups=LaBreña_E_S_R$La_Breña_II, statistics=c("mean", "sd",
"quantiles"), quantiles=c(0,.25,.5,.75,1))
tapply(LaBreña_E_S_R$Agosto, list(La_Breña_II=LaBreña_E_S_R$La_Breña_II), sd, na.rm=TRUE)
cor(LaBreña_E_S_R[,c("Abril","Volumen.anual")], use="complete.obs")
cor.test(LaBreña_E_S_R$Abril, LaBreña_E_S_R$Volumen.anual, alternative="two.sided", method="pearson")
Ejecutar
Ventana de resultados
> cor(LaBreña_E_S_R[,c("Abril","Volumen.anual")], use="complete.obs")
Abril Volumen.anual
Abril 1.0000000 0.4808236
Volumen.anual 0.4808236 1.0000000
Hipótesis:
H0:ρxy =0
H1: ρxy ≠0
> cor.test(LaBreña_E_S_R$Abril, LaBreña_E_S_R$Volumen.anual, alternative="two.sided", method="pearson")
Pearson's product-moment correlation
data: LaBreña_E_S_R$Abril and LaBreña_E_S_R$Volumen.anual
t = 6.2283, df = 129, p-value = 6.147e-09
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
0.3370999 0.6026467
sample estimates:
cor
0.4808236
Decisión:
Para todo α ≤ p ➔ se acepta H0
Para todo α > p ➔ se rechaza H0
α = 0.10, 0.05, 0.01
Se rechaza H0, es decir, las dos variables están Relacionadas
Estimación por Intervalos (1-α) = 0.95
Por defecto
Estimador Puntual: R = 0.4808236

Test de Normalidad. Shapiro-Wilk





Hipótesis:

$$\begin{cases} H_0 : X \in N\left(\mu = \overline{X}; \sigma^2 = \overline{S}^2\right) \\ H_1 : X \notin N\left(\mu = \overline{X}; \sigma^2 = \overline{S}^2\right) \end{cases}$$

Decisión: Para todo $\alpha \leq p$ ➔ se acepta H_0

Para todo $\alpha > p$ ➔ se rechaza H_0

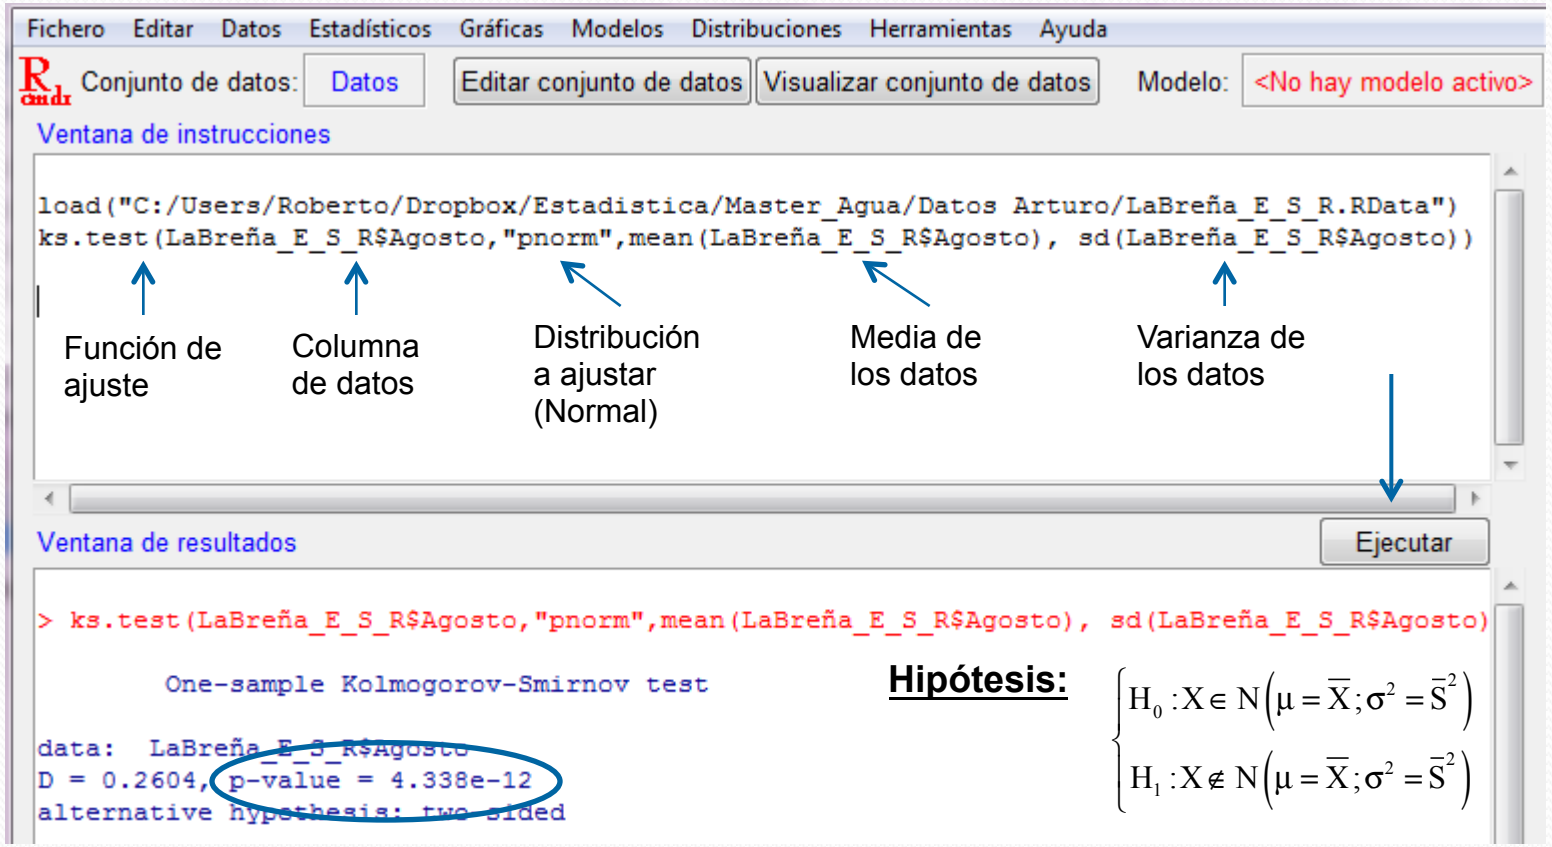
se rechaza H_0, es decir, los datos No se ajustan a la distribución Normal correspondiente

α = 0.10 / 0.05 / 0.01

Test de Normalidad de Kolmogorov-Smirnov.

Permite el ajuste a una distribución de parámetros conocidos.

Esta implementado en el programa base de R pero no en Rcommander, con lo que hay que introducirlo mediante comando.



Hipótesis:

$$\begin{cases} H_0 : X \in N\left(\mu = \overline{X}; \sigma^2 = \overline{S}^2\right) \\ H_1 : X \notin N\left(\mu = \overline{X}; \sigma^2 = \overline{S}^2\right) \end{cases}$$

se rechaza H_0,
es decir, los datos No se ajustan a la distribución Normal correspondiente

Decisión:

Para todo $\alpha \leq p$ ➔ se acepta H_0

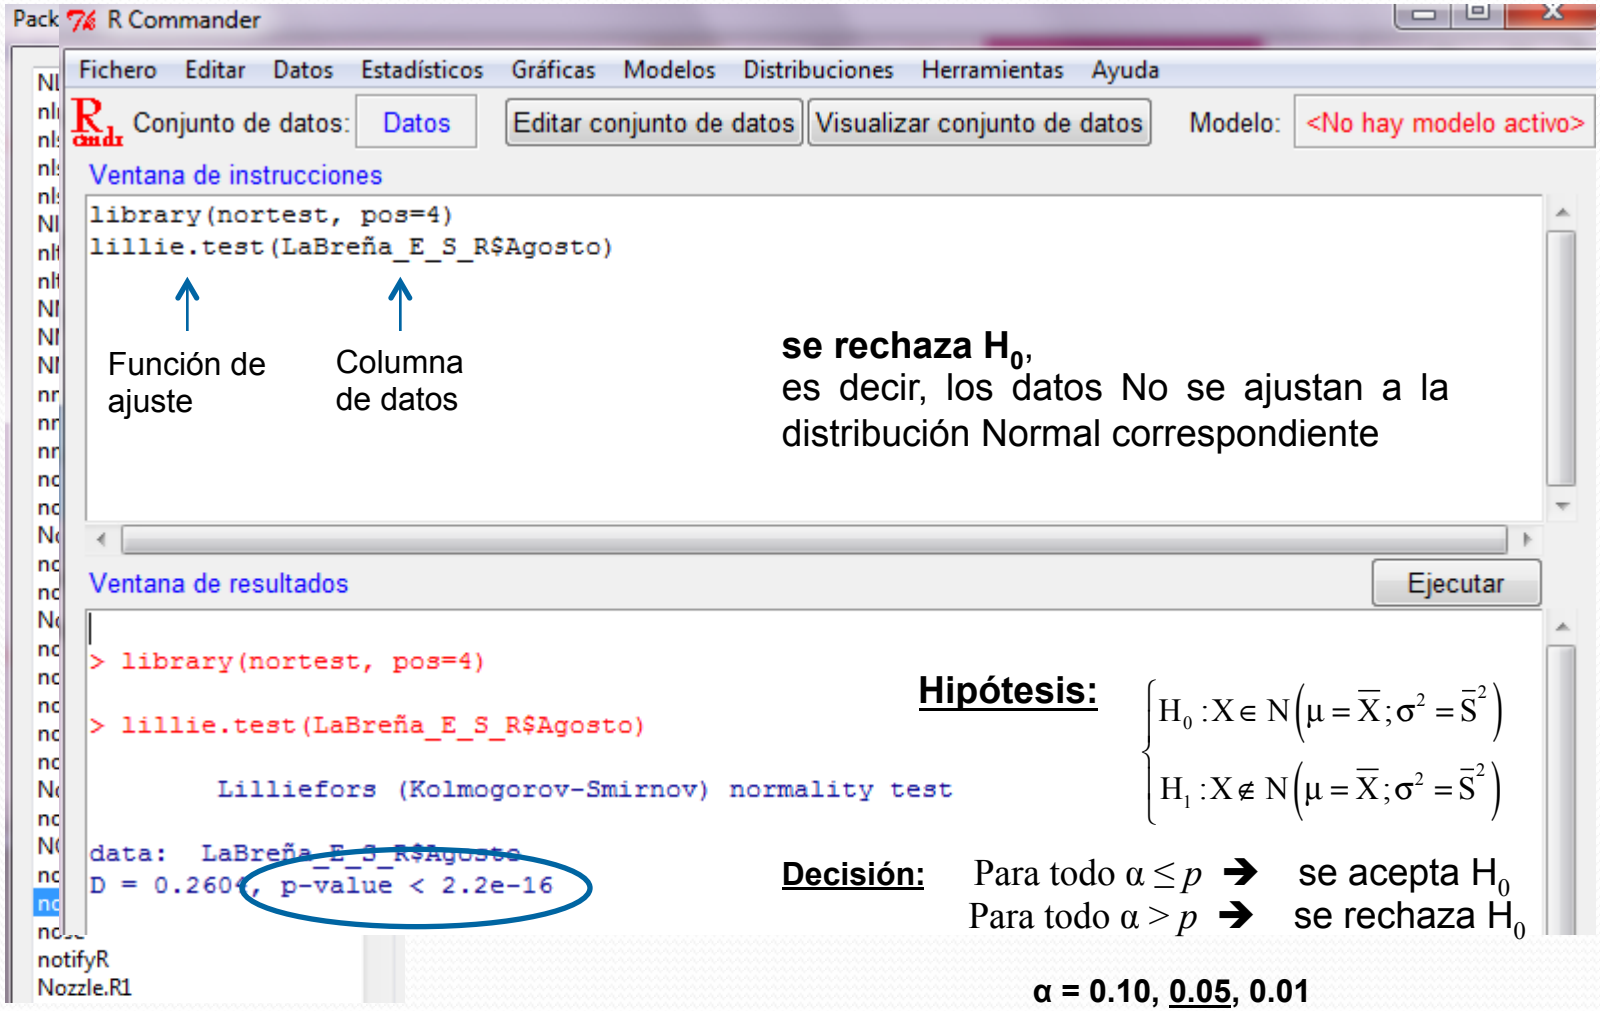
Para todo $\alpha > p$ ➔ se rechaza H_0

α = 0.10, 0.05, 0.01

Test de Normalidad de Kolmogorov-Smirnov (Corrección de Lilliefors).

En este caso, la distribución del estadístico es diferente cuando los parámetros son estimados, lo que afecta a la probabilidad límite.

Por tanto, en la mayoría de las situaciones es mas correcto usar Lilliefors.



se rechaza H_0,
es decir, los datos No se ajustan a la distribución Normal correspondiente

Hipótesis:

$$\begin{cases} H_0 : X \in N\left(\mu = \overline{X}; \sigma^2 = \overline{S}^2\right) \\ H_1 : X \notin N\left(\mu = \overline{X}; \sigma^2 = \overline{S}^2\right) \end{cases}$$

Decisión: Para todo $\alpha \leq p$ ➔ se acepta H_0
Para todo $\alpha > p$ ➔ se rechaza H_0

α = 0.10, <u>0.05</u>, 0.01

FUNDAMENTOS Y HERRAMIENTAS PARA LA MODELIZACIÓN DE PROCESOS TÉCNICOS-CIENTÍFICOS DE INVESTIGACIÓN

Bloque III: Modelización estadística.

Estadística descriptiva con R (Rcommander)



Roberto Espejo Mohedano e-mail: ma1esmor@uco.es

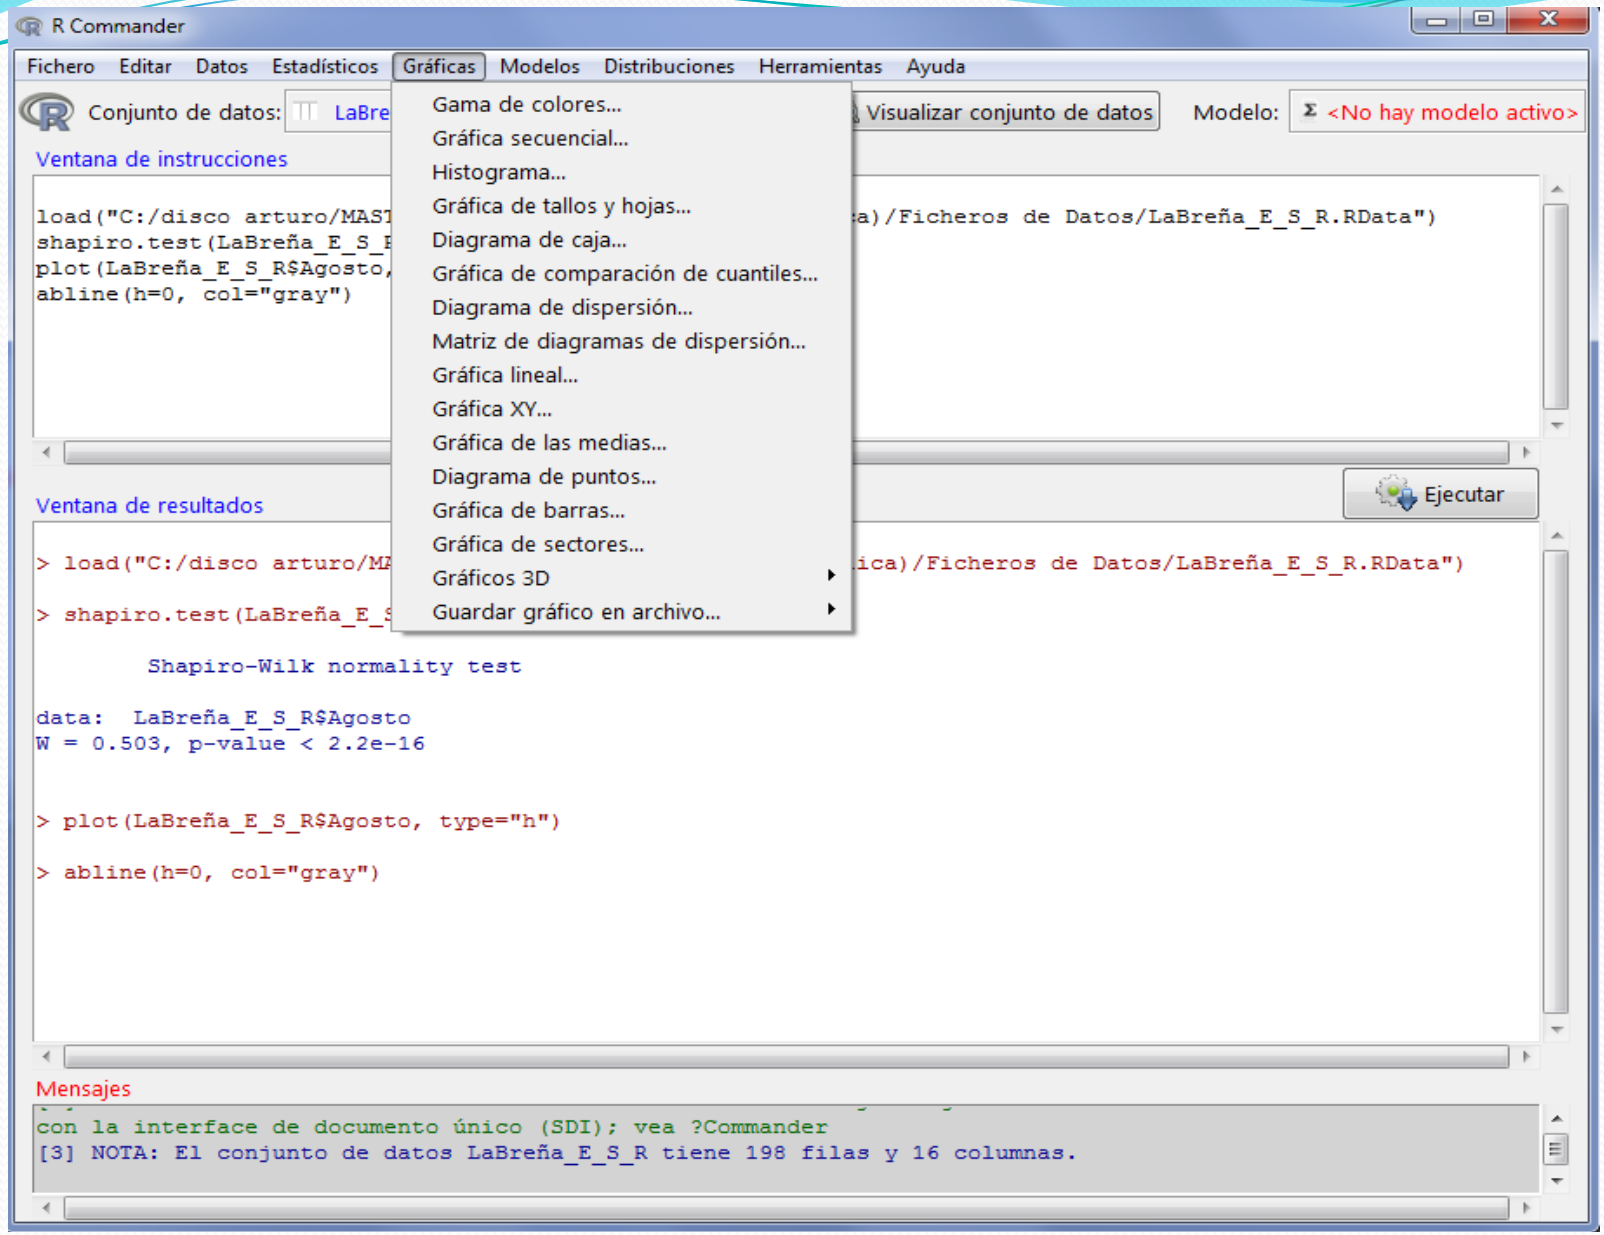
FUNDAMENTOS Y HERRAMIENTAS PARA LA MODELIZACIÓN DE PROCESOS TÉCNICOS-CIENTÍFICOS DE INVESTIGACIÓN

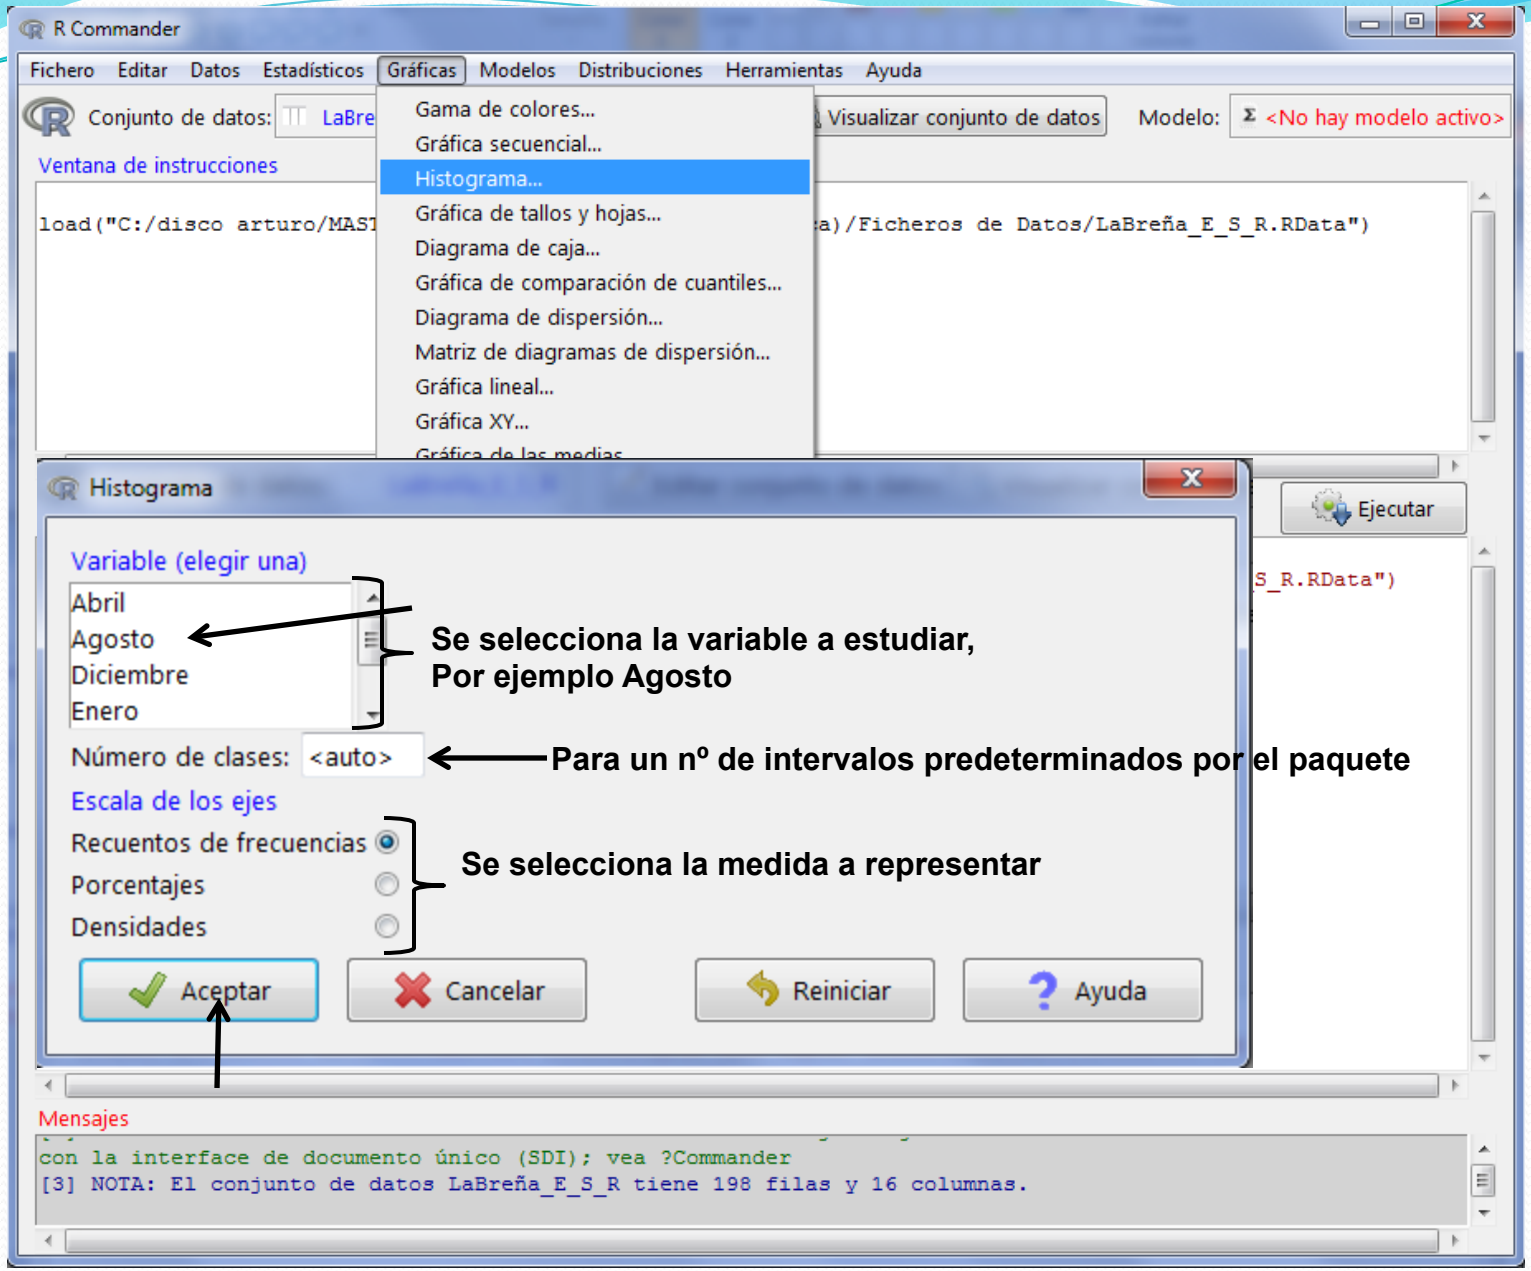
Bloque III: Modelización estadística.

Gráficos con R (Rcommander)

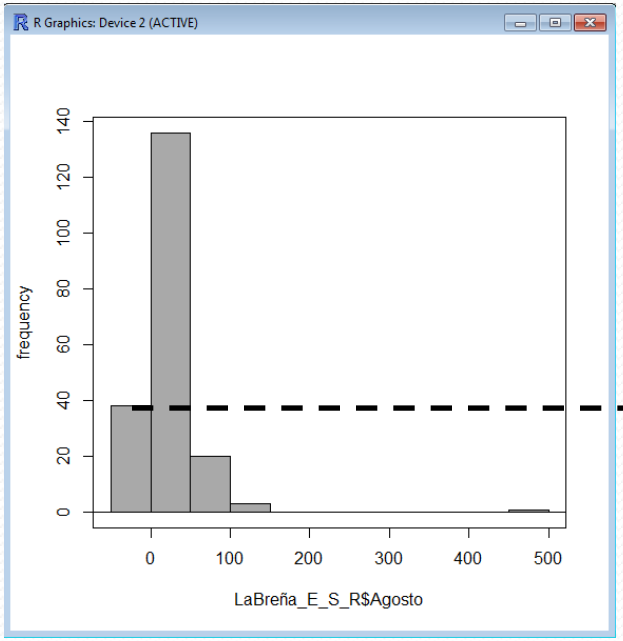


Roberto Espejo Mohedano e-mail: ma1esmor@uco.es

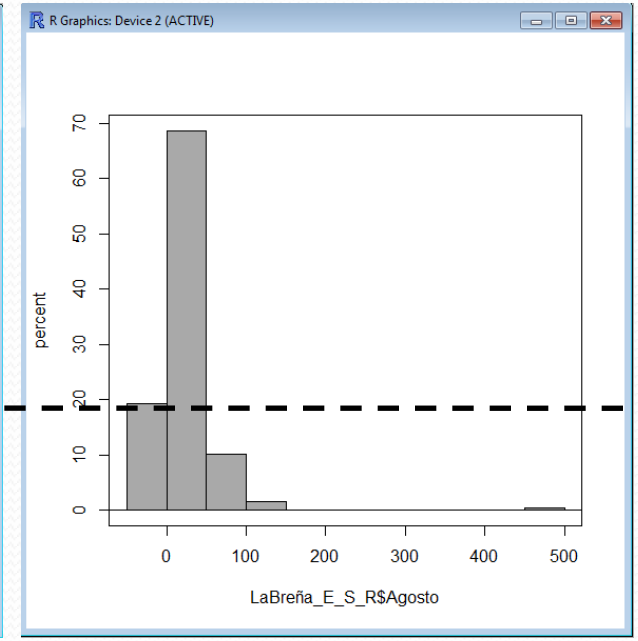

R Commander
Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda
Conjunto de datos:
Visualizar conjunto de datos
Modelo:
<No hay modelo activo>
Gama de colores...
Gráfica secuencial...
Histograma...
Gráfica de tallos y hojas...
Diagrama de caja...
Gráfica de comparación de cuantiles...
Diagrama de dispersión...
Matriz de diagramas de dispersión...
Gráfica lineal...
Gráfica XY...
Gráfica de las medias...
Diagrama de puntos...
Gráfica de barras...
Gráfica de sectores...
Gráficos 3D
Guardar gráfico en archivo...
Ventana de instrucciones
load("C:/disco arturo/MAST
shapiro.test(LaBreña_E_S_
plot(LaBreña_E_S_R$Agosto,
abline(h=0, col="gray")
a)/Ficheros de Datos/LaBreña_E_S_R.RData")
Ejecutar
Ventana de resultados
> load("C:/disco arturo/MA
ica)/Ficheros de Datos/LaBreña_E_S_R.RData")
> shapiro.test(LaBreña_E_S
Shapiro-Wilk normality test
data: LaBreña_E_S_R$Agosto
W = 0.503, p-value < 2.2e-16
> plot(LaBreña_E_S_R$Agosto, type="h")
> abline(h=0, col="gray")
Mensajes
con la interface de documento único (SDI); vea ?Commander
[3] NOTA: El conjunto de datos LaBreña_E_S_R tiene 198 filas y 16 columnas.


R Commander
Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda
Conjunto de datos:
Visualizar conjunto de datos
Modelo: <No hay modelo activo>
Ventana de instrucciones
load("C:/disco arturo/MAST
a)/Ficheros de Datos/LaBreña_E_S_R.RData")
Gama de colores...
Gráfica secuencial...
Histograma...
Gráfica de tallos y hojas...
Diagrama de caja...
Gráfica de comparación de cuantiles...
Diagrama de dispersión...
Matriz de diagramas de dispersión...
Gráfica lineal...
Gráfica XY...
Histograma
Ejecutar
Variable (elegir una)
Abril
Agosto
Diciembre
Enero
Se selecciona la variable a estudiar,
Por ejemplo Agosto
Número de clases: <auto>
Para un nº de intervalos predeterminados por el paquete
Escala de los ejes
Recuentos de frecuencias
Porcentajes
Densidades
Se selecciona la medida a representar
Aceptar
Cancelar
Reiniciar
Ayuda
Mensajes
con la interface de documento único (SDI); vea ?Commander
[3] NOTA: El conjunto de datos LaBreña_E_S_R tiene 198 filas y 16 columnas.

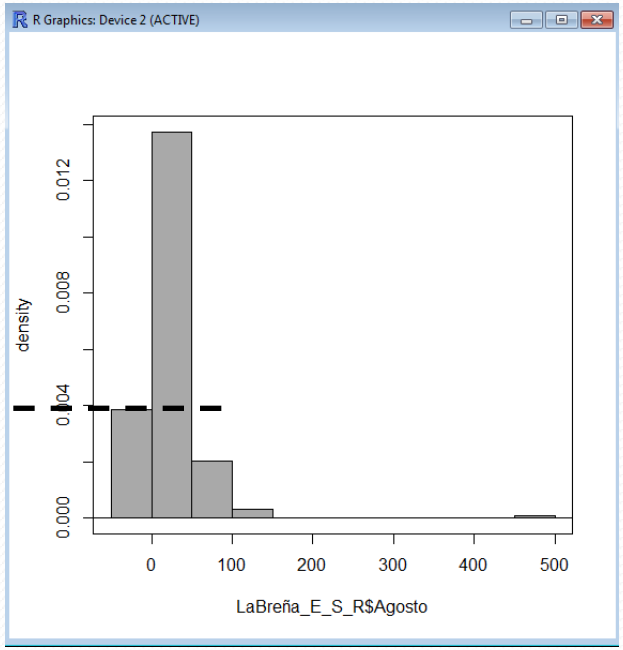
En la ventana de R-Console aparece el gráfico pedido



Frecuencias: Nº de observaciones en cada intervalo. Frecuencia Absoluta

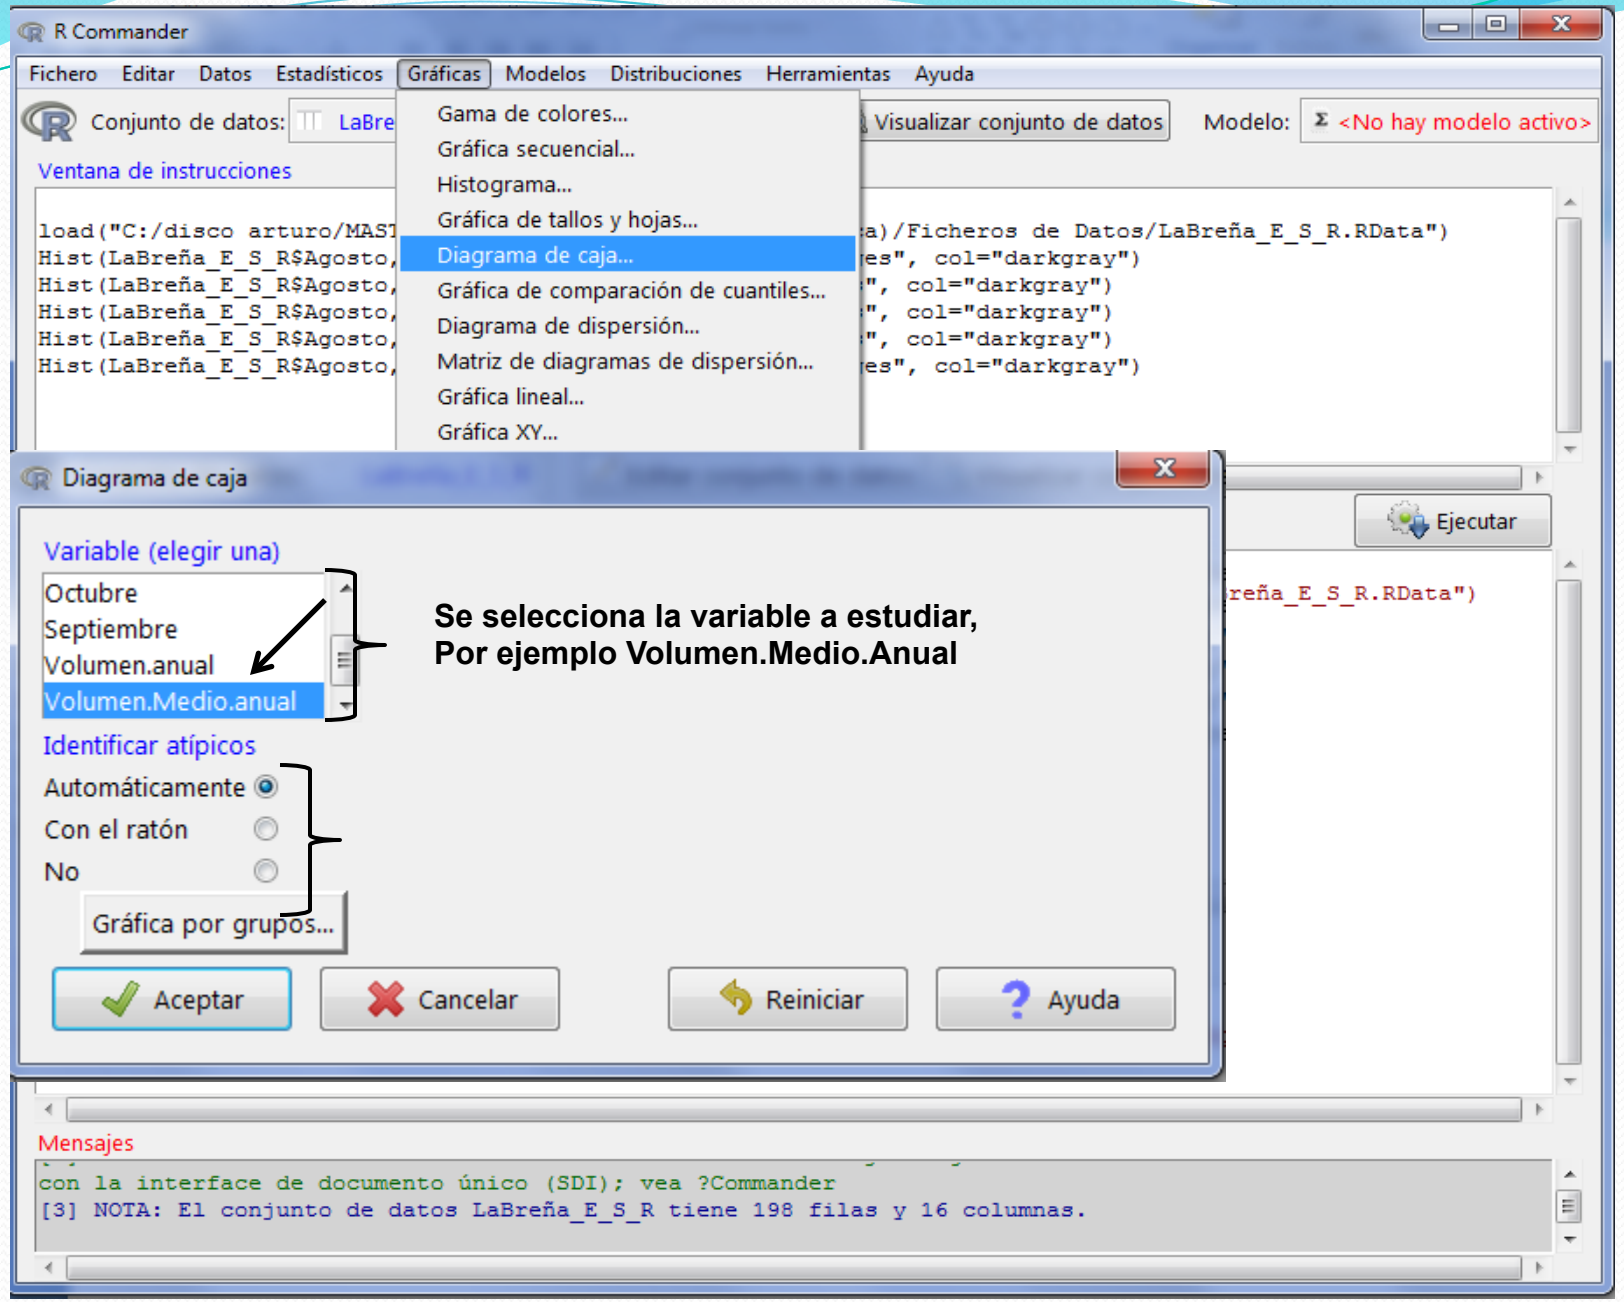


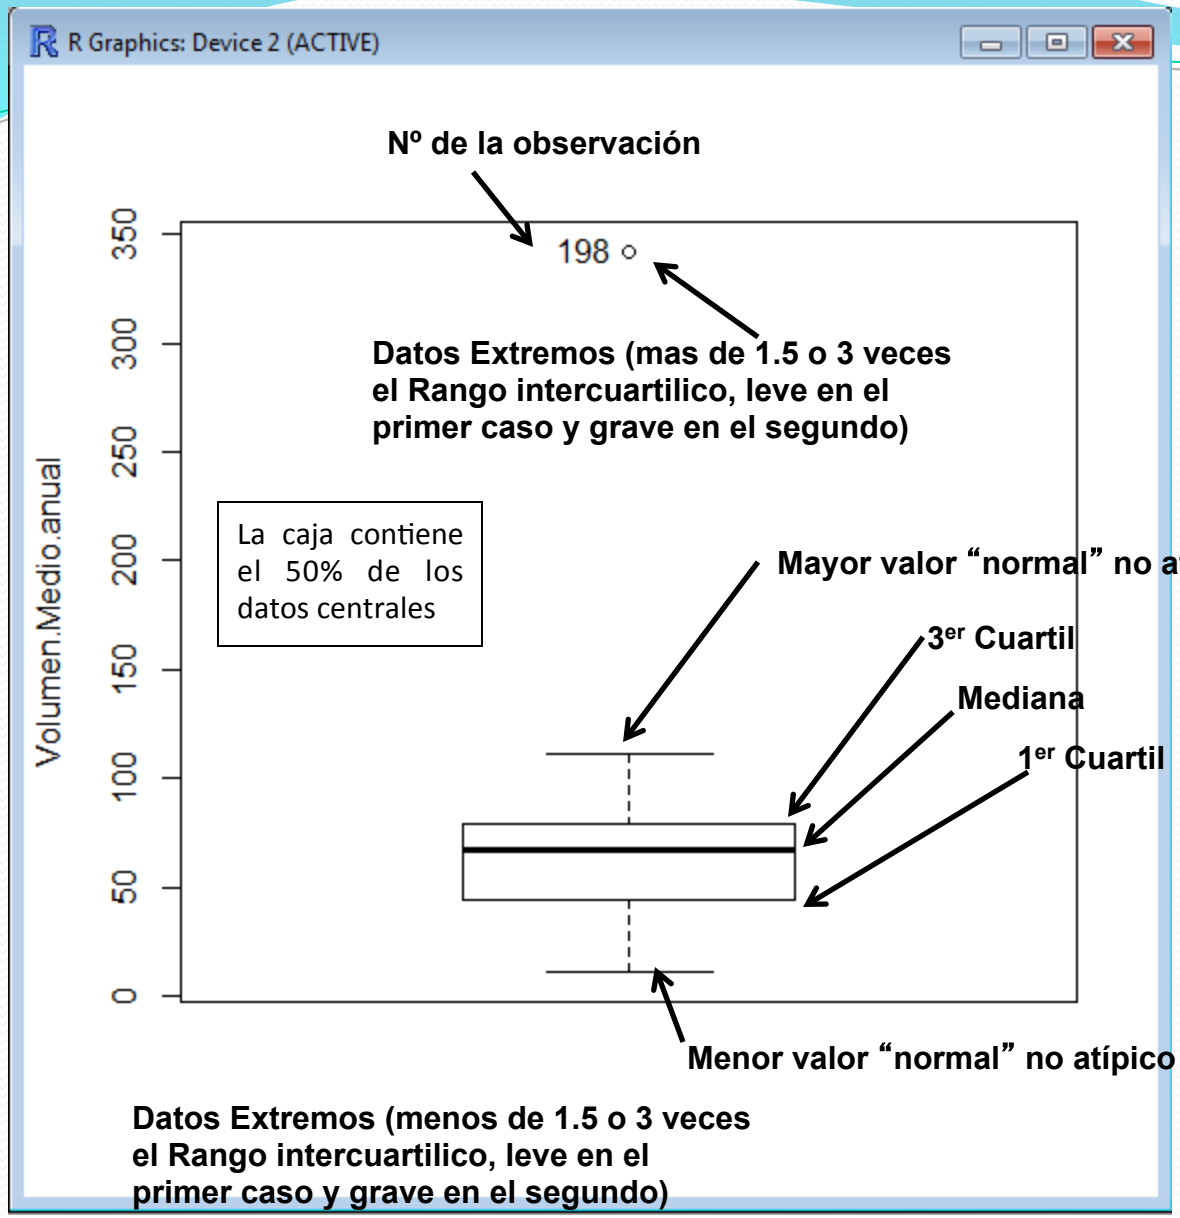
Porcentajes: Tanto por ciento de observaciones en cada intervalo.

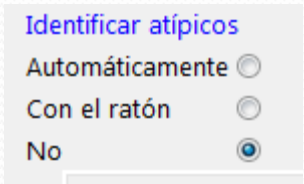


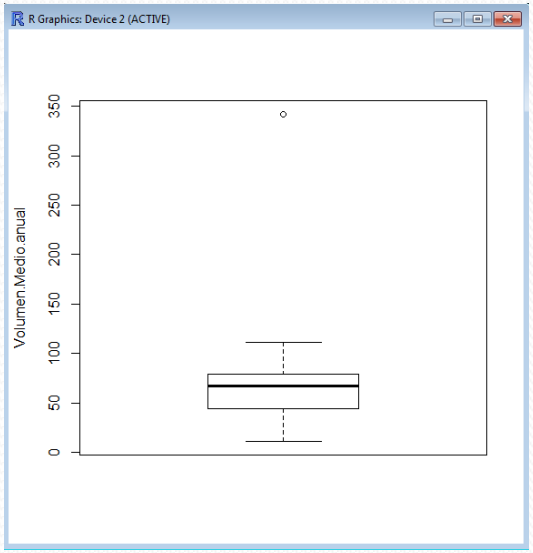
Densidad: Igual al anterior, pero en tantos por uno. Frecuencia Relativa

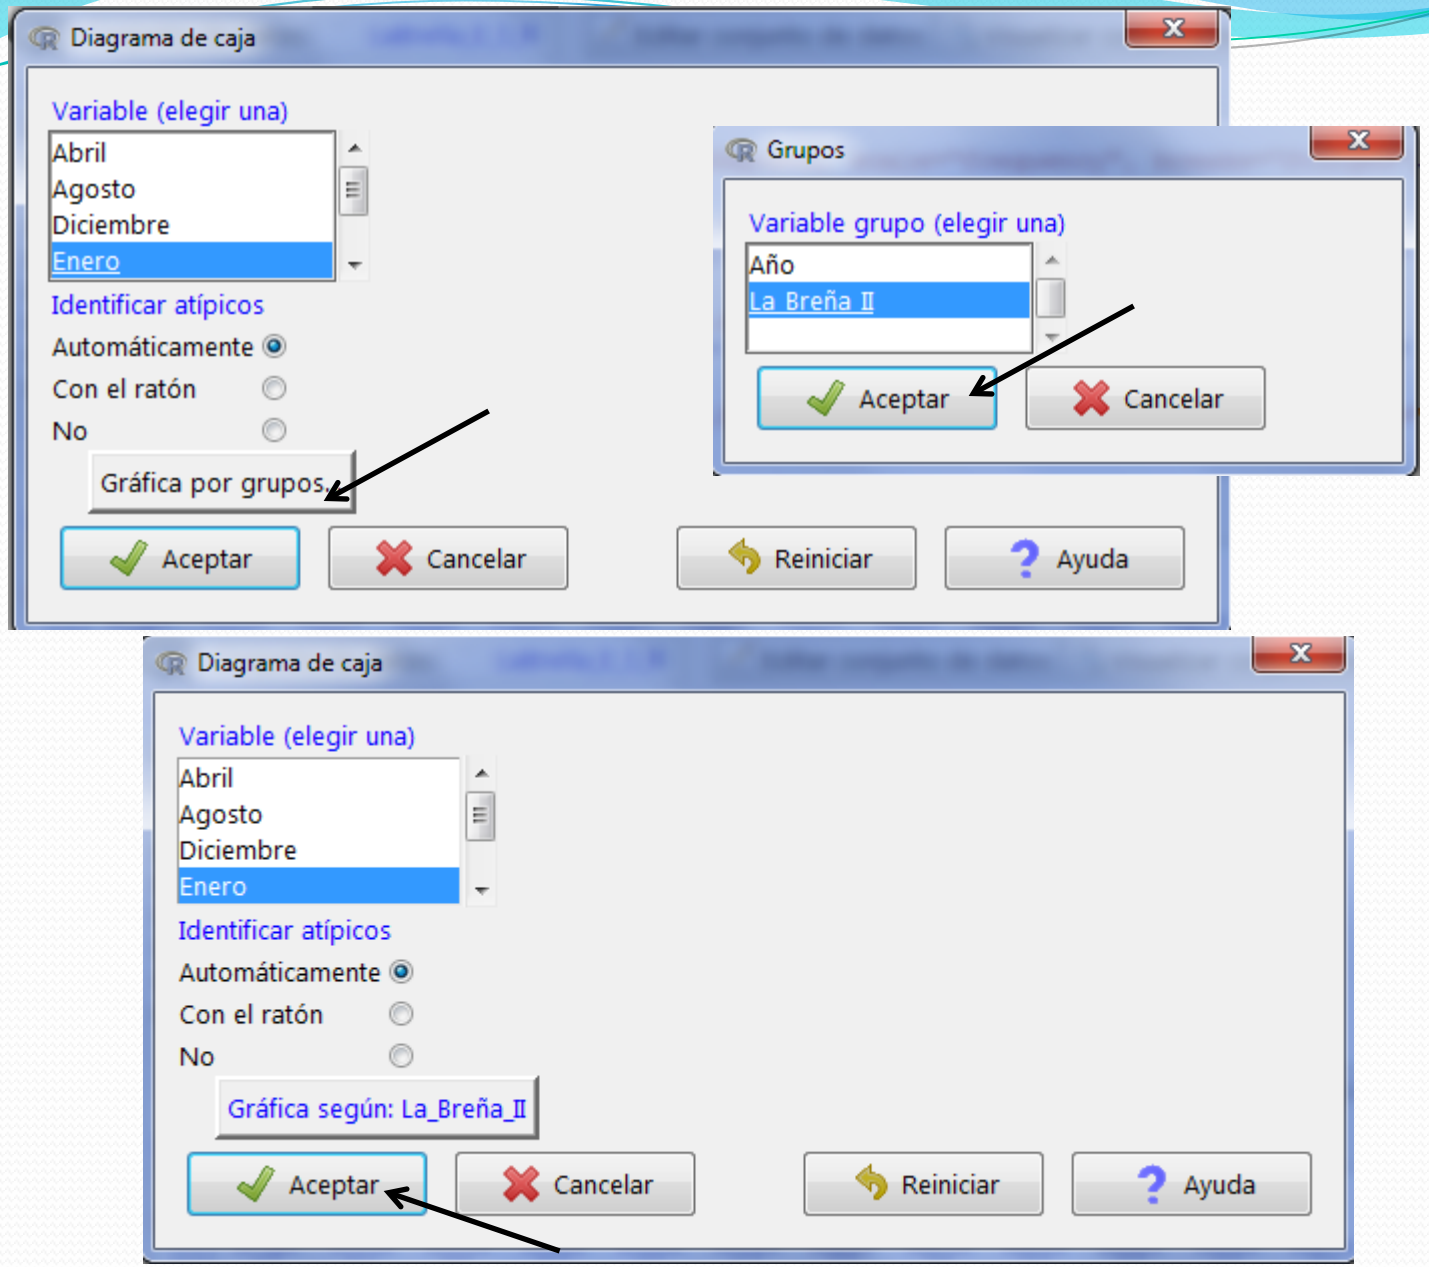
No se pueden simultanear los tres gráficos, al representar uno de ellos, borra el anterior

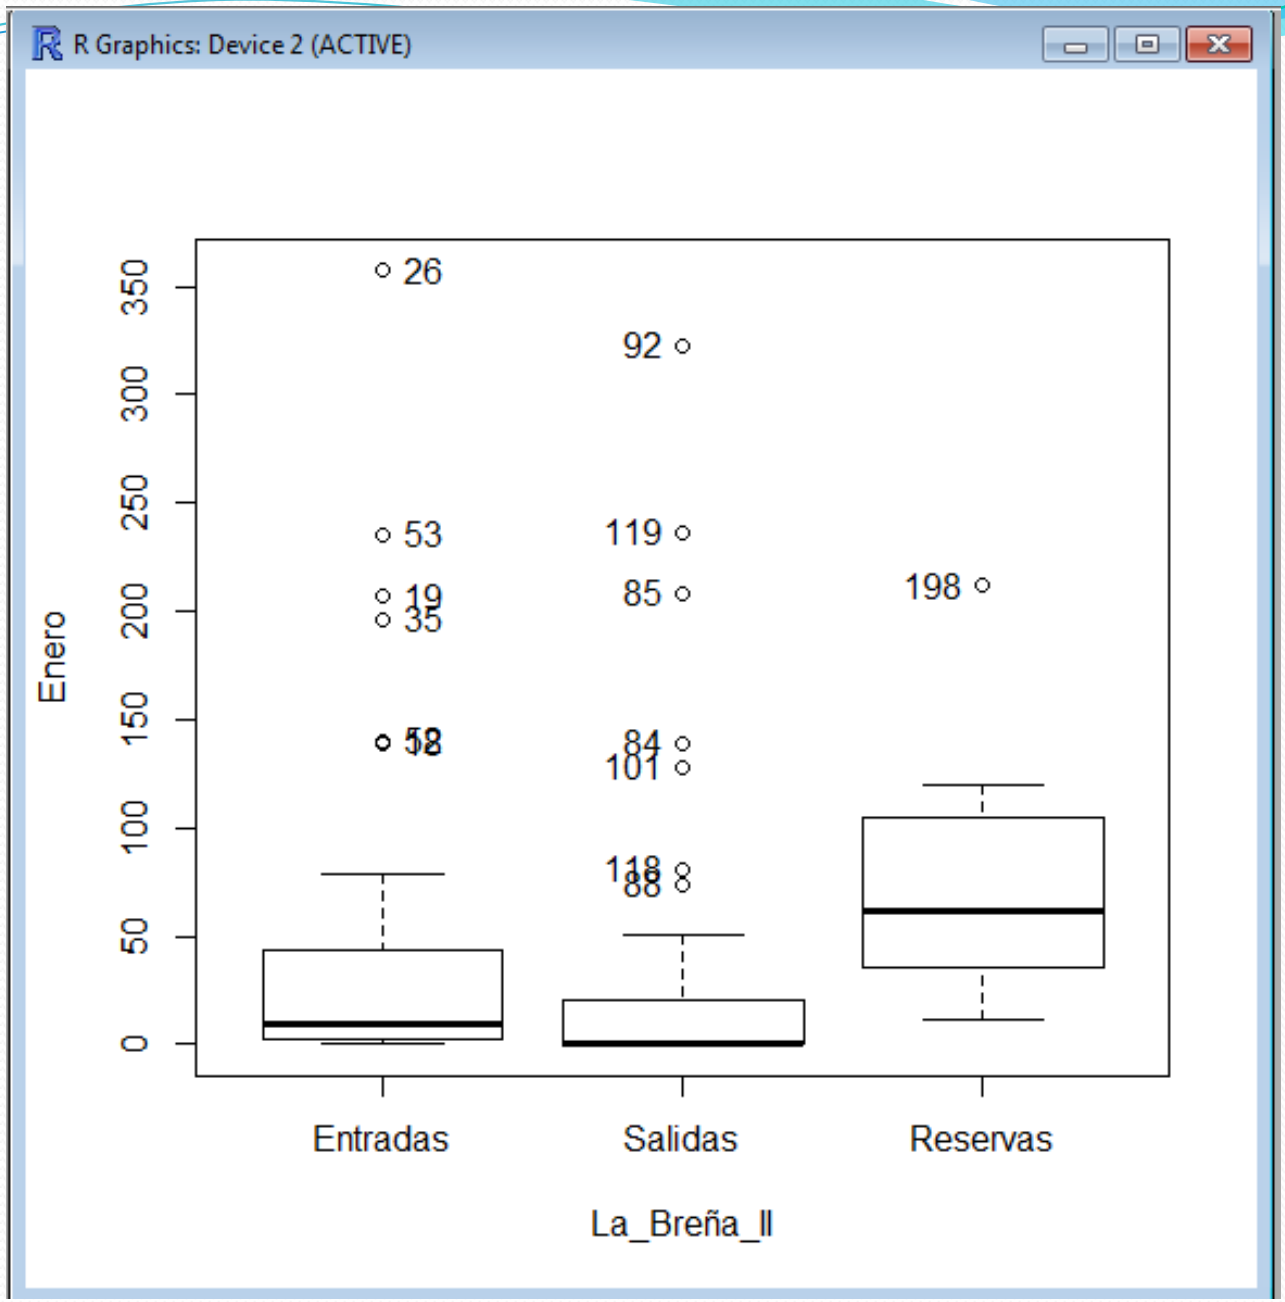

R Commander
Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda
Conjunto de datos:
Visualizar conjunto de datos
Modelo: <No hay modelo activo>
Ventana de instrucciones
Gama de colores...
Gráfica secuencial...
Histograma...
Gráfica de tallos y hojas...
Diagrama de caja...
Gráfica de comparación de cuantiles...
Diagrama de dispersión...
Matriz de diagramas de dispersión...
Gráfica lineal...
Gráfica XY...
Diagrama de caja
Variable (elegir una)
Octubre
Septiembre
Volumen.anual
Volumen.Medio.anual
Se selecciona la variable a estudiar,
Por ejemplo Volumen.Medio.Anual
Identificar atípicos
Automáticamente
Con el ratón
No
Gráfica por grupos...
Aceptar
Cancelar
Reiniciar
Ayuda
Ejecutar
Mensajes
con la interface de documento único (SDI); vea ?Commander
[3] NOTA: El conjunto de datos LaBreña_E_S_R tiene 198 filas y 16 columnas.

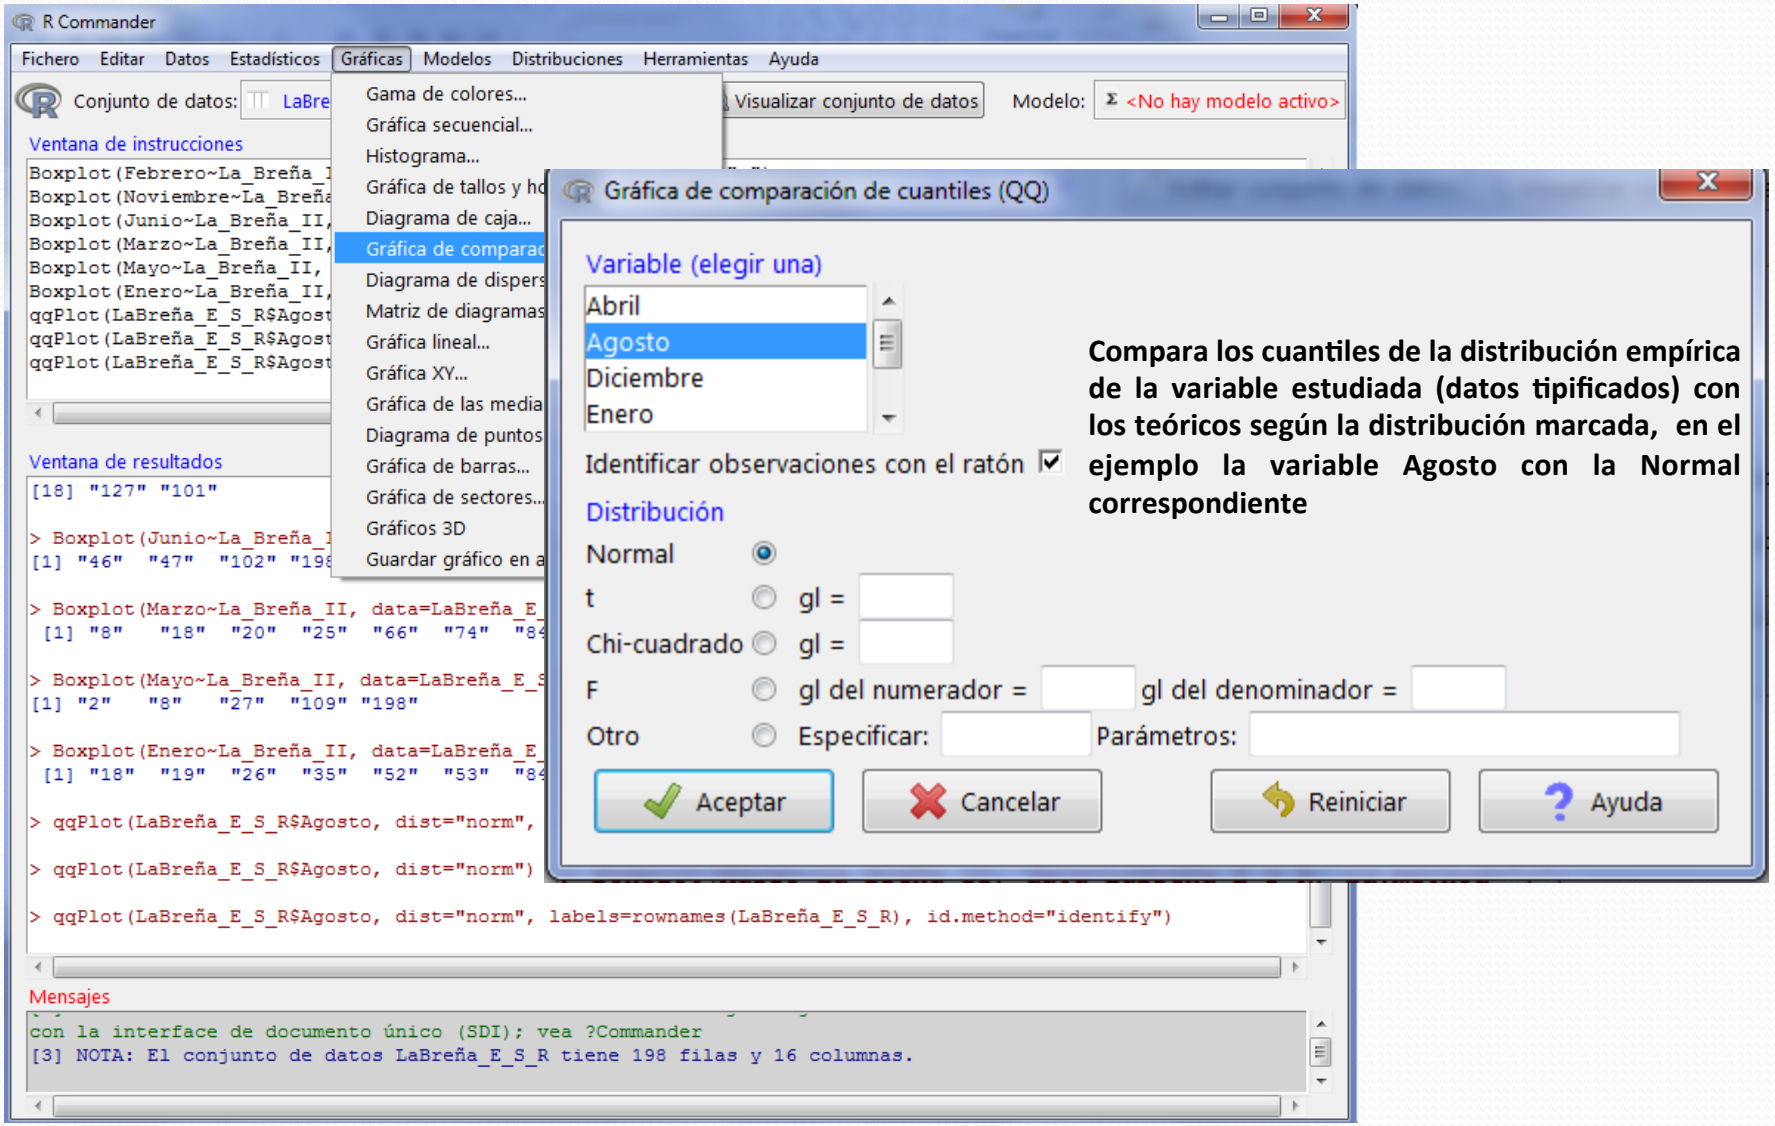

R Graphics: Device 2 (ACTIVE)
Nº de la observación
198
Datos Extremos (mas de 1.5 o 3 veces el Rango intercuartilico, leve en el primer caso y grave en el segundo)
La caja contiene el 50% de los datos centrales
Mayor valor "normal" no atípico
3er Cuartil
Mediana
1er Cuartil
Menor valor "normal" no atípico
Datos Extremos (menos de 1.5 o 3 veces el Rango intercuartilico, leve en el primer caso y grave en el segundo)
Volumen.Medio.anual
0
50
100
150
200
250
300
350


Identificar atípicos
Automáticamente
Con el ratón
No

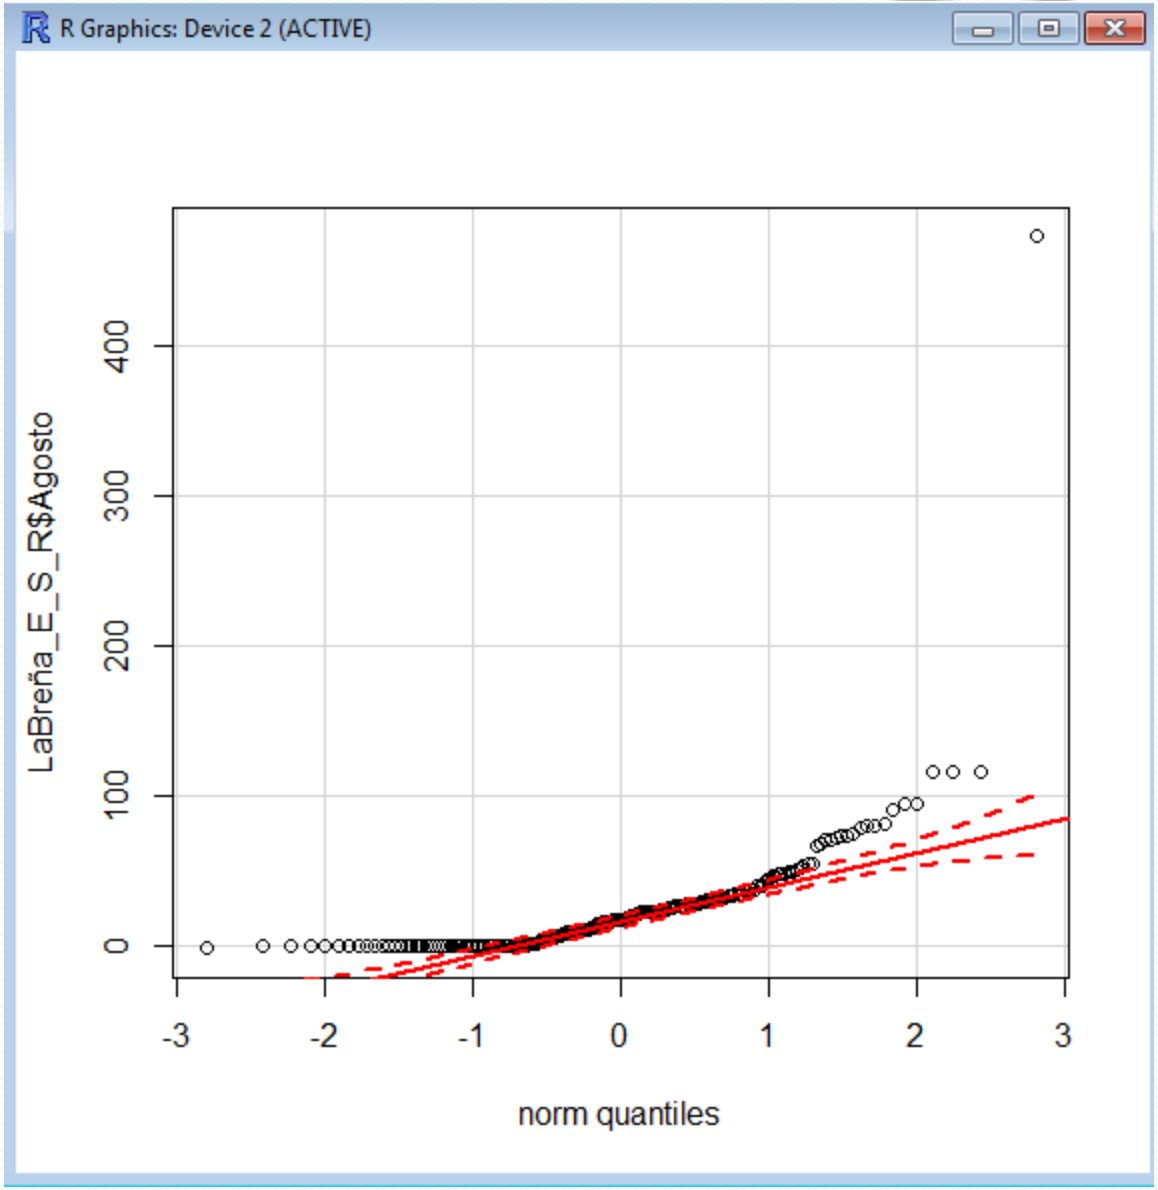

R Graphics: Device 2 (ACTIVE)
Volumen.Medio.anual
0
50
100
150
200
250
300
350

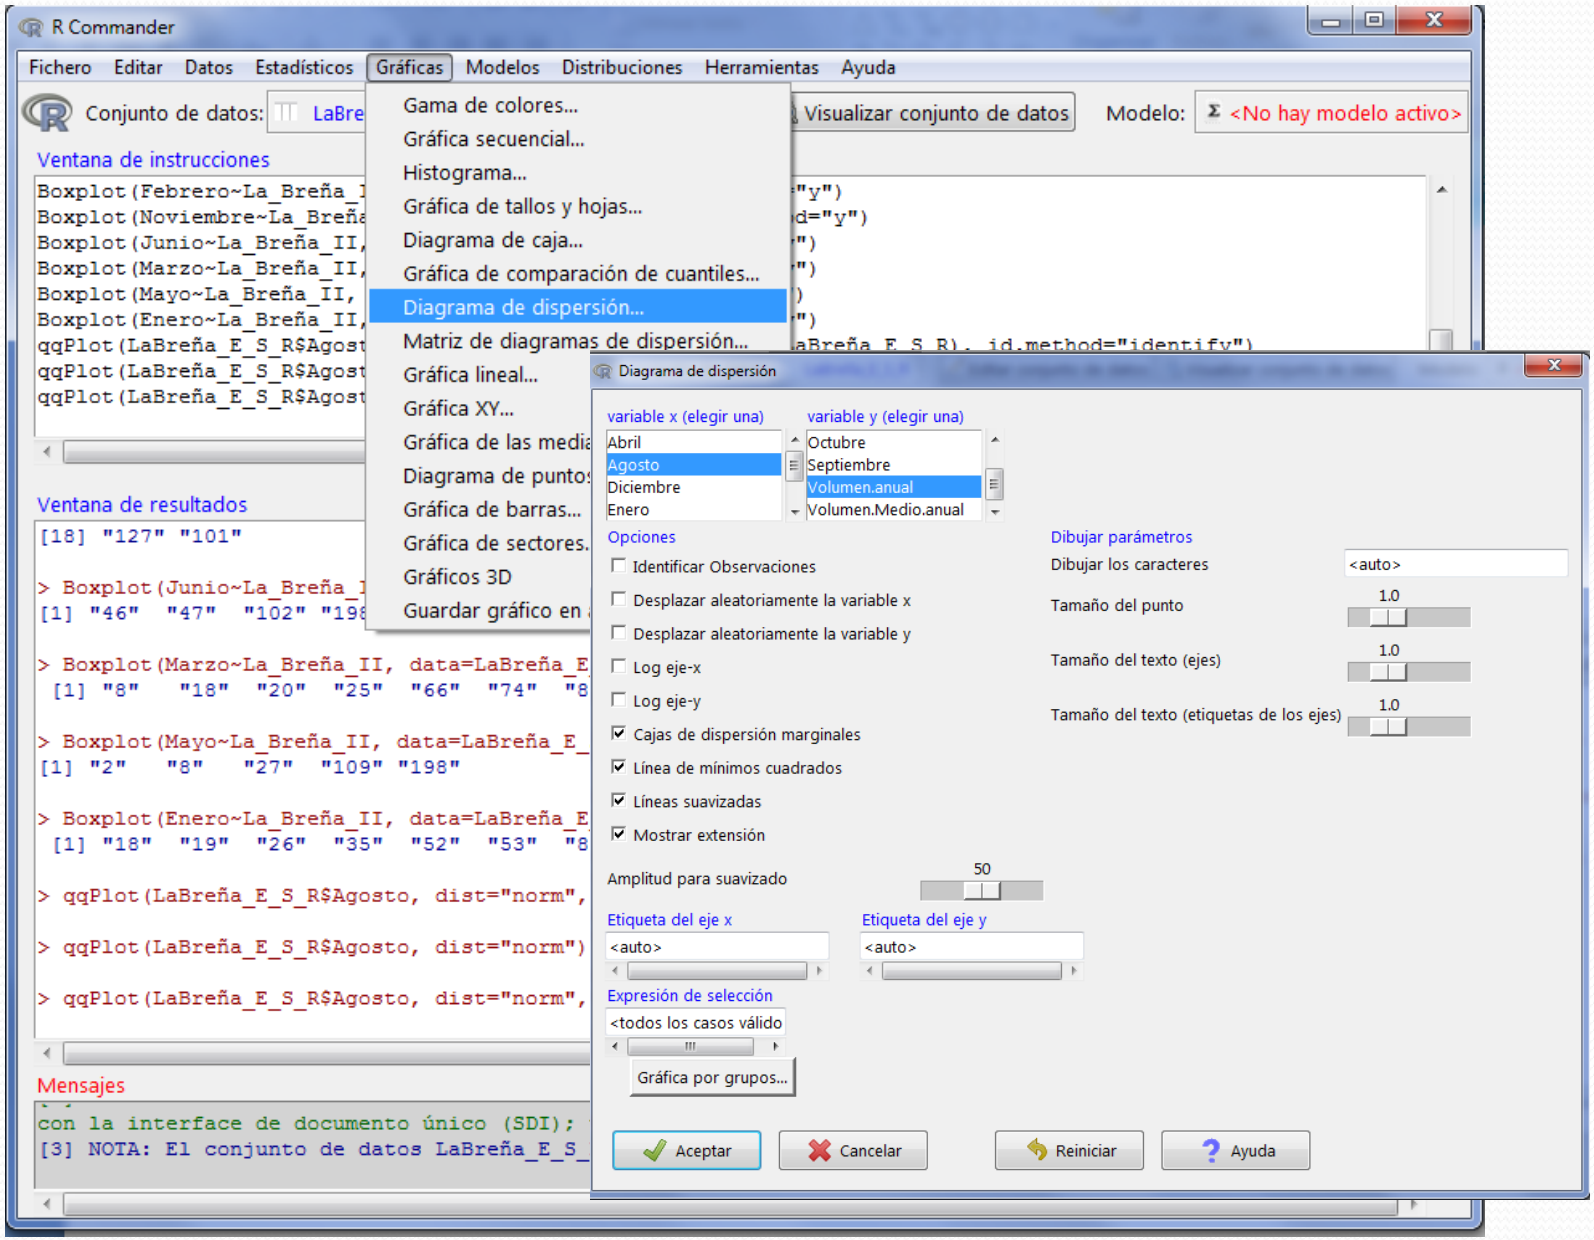

Diagrama de caja
Variable (elegir una)
Abril
Agosto
Diciembre
Enero
Identificar atípicos
Automáticamente
Con el ratón
No
Gráfica por grupos
Aceptar
Cancelar
Reiniciar
Ayuda
Grupos
Variable grupo (elegir una)
Año
La Breña II
Aceptar
Cancelar
Diagrama de caja
Variable (elegir una)
Abril
Agosto
Diciembre
Enero
Identificar atípicos
Automáticamente
Con el ratón
No
Gráfica según: La_Breña_II
Aceptar
Cancelar
Reiniciar
Ayuda

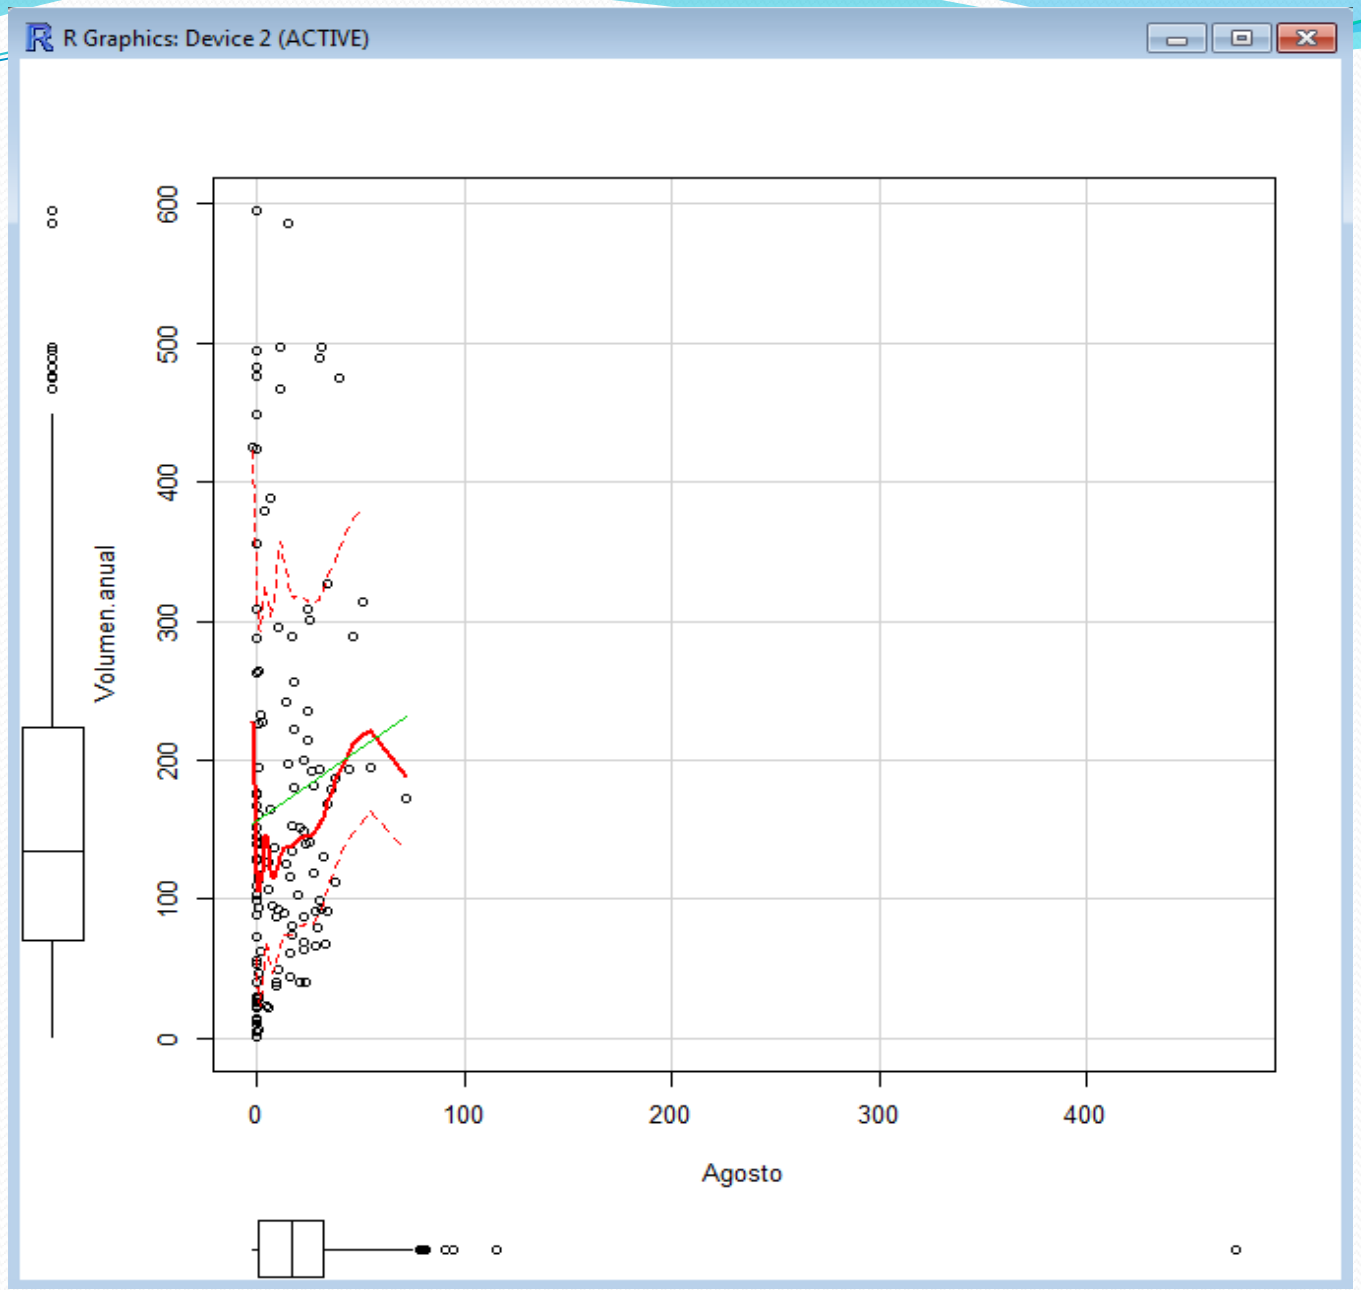

R Graphics: Device 2 (ACTIVE)
Enero
0
50
100
150
200
250
300
350
26
92
53
119
19
85
35
198
84
101
118
88
Entradas
Salidas
Reservas
La_Breña_II

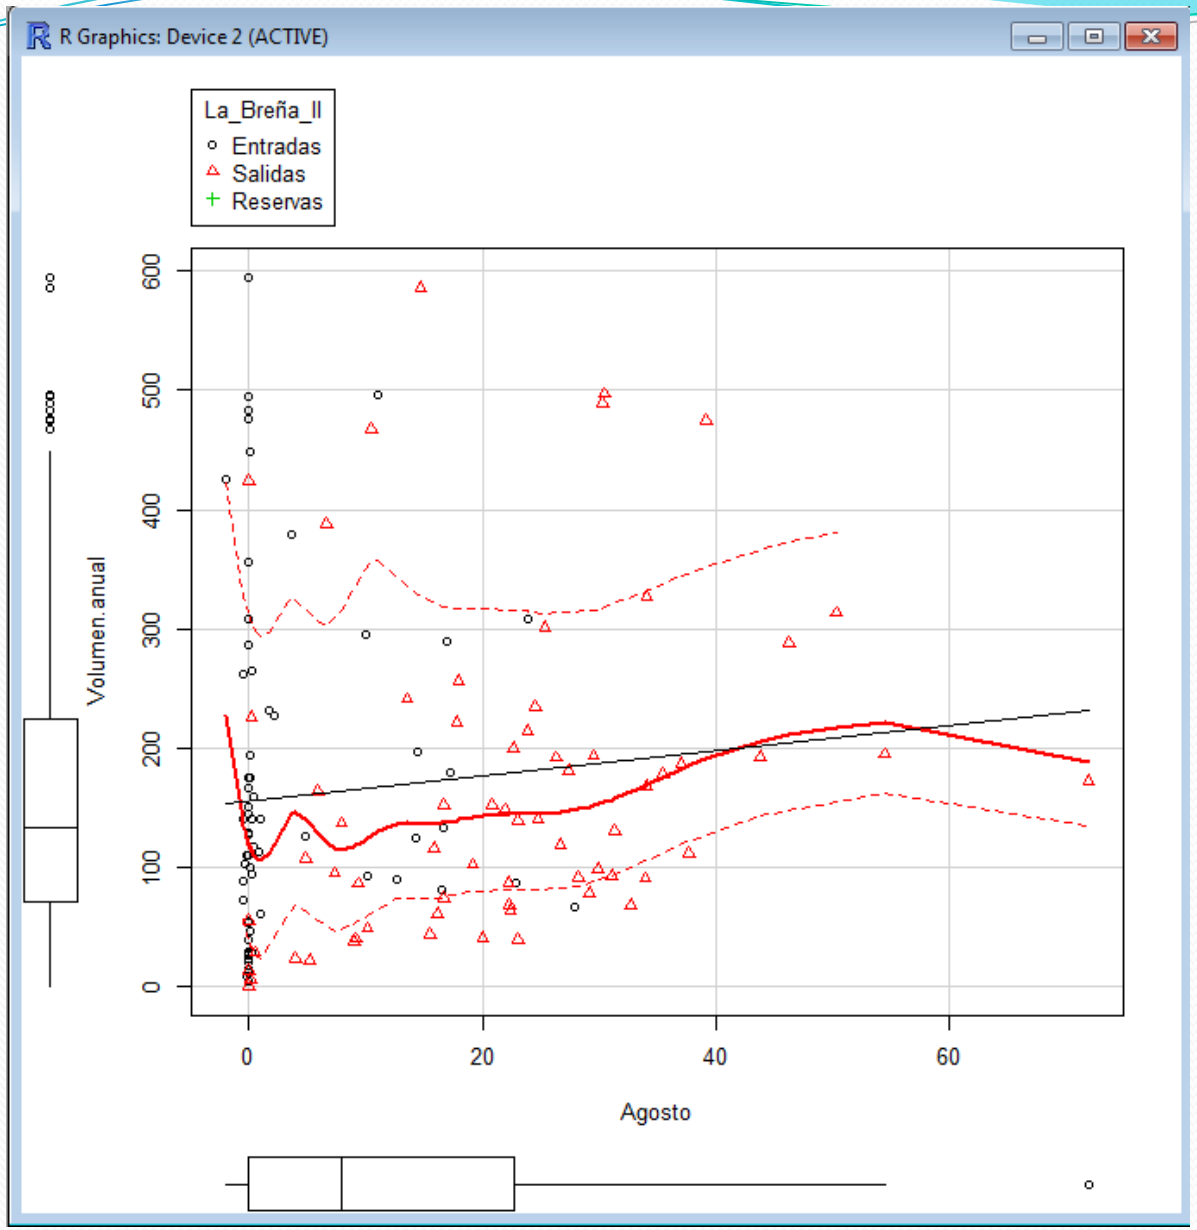


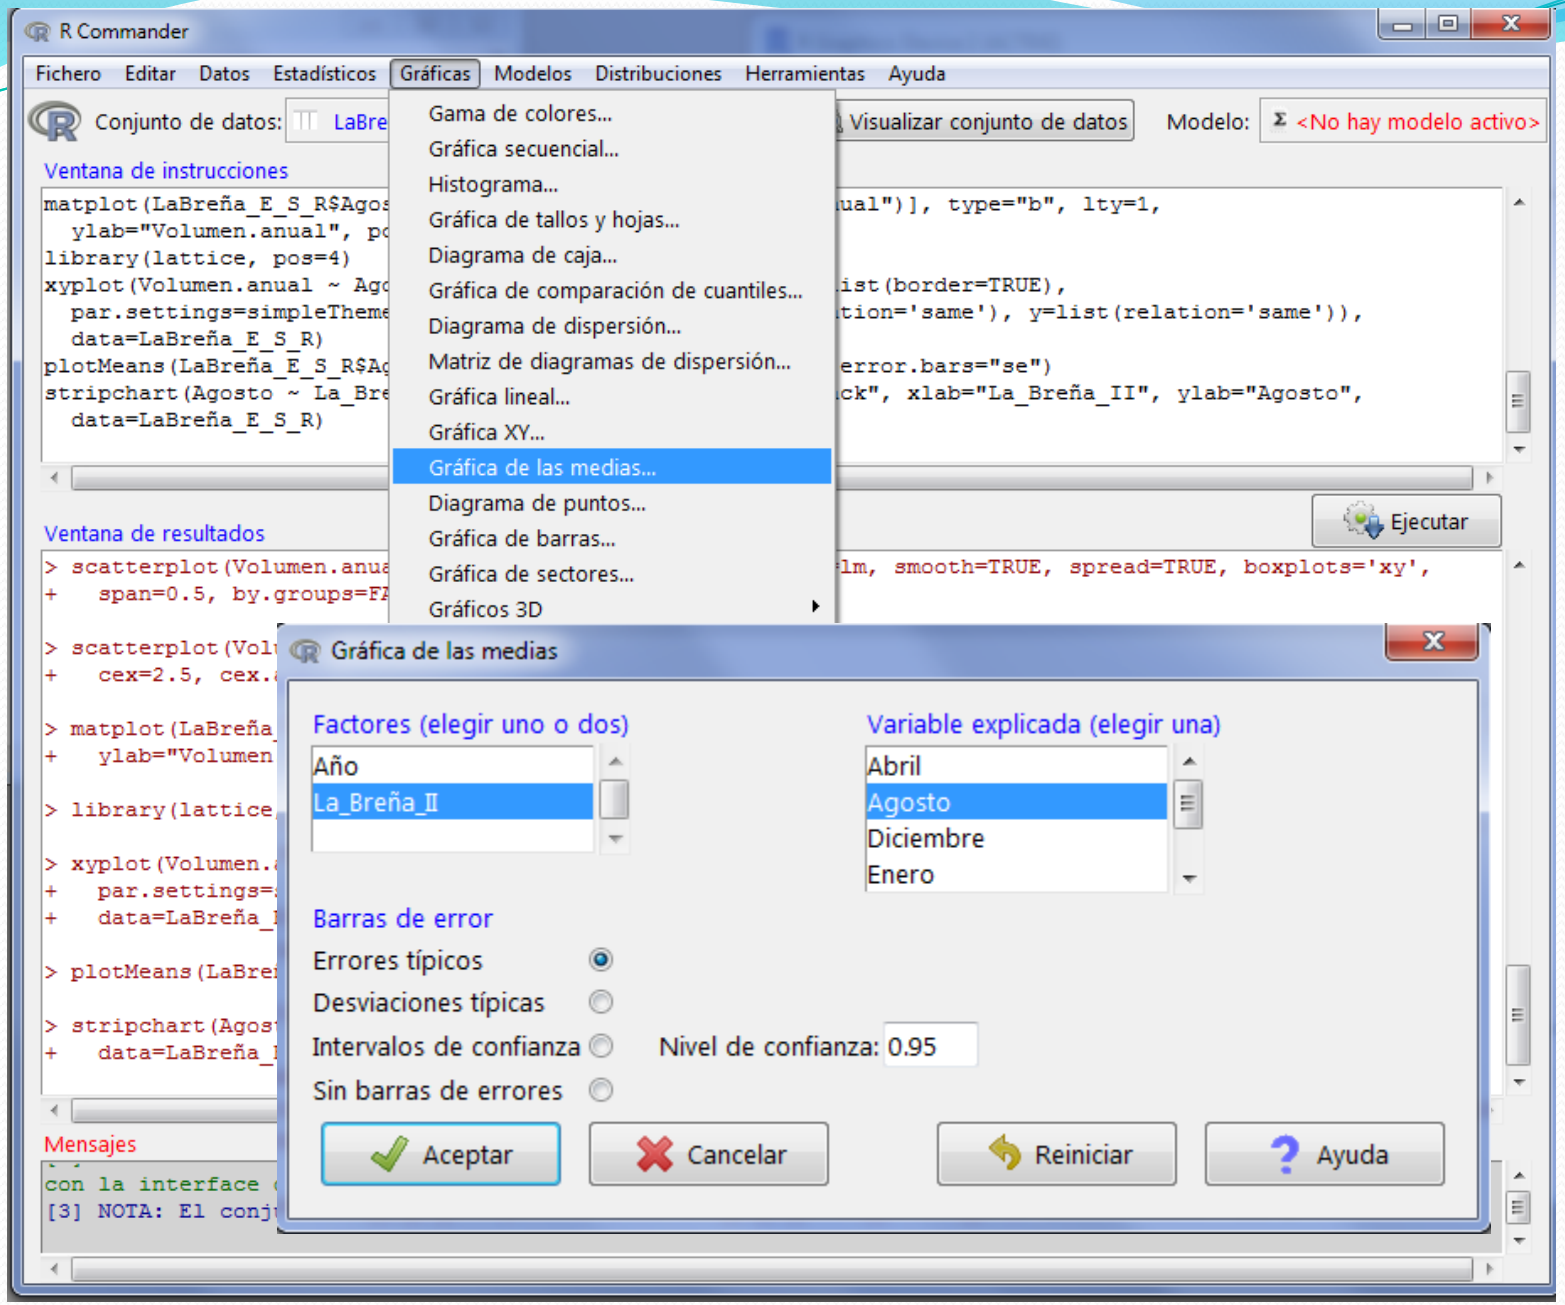
Compara los cuantiles de la distribución empírica de la variable estudiada (datos tipificados) con los teóricos según la distribución marcada, en el ejemplo la variable Agosto con la Normal correspondiente

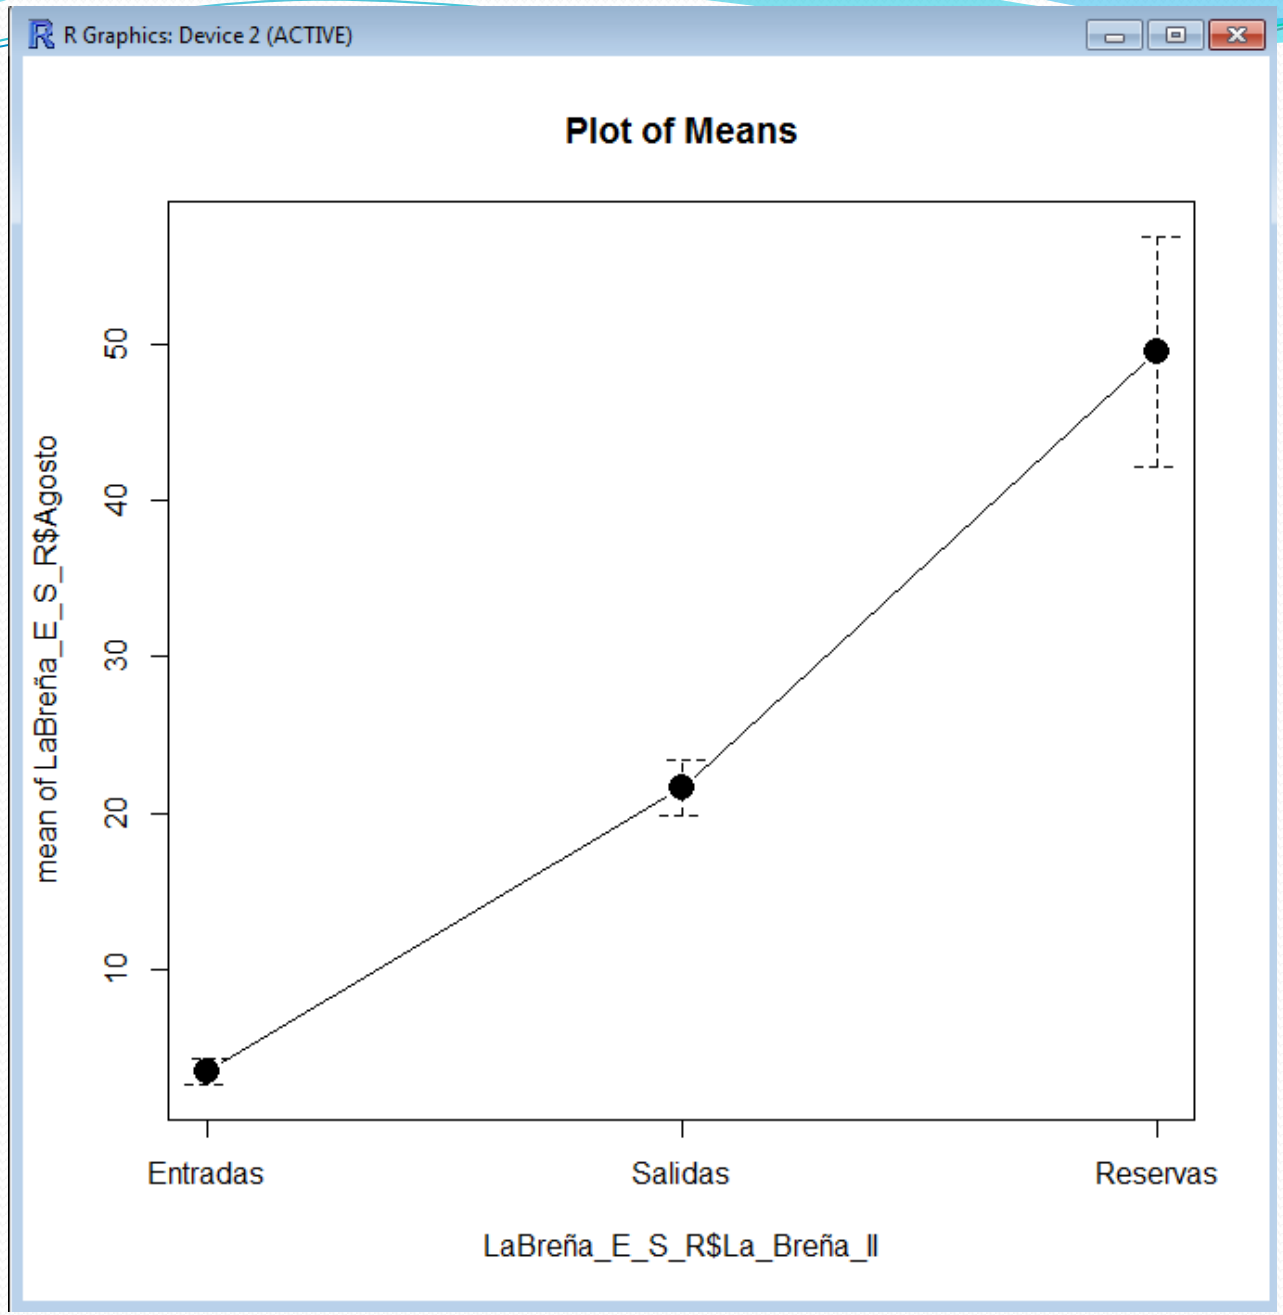

R Graphics: Device 2 (ACTIVE)
LaBreña_E_S_R$Agosto
0
100
200
300
400
-3
-2
-1
0
1
2
3
norm quantiles

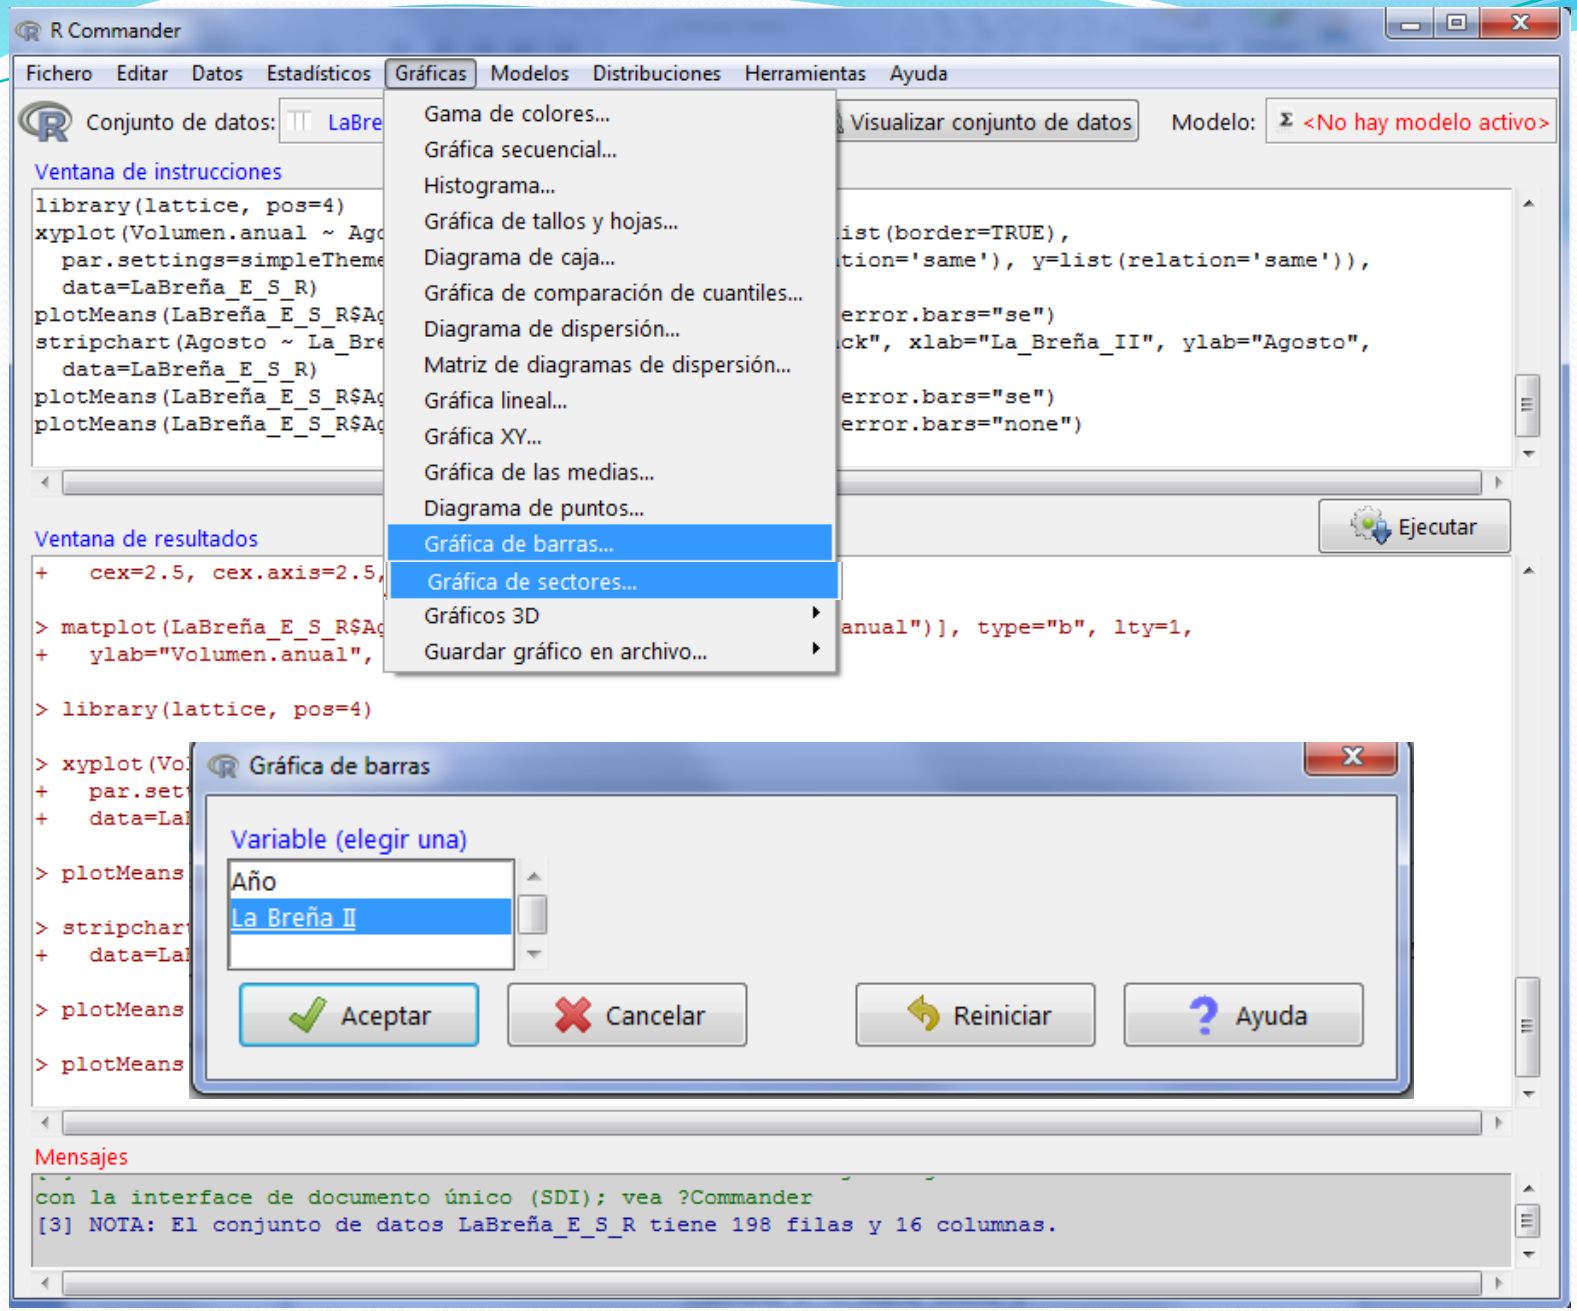

R Commander
Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda
Conjunto de datos:
Visualizar conjunto de datos
Modelo: <No hay modelo activo>
Ventana de instrucciones
Boxplot(Febrero~La_Breña_I
Boxplot(Noviembre~La_Breña
Boxplot(Junio~La_Breña_II,
Boxplot(Marzo~La_Breña_II,
Boxplot(Mayo~La_Breña_II,
Boxplot(Enero~La_Breña_II,
qqPlot(LaBreña_E_S_R$Agost
qqPlot(LaBreña_E_S_R$Agost
qqPlot(LaBreña_E_S_R$Agost
Gama de colores...
Gráfica secuencial...
Histograma...
Gráfica de tallos y hojas...
Diagrama de caja...
Gráfica de comparación de cuantiles...
Diagrama de dispersión...
Matriz de diagramas de dispersión...
Gráfica lineal...
Gráfica XY...
Gráfica de las media
Diagrama de puntos
Gráfica de barras...
Gráfica de sectores...
Gráficos 3D
Guardar gráfico en
Ventana de resultados
[18] "127" "101"
> Boxplot(Junio~La_Breña_I
[1] "46" "47" "102" "198
> Boxplot(Marzo~La_Breña_II, data=LaBreña_E
[1] "8" "18" "20" "25" "66" "74" "8
> Boxplot(Mayo~La_Breña_II, data=LaBreña_E_
[1] "2" "8" "27" "109" "198"
> Boxplot(Enero~La_Breña_II, data=LaBreña_E
[1] "18" "19" "26" "35" "52" "53" "8
> qqPlot(LaBreña_E_S_R$Agosto, dist="norm",
> qqPlot(LaBreña_E_S_R$Agosto, dist="norm")
> qqPlot(LaBreña_E_S_R$Agosto, dist="norm",
Mensajes
con la interface de documento único (SDI);
[3] NOTA: El conjunto de datos LaBreña_E_S_
Diagrama de dispersión
variable x (elegir una)
Abril
Agosto
Diciembre
Enero
variable y (elegir una)
Octubre
Septiembre
Volumen.anual
Volumen.Medio.anual
Opciones
Identificar Observaciones
Desplazar aleatoriamente la variable x
Desplazar aleatoriamente la variable y
Log eje-x
Log eje-y
Cajas de dispersión marginales
Línea de mínimos cuadrados
Líneas suavizadas
Mostrar extensión
Amplitud para suavizado
50
Etiqueta del eje x
<auto>
Etiqueta del eje y
<auto>
Expresión de selección
<todos los casos válido
Gráfica por grupos...
Dibujar parámetros
Dibujar los caracteres
<auto>
Tamaño del punto
1.0
Tamaño del texto (ejes)
1.0
Tamaño del texto (etiquetas de los ejes)
1.0
Aceptar
Cancelar
Reiniciar
Ayuda

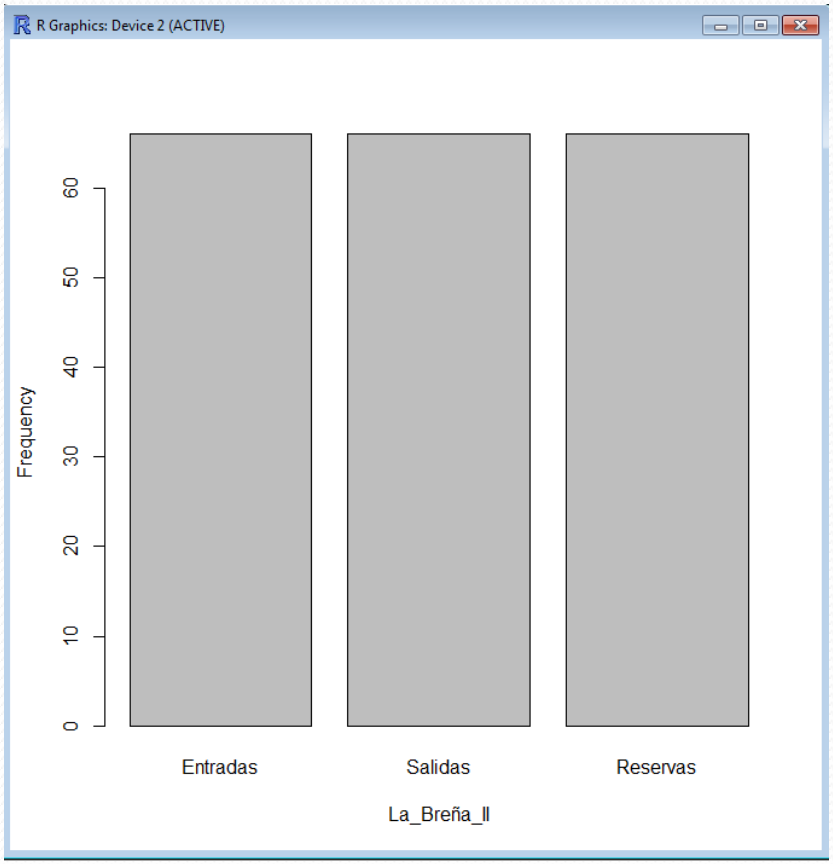

R Graphics: Device 2 (ACTIVE)
Volumen.anual
0
100
200
300
400
500
600
Agosto
0
100
200
300
400

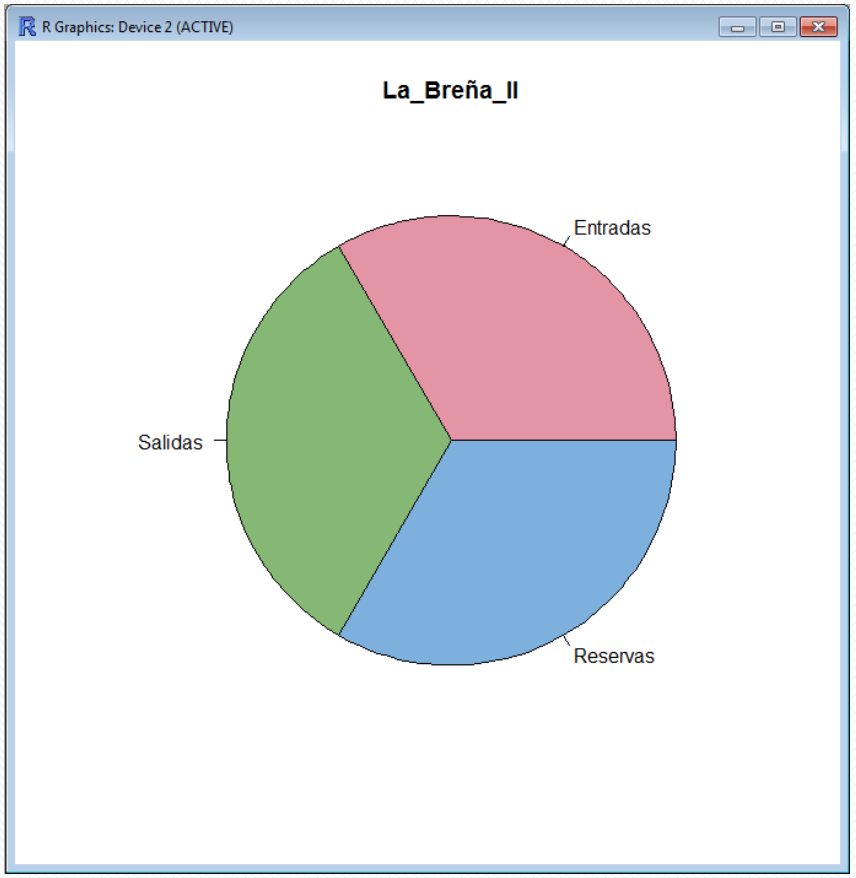

R Graphics: Device 2 (ACTIVE)
La_Breña_II
Entradas
Salidas
Reservas
Volumen.anual
0
100
200
300
400
500
600
0
20
40
60
Agosto


R Commander
Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda
Conjunto de datos:
Visualizar conjunto de datos
Modelo: <No hay modelo activo>
Ventana de instrucciones
Gama de colores...
Gráfica secuencial...
Histograma...
Gráfica de tallos y hojas...
Diagrama de caja...
Gráfica de comparación de cuantiles...
Diagrama de dispersión...
Matriz de diagramas de dispersión...
Gráfica lineal...
Gráfica XY...
Gráfica de las medias...
Diagrama de puntos...
Gráfica de barras...
Gráfica de sectores...
Gráficos 3D
Ejecutar
Ventana de resultados
Mensajes
Gráfica de las medias
Factores (elegir uno o dos)
Año
La_Breña_II
Variable explicada (elegir una)
Abril
Agosto
Diciembre
Enero
Barras de error
Errores típicos
Desviaciones típicas
Intervalos de confianza
Nivel de confianza: 0.95
Sin barras de errores
Aceptar
Cancelar
Reiniciar
Ayuda


R Graphics: Device 2 (ACTIVE)
Plot of Means
mean of LaBreña_E_S_R$Agosto
10
20
30
40
50
Entradas
Salidas
Reservas
LaBreña_E_S_R$La_Breña_II


R Commander
Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda
Conjunto de datos:
Visualizar conjunto de datos
Modelo: <No hay modelo activo>
Ventana de instrucciones
library(lattice, pos=4)
xyplot(Volumen.anual ~ Ago
par.settings=simpleTheme
data=LaBreña_E_S_R)
plotMeans(LaBreña_E_S_R$Ag
stripchart(Agosto ~ La_Bre
data=LaBreña_E_S_R)
plotMeans(LaBreña_E_S_R$Ag
plotMeans(LaBreña_E_S_R$Ag
ist(border=TRUE),
tion='same'), y=list(relation='same')),
error.bars="se")
ck", xlab="La_Breña_II", ylab="Agosto",
error.bars="se")
error.bars="none")
Gama de colores...
Gráfica secuencial...
Histograma...
Gráfica de tallos y hojas...
Diagrama de caja...
Gráfica de comparación de cuantiles...
Diagrama de dispersión...
Matriz de diagramas de dispersión...
Gráfica lineal...
Gráfica XY...
Gráfica de las medias...
Diagrama de puntos...
Gráfica de barras...
Gráfica de sectores...
Gráficos 3D
Guardar gráfico en archivo...
Ejecutar
Ventana de resultados
+ cex=2.5, cex.axis=2.5,
> matplot(LaBreña_E_S_R$Ag
anual")], type="b", lty=1,
+ ylab="Volumen.anual",
> library(lattice, pos=4)
> xyplot(Vo
+ par.set
+ data=La
> plotMeans
> stripchar
+ data=La
> plotMeans
> plotMeans
Gráfica de barras
Variable (elegir una)
Año
La Breña II
Aceptar
Cancelar
Reiniciar
Ayuda
Mensajes
con la interface de documento único (SDI); vea ?Commander
[3] NOTA: El conjunto de datos LaBreña_E_S_R tiene 198 filas y 16 columnas.


R Graphics: Device 2 (ACTIVE)
Frequency
0
10
20
30
40
50
60
Entradas
Salidas
Reservas
La_Breña_II


R Graphics: Device 2 (ACTIVE)
La_Breña_II
Entradas
Salidas
Reservas

FUNDAMENTOS Y HERRAMIENTAS PARA LA MODELIZACIÓN DE PROCESOS TÉCNICOS-CIENTÍFICOS DE INVESTIGACIÓN

Bloque III: Modelización estadística.

Gráficos con R (Rcommander)



Roberto Espejo Mohedano e-mail: ma1esmor@uco.es

FUNDAMENTOS Y HERRAMIENTAS PARA LA MODELIZACIÓN DE PROCESOS TÉCNICOS-CIENTÍFICOS DE INVESTIGACIÓN

Bloque III: Modelización estadística.

Regresión y correlación



Roberto Espejo Mohedano e-mail: ma1esmor@uco.es

Modelización.

- Necesidad del estudio simultaneo de varias variables aleatorias.
  - Analizar las posibles relaciones entre ellas. (Estudios de correlación).
  - Intentar establecer el modelo matemático que las relacione. (Estudios de regresión o ajuste).

- Interés por estimar una magnitud Y (variable dependiente) en función de una o varias $X_1, X_2, \cdots, X_k$ variables explicativas (variables independientes).
  - Imposibilidad de predicción exacta. Perturbación aleatoria ε.
  - Modelos lineales:

$$\hat{Y} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k$$

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k + \varepsilon$$

Modelos comunes

Lineales

Lineal simple: $\hat{Y} = \beta_0 + \beta_1 X$

Parabólico: $\hat{Y} = \beta_0 + \beta_2 X + \beta_1 X^2$

Cúbico: $\hat{Y} = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^3$

Polinómico: $\hat{Y} = \beta_0 + \beta_1 X + \beta_2 X^2 + \beta_3 X^2 + \cdots + \beta_h X^h$

No Lineales

Exponencial: $\hat{Y} = \beta_0 k^{\beta_1 X}$

Potencial: $\hat{Y} = \beta_0 X^{\beta_1}$

Hiperbólico: $\hat{Y} = 1 / \beta_0 + \beta_1 X$

Logístico: $\hat{Y} = 1 / e^{-\beta_0 - \beta_1 X}$

Estimación de los coeficientes: $\beta_0, \beta_1, \beta_2, \cdots, \beta_k$

Problema de inferencia:

Contrastes sobre los coeficientes y sobre el ajuste del modelo.

Correlación simple.

$$R_{xy} = \frac{S_{xy}}{S_x S_y} \in (-1;1)$$

$$R_{x_j x_i} = \frac{S_{x_j x_i}}{S_{x_j} S_{x_i}} \; \forall \; i \neq j = 1,2,\ldots$$

Matriz de Correlación: $\Gamma_{yx_1x_2\ldots} = \begin{pmatrix} 1 & R_{yx_1} & R_{yx_2} & \cdots \\ R_{yx_1} & 1 & R_{x_1x_2} & \cdots \\ R_{yx_2} & R_{x_1x_2} & 1 & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{pmatrix}$

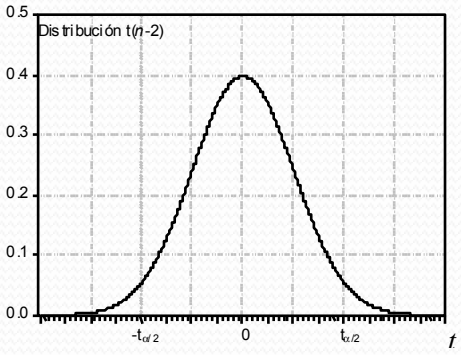
Contrastes de incorrelación

Poblaciones *X* e *Y* numéricas.

Hipótesis: $\begin{cases} H_0: X \text{ está incorrelada con } Y \\ H_1: X \text{ está correlada con } Y \end{cases} \Rightarrow \begin{cases} H_0: \rho_{xy} = 0 \\ H_1: \rho_{xy} \neq 0 \end{cases}$

Estadístico: $T = \dfrac{r\sqrt{n-2}}{\sqrt{1-r^2}} \in t_{(n-2)}$ $\quad r = r_{xy} = \dfrac{S_{xy}}{S_x S_y}$

Regla de decisión de nivel α: $C_0 = (-t_{\alpha/2}; +t_{\alpha/2})$



Decisión: A nivel α: Si $t \in C_0$ ➔ se acepta H_0

Para todo α ≤ *p* ➔ se acepta H_0

Para todo α > *p* ➔ se rechaza H_0

Probabilidad límite: $p = P(T > |t|)$

Contrastes de independencia

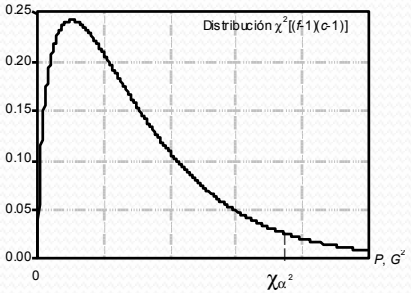
Poblaciones no numéricas. $X \in S_x = \{x_1^*, \ldots, x_f^*\}$

$Y \in S_y = \{y_1^*, \ldots, y_c^*\}$

Hipótesis: $\begin{cases} H_0 : X \text{ es independiente de } Y \\ H_1 : X \text{ esta relacionada con } Y \end{cases}$

Muestra: $(x_t, y_t) \quad t = 1, \cdots, n$ tabulada en forma de tabla de contingencia

$$\|n_{ij}\| \quad i = 1 \cdots f; j = 1 \cdots c$$



Estadísticos: $G^2 = 2\sum_{i=1}^{f}\sum_{j=1}^{c} n_{ij} \ln \frac{n_{ij}}{E_{ij}}$

$$P = \sum_{i=1}^{f}\sum_{j=1}^{c} \frac{(n_{ij} - E_{ij})^2}{E_{ij}} \qquad P_c = \sum_{i=1}^{2}\sum_{j=1}^{2} \frac{\left(|n_{ij} - E_{ij}| - 0.5\right)^2}{E_{ij}}$$

Regla de decisión de nivel α:

$$C_0 = \left(0, \chi_\alpha^2\right)$$

Decisión: A nivel α: Si $P, P_c, G^2 \in C_0$ ➔ se acepta H_0

Para todo α ≤ *p* ➔ se acepta H_0

Para todo α > *p* ➔ se rechaza H_0

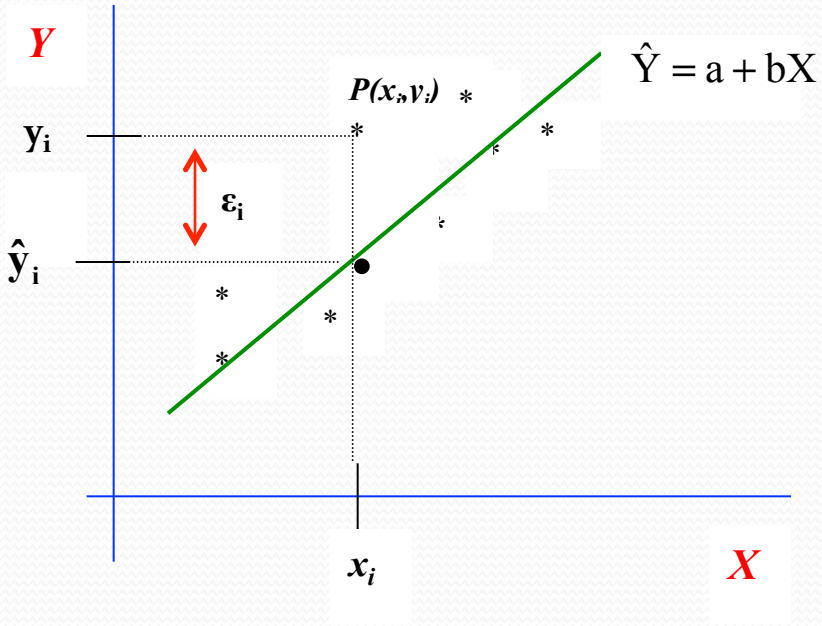
Distribución muestral (asintótica):

$$G^2 / H_0, P / H_0, P_C / H_0 \in \chi^2\left((f-1),(c-1)\right)$$

Condiciones asintóticas: $E_{ij} = \frac{n_{i.}\, n_{.j}}{n} \geq 1 \qquad \forall i, j$

Regresión Simple: Línea de Regresión

Recta de regresión de Y sobre X



$\hat{y}_i$ valor estimado de *Y* para $X=x_i$

ε_i residuos: $\varepsilon_i = y_i - \hat{y}_i$

Mínimos cuadrados $H = \sum_{i=1}^{n} \varepsilon_i^2 = \sum_{i=1}^{n} \left(y_i - \hat{y}_i\right)^2 = \sum_{i=1}^{n} \left(y_i - a - bx_i\right)^2$

$$b = \frac{S_{XY}}{S_X^2} \qquad a = \overline{Y} - b\overline{X}$$

Los modelos de Regresión requieren Normalidad en la variable Dependiente

Regresión Múltiple: $\hat{Y} = a + b_1 X_1 + b_2 X_2 + \ldots + b_n X_n$

Matriz de Covarianzas

$$\sum_{yx_1x_2\ldots} = \begin{pmatrix} S_y^2 & S_{yx_1} & S_{yx_2} & \ldots \\ S_{x_1y} & S_{x_1}^2 & S_{x_1x_2} & \ldots \\ S_{x_2y} & S_{x_1x_2} & S_{x_2}^2 & \ldots \\ \ldots & \ldots & \ldots & \ldots \end{pmatrix}$$

Vector de Medias

$$\vec{\mu}_{yx_1x_2\ldots} = \begin{pmatrix} \overline{Y} \\ \overline{X}_1 \\ \overline{X}_2 \\ \ldots \end{pmatrix}$$

$$b_i = -\frac{A_{1,i+1}}{A_{1,1}} \quad \forall \quad i = 1,2,\ldots$$

$$a = \overline{Y} - b_1\overline{X}_1 - b_2\overline{X}_2 - \ldots \qquad \left(\overline{Y} = a + b_1\overline{X}_1 + b_2\overline{X}_2 + \ldots\right)$$

Correlación múltiple: $$R_{yx_1x_2\ldots} = R_y = \frac{S_{y\hat{y}}}{S_y S_{\hat{y}}} \in \left[-1,1\right]$$

Se verifica que: $$R_y^2 \geq R_{yx_i}^2 \;\forall\, i = 1,2,\ldots$$

Coeficiente de determinación: $$R^2 = R_{xy}^2 = \left(\frac{S_{xy}}{S_x S_y}\right)^2 = 1 - \frac{S_\varepsilon^2}{S_y^2} \in \left[\,0\,;1\,\right]$$

"Tanto por 1 (ó %) de la varianza de *Y* explicada por el modelo."

Nos informa de hasta que punto el modelo se ajusta a los datos.

Test de hipótesis sobre el modelo de regresión: Test F

Se basa en el **Teorema de descomposición de la varianza** $S_y^2 = S_{\hat{y}}^2 + S_e^2$

o multiplicando por el número de datos (n), la suma de cuadrados totales se descompone en: $S_y = S_{\hat{y}} + S_e$

Siendo: $S_y = \sum_{i=1}^{n} \left(y_i - \bar{y}\right)^2$ La Suma de cuadrados total

$S_{\hat{y}} = \sum_{i=1}^{n} \left(\hat{y}_i - \bar{y}\right)^2$ La Suma de cuadrados asociada a las variables explicativas (la regresión)

$S_e = \sum_{i=1}^{n} e_i^2$ La Suma de cuadrados residual, la no explicada por la regresión

Hipótesis a contrastar: $\begin{cases} H_0 : \beta_1 = \beta_2 = \ldots = \beta_k = 0 \\ H_1 : \text{algún o algunos } \beta_i \neq 0 \end{cases} \Rightarrow \begin{cases} H_0 : \text{Rechazo Gobalmente el modelo} \\ H_1 : \text{Acepto Gobalmente el modelo} \end{cases}$

Estadístico del contraste: $F = \dfrac{S_{\hat{y}} / (k-1)}{S_e / (n-k-1)}$ Siendo su distribución muestral es: $F / H_0 \in F(k-1; n-k-1)$

Siendo k el número de variables explicativas (independientes) del modelo

Regla de decisión de nivel *α*: $C_0 = (0 ; F_\alpha)$

Para todo $\alpha \leq p$ ➔ se acepta H_0

Para todo $\alpha > p$ ➔ se rechaza H_0

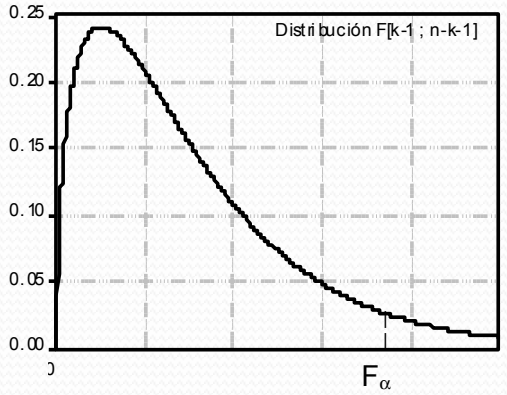
Test de hipótesis sobre el modelo de regresión: Test F

Los cálculos anteriores se resumen en la siguiente tabla de análisis de la Varianza

Fuente de Variación	Grados de Libertad	Sumas de Cuadrados	Medias de Cuadrados	Estadístico F
Regresión	k-1	$S_{\hat{y}} = \sum_{i=1}^{n} \left(\hat{y}_i - \bar{y}\right)^2$	$M_{\hat{y}} = \frac{S_{\hat{y}}}{k-1}$	$F = \frac{M_{\hat{y}}}{M_e}$
Residuo	n-k-1	$S_e = \sum_{i=1}^{n} e_i^2$	$M_e = \frac{S_e}{n-k-1}$	
Variación Total	n-1	$S_y = \sum_{i=1}^{n} \left(y_i - \bar{y}\right)^2 = S_{\hat{y}} + S_e$		

Decisión: A nivel α: Si $F \in C_0$ ➔ se acepta H_0

Para todo α ≤ *p* ➔ se acepta H_0
Para todo α > *p* ➔ se rechaza H_0



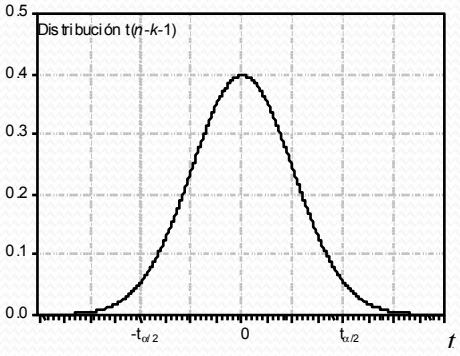
Contrastes sobre los Coeficientes de Regresión

Tests T

Hipótesis: $\begin{cases} H_0 : \beta_j = 0 \\ H_1 : \beta_j \neq 0 \end{cases}$

Estadístico: $T = \dfrac{b_j}{\overline{s}_{b_j}} \qquad \overline{s}_{b_j}^2 = \overline{s}_e^2 a_{jj} \qquad \overline{s}_e^2 = \dfrac{1}{n-k-1}\sum e_i^2 \qquad A = \left\| a_{ij} \right\| = (X'X)^{-1}$

Distribución muestral: Si $e_i \in N\left(0_n, \sigma_\varepsilon^2 I_n\right) \rightarrow T \in t(n-k-1)$



Regla de decisión de nivel *α*: $C_0 = (-t_{\alpha/2}; t_{\alpha/2})$

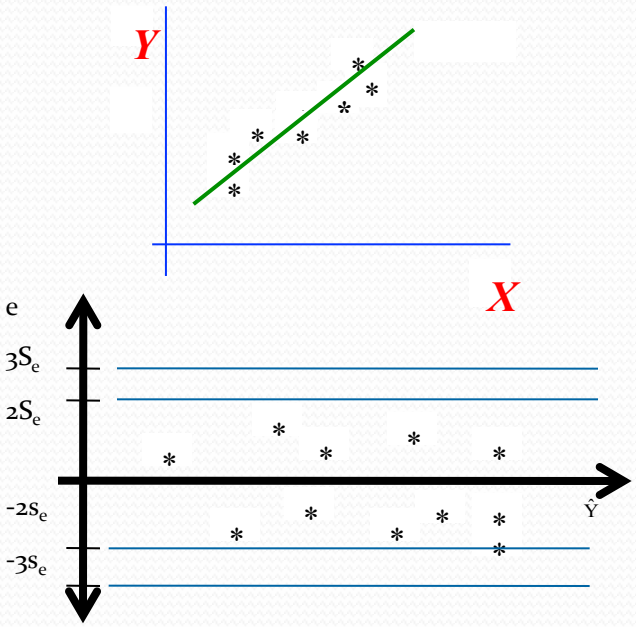
Decisión: A nivel α: Si $t \in C_0$ ➔ se acepta H_0

Para todo α ≤ *p* ➔ se acepta H_0
Para todo α > *p* ➔ se rechaza H_0

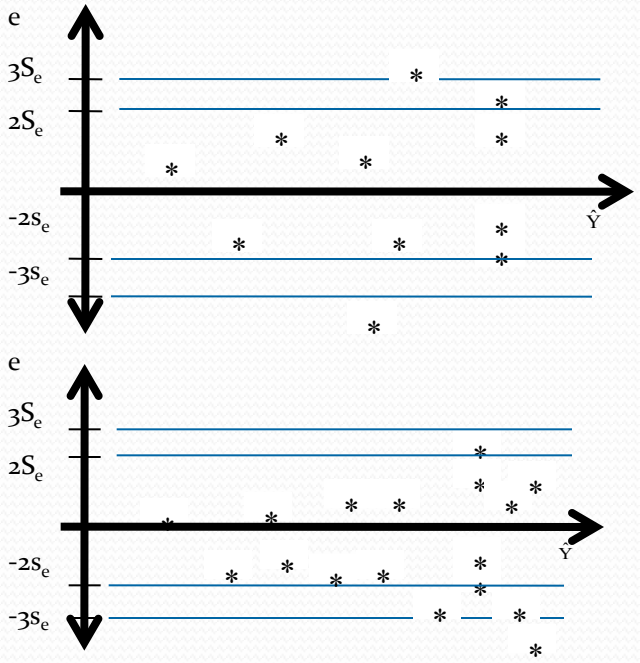
Propiedades de los Residuos

1ª.- $\bar{e} = 0$

2ª.- Var(ε_i) = cte Varianza constante. (homocedásticos)



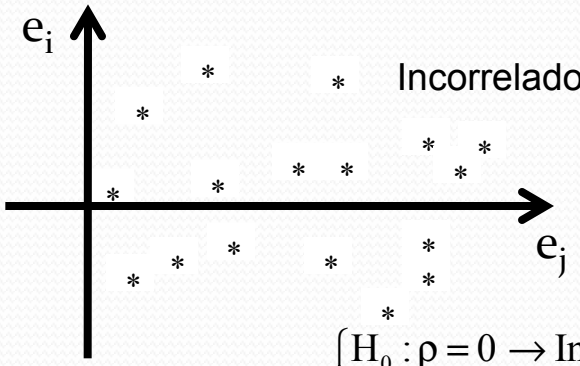
Homocedasticidad



Heterocedasticidad

Propiedades de los Residuos

3ª.- Los residuos han de estar incorrelados entre si.



Incorrelados

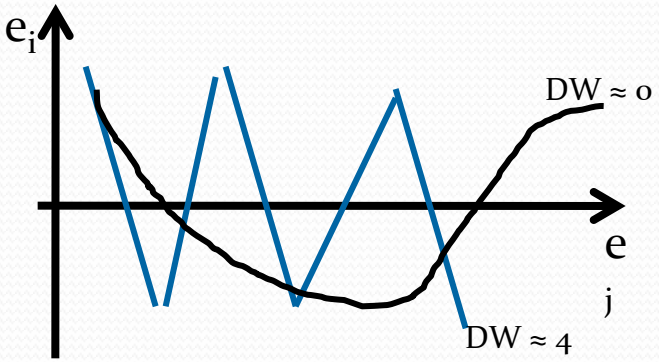
Estadístico de Durbin-Watson

$$DW = \frac{\sum_{i=2}^{n}\left(e_i - e_{i-1}\right)^2}{\sum_{i=1}^{n} e_i^2} \in \left[0\,;\,4\right]$$

DW ≈ 2, Incorrelados
DW ≈ 4 Autocorrelación negativa
DW ≈ 0 Autocorrelación positiva

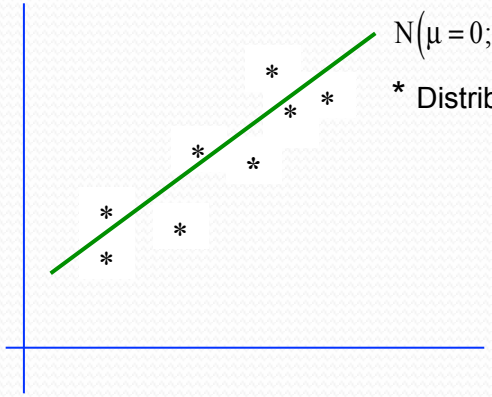
Test de Hipótesis:

$$\begin{cases} H_0 : \rho = 0 \rightarrow \text{Incorrelados} \\ H_1 : \rho \begin{cases} > 0 \rightarrow \text{Autocorrelacion Positiva} \\ \neq 0 \rightarrow \text{Autocorrelados} \\ < 0 \rightarrow \text{Autocorrelacion Negativa} \end{cases} \end{cases}$$



4ª.- Normales

$$e \in N\left(\mu = 0; \sigma^2 = S_e^2\right)$$



$$N\left(\mu = 0; \sigma^2 = S_e^2\right)$$

* Distribución Residual

Transformaciones no lineales.

Tratan de corregir la falta de simetría de algunas distribuciones de datos. En ocasiones, estas transformaciones corrigen las desviaciones de normalidad.

La transformación mas utilizada es el logaritmo aunque existen otras mas simples como la raíz cuadrada o la inversa.

La transformación de Box-Cox (perteneciente a las transformaciones logarítmicas) también es muy usada y suele corregir las desviaciones de los supuestos necesarios para los modelos de regresión.

Dada una variable *X*, su transformada de Box-Cox se define como:

$$X^* = \left\{ \begin{array}{lll} \dfrac{(X+m)^{\lambda}-1}{\lambda} & si & \lambda \neq 0 \\ \ln(X+m) & si & \lambda = 0 \end{array} \right\}$$

m se escoge de tal forma que (*X* + *m*) sea positivo.

Si λ > 1 se corrige la asimetría a la izquierda y si λ < 1 la asimetría a la derecha.

FUNDAMENTOS Y HERRAMIENTAS PARA LA MODELIZACIÓN DE PROCESOS TÉCNICOS-CIENTÍFICOS DE INVESTIGACIÓN

Bloque III: Modelización estadística.

Regresión y correlación con R (Rcommander)



Roberto Espejo Mohedano e-mail: ma1esmor@uco.es

FUNDAMENTOS Y HERRAMIENTAS PARA LA MODELIZACIÓN DE PROCESOS TÉCNICOS-CIENTÍFICOS DE INVESTIGACIÓN

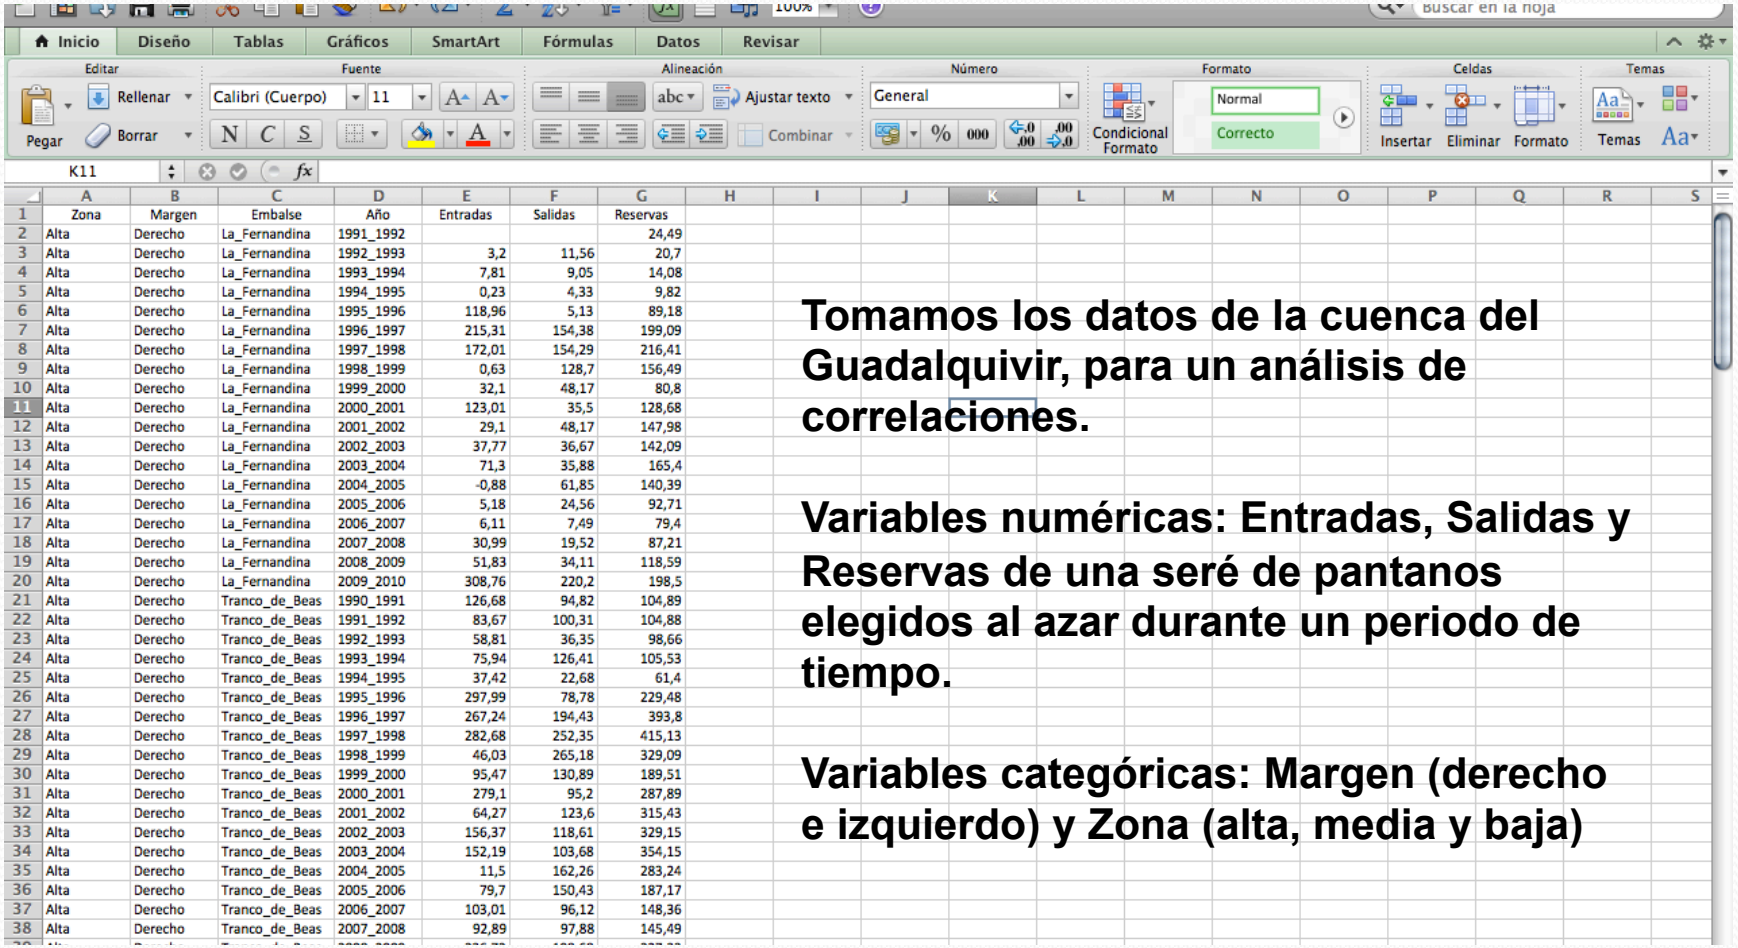
Bloque III: Modelización estadística.

Regresión y correlación con R (Rcommander)



Roberto Espejo Mohedano e-mail: ma1esmor@uco.es

Correlación



	A	B	C	D	E	F	G
1	Zona	Margen	Embalse	Año	Entradas	Salidas	Reservas
2	Alta	Derecho	La_Fernandina	1991_1992			24,49
3	Alta	Derecho	La_Fernandina	1992_1993	3,2	11,56	20,7
4	Alta	Derecho	La_Fernandina	1993_1994	7,81	9,05	14,08
5	Alta	Derecho	La_Fernandina	1994_1995	0,23	4,33	9,82
6	Alta	Derecho	La_Fernandina	1995_1996	118,96	5,13	89,18
7	Alta	Derecho	La_Fernandina	1996_1997	215,31	154,38	199,09
8	Alta	Derecho	La_Fernandina	1997_1998	172,01	154,29	216,41
9	Alta	Derecho	La_Fernandina	1998_1999	0,63	128,7	156,49
10	Alta	Derecho	La_Fernandina	1999_2000	32,1	48,17	80,8
11	Alta	Derecho	La_Fernandina	2000_2001	123,01	35,5	128,68
12	Alta	Derecho	La_Fernandina	2001_2002	29,1	48,17	147,98
13	Alta	Derecho	La_Fernandina	2002_2003	37,77	36,67	142,09
14	Alta	Derecho	La_Fernandina	2003_2004	71,3	35,88	165,4
15	Alta	Derecho	La_Fernandina	2004_2005	-0,88	61,85	140,39
16	Alta	Derecho	La_Fernandina	2005_2006	5,18	24,56	92,71
17	Alta	Derecho	La_Fernandina	2006_2007	6,11	7,49	79,4
18	Alta	Derecho	La_Fernandina	2007_2008	30,99	19,52	87,21
19	Alta	Derecho	La_Fernandina	2008_2009	51,83	34,11	118,59
20	Alta	Derecho	La_Fernandina	2009_2010	308,76	220,2	198,5
21	Alta	Derecho	Tranco_de_Beas	1990_1991	126,68	94,82	104,89
22	Alta	Derecho	Tranco_de_Beas	1991_1992	83,67	100,31	104,88
23	Alta	Derecho	Tranco_de_Beas	1992_1993	58,81	36,35	98,66
24	Alta	Derecho	Tranco_de_Beas	1993_1994	75,94	126,41	105,53
25	Alta	Derecho	Tranco_de_Beas	1994_1995	37,42	22,68	61,4
26	Alta	Derecho	Tranco_de_Beas	1995_1996	297,99	78,78	229,48
27	Alta	Derecho	Tranco_de_Beas	1996_1997	267,24	194,43	393,8
28	Alta	Derecho	Tranco_de_Beas	1997_1998	282,68	252,35	415,13
29	Alta	Derecho	Tranco_de_Beas	1998_1999	46,03	265,18	329,09
30	Alta	Derecho	Tranco_de_Beas	1999_2000	95,47	130,89	189,51
31	Alta	Derecho	Tranco_de_Beas	2000_2001	279,1	95,2	287,89
32	Alta	Derecho	Tranco_de_Beas	2001_2002	64,27	123,6	315,43
33	Alta	Derecho	Tranco_de_Beas	2002_2003	156,37	118,61	329,15
34	Alta	Derecho	Tranco_de_Beas	2003_2004	152,19	103,68	354,15
35	Alta	Derecho	Tranco_de_Beas	2004_2005	11,5	162,26	283,24
36	Alta	Derecho	Tranco_de_Beas	2005_2006	79,7	150,43	187,17
37	Alta	Derecho	Tranco_de_Beas	2006_2007	103,01	96,12	148,36
38	Alta	Derecho	Tranco_de_Beas	2007_2008	92,89	97,88	145,49

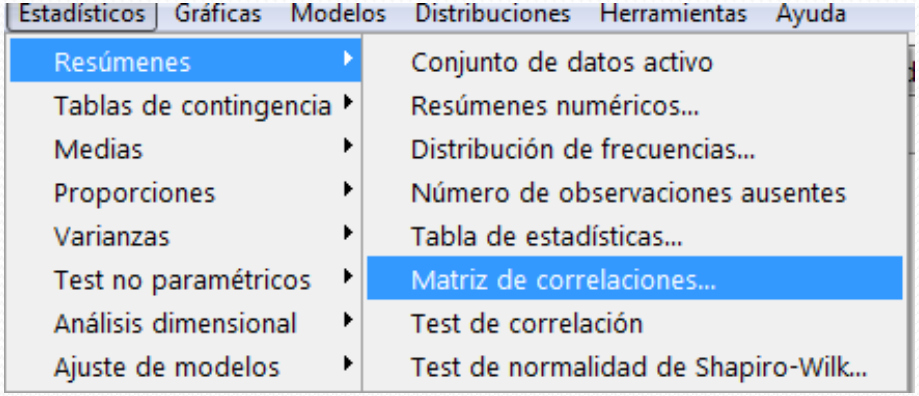
Tomamos los datos de la cuenca del Guadalquivir, para un análisis de correlaciones.

Variables numéricas: Entradas, Salidas y Reservas de una seré de pantanos elegidos al azar durante un periodo de tiempo.

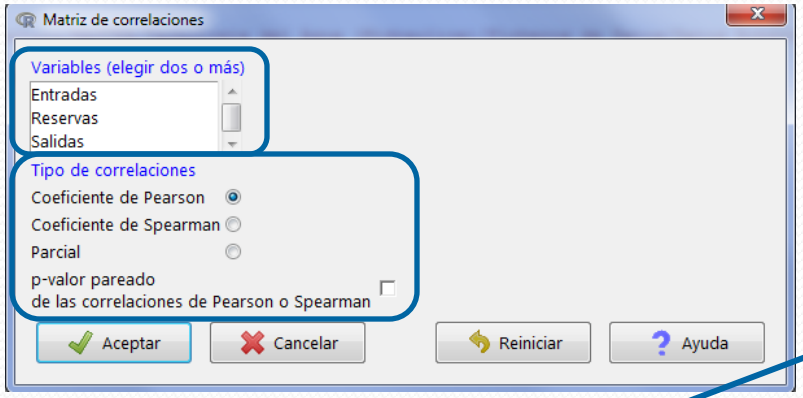
Variables categóricas: Margen (derecho e izquierdo) y Zona (alta, media y baja)


CONFEDERACIÓN HIDROGRÁFICA DEL GUADALQUIVIR
PLANO GENERAL
AÑO : 2009-2010
N
Zona Media
Zona Alta
Zona Baja
Margen Derecho
Margen Izquierdo
GUADIANA
MONTORO III
EL YEGUAS
MARMOLEJO
JÁNDULA
ENCINAREJO
LA FRESNEDA (AZUD)
LA FRESNEDA
RUMBLAR
VÍBORAS
QUIEBRAJANO
LA FERNANDINA
DAÑADOR
GUADALMENA
SAN RAFAEL DE NAVALLANA
GUADALMELLATO
GUADANUÑO-CERRO MURIANO
PUENTE NUEVO
LA BRENA II
SIERRA BOYERA
BEMBÉZAR
HORNACHUELOS
RETORTILLO
RETORTILLO (DERIVACIÓN)
EL PINTADO
LOS MELONARES
CANTILLANA
HUESNA
JOSE TORÁN
MARTÍN GONZALO
ARENOSO
EL CARPIO
VILLAFRANCA
VADOMOJÓN
GUADALÉN
GIRIBAILE
TRANCO DE BEAS
ACUASCEBAS
SAN CLEMENTE
EL PORTILLO
LA BOLERA
DOÑA ALDONZA
NEGRATÍN
FRANCISCO ABELLÁN-PEÑÓN DE LOS GITANOS
PEDRO MARÍN
QUENTAR
CANALES
CUBILLAS
COLOMERA
LOS BERMEJALES
MALPASILLO-JAUJA
IZNÁJAR
CORDOBILLA
PUEBLA DE CAZALLA
TORRE DEL ÁGUILA
ALCALÁ DEL RÍO
AGRIO
EL GERGAL
LA MINILLA
ZUFRE
ARACENA
CALA
CÓRDOBA
JAÉN
SEVILLA
GRANADA

Coeficientes de Correlación Simples



$$R_{xy} = \frac{S_{xy}}{S_x S_y} \in (-1;1)$$



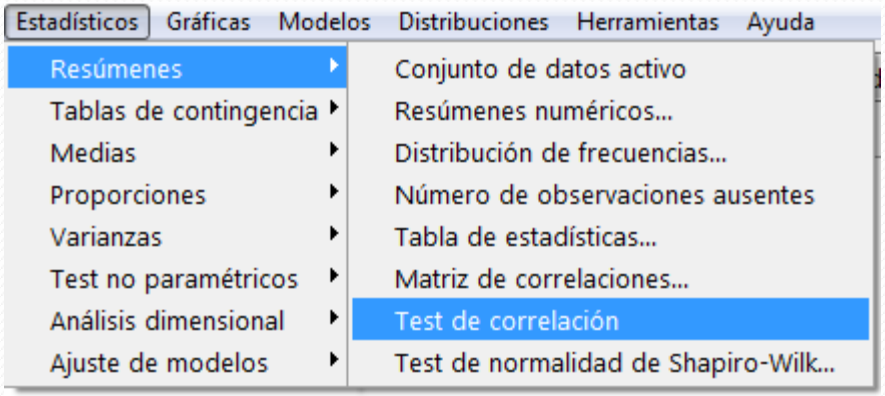
$$\Gamma_{yx_1x_2\ldots} = \begin{pmatrix} 1 & R_{yx_1} & R_{yx_2} & \cdots \\ R_{yx_1} & 1 & R_{x_1x_2} & \cdots \\ R_{yx_2} & R_{x_1x_2} & 1 & \cdots \\ \vdots & \vdots & \vdots & \ddots \end{pmatrix}$$

$$R_{ER} = 0.4170537$$
$$R_{ES} = 0.9116159$$
$$R_{SR} = 0.3835474$$

```
> cor(Datos[,c("Entradas","Reservas","Salidas")], use="complete.obs")
           Entradas  Reservas   Salidas
Entradas  1.0000000 0.4170537 0.9116159
Reservas  0.4170537 1.0000000 0.3835474
Salidas   0.9116159 0.3835474 1.0000000
```

¿Son significativos estos Coeficientes?

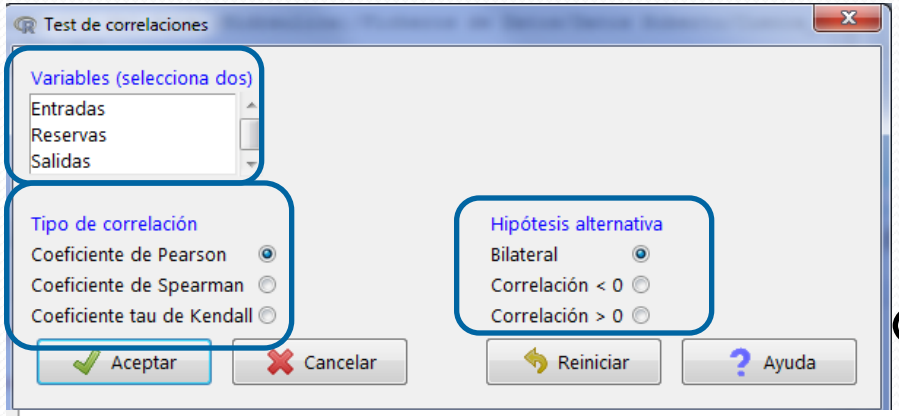
Test T sobre los Coeficientes de Correlación Simples




```
        Pearson's product-moment correlation

data:  Datos$Entradas and Datos$Reservas
t = 7.4415, df = 263, p-value = 1.417e-12
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.3122469 0.5118306
sample estimates:
      cor
0.4170537
```

Rechazamos H_o en ambos casos




```
        Pearson's product-moment correlation

data:  Datos$Reservas and Datos$Salidas
t = 6.7352, df = 263, p-value = 1.026e-10
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.2757951 0.4817796
sample estimates:
      cor
0.3835474
```

$$\begin{cases} H_0: X \text{ está incorrelada con Y} \\ H_1: X \text{ está correlada con Y} \end{cases} \Rightarrow \begin{cases} H_0: \rho_{xy} = 0 \\ H_1: \rho_{xy} \neq 0 \end{cases}$$

```
> cor.test(Datos$Entradas, Datos$Salidas, alternative="two.sided", method="pearson")

        Pearson's product-moment correlation

data:  Datos$Entradas and Datos$Salidas
t = 35.9669, df = 263, p-value < 2.2e-16
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.8887445 0.9299599
sample estimates:
      cor
0.9116159
```

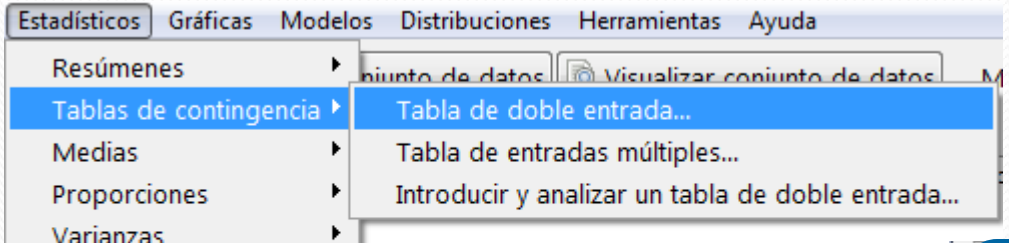
Decisión: Para todo $\alpha \leq p$ ➔ se acepta H_o
Para todo $\alpha > p$ ➔ se rechaza H_o

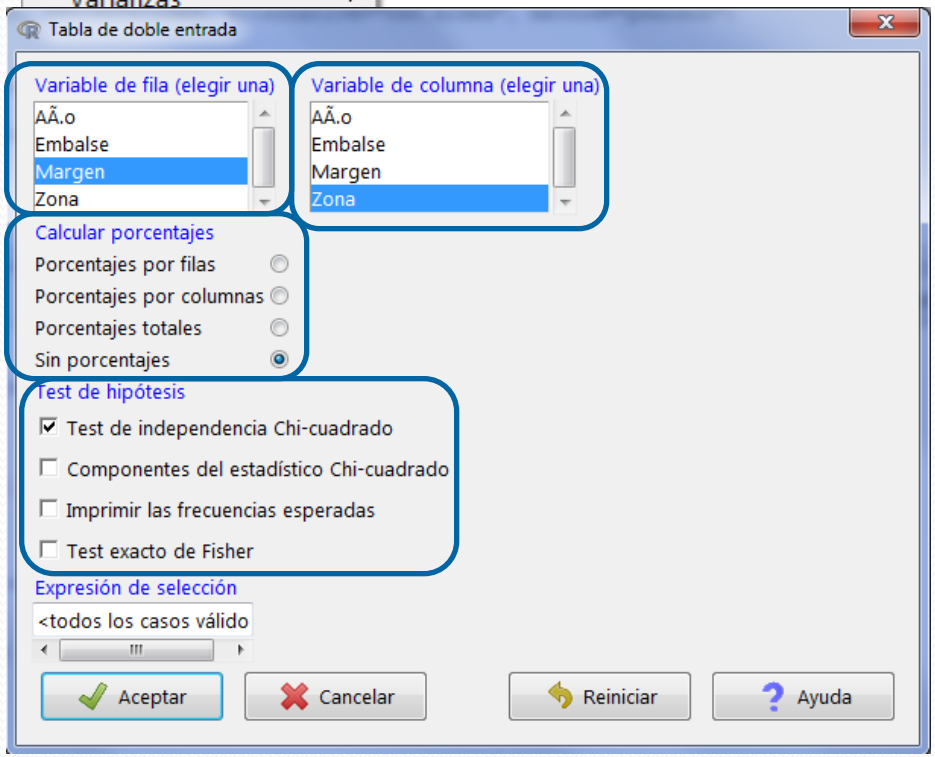
Rechazamos H_o

$I(R_{ES})_{0.95} = (0.8887445, 0.9299599)$

$R_{ES} = 0.9116159$

Test de Independencia para variables Categóricas






```
> .Table
          Zona
Margen     Alta Baja Media
  Derecho    39   38    59
  Izquierdo  60   37    38

> .Test <- chisq.test(.Table, correct=FALSE)

> .Test

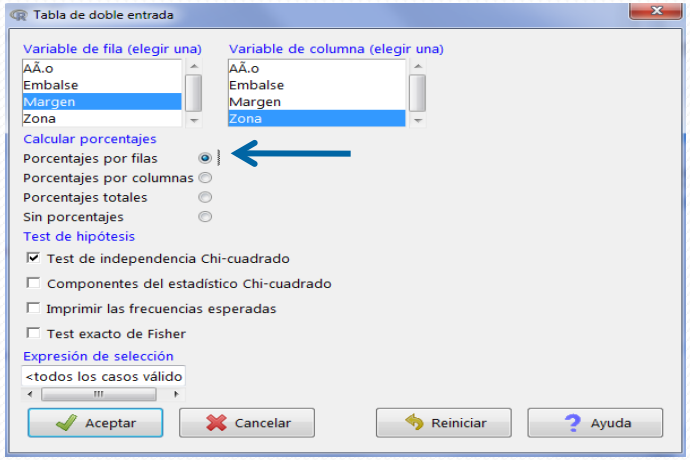
        Pearson's Chi-squared test

data:  .Table
X-squared = 9.0107, df = 2, p-value = 0.01105
```

$$\begin{cases} H_0 : X \text{ es independiente de } Y \\ H_1 : X \text{ esta relacionada con } Y \end{cases}$$

Decisión: Para todo $\alpha \leq p$ ➔ se acepta H_0
Para todo $\alpha > p$ ➔ se rechaza H_0

Rechazamos H_0 a nivel del 5%, es decir, existe relación entre los pantanos de uno u otro Margen con la Zona




```
> .Table
          Zona
Margen     Alta Baja Media
  Derecho    39   38    59
  Izquierdo  60   37    38
```

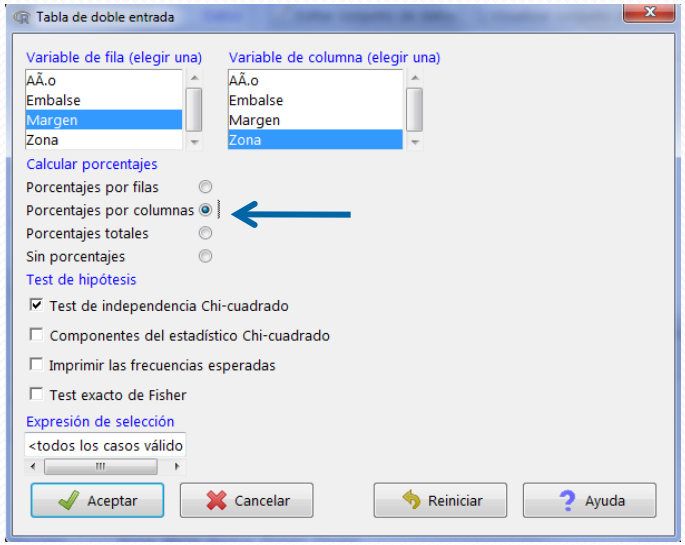
```
> rowPercents(.Table) # Row Percentages
          Zona
Margen     Alta Baja Media Total Count
  Derecho  28.7 27.9  43.4 100.0   136
  Izquierdo 44.4 27.4  28.1  99.9   135
```

```
> .Test <- chisq.test(.Table, correct=FALSE)

> .Test

        Pearson's Chi-squared test

data:  .Table
X-squared = 9.0107, df = 2, p-value = 0.01105
```




```
> .Table
          Zona
Margen     Alta Baja Media
  Derecho    39   38    59
  Izquierdo  60   37    38
```

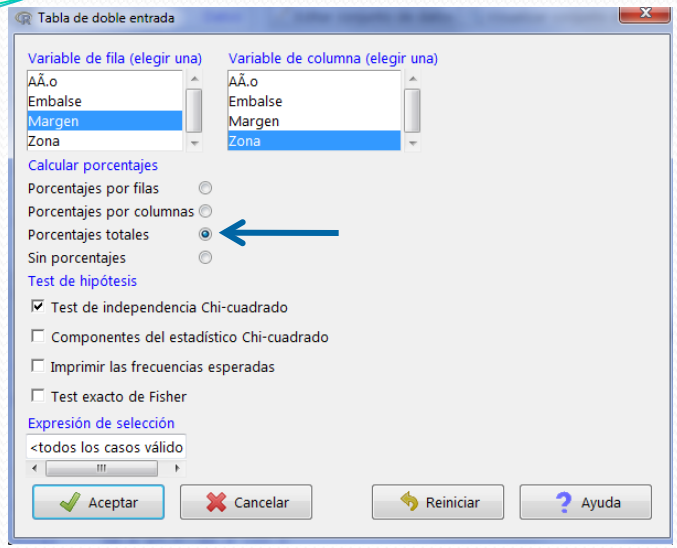
```
> colPercents(.Table) # Column Percentages
          Zona
Margen     Alta  Baja Media
  Derecho  39.4  50.7  60.8
  Izquierdo 60.6  49.3  39.2
  Total   100.0 100.0 100.0
  Count    99.0  75.0  97.0
```

```
> .Test <- chisq.test(.Table, correct=FALSE)

> .Test

        Pearson's Chi-squared test

data:  .Table
X-squared = 9.0107, df = 2, p-value = 0.01105
```




```
> .Table
          Zona
Margen     Alta Baja Media
  Derecho    39   38    59
  Izquierdo  60   37    38

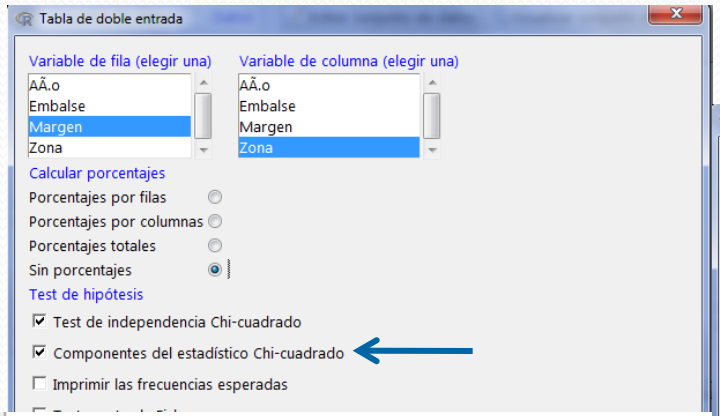
> totPercents(.Table) # Percentage of Total
          Alta Baja Media Total
Derecho   14.4 14.0  21.8  50.2
Izquierdo 22.1 13.7  14.0  49.8
Total     36.5 27.7  35.8 100.0

> .Test <- chisq.test(.Table, correct=FALSE)

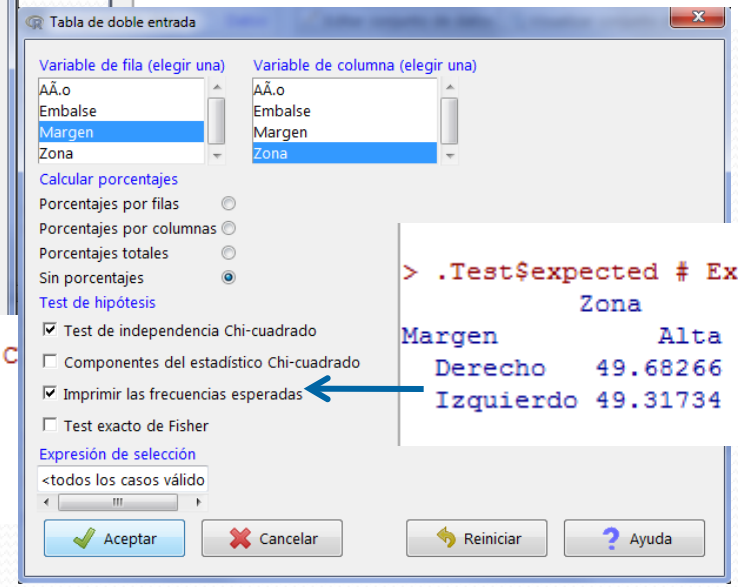
> .Test

        Pearson's Chi-squared test

data:  .Table
X-squared = 9.0107, df = 2, p-value = 0.01105
```

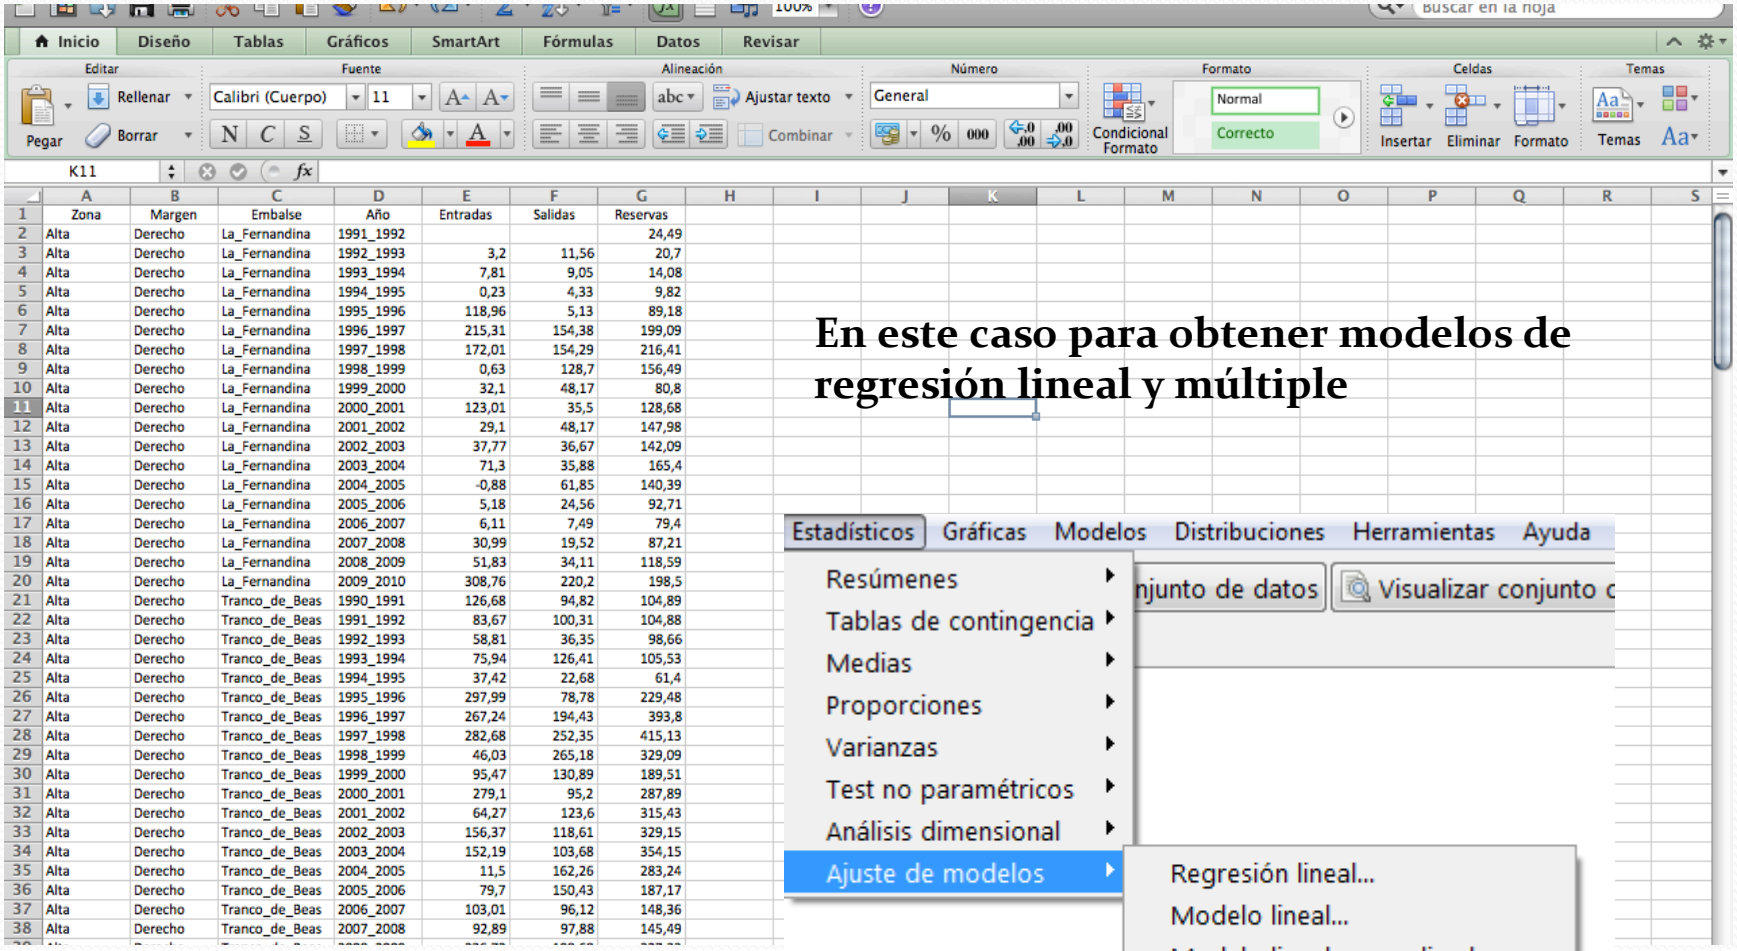



```
> round(.Test$residuals^2, 2) # Chi-square C
          Zona
Margen     Alta Baja Media
  Derecho  2.30 0.00  2.19
  Izquierdo 2.31 0.00  2.20
```



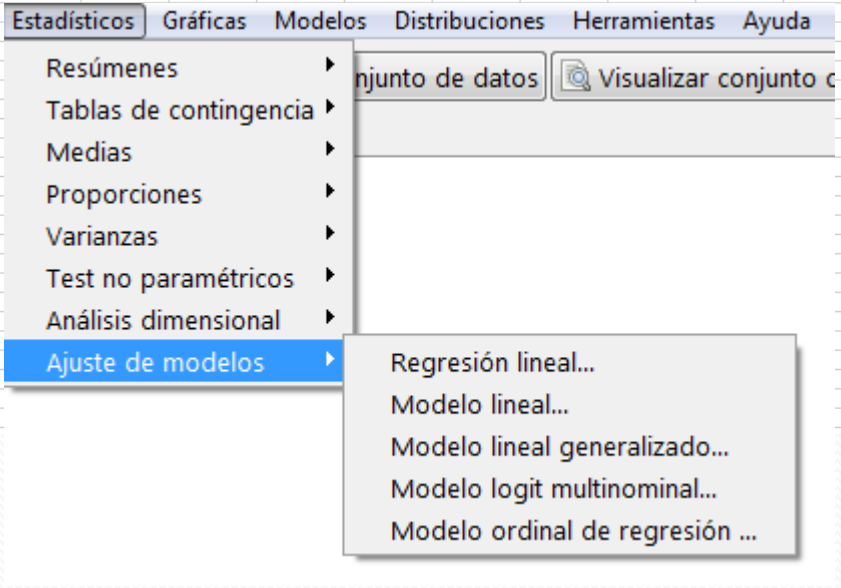

```
> .Test$expected # Expected Counts
          Zona
Margen          Alta     Baja    Media
  Derecho   49.68266 37.63838 48.67897
  Izquierdo 49.31734 37.36162 48.32103
```

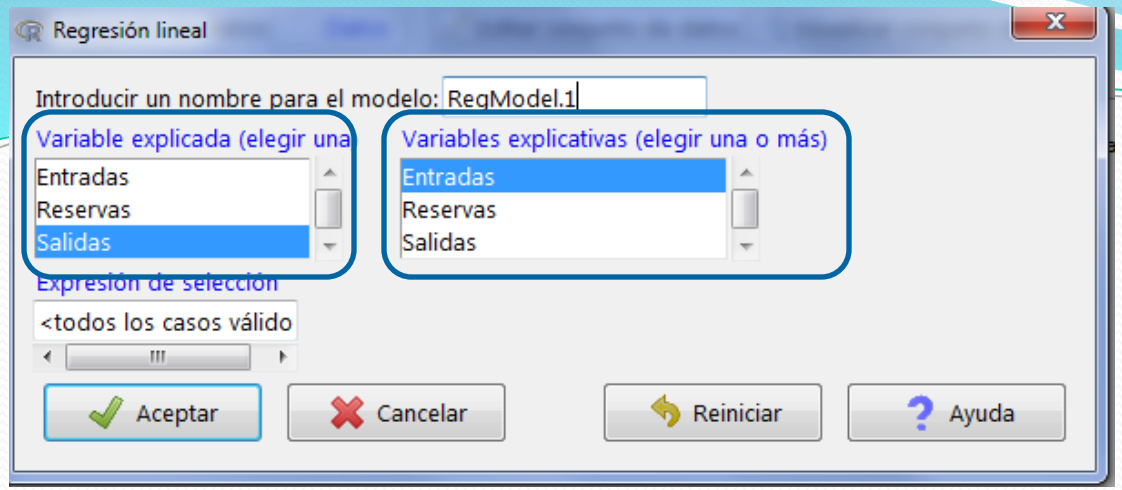
Modelos de Regresión



	Zona	Margen	Embalse	Año	Entradas	Salidas	Reservas
2	Alta	Derecho	La_Fernandina	1991_1992			24,49
3	Alta	Derecho	La_Fernandina	1992_1993	3,2	11,56	20,7
4	Alta	Derecho	La_Fernandina	1993_1994	7,81	9,05	14,08
5	Alta	Derecho	La_Fernandina	1994_1995	0,23	4,33	9,82
6	Alta	Derecho	La_Fernandina	1995_1996	118,96	5,13	89,18
7	Alta	Derecho	La_Fernandina	1996_1997	215,31	154,38	199,09
8	Alta	Derecho	La_Fernandina	1997_1998	172,01	154,29	216,41
9	Alta	Derecho	La_Fernandina	1998_1999	0,63	128,7	156,49
10	Alta	Derecho	La_Fernandina	1999_2000	32,1	48,17	80,8
11	Alta	Derecho	La_Fernandina	2000_2001	123,01	35,5	128,68
12	Alta	Derecho	La_Fernandina	2001_2002	29,1	48,17	147,98
13	Alta	Derecho	La_Fernandina	2002_2003	37,77	36,67	142,09
14	Alta	Derecho	La_Fernandina	2003_2004	71,3	35,88	165,4
15	Alta	Derecho	La_Fernandina	2004_2005	-0,88	61,85	140,39
16	Alta	Derecho	La_Fernandina	2005_2006	5,18	24,56	92,71
17	Alta	Derecho	La_Fernandina	2006_2007	6,11	7,49	79,4
18	Alta	Derecho	La_Fernandina	2007_2008	30,99	19,52	87,21
19	Alta	Derecho	La_Fernandina	2008_2009	51,83	34,11	118,59
20	Alta	Derecho	La_Fernandina	2009_2010	308,76	220,2	198,5
21	Alta	Derecho	Tranco_de_Beas	1990_1991	126,68	94,82	104,89
22	Alta	Derecho	Tranco_de_Beas	1991_1992	83,67	100,31	104,88
23	Alta	Derecho	Tranco_de_Beas	1992_1993	58,81	36,35	98,66
24	Alta	Derecho	Tranco_de_Beas	1993_1994	75,94	126,41	105,53
25	Alta	Derecho	Tranco_de_Beas	1994_1995	37,42	22,68	61,4
26	Alta	Derecho	Tranco_de_Beas	1995_1996	297,99	78,78	229,48
27	Alta	Derecho	Tranco_de_Beas	1996_1997	267,24	194,43	393,8
28	Alta	Derecho	Tranco_de_Beas	1997_1998	282,68	252,35	415,13
29	Alta	Derecho	Tranco_de_Beas	1998_1999	46,03	265,18	329,09
30	Alta	Derecho	Tranco_de_Beas	1999_2000	95,47	130,89	189,51
31	Alta	Derecho	Tranco_de_Beas	2000_2001	279,1	95,2	287,89
32	Alta	Derecho	Tranco_de_Beas	2001_2002	64,27	123,6	315,43
33	Alta	Derecho	Tranco_de_Beas	2002_2003	156,37	118,61	329,15
34	Alta	Derecho	Tranco_de_Beas	2003_2004	152,19	103,68	354,15
35	Alta	Derecho	Tranco_de_Beas	2004_2005	11,5	162,26	283,24
36	Alta	Derecho	Tranco_de_Beas	2005_2006	79,7	150,43	187,17
37	Alta	Derecho	Tranco_de_Beas	2006_2007	103,01	96,12	148,36
38	Alta	Derecho	Tranco_de_Beas	2007_2008	92,89	97,88	145,49

En este caso para obtener modelos de regresión lineal y múltiple






```
> RegModel.1 <- lm(Salidas~Entradas, data=Datos)

> summary(RegModel.1)

Call:
lm(formula = Salidas ~ Entradas, data = Datos)

Residuals:
    Min      1Q  Median      3Q     Max
-314.62  -18.65   -7.18   20.30  435.09

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 19.75000    5.36355   3.682 0.000281 ***
Entradas     0.81685    0.02271  35.967  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 69.55 on 263 degrees of freedom
  (6 observations deleted due to missingness)
Multiple R-squared: 0.831,  Adjusted R-squared: 0.8304
F-statistic:  1294 on 1 and 263 DF,  p-value: < 2.2e-16
```

Salidas = 19.75 + 0.81685 Entradas + Error

Test F sobre el Modelo de Regresión

$$\begin{cases} H_0 : \text{Rechazo Gobalmente el modelo} \\ H_1 : \text{Acepto Gobalmente el modelo} \end{cases}$$

Aceptamos Globalmente el Modelo

Test T sobre los Coeficientes del Modelo

$$\begin{cases} H_0 : \beta_{Ent} = 0 \\ H_1 : \beta_{Ent} \neq 0 \end{cases}$$

Aceptamos β_{Ent} como válido

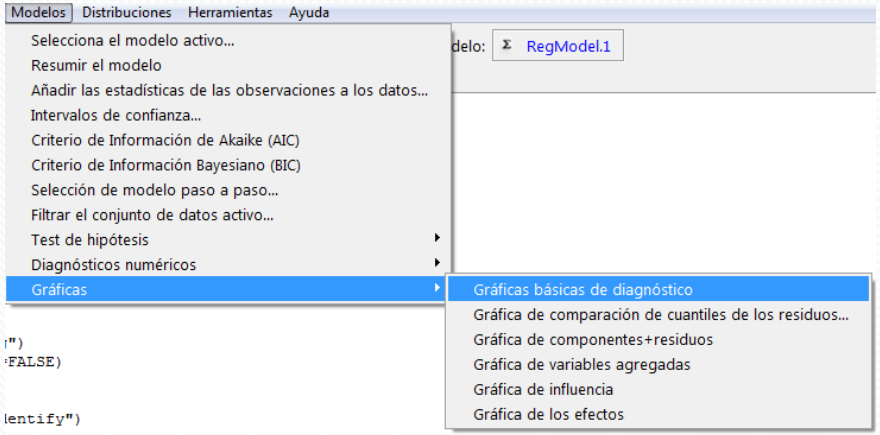
Las Salidas son explicadas en un 83.1% por las Entradas de acuerdo con el modelo calculado.

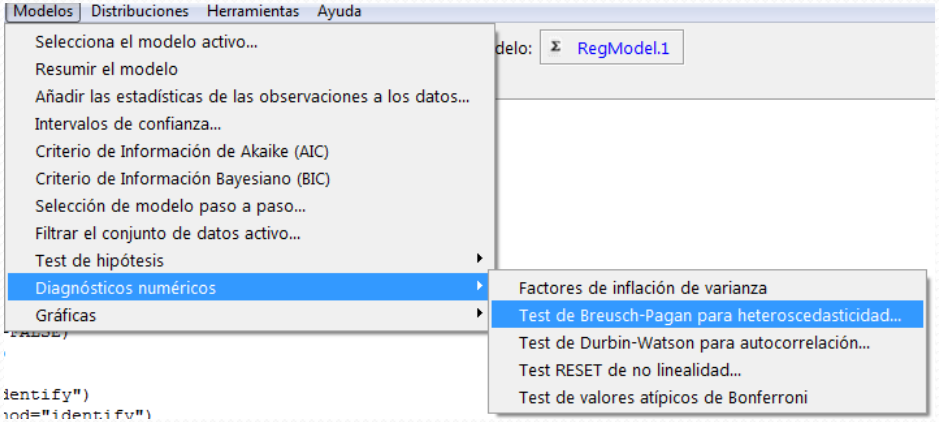
Decisión: Para todo $\alpha \leq p$ ➔ se acepta H_o
Para todo $\alpha > p$ ➔ se rechaza H_o

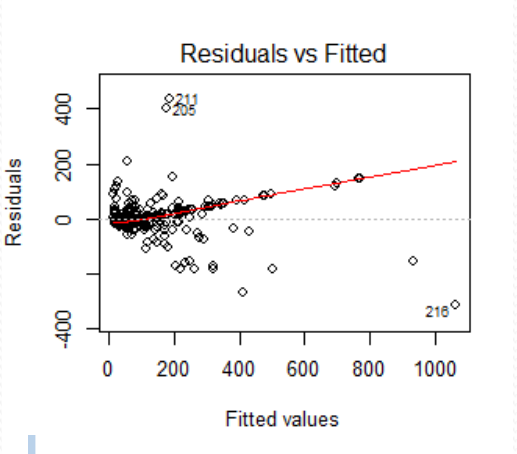
Análisis de Residuos

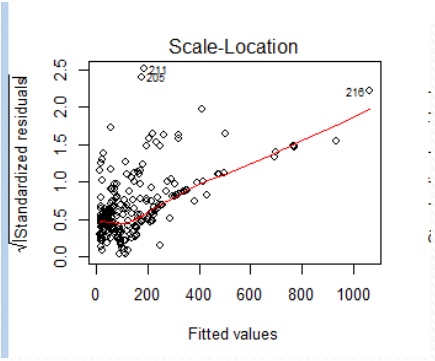
1ª.- $\bar{e} = 0$

2ª.- $Var(\varepsilon_i) = cte$ Varianza constante. (homocedásticos)







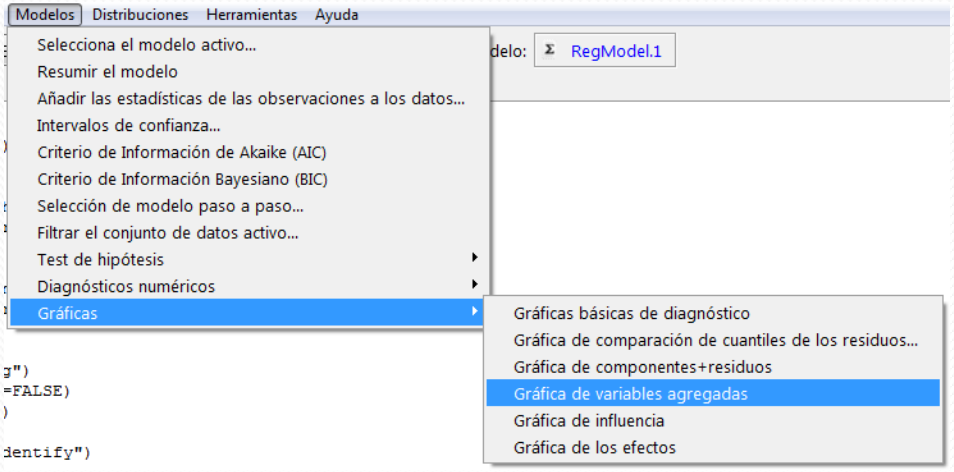


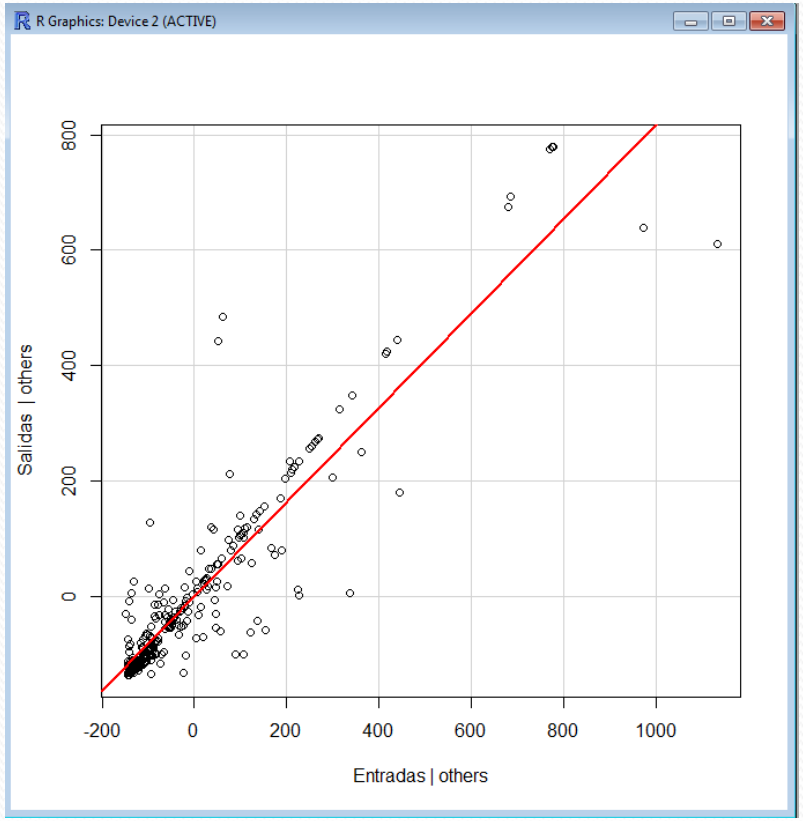
Existe Heterocedasticidad

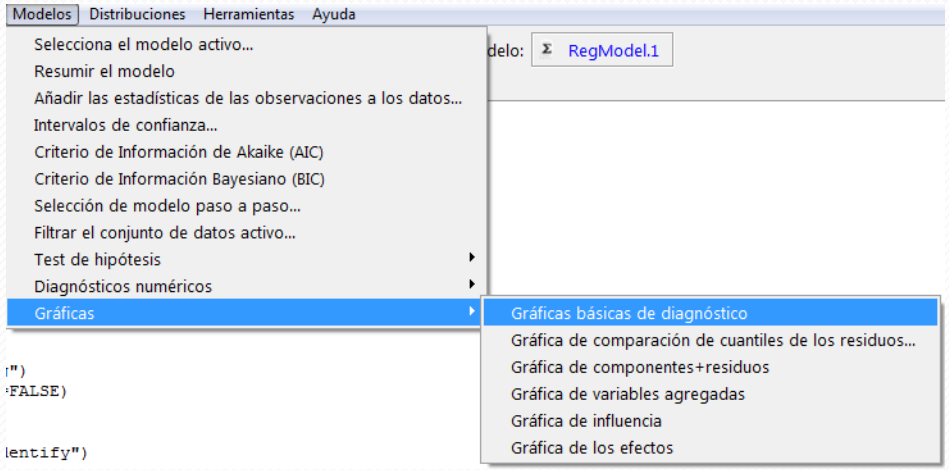
$$\begin{cases} H_0 : \text{Homocedasticidad} \\ H_1 : \text{Heterocedasticidad} \end{cases}$$

```
        Breusch-Pagan test

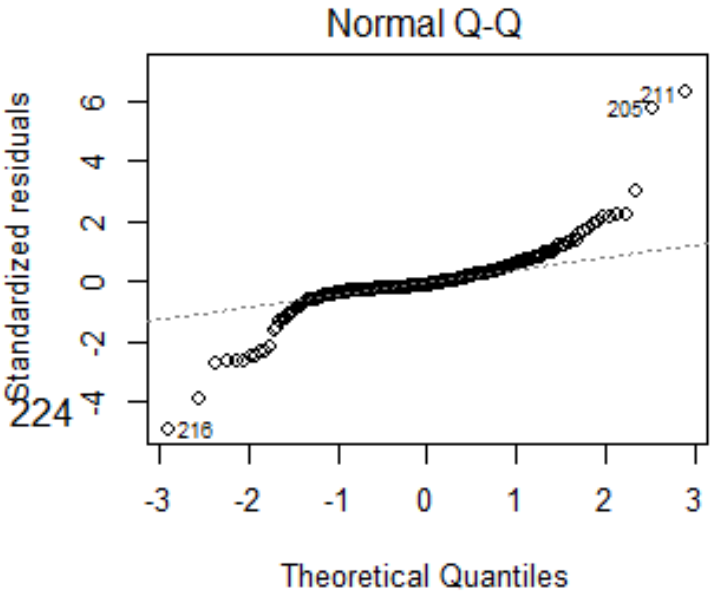
data:  Salidas ~ Entradas
BP = 217.8706, df = 1, p-value < 2.2e-16
```


Modelos
Distribuciones
Herramientas
Ayuda
Selecciona el modelo activo...
Resumir el modelo
Añadir las estadísticas de las observaciones a los datos...
Intervalos de confianza...
Criterio de Información de Akaike (AIC)
Criterio de Información Bayesiano (BIC)
Selección de modelo paso a paso...
Filtrar el conjunto de datos activo...
Test de hipótesis
Diagnósticos numéricos
Gráficas
Gráficas básicas de diagnóstico
Gráfica de comparación de cuantiles de los residuos...
Gráfica de componentes+residuos
Gráfica de variables agregadas
Gráfica de influencia
Gráfica de los efectos
delo:
RegModel.1
g")
=FALSE)
)
dentify")


R Graphics: Device 2 (ACTIVE)
Salidas | others
Entradas | others
0
200
400
600
800
-200
0
200
400
600
800
1000



4ª.- Normales $\quad e \in N\left(\mu = 0; \sigma^2 = S_e^2\right)$



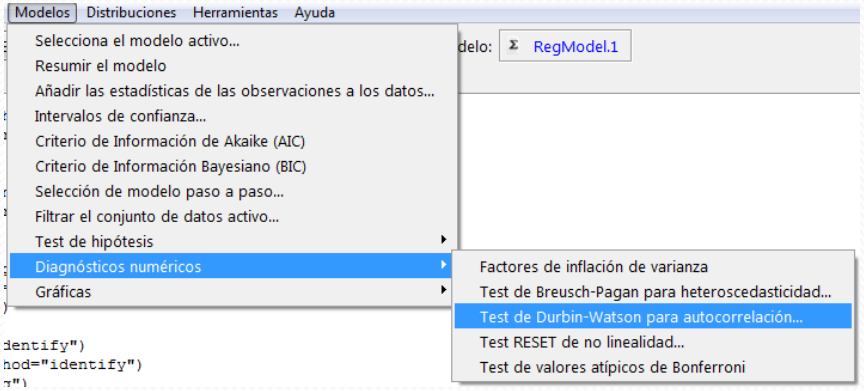
3ª.- Los residuos han de estar incorrelados entre si.

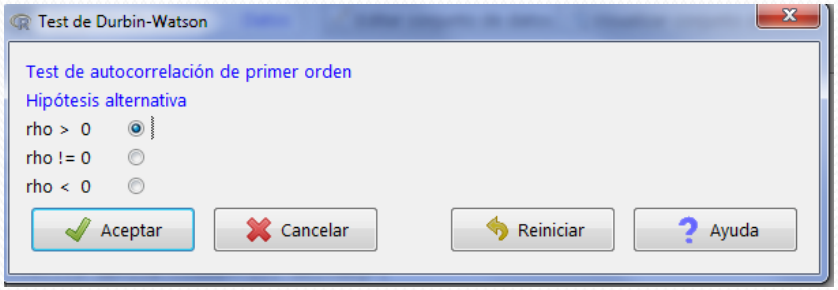
$$\begin{cases} H_0 : \rho = 0 \rightarrow \text{Incorrelados} \\ H_1 : \rho \begin{cases} > 0 \rightarrow \text{Autocorrelacion Positiva} \\ \neq 0 \rightarrow \text{Autocorrelados} \\ < 0 \rightarrow \text{Autocorrelacion Negativa} \end{cases} \end{cases}$$

Estadístico de Durbin-Watson

$$DW = \frac{\sum_{i=2}^{n} (e_i - e_{i-1})^2}{\sum_{i=1}^{n} e_i^2} \in [0\,;\,4]$$

DW ≈ 2, Incorrelados
DW ≈ 4 Autocorrelación negativa
DW ≈ 0 Autocorrelación positiva





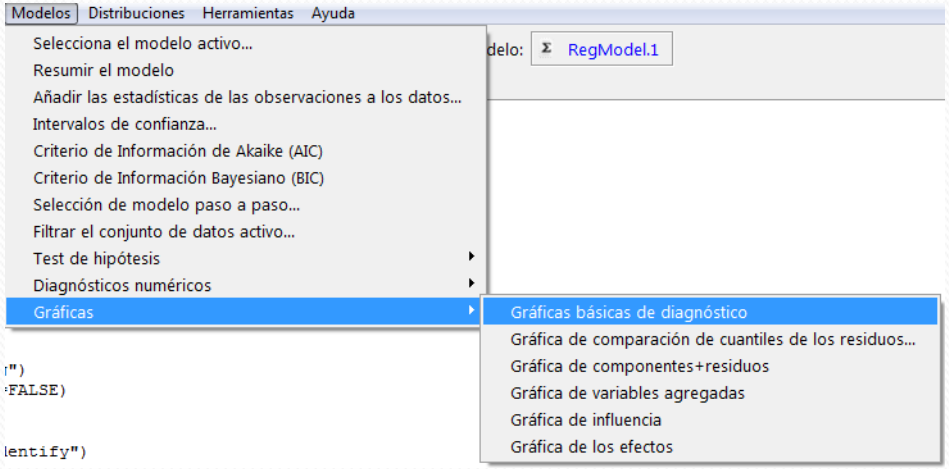

```
> dwtest(Salidas ~ Entradas, alternative="greater", data=Datos)

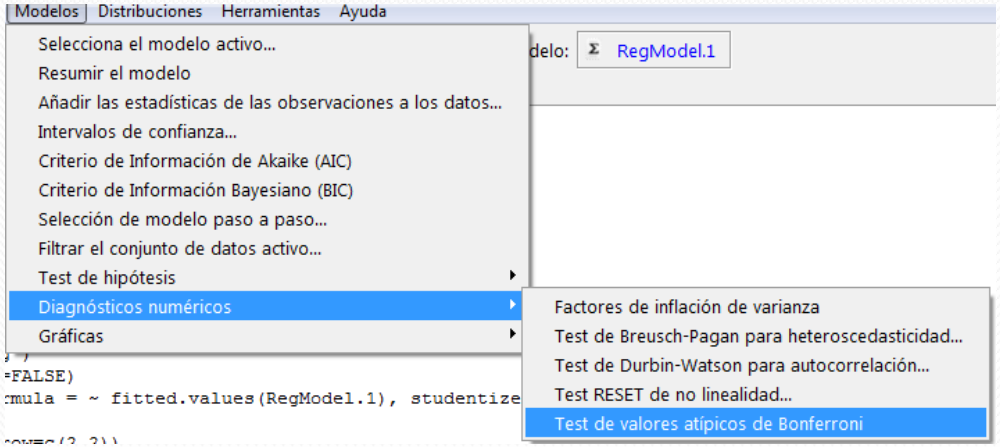
        Durbin-Watson test

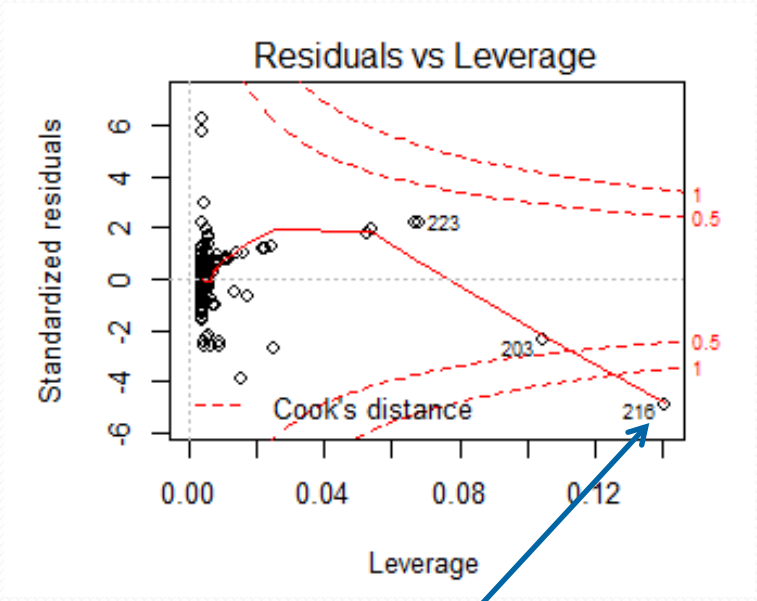
data:  Salidas ~ Entradas
DW = 1.5642, p-value = 0.0001611
alternative hypothesis: true autocorrelation is greater than 0
```

Decisión: Para todo $\alpha \leq p$ ➔ se acepta H_o
Para todo $\alpha > p$ ➔ se rechaza H_o

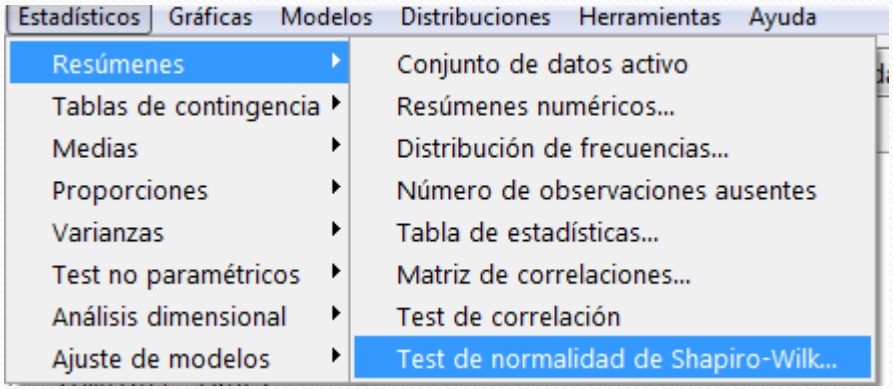
A pesar de que DW=1.5642, existe autocorrelación positiva

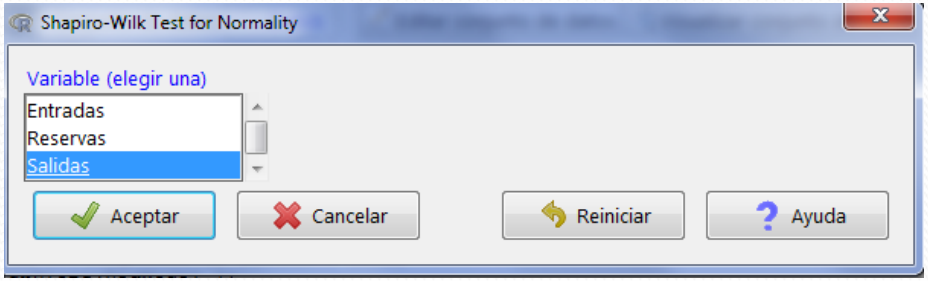







```
> outlierTest(RegModel.1)
     rstudent unadjusted p-value Bonferonni p
211  6.784652          7.7222e-11   2.0464e-08
205  6.149760          2.8842e-09   7.6432e-07
216 -5.107167          6.3007e-07   1.6697e-04
202 -3.990202          8.5738e-05   2.2721e-02
```





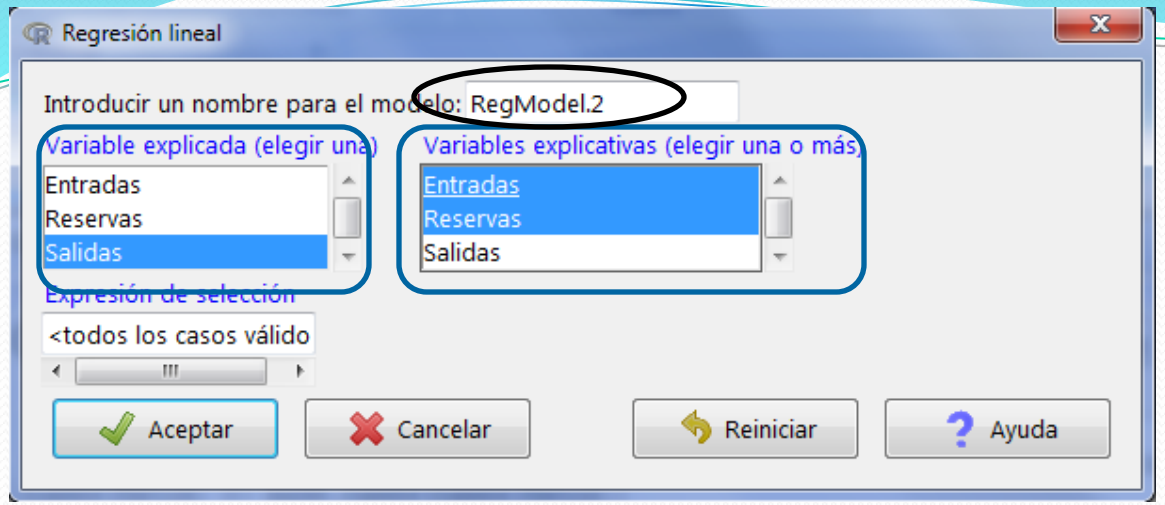

```
> shapiro.test(Datos$Salidas)

        Shapiro-Wilk normality test

data:  Datos$Salidas
W = 0.7171, p-value < 2.2e-16
```

La variable Dependiente, Salidas, No es Normal.

Regresión Múltiple



Modelo: RegModel.2

```
Call:
lm(formula = Salidas ~ Entradas + Reservas, data = Datos)

Residuals:
    Min      1Q  Median      3Q     Max
-315.72  -18.53   -7.17   19.87  432.74

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) 19.484519   5.675519   3.433 0.000693 ***
Entradas     0.815330   0.025035  32.568  < 2e-16 ***
Reservas     0.004439   0.030544   0.145 0.884549
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 69.68 on 262 degrees of freedom
  (6 observations deleted due to missingness)
Multiple R-squared: 0.8311, Adjusted R-squared: 0.8298
F-statistic: 644.4 on 2 and 262 DF,  p-value: < 2.2e-16
```

Las Salidas son explicadas en un 83.11% por las Entradas de acuerdo con el modelo calculado.

Salidas = 19.484519 + 0.81533 Entradas + 0.004439 Reservas + Error

Test F sobre el Modelo de Regresión

$$\begin{cases} H_0: \text{Rechazo Gobalmente el modelo} \\ H_1: \text{Acepto Gobalmente el modelo} \end{cases}$$

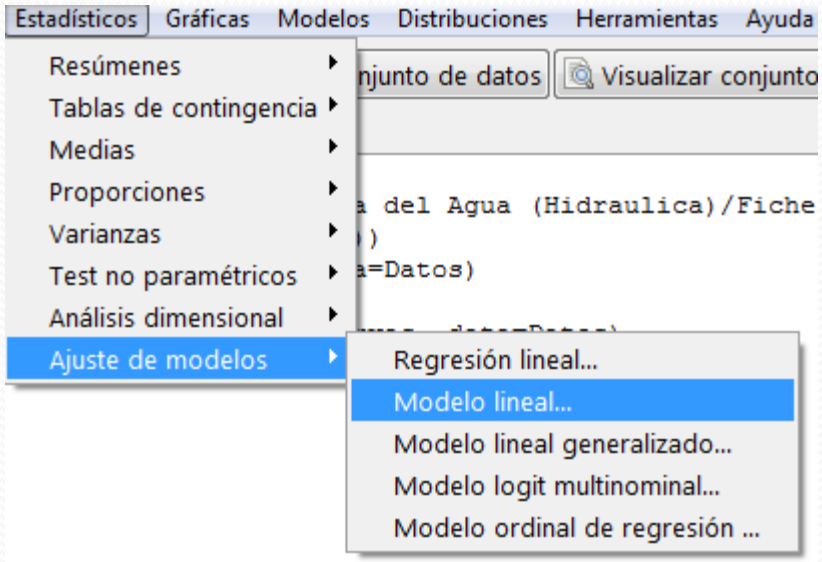
Decisión: Para todo $\alpha \leq p$ ➔ se acepta H_0
Para todo $\alpha > p$ ➔ se rechaza H_0

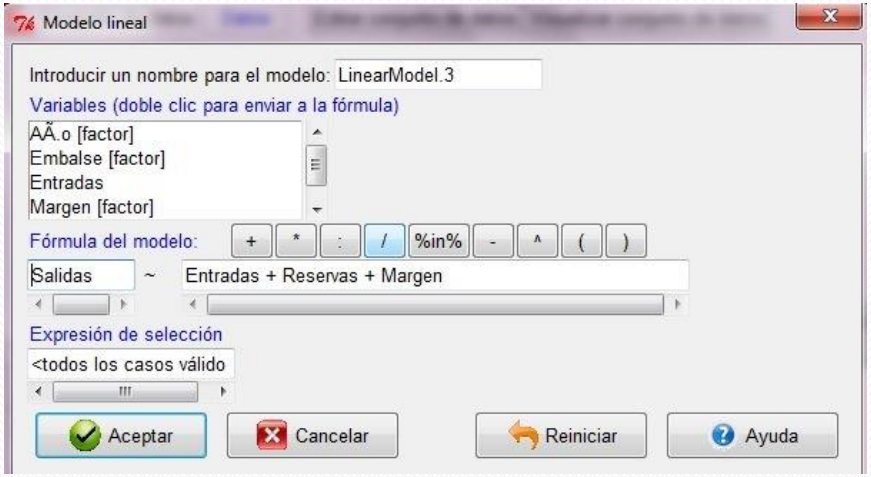
Aceptamos Globalmente el Modelo

Test T sobre los Coeficientes del Modelo

$$\begin{cases} H_0: \beta_{Ent} = 0 \\ H_1: \beta_{Ent} \neq 0 \end{cases} \qquad \begin{cases} H_0: \beta_{Res} = 0 \\ H_1: \beta_{Res} \neq 0 \end{cases}$$

Aceptamos β_{Ent} como válido y se Rechaza β_{Res}





Permite introducir en los modelos de regresión anteriores variables tipo factor

Ventana de resultados

Ejecutar

```
Call:
lm(formula = Salidas ~ Entradas + Reservas + Margen, data = Datos)

Residuals:
    Min      1Q  Median      3Q     Max
-311.01  -23.42   -5.08   19.92  425.14

Coefficients:
                 Estimate Std. Error t value Pr(>|t|)
(Intercept)     12.684011   6.674167   1.900   0.0585 .
Entradas         0.803853   0.025622  31.376   <2e-16 ***
Reservas         0.004278   0.030390   0.141   0.8882
Margen[T.Izquierdo] 16.849950   8.814666   1.912   0.0570 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 69.33 on 261 degrees of freedom
  (6 observations deleted due to missingness)
Multiple R-squared: 0.8334, Adjusted R-squared: 0.8315
F-statistic: 435.2 on 3 and 261 DF,  p-value: < 2.2e-16
```

Test T sobre los Coeficientes del Modelo

$$\begin{cases} H_0 : \beta_{Ent} = 0 \\ H_1 : \beta_{Ent} \neq 0 \end{cases} \quad \begin{cases} H_0 : \beta_{Res} = 0 \\ H_1 : \beta_{Res} \neq 0 \end{cases} \quad \begin{cases} H_0 : \beta_{Mar} = 0 \\ H_1 : \beta_{Mar} \neq 0 \end{cases}$$

Decisión: Para todo $\alpha \leq p$ ➔ se acepta H_0
Para todo $\alpha > p$ ➔ se rechaza H_0

Aceptamos sólo β_{Ent} como parámetro válido en el modelo

No son significativas ni las reservas ni el margen

Modelo:
Salidas= 12.684011 + 0.803853*Entradas + 0.004278*Reservas + 16.849950*Margen

Donde Margen = 0 en el caso de considerarse el derecho y 1 en el caso de ser el izquierdo

Tabla de modelos

Modelo	Instrucción	Ecuación
Lineal	>lm($Y \sim X$, data=Datos)	$Y = a + b \cdot X$
Lineal sin término independiente	>lm($Y \sim 0 + X$, data=Datos)	$Y = a \cdot X$
Polinomial	>lm($Y \sim X + I(X^2) +$ $+ I(X^3) + \cdots + I(X^n)$, data=Datos)	$Y = a_0 + a_1 \cdot X +$ $+ \cdots + a_n \cdot X^n$
Polinomial sin término independiente	>lm($Y \sim 0 + X + I(X^2) +$ $+ I(X^3) + \cdots + I(X^n)$, data=Datos)	$Y = a_1 \cdot X +$ $+ \cdots + a_n \cdot X^n$
Potencial	>lm($\log(Y) \sim \log(X)$, data=Datos)	$Y = a' \cdot X^b$, (1)
Exponencial	>lm($\log(Y) \sim X$, data=Datos)	$Y = e^{a+b \cdot X}$
Logarítmico	>lm($Y \sim \log(X)$, data=Datos)	$Y = a + b \cdot \log(X)$
Hiperbólico	>lm($Y \sim I(1/X)$, data=Datos)	$Y = a + \frac{b}{X}$
Doble inverso	>lm($I(1/Y) \sim I(1/X)$, data=Datos)	$Y = \frac{1}{a + \frac{b}{X}}$
Lineal generalizado	>glm(fórmula, family= =familia(link), data=Datos)	(2)

(1) Los coeficientes a y b obtenidos en **Rcmdr** corresponden a la ecuación $\log(Y) = a + b \cdot \log(X)$, con lo que el modelo potencial sería $Y = e^a \cdot X^b$.

(2) `familia` puede tomar los valores `gaussian`, `binomial`, `poisson`, `Gamma`, `inverse.gauss` `quasibinomial` y `quasipoisson`. La función de enlace (`link`) puede tomar distintos valores según la familia seleccionada. Podemos ver las distintas opciones consultando en la ayuda de **R** la función `family` (`help(family)` o `?family`).

Transformaciones no lineales.

Tratan de corregir la falta de simetría de algunas distribuciones de datos. En ocasiones, estas transformaciones corrigen las desviaciones de normalidad.

La transformación mas utilizada es el logaritmo aunque existen otras mas simples como la raíz cuadrada o la inversa.

La transformación de Box-Cox (perteneciente a las transformaciones logarítmicas) también es muy usada y suele corregir las desviaciones de los supuestos necesarios para los modelos de regresión.

Dada una variable *X*, su transformada de Box-Cox se define como:

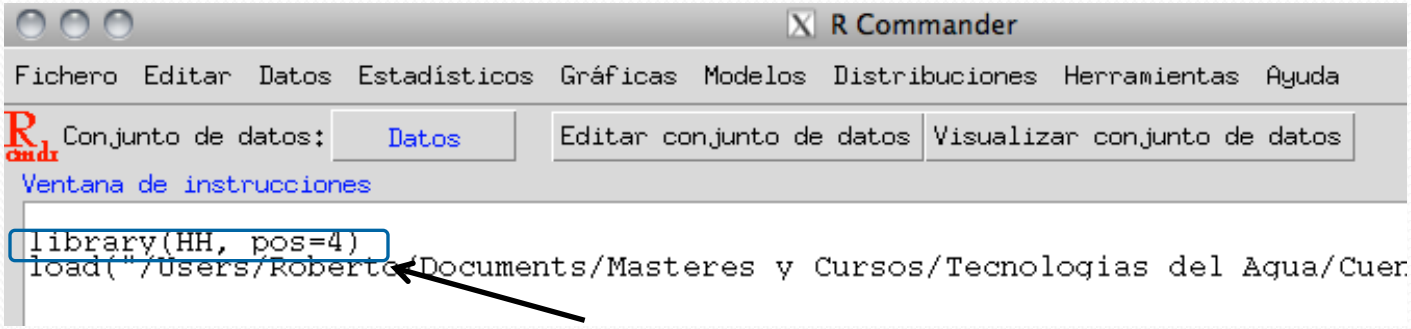
$$X^* = \left\{ \begin{array}{lll} \dfrac{(X+m)^{\lambda}-1}{\lambda} & si & \lambda \neq 0 \\ \ln(X+m) & si & \lambda = 0 \end{array} \right\}$$

m se escoge de tal forma que (*X* + *m*) sea positivo.

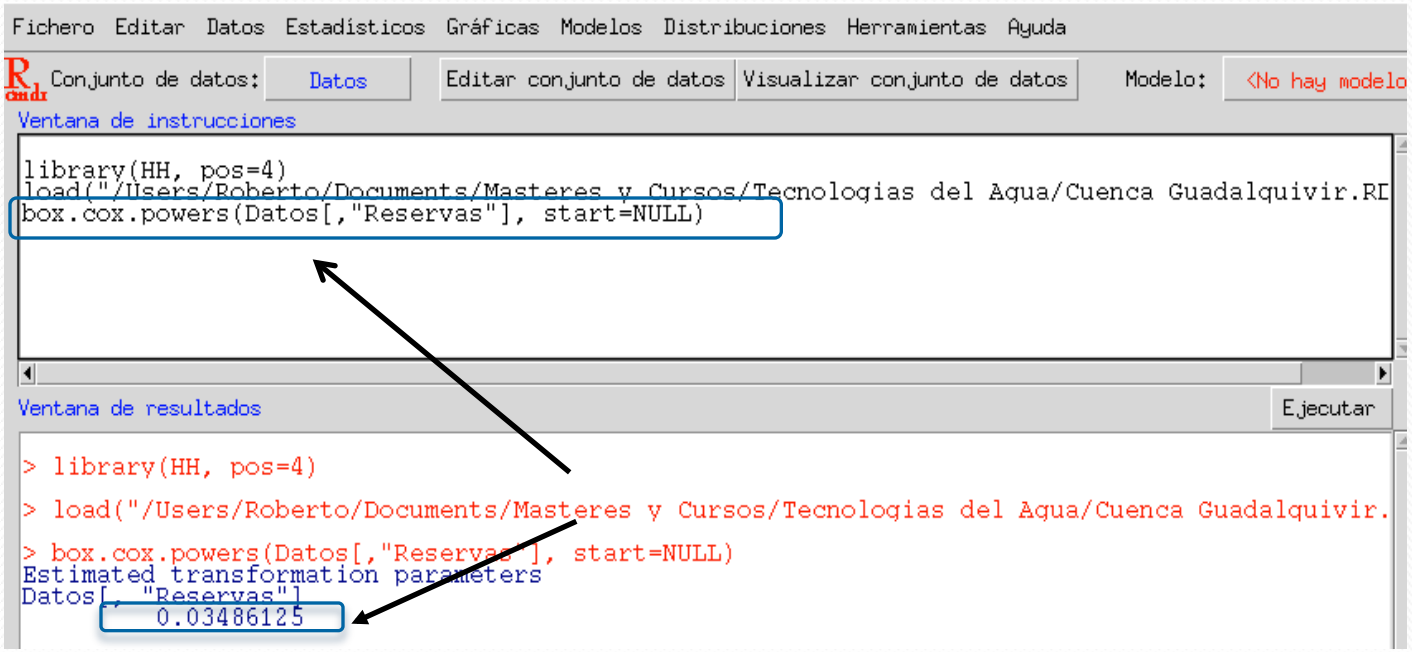
Si λ > 1 se corrige la asimetría a la izquierda y si λ < 1 la asimetría a la derecha.

Transformación de Box-Cox en R.

En primer lugar hay que instalar y cargar, entre otras posibles (p.e MASS), la librería HH.



Si existiese algún dato negativo, hay que sumar una constante *m* para que esto no ocurra.
A continuación, hay que determinar el mejor valor posible para el parámetro λ.



Obtener la nueva serie de datos transformados, o bien con la opción de transformación o bien mediante comandos y agregar al fichero de datos.

Fichero Editar Datos Estadísticos Gráficas Modelos Distribuciones Herramientas Ayuda

Conjunto de datos: Datos | Editar conjunto de datos | Visualizar conjunto de datos | Modelo: <No hay modelo

Ventana de instrucciones

```
library(HH, pos=4)
load("/Users/Roberto/Documents/Masteres y Cursos/Tecnologias del Agua/Cuenca Guadalquivir.RD
box.cox.powers(Datos[,"Reservas"], start=NULL)
nuevodato<-box.cox(Datos[,"Reservas"], 0.03486125)
nuevodato
Datos$ReserBoxCox <-nuevodato
```

Realizamos la transformación
Visualizamos los datos
Se añade una columna con los datos transformados al fichero de datos

Ventana de resultados — Ejecutar

```
> nuevodato<-box.cox(Datos[,"Reservas"], 0.03486125)
> nuevodato
  [1] 3.3833763 3.1959640 2.7705129 2.3778478 4.8612465 5.8137183 5.9141887
 [8] 5.5253686 4.7460417 5.2928103 5.4587482 5.4104366 5.5914734 5.3961330
[15] 4.9066755 4.7256774 4.8351333 5.1962246 5.8101491 5.0515368 5.0514247
[22] 4.9795978 5.0586919 4.4275732 5.9849926 6.6438761 6.7089017 6.4234771
[29] 5.7544592 6.2601540 6.3716275 6.4237002 6.5134155 6.2403221 5.7395455
[36] 5.4618010 5.4385550 5.9736172 6.4998654 3.7860418 3.3152170 2.2907408
[43] 2.0316265 2.2702928 3.8514024 3.8978484 3.9518290 3.4602029 3.8283521
[50] 3.8949066 3.8310543 3.8895928 3.9699318 3.2135473 2.5254135 3.7236591
[57] 3.8027263 4.2160577 4.9016124 5.1234879 4.1450549 3.8695997 3.8617488
```

	Zona	Margen	Embalse	Año	Entradas	Salidas	Reservas	ReserBoxCox
1	Alta	Derecho	La Fernandina	1991 1992	NA	NA	24.49	3.3833760
2	Alta	Derecho	La Fernandina	1992 1993	3.20	11.56	20.70	3.1959640
3	Alta	Derecho	La Fernandina	1993 1994	7.81	9.05	14.08	2.7705130
4	Alta	Derecho	La Fernandina	1994 1995	0.23	4.33	9.82	2.3778480
5	Alta	Derecho	La Fernandina	1995 1996	118.96	5.13	89.18	4.8612460
6	Alta	Derecho	La Fernandina	1996 1997	215.31	154.38	199.09	5.8137180
7	Alta	Derecho	La Fernandina	1997 1998	172.01	154.29	216.41	5.9141890
8	Alta	Derecho	La Fernandina	1998 1999	0.63	128.70	156.49	5.5253690
9	Alta	Derecho	La Fernandina	1999 2000	32.10	48.17	80.80	4.7460420
10	Alta	Derecho	La Fernandina	2000 2001	123.01	35.50	128.68	5.2928100

FUNDAMENTOS Y HERRAMIENTAS PARA LA MODELIZACIÓN DE PROCESOS TÉCNICOS-CIENTÍFICOS DE INVESTIGACIÓN

Bloque III: Modelización estadística.

Regresión y correlación con R (Rcommander)



Roberto Espejo Mohedano e-mail: ma1esmor@uco.es